

决策的认知神经计算

中文课程讲义

从实验中的选择与反应时
理解价值、学习、规划与社会推断

VON

课程参考：2025 秋决策的认知神经计算
朱露莎 (Lusha Zhu)

贝叶斯观察者专题：张航 (Hang Zhang)

北京大学

目录

从一个选择开始	iv
第 1 章 怎样把一个心理学问题变成可检验的模型	1
1.1 先区分研究对象与测量方式	1
1.2 实验的力量来自对照	1
1.3 模型不是给现象换个名字	2
1.4 神经证据怎样进入解释	2
第 2 章 价值：怎样把不同东西放到一起比较	3
2.1 效用表示的是顺序，不是一种可直接读取的物质	3
2.2 面对风险，平均收益还不够	3
2.3 怎样测量一个人愿意付出的代价	4
2.4 从行为无差异点走向神经编码	5
2.5 社会价值也需要具体的取舍	7
第 3 章 情境为什么会改变价值与选择	8
3.1 先分清几种不同的情境效应	8
3.2 除法归一化：把有限的表示范围分给当前环境	8
3.3 噪声为什么让第三个选项影响前两个	9
3.4 同一轮的比较与跨时间的适应	10
3.5 多属性选择不一定先算一个固定总分	10
第 4 章 贝叶斯判断：看见的证据怎样改变信念	11
4.1 先写生成过程，再写推断	11
4.2 信号检测：敏感性与回答倾向是两件事	11
4.3 最合理的动作不一定是可能的状态	12
4.4 三门问题：信息来自观察方式	13
4.5 从连续估计走向损失函数	13
第 5 章 从判断到行动：反应时与认知控制	14
5.1 先观察一项可以调节难度的任务	14
5.2 为什么证据可以相加	15
5.3 参数改变的是哪个环节	15
5.4 为什么“更快”不等于“更自私”或“更合作”	16
5.5 控制可以改变信息的权重，而不必是两个系统打架	17
第 6 章 多种线索与潜在结构：什么时候应该合在一起	19
6.1 可靠的线索为什么得到更大权重	19
6.2 先验怎样产生向平均值回归	20
6.3 共同原因推断：整合之前先问是不是一回事	20
6.4 类别数未知时，怎样产生一个新类别	22
第 7 章 结果与反事实：得到多少不是体验的全部	24
7.1 先把比较对象说清楚	24
7.2 怎样在实验中区分两种比较	25
7.3 反事实怎样进入选择模型	25
7.4 替代反馈为什么可能加快学习	26

7.5 有神经信号，不一定被行为利用	26
第 8 章 从意外中学习：预测误差与多巴胺	27
8.1 用一次更新理解学习率与误差	27
8.2 阻断：为什么一起出现还不够	27
8.3 经典多巴胺结果的逻辑	29
8.4 怎样从相关走向教学信号的因果检验	29
8.5 从被动预测到主动选择	30
8.6 经典模式也需要竞争解释	31
第 9 章 探索、变化与注意：学习的不只是价值	32
9.1 随机探索与有目的的信息搜集	32
9.2 用 Beta 分布表示二元奖励的不确定性	32
9.3 环境变化时，旧证据不一定仍然有用	33
9.4 隐状态推断：改变的是价值，还是“现在在哪种环境”	33
9.5 注意决定学什么，学习也决定注意什么	34
第 10 章 把未来接起来：Bellman 方程与时间差分学习	36
10.1 状态、行动与奖励的时间顺序	36
10.2 Bellman 方程只是把第一步拆出来	36
10.3 一个两状态例子	37
10.4 不知道转移概率，怎样学习	37
10.5 从预测价值到选择更好的行动	38
10.6 把逐试次计算带进神经分析	39
第 11 章 不只记一个平均数：奖励分布与多时间尺度	40
11.1 平均值由哪一种误差规则产生	40
11.2 分位数与期望分位数不能混为一谈	40
11.3 为什么一群神经元的差异可能有计算意义	41
11.4 未来的折扣也可以有不同时间尺度	41
11.5 用一组价值保留奖励何时发生的信息	43
第 12 章 知道路通向哪里：规划与两阶段任务	45
12.1 无模型与有模型：差别在于是否调用转移结构	45
12.2 两阶段任务到底让被试做什么	45
12.3 为什么少见转移特别重要	46
12.4 怎样写出能生成完整选择序列的模型	47
12.5 认知资源、可靠性与规划证据	48
第 13 章 没有行动时也在学习：重放与后继表示	50
13.1 Dyna：把真实经历与内部模拟放进同一更新	50
13.2 怎样从神经活动识别重放	50
13.3 值得先回想什么：增益乘以需求	51
13.4 后继表示：把路线结构与奖励分开保存	52
13.5 用重新评价实验区分几种表示	53
13.6 从位置细胞到预测地图	53
第 14 章 对手也在思考：社会价值、信念与博弈	55
14.1 独裁者、最后通牒与信任任务各在测什么	55
14.2 公平怎样变成可检验的效用	55
14.3 均衡是互相一致的最佳回应	56
14.4 从奖励学习转向对手信念学习	57
14.5 选美博弈：多想一层会怎样	57

14.6 心理理论与神经证据	58
第 15 章 从解释到证据：参数估计与模型比较	59
15.1 似然评价的是已发生选择的概率	59
15.2 优化只是找参数，不是完成解释	60
15.3 参数可辨识：数据是否真的包含答案	61
15.4 模型恢复：实验能否分出不同机制	61
15.5 拟合得更好，不等于预测得更好	62
15.6 看模型能否重现真正关心的现象	62
15.7 个体差异与神经回归的最后一段距离	63
第 16 章 把实验与模型连成一项研究	64
16.1 先把问题缩小到可操作的差别	64
16.2 先看原始行为，避免模型遮住问题	64
16.3 竞争解释如何落实为模型	65
16.4 在招募之前，先让模拟被试做任务	65
16.5 如果加入神经测量，问题要更具体	66
16.6 怎样写出与证据匹配的结论	66
附录 A 概率与计算的几块基石	67
附录 B 几个值得自己推一遍的问题	69
参考文献	71

从一个选择开始

晚饭时，你在熟悉的食堂与一家新店之间犹豫。食堂的味道比较稳定，新店可能更好，也可能踩雷。朋友的一句推荐、刚刚吃过的东西、今天的时间压力，都可能改变选择。一次简单的决定，已经包含价值比较、不确定性、经验学习、行动控制和社会推断。

研究这些过程，不能只问“这个人理不理性”。我们需要把问题缩小到可以观察、可以操纵的尺度：他过去看到了什么？这次知道什么？选择怎样改变下一次获得的信息？哪一种计算过程能同时解释选择、反应时和神经活动？

本书从这些问题出发。公式用于把口头解释说清楚，实验用于判断解释是否站得住。每个模型都有适用条件；当两个模型给出相同预测时，再精确的数据也不能凭空把它们分开。读到一个神经结果时，也要区分“活动随某个量变化”与“这个活动是行为所必需的”。

记号	默认含义
t, s_t, a_t	时间步或试次；状态；采取的行动。使用前会说明时间单位。
r_{t+1}, G_t	行动后收到的即时奖励；从当前开始的折扣回报。
$V(s), Q(s, a)$	状态价值；在状态 s 采取行动 a 的价值。
α, β, γ	学习率；选择的逆温度；未来奖励的折扣因子。
δ_t	预测误差；具体比较哪些量由所在模型决定。
$p(x z), p(z x)$	给定潜在原因生成观察的概率；观察后对原因的信念。
θ, D	研究者要估计的参数；实际记录的数据。

同一个字母在不同模型中可能承担不同角色。例如信号检测的判别准则与学习率不是同一个量。神经图中的放电率、血氧信号与模型中的价值也不是同一种单位。没有明确说明时，不把它们直接画等号。

第 1 章 怎样把一个心理学问题变成可检验的模型

两个人都选择了稳妥的方案，一个可能讨厌风险，另一个可能认为冒险方案根本不会成功。行为相同，原因却不同。决策研究的困难就在这里：我们直接看到的是选择，想理解的却是选择背后的计算。

本章先建立一套读实验的办法。后面的效用、贝叶斯推断和强化学习，都要回答同一件事：哪些观察支持这个解释，哪些观察能把它与别的解释区分开？

1.1 先区分研究对象与测量方式

假设我们让被试在两个符号之间选择。选左边通常得到一分，选右边通常得不到分。研究者记录选择和反应时，并在某个时刻交换两边的奖励概率。被试并不知道切换发生在哪一轮。

这里至少有三个问题。“环境变化后，被试多久改变选择”是行为问题；“改变来自价值更新还是对规则切换的推断”是算法问题；“哪些细胞或脑网络参与这一过程”是神经实现问题。它们彼此约束，却不能互相代替。一个模型能很好地预测行为，并不意味着大脑逐行执行了模型代码。

Marr 的三个层次有助于分解释释目标。计算层问任务要解决什么问题、在什么约束下什么算好；算法与表征层问信息如何被表示和处理；实现层问物理系统怎样完成处理。所谓“最优”，总是相对于指定目标、可用信息和成本而言。例如知道真实奖励概率的研究者，与只能边试边学的被试，面对的不是同一个信息条件。

实验解读 一轮试次里到底发生了什么

一次学习试次可以写为：呈现两个符号，等待选择，显示结果，进入下一轮。研究者需要分别记录刺激身份、左右位置、按键、反应时、奖励及反馈时间。符号身份与左右位置应交叉安排，否则“偏爱左手按键”可能被误认为“学会了某个符号的价值”。

分析时还要分清选择之前和反馈之后。第 t 轮的选择只能由此前可用的信息解释；如果先把第 t 轮奖励更新进模型，再预测同一轮选择，就把被试还没见过的答案泄露给了模型。

1.2 实验的力量来自对照

观察“人们在高奖励条件下更快”还不够。奖励高的试次会不会也更容易？刺激是否更清楚？被试是否提前知道答案？如果这些因素同时变化，就无法单独解释奖励的作用。

一个好的对照不是把所有现实复杂性都删掉，而是保留问题需要的差异，同时控制其他解释。例如要区分“学得慢”与“选得随意”，可以先让两个选项反复产生稳定反馈，再突然反转。随意选择会让整段行为更分散；低学习率则会让反转后的调整持续滞后。这种时间结构比整段正确率更有信息。

实验条件应当让竞争模型给出不同预测。若两种模型在所选任务上总是输出相同的选择概率，增加被试数量只能更准确地估计相同的预测，不能解决理论上的不可区分。

实际设计还应考虑练习、疲劳和任务理解。条件顺序可以随机化或平衡；关键指导语需要理解检查；反应时剔除规则应在看结果前确定。重复试次不是独立被试，同一人的行为相关性也不能靠把每轮当成一个新人来消除。

1.3 模型不是给现象换个名字

“奖励会增强选择倾向”只是口头假设。要成为可以计算的模型，还需要说明增强多少、持续多久、如何变成选择。最小的两臂学习模型可以由两步组成：

$$Q_{t+1}(a_t) = Q_t(a_t) + \alpha[r_{t+1} - Q_t(a_t)], \quad (1.1)$$

$$P_t(A) = \frac{1}{1 + \exp\{-\beta[Q_t(A) - Q_t(B)]\}}. \quad (1.2)$$

第一行说明反馈怎样改写记忆，第二行说明记忆怎样影响行动。其他选项的价值在这个最小模型中保持不变。 α 大，近期结果影响大； β 大，选择更偏向当前估计较好的选项。两者的作用不同，但在有限数据上可能互相补偿。

模型必须能从给定初始条件生成完整行为。若需要每轮偷偷根据真实选择调整一个自由参数，它就没有承担足够的预测责任。另一方面，简单也不是唯一标准：一个模型若根本不能表示规则变化，就不能因为参数少而被当成完整解释。

数学直觉 从正向生成到反向推断

正向问题是：假如学习率为 0.2，经历这一串反馈后，会怎样选择？反向问题是：看见这一串选择，哪些学习率比较可能？先把正向过程写清楚，才知道反向估计的参数到底代表什么。

1.4 神经证据怎样进入解释

单细胞记录可以观察毫秒尺度的放电变化，适合研究线索、动作和结果附近的响应。fMRI 的 BOLD 信号反映与神经活动相关的血流动力学变化，时间过程更慢，也不是对某一种递质的直接测量。两种方法都可能发现与价值或误差相关的信号，但“相关”还没有告诉我们该信号是否推动了学习。

病损与干预提供另一类约束。若改变某处活动后，模型预言的行为参数发生选择性改变，因果论证会更强。但还要检查刺激扩散、感觉或运动副作用，以及任务理解是否改变。病损患者也可能存在长期代偿，因此一次阴性结果不等于该脑区毫无作用。

一个常见推理错误是：某脑区在控制任务中活跃；现在它也活跃；所以被试正在进行控制。这忽略了同一区域参与其他过程的可能性。后文会反复使用更具体的论证：先写出计算量的逐试次预测，再让任务操纵和神经数据共同约束它。

第 2 章 价值：怎样把不同东西放到一起比较

一杯咖啡和半小时休息没有共同的物理单位，却可以放在同一次选择里。我们说“休息对我更值”，并不是声称大脑里有一个直接显示价值的仪表。价值首先是一种表示方法：把选择中的取舍写成可比较的量，再问这种表示能解释多少行为。

本章从偏好与效用讲起，接着说明实验怎样测量主观价值，最后讨论神经数据能为价值表示提供什么证据。

2.1 效用表示的是顺序，不是一种可直接读取的物质

记 $x \succeq y$ 为至少和 y 一样喜欢 x 。完备性要求能够比较任意两个备选项；传递性要求若 $x \succeq y$ 且 $y \succeq z$ ，则 $x \succeq z$ 。在合适的连续性等条件下，可以用效用函数表示这样的偏好：

$$x \succeq y \iff U(x) \geq U(y). \quad (2.1)$$

这个等价关系没有规定数值刻度。若 U 能表示确定性选择中的偏好，那么严格递增的 $f(U)$ 也能表示。把所有效用乘十，不会改变哪个选项更好。仅凭排序，不能说某个东西带来的幸福是另一个的两倍。

当我们进一步规定选择概率由效用差决定时，数值刻度开始与噪声参数相联系。例如 $P(A) = \sigma[\beta(U_A - U_B)]$ 中，把效用乘十、把 β 除十，预测完全不变。因此估计参数前必须固定一种尺度。

从边际效用理解取舍

设 x 是咖啡数量， y 是点心数量，预算为 m ，价格分别为 p_x, p_y 。约束为 $p_x x + p_y y \leq m$ 。若效用可微，沿一条无差异曲线移动时

$$dU = U_x dx + U_y dy = 0, \quad -\frac{dy}{dx} = \frac{U_x}{U_y}. \quad (2.2)$$

右侧叫边际替代率：为了多一点咖啡，愿意放弃多少点心。预算线的对应斜率是 p_x/p_y 。在内点最优解处，两种交换率相等；否则还可以沿预算线换一换，让自己更满意。

以 $U(x, y) = \sqrt{xy}$ 为例， $U_x/U_y = y/x$ 。若 $p_x = 2, p_y = 1, m = 12$ ，内点条件给出 $y = 2x$ ，代入预算得到 $x = 3, y = 6$ 。这个例子不是关于人的普遍定律，而是演示“偏好与资源约束共同决定选择”。若只喜欢咖啡，最优解可能在边界，不能强行使用相切条件。

2.2 面对风险，平均收益还不够

确定获得 50 元，与各有一半机会获得 0 元或 100 元，期望金额相同。若结果效用为 $u(m) = \sqrt{m}$ ，前者效用约为 7.07，后者期望效用为 5。这里比较的是

$$\mathbb{E}[u(M)] = \sum_i p_i u(m_i), \quad (2.3)$$




图 2.1 教学计算：预算线与无差异曲线。最优点处的局部交换率匹配；曲线的数值标签取决于效用刻度。

而不是先求平均金额再代入效用。凹函数的边际收益递减，因此大幅波动可能降低平均效用。期望效用理论对彩票偏好的表示还需要独立性等条件；它的效用允许正仿射变换，不能像确定性序数效用那样做任意递增变换。

框架效应提醒我们：实验者认为“结果相同”，不代表被试用相同方式表征结果。例如“挽救多少人”和“多少人死亡”会改变参照点与注意。前景理论的一种简化写法是

$$v(x) = \begin{cases} x^\eta, & x \geq 0, \\ -\lambda(-x)^\eta, & x < 0, \end{cases} \quad (2.4)$$

其中 x 是相对参照点的变化， $\lambda > 1$ 表示该模型下损失一侧更陡。概率加权是另一个独立成分，不应与效用曲率混为一谈。这里最重要的问题是：参照点如何确定、收益与损失是否被正确理解、概率是在描述中给出还是通过经验学到。改变这些条件，可能改变观测到的风险态度。

备注 用模型描述偏差，不急着评价一个人

同一个人会随财富、饥饿、时间压力和信息来源改变选择。一次拒绝风险的行为，不足以确定稳定的“风险厌恶人格”。参数首先描述指定任务与模型下的数据规律。

2.3 怎样测量一个人愿意付出的代价

直接询问“你愿意付多少钱”可能没有后果，答案也可能带有策略。BDM 机制将报出的最高愿付价与实际支付价格分开，使如实出价在标准假设下成为合适策略。

假设商品对你的货币价值为 $v = 6$ ，报出 b ，实验者独立抽出价格 p 。若 $b \geq p$ 则以 p 购买，否则不买。报低了，例如 $b = 4$ ，在 $p = 5$ 时会失去本来愿意接受的交易；报高了，例如 $b = 8$ ，在 $p = 7$ 时又可能被迫接受不愿意的交易。报 $b = v$ 可以接受所有对自己有利的价格，拒绝所有不利的价格。

这个论证依赖明确规则：自己的报价不改变抽价分布，被试理解机制，商品与支付有真实后果，并且当轮的愿付价能形成稳定阈值。多轮任务若只随机兑现一轮，也要说明兑现方式，避免把多件商品的联合预算或组合偏好无意带进来。




图 2.2 BDM 机制的教学示例。6 元是报出的最高愿付价；成交时支付独立抽取的价格。图中 4 元与 8 元是两种可能的抽价结果。

实验解读 把价格测量与扫描选择连接起来

Chib 等人的任务先测量被试对不同商品的愿付价，再在扫描中让他们比较商品。商品包括不同类别，因而可以问：某个脑区的活动是否随跨类别的主观价值一起变化？如果只用金额作为解释变量，就无法区分“物品更值”与“屏幕上数字更大”。

共同相关的信号支持可比较的价值表示，却不足以证明所有价值都由单一脑区统一计算。类别、视觉特征、注意和选择难度仍需在设计或分析中控制。[3]

2.4 从行为无差异点走向神经编码

动物无法直接填写愿付价问卷，但可以通过真实选择显示取舍。让猴子在不同种类、不同数量的饮料之间选择，逐步改变数量比例。如果一份 A 与约三份 B 被选择的概率相近，就可以在该任务中把两种饮料换算到共同的行为尺度。

Padoa-Schioppa 与 Assad 将这类行为测量与眶额皮层（OFC）单细胞记录结合，区分了与提供价值、被选价值及被选商品等变量相关的响应。关键不只是“喜欢的东西让细胞更活跃”，而是数量、饮料种类和选择结果的组合，能使不同候选编码给出不同预测。[2]

例如一个细胞若只随选择的总主观价值变化，选择 A 或 B 后的数据可能落到同一条价值响应关系上；若它只编码 A 的物理数量，换成 B 时就不应保留同样关系。分析还要避免选择变量之间过度相关。只把一条好看的回归线画出来，不能排除别的解释。

进一步的 OFC 电刺激研究将相关证据推进到干预证据：不同电流强度下，选择偏移与选择变异出现不同变化。值得学习的是它的逻辑：先利用编码模型预言干预会怎样改变行为，再观察偏移方向是否符合预言。[4] 这仍不等于所有决策都必须采用同一种神经机制。




图 2.3 饮料选择任务：先注视，再看到两种饮料及其数量，随后作出选择并获得相应饮料。数量和种类共同决定主观价值。（课件 2 value，第 39 页）




图 2.4 课件中的选择曲线。横轴改变 B 与 A 的份数比例，纵轴为选择 B 的比例。接近 50% 的位置给出行为上的无差异点。（课件 2 value，第 40 页）

2.5 社会价值也需要具体的取舍

捐款、分配和公平选择可以放进价值框架，但不能只用自己获得的金额解释。一种教学模型是

$$U_i = x_i + \rho x_j - \lambda |x_i - x_j|. \quad (2.5)$$

x_i 为自己收入， x_j 为他人收入； ρ 表示对他人收入的权重， λ 表示对差距的厌恶。这只是简化模型，因为人们对自己处于优势和劣势的差距可能有不同反应。

看一个具体比较：方案 A 为 (10, 0)，方案 B 为 (7, 7)。在 $\rho = 0.2, \lambda = 0.1$ 时， $U(A) = 9$ ， $U(B) = 8.4$ ；把 λ 改为 0.2，则 $U(A) = 8$ ， $U(B) = 8.4$ 。同样的平等选择，既可能来自更重视别人，也可能来自更不喜欢差距。若实验只提供这一对方案，两个动机难以分开；需要同时改变总收益与差距。

社会价值的研究因而不是给每种美德安排一个脑区。它要求把利益、规范、他人的意图和自己的信念分开操作，观察哪些因素影响价值、哪些因素影响推断。这条区分会在社会博弈中再次出现。

第 3 章 情境为什么会改变价值与选择

同一杯咖啡，放在便宜饮料旁边显得贵，放在更贵的精品咖啡旁边又显得合理。单凭这一现象，我们还不知道发生了什么：可能是价值表示改变，可能是注意改变，也可能是被试从菜单推断出了质量信息。

本章关注一种可计算的解释：神经系统的表示范围有限，价值信号会随周围选项调整。我们不仅要写出归一化公式，还要弄清它在什么条件下真的会改变行为。

3.1 先分清几种不同的情境效应

设在 $\{A, B\}$ 中，选择概率为 $P(A), P(B)$ 。在标准多项 logit 模型中，加入 C 后， A 与 B 的相对概率满足

$$\frac{P(A | A, B, C)}{P(B | A, B, C)} = \frac{\exp(\beta V_A)}{\exp(\beta V_B)}. \quad (3.1)$$

只要价值与温度保持不变，这个比值与 C 无关，这就是该模型的无关选项独立性。它比“人不会选明显差的选项”强得多。

诱饵效应讨论的是：加入一个被某选项支配的备选，可能提高那个选项的吸引力。折中效应讨论的是：成为中间选项后更容易被选。选择过载则讨论集合变大后购买率、满意度或决策难度如何变化。这些现象不是同一件事，也不必共享单一机制。

对订阅套餐的课堂例子，可以直接比较两个菜单：电子版 59 元与纸质加电子版 125 元；再加入仅纸质版 125 元。后者被组合版支配，但其存在可能改变比较方式。这个例子说明应检查集合效应，并不代表任何加入的诱饵都必定有效。

3.2 除法归一化：把有限的表示范围分给当前环境

设非负输入价值为 V_i ，一个简单的归一化响应为


$$\mu_i = K \frac{V_i}{\sigma + \sum_j w_j V_j}, \quad \sigma > 0. \quad (3.2)$$

分子是当前选项的驱动，分母是背景与多个输入汇总形成的抑制尺度。 K 控制输出范围， σ 防止小输入时分母过小， w_j 决定各选项对归一化池的贡献。

如果整个环境的输入都很大，分母也变大，神经响应不至于无限增长。代价是：相同的 V_i 在不同背景下得到不同输出。因此 μ_i 不只是该选项的绝对价值，还携带了它相对于当前集合的信息。

数学直觉 单纯“除一下”不会自动翻转偏好

若所有选项使用相同正分母，而且最终总是选择最大响应，那么 $V_A > V_B$ 仍然推出 $\mu_A > \mu_B$ 。归一化不会凭空把大小关系倒过来。要解释选择概率的变化，还必须说明噪声加在哪里、如何比较响应，以及注意是否改变权重。



Louie et al., *J Neuro*, 2011

图 3.1 情境编码的实验思路：改变反应场内与反应野外目标关联的奖励，观察同一细胞的响应如何变化。刺激位置与奖励价值应分开操纵。（课件 3 context，第 30 页）

3.3 噪声为什么让第三个选项影响前两个

为了把逻辑看清楚，先研究 A 与 B 的成对神经证据。设 $r_i = \mu_i + \epsilon_i$ ，且两个输出噪声独立、均为 $\mathcal{N}(0, s^2)$ 。那么

$$P(r_A > r_B) = \Phi\left(\frac{\mu_A - \mu_B}{\sqrt{2}s}\right). \quad (3.3)$$

若 $V_A = 8, V_B = 6$ ，共同分母记为 D ，则响应差为 $2K/D$ 。加入较有价值的 C，会增大 D ；在输出噪声尺度 s 不变的假设下，A 与 B 更难区分，成对概率向 $1/2$ 靠近。

这一推导说的是成对响应比较，**不应直接把它当成三选一时排除 C 后的条件选择概率**。在三选一任务中，还要计算 C 赢得比较的概率；只保留未选 C 的试次也会产生选择筛选。完整模型可以对三个带噪声响应一起取最大值，然后统计目标选项之间的相对选择率。Louie 等人的工作正是把归一化编码与含噪读出结合，检验情境对行为的影响。[5]




图 3.2 教学模型预测：第三个输入增大时，A、B 的归一化响应同时下降，固定输出噪声下的成对可分性降低。这不是实验数据，也不是所有三选一模型的通用结论。

如果噪声在归一化之前产生，信号与噪声可能一起缩放，信噪比未必这样变化。若噪声与均值有关，结论也要重新计算。公式外那一句“固定输出噪声”并非细枝末节，它承担了行为预测的一部分。

3.4 同一轮的比较与跨时间的适应

归一化可以依赖当前同时出现的选项；适应则可以依赖前面许多轮的价值范围。例如先让被试看大量高价值商品，再呈现中等价值商品，观察评价是否降低。此时即使当前菜单不变，历史环境也可能改变响应增益。

为了区分两者，可以交叉操纵当前竞争选项与此前的价值分布。前者要求控制本轮集合；后者要求让历史背景不同、当前目标相同。顺序效应、疲劳和价格锚定也可能产生类似行为，因此需要平衡呈现顺序，并提出各模型对时间过程的不同预测。

3.5 多属性选择不一定先算一个固定总分

挑选食品时，味道与健康并不总以固定比例合成。一个基础模型写为

$$V_i = w_{\text{taste}} T_i + w_{\text{health}} H_i. \quad (3.4)$$

如果开始时主要看味道，后来才注意健康，权重可能随时间变化。竞争也可以发生在属性内部：先比较各选项的味道，再比较健康程度，然后整合两种比较信号。两种算法有时给出相同最终选择，却预言不同的注视顺序或反应时。

MODEL




图 3.3 课件中的多层竞争模型。底层先处理属性相关信息，上层形成选项竞争。连线区分兴奋、抑制与增益调节；图中的结构是候选计算机制。（课件 3 context，第 48 页）

实验可以通过提示语、信息呈现顺序、注视操纵或时间限制，改变某个属性进入比较的机会。若只在事后看到“选择更健康”，仍需区分健康权重提高、味道权重降低、起点偏向变化与按键策略变化。一个有用的模型，应能解释这些操作如何影响完整的选择过程，而不只给结果贴上“情境依赖”的标签。

第 4 章 贝叶斯判断：看见的证据怎样改变信念

黑暗中看到一个模糊的影子，你要判断那里是否有人。眼睛给出的证据不完美，场景也有先验差异：空教室和拥挤车站里，“有人”的基础概率不同。即使得到相同感觉证据，两种场景下合理的判断也可能不同。

贝叶斯观察者模型把这件事拆开：世界怎样产生感觉，观察者原先相信什么，以及判断错误要付出什么代价。把三者混在一个“偏差”参数里，反而会丢失最有趣的心理学问题。

4.1 先写生成过程，再写推断

设 S 表示有信号， N 表示无信号， x 是内部感觉证据。生成模型指定 $p(x | S)$ 与 $p(x | N)$ ；例如有信号时证据平均更大，但两种分布仍重叠。观察到 x 后，贝叶斯公式给出

$$p(S | x) = \frac{p(x | S)p(S)}{p(x | S)p(S) + p(x | N)p(N)}. \quad (4.1)$$

分子衡量“有信号且出现这份证据”的相对支持度。分母把所有可能原因的支持度加起来，使概率归一化。连续变量中 $p(x | S)$ 是密度，可以大于 1；真正的区间概率由积分给出。

把公式改写成赔率更容易看出每部分的作用：

$$\frac{p(S | x)}{p(N | x)} = \underbrace{\frac{p(x | S)}{p(x | N)}}_{\text{似然比}} \underbrace{\frac{p(S)}{p(N)}}_{\text{先验赔率}}. \quad (4.2)$$

似然比为 8，表示这份证据在 S 条件下出现的可能性是 N 条件下的八倍。它没有直接说 S 的后验概率是八分之七。如果 S 原先只有 0.2 的概率，先验赔率为 $1/4$ ，后验赔率就是 2，后验概率为 $2/3$ 。

数学直觉 用人数检查一次概率计算

在 1000 次情况中，假设 200 次有信号。某种“阳性证据”在有信号时出现率为 0.8，无信号时为 0.1。阳性证据来自有信号的约 160 次，来自无信号的约 80 次。因此看到阳性证据后，有信号的比例是 $160/(160 + 80) = 2/3$ 。分母里不能漏掉无信号也产生相同证据的情况。

4.2 信号检测：敏感性与回答倾向是两件事

最常见的等方差高斯模型为

$$x | N \sim \mathcal{N}(\mu_N, \sigma^2), \quad x | S \sim \mathcal{N}(\mu_S, \sigma^2), \quad \mu_S > \mu_N. \quad (4.3)$$

观察者在 $x > k$ 时回答“有信号”。改变 k 会同时改变命中率和虚警率。一个总回答“有”的人，可以命中所有信号，却也会在无信号时全部误报。

	实际有信号	实际无信号
回答有	命中 (hit)	虚警 (false alarm)
回答无	漏报 (miss)	正确拒绝

等方差模型的敏感性为

$$d' = \frac{\mu_S - \mu_N}{\sigma} = \Phi^{-1}(H) - \Phi^{-1}(F), \quad (4.4)$$

其中 H, F 为命中率与虚警率。常用的标准化准则为

$$c = -\frac{\Phi^{-1}(H) + \Phi^{-1}(F)}{2}. \quad (4.5)$$

当 $c > 0$ 时，准则相对保守；当 $c < 0$ 时，更容易回答有。这里的“保守”描述回答倾向，不代表感觉能力更差。




图 4.1 教学计算：左图的两条分布决定可分性，竖线决定回答准则；右图沿 ROC 曲线移动对应改变准则。提高敏感性与改变准则会产生不同模式。

实验中要同时收集信号与无信号试次。若某条件的命中率为 1 或虚警率为 0，直接做反正态变换会得到无穷大。小样本下可用例如 $(h + 0.5)/(n_S + 1)$ 的校正，或直接拟合二项观测模型。校正有限样本处理，不是“完美感知”的证据。

4.3 最合理的动作不一定是可能的状态

如果漏掉一个信号的代价远大于误报，观察者可能在 S 的后验概率尚未超过一半时就回答“有”。设正确判断损失为 0，虚警损失为 $C_{FA} > 0$ ，漏报损失为 $C_M > 0$ 。两种动作的后验期望损失分别为

$$L(\text{报有} | x) = C_{FA}p(N | x), \quad (4.6)$$

$$L(\text{报无} | x) = C_M p(S | x). \quad (4.7)$$

选择损失更小的动作，得到

$$\frac{p(x | S)}{p(x | N)} > \frac{p(N) C_{FA}}{p(S) C_M}. \quad (4.8)$$

左边是感觉证据，右边是由基础概率与任务代价决定的标准。增加漏报代价会降低阈值；减少信号出现率会提高阈值。这两种操作不必改变感觉分布。

实验解读 区分看不清与不愿冒险

让同一被试做几组视觉检测。第一种操纵降低刺激对比度，预计主要改变感觉可分性。第二种保持刺激不变，改变信号出现频率或报错代价，预计主要改变准则。观察命中率、虚警率与 ROC，而不只比较总正确率。

如果被试并未准确学到基础概率，行为准则也可能偏离研究者算出的最优值。这时应检验主观先验或学习过程，而不能直接把偏离归为“没有使用贝叶斯规则”。

4.4 三门问题：信息来自观察方式

三扇门后只有一辆车。你先选 1 号门。主持人知道车在哪里，必须从你没选的门中打开一扇空门，然后允许换门；有两扇可开的空门时随机选一扇。现在他打开了 3 号门。

在车位分别为 1、2、3 时，观察到主持人打开 3 号门的概率为 $1/2, 1, 0$ 。乘上各自 $1/3$ 的先验，再归一化，得到车在 1 号门的概率为 $1/3$ ，在 2 号门为 $2/3$ 。因此应换门。

如果主持人只是随手开门、恰好没有开出车，条件概率就不同。**贝叶斯推断必须把产生信息的过程写进模型**。“看到一扇空门”是观察；“主持人怎样选择要开的门”决定这个观察有多大信息量。在社会推断中，别人为什么告诉你某句话，也承担类似作用。

4.5 从连续估计走向损失函数

对连续位置 s ，后验不是一个标签，而是一条分布。若报告值为 a ，最优报告需要最小化后验期望损失：

$$a^* = \operatorname{argmin}_a \int L(a, s) p(s | x) ds. \quad (4.9)$$

平方损失 $L = (a - s)^2$ 下，对 a 求导得到 $2[a - \mathbb{E}(s | x)] = 0$ ，所以报告后验均值。绝对损失 $|a - s|$ 下，最优报告是后验中位数。用很窄的容差窗口判对错时，报告更接近后验最密集的位置；不能把所有情形都说成“取最大后验”。

观察者的推断与研究者的拟合也是不同层次。观察者推断“声音在哪”；研究者推断“这个人的感觉噪声多大”。我们完全可以用最大似然法拟合一个贝叶斯观察者模型。模型中的“贝叶斯”描述被假定的认知过程，不规定研究者必须使用哪一种估计工具。

第 5 章 从判断到行动：反应时与认知控制

一个人做得快，可能是非常熟练，也可能是不够谨慎；做得慢，可能是认真权衡，也可能只是两个选项太接近。反应时很有价值，但它不会自动告诉我们用了哪个心理系统。

本章把时间放进决策过程。先看证据如何积累，再用这一思路重新理解速度、合作和自我控制之间的关系。

5.1 先观察一项可以调节难度的任务

随机点运动任务要求被试判断一群点整体向左还是向右。研究者改变同向运动的点所占比例，称为运动一致性。低一致性时，多数局部运动相互干扰；高一一致性时，方向更清楚。




图 5.1 随机点运动任务的教学图示。实际刺激是运动点，图中的箭头仅用于说明方向。反应时通常从规定的刺激起点计到按键，需与刺激呈现方式一致。

同一条件反复呈现，反应时不会完全相同，也会出现错误。一个只输出“选择更大价值”的规则无法解释这些分布。积累模型则假定观察者随时间获得带噪声的证据，积累到足够程度时才作答。

5.2 为什么证据可以相加

若在 S 与 N 两种状态下，连续证据 $x_1, \dots, x_n$ 条件独立，则后验对数赔率满足

$$\log \frac{p(S | x_{1:n})}{p(N | x_{1:n})} = \log \frac{p(S)}{p(N)} + \sum_{i=1}^n \log \frac{p(x_i | S)}{p(x_i | N)}. \quad (5.1)$$

每一份新证据贡献一个增量。支持 S 的证据把累积量往上推，支持 N 的证据往下推。条件独立很重要：如果同一信息被重复看到，不能把它当成很多独立证据无限累加。

在合适近似下，许多小增量可以写成漂移扩散过程。用 $x(t)$ 表示累积量，模型为

$$dx = v dt + \sigma dW_t, \quad x(0) = z, \quad 0 < z < a. \quad (5.2)$$

两条边界为 0 与 a 。先碰到 a 就选上方选项，先碰到 0 就选下方选项。 v 是平均证据增长速度， σ 控制随机波动， z 是起点， a 是边界间距。观察到的反应时还包括刺激编码和运动执行：

$$RT = T_{\text{decision}} + T_{\text{nd}}. \quad (5.3)$$

T_{nd} 称非决策时间。边界命中的时间是随机的，所以模型自然产生一整条反应时分布。




图 5.2 教学模拟：轨迹在两条边界之间积累，首次到达边界决定选择和决策时间。另一面板比较不同边界间距下的反应时分布；更谨慎通常意味着更慢。

5.3 参数改变的是哪个环节

较大的正 v 表示证据更稳定地支持上方选项，通常带来更高的上方选择率和更短决策时间。增大边界间距 a ，则要求更多证据，通常提高准确率、延长时间。把 z 向上移动，会偏向上方选项；增加 T_{nd} 则主要把反应时整体后移，而不直接改变选择概率。

最简单模型中，上边界命中概率为

$$P(\text{上}) = \frac{1 - \exp(-2vz/\sigma^2)}{1 - \exp(-2va/\sigma^2)} \quad (v \neq 0), \quad (5.4)$$

$v = 0$ 时取极限 z/a 。若起点居中 $z = a/2$ ，它简化为 $\sigma_{\log}[va/\sigma^2]$ ，其中 $\sigma_{\log}(u) = 1/(1 + e^{-u})$ 是 logistic 函数。只看选择率时，增大漂移与增大边界可能产生类似效果；加入反应时后才有机会区分。

居中起点下，平均决策时间为

$$\mathbb{E}[T] = \frac{a}{2v} \tanh\left(\frac{av}{2\sigma^2}\right), \quad (5.5)$$

$v \rightarrow 0$ 时为 $a^2/(4\sigma^2)$ 。这是最简固定参数模型的结果；真实数据中的慢错误、极端快反应或长尾，可能要求试次间参数变异、污染过程或更复杂边界。

模型计算 怎样生成一条决策轨迹

```
import numpy as np

def one_trial(v, a, rng, dt=0.001, sigma=1.0):
    x, elapsed = a / 2, 0.0 # 从两边界中间开始
    while elapsed < 20.0:
        # 随机增量的标准差是 sqrt(dt)，不是 dt
        x += v * dt + sigma * np.sqrt(dt) * rng.normal()
        elapsed += dt
        if x >= a:
            return 1, elapsed + 0.3 # 加入非决策时间
        if x <= 0:
            return 0, elapsed + 0.3
    return None, None # 超时不能伪装成一次普通作答

rng = np.random.default_rng(7)
choice, rt = one_trial(v=1.0, a=1.2, rng=rng)
print(choice, rt)
```

重复很多轮才能得到概率与分布。离散模拟可能跨过边界，因此减小时间步能降低离散误差。这段代码用于理解生成过程；正式参数估计还需要首达时密度或合适的数值方法。

5.4 为什么“更快”不等于“更自私”或“更合作”

公共品任务让 n 个人各有禀赋 e ，投入 c_i ，公共池乘以 m 后平均返还。个人收入为

$$x_i = e - c_i + \frac{m}{n} \sum_j c_j, \quad 1 < m < n. \quad (5.6)$$

一个人多投入 1 单位，自己直接损失 $1 - m/n > 0$ ，但全组收入增加 $m - 1 > 0$ 。这形成个人与集体利益的张力。改变返还倍数也会改变选择难度，不能只把它当成“合作程度”刻度。

设某人很重视他人的收益，高回报条件下合作明显更好，于是很快；另一个人很不重视他人，自私方案明显更好，也很快。当样本中不同偏好的人混在一起时，平均反应时与合作的相关方向可能取决于任务给出的收益范围。

Krajch 等人的分析强调了这种选择可分性的作用。用主观价值差解释反应时，可以重现、减弱甚至逆转一些“快就是某种动机”的关系。[6] 这不是说所有双过程理论都被否定，而是说单凭快慢不足以识别心理过程。




图 5.3 课件中的反应时与选择倾向关系。要理解组间平均快慢，必须同时考虑每个人对两类方案的偏好强度。（课件 4-5 action，第 30 页）

5.5 控制可以改变信息的权重，而不必是两个系统打架

在食品选择中，先独立测量味道与健康评价，再让被试选择是否食用某个食品，可以把主观价值写为 $V = w_T T + w_H H$ 。若健康信息进入得较晚，或者权重较小，时间限制会有特定影响；若是起点已偏向某类食物，预测又不同。




图 5.4 食品自我控制任务：分别评价健康与味道，再进行真实选择。先测属性评价，才有机会检验选择价值由哪些属性构成。（课件 4-5 action，第 42 页）

Hare 等人的研究考察 vmPFC 价值信号与健康属性、自我控制及外侧前额叶活动之间的联系。[7] 一个有用的解释是控制过程影响信息整合，使健康属性更充分地进入价值计算。脑区之间的相关或 PPI 分析本身不能证明一条单向抑制通路。

诚实任务中也需要类似谨慎。若一个人可以通过虚报结果增加收入，“少撒谎”可能涉及冲突处理、规范权重或收益敏感性。右侧 DLPFC 的脑刺激研究发现特定条件下诚实行为增加，但并未由此建立所有极性刺激都产生对称、相反的行为效应。[10] 更不应把一处脑区简单称为“道德开关”。

病损研究：同一收入选择，有无诚实冲突

朱露莎等人的研究把利益分配与诚实要求分开：有的条件需要通过向另一人发送信息来影响其选择，另一些条件提供相近的经济取舍，却没有同样的诚实顾虑。DLPFC 病损对包含诚实冲突的行为影响，与没有诚实顾虑时的选择并不相同。[8]

这个对照使结论更具体：差异不只是“患者更爱钱”，而涉及诚实动机与自利动机的权衡。不过它仍不能独自证明自利就是每个人的默认反应，也不能把病损效应等同于健康人短时增加认知负荷的效应。

道德困境中的 vmPFC 病损结果进一步说明，控制、情感与价值并不适合被排成一条简单的“理性对情绪”直线。在部分高冲突个人道德情境中，病损组更常接受伤害一人以获得更大总体收益的方案；其他情境的模式不同。[9]




图 5.5 不同类别情境下的道德判断。差异集中在哪类情境，往往比“哪一组更功利”这一总体标签更有解释力。（课件 4-5 action，第 58 页）

这种结果不是价值判断的标准答案。它提供的是过程约束：哪些信息或情绪反应在特定冲突条件下影响了选择，还需要用更具体的任务与模型追问。

这些例子共同要求：把控制落实到可区分的计算环节，并使用操纵、选择与反应时共同检验。模型参数不是脑区的别名；它们是连接任务与数据的中间语言。

第 6 章 多种线索与潜在结构：什么时候应该合在一起

看电影时，我们通常把声音定位到屏幕上的人物；如果声音从很远的门外传来，又不一定这样。这说明感知不是永远相信眼睛，也不是永远把所有线索求平均。系统既要估计每条线索有多可靠，还要判断它们是否来自同一个原因。

这一章把贝叶斯推断从二选一扩展到连续估计和结构学习。重点不是复杂积分本身，而是看清：同一套推断原则，怎样产生加权平均、向均值回归以及新类别的形成。

6.1 可靠的线索为什么得到更大权重

假设视觉测量 x_v 与触觉测量 x_h 都针对同一个物体高度 s ，两者条件独立：

$$x_v | s \sim \mathcal{N}(s, \sigma_v^2), \quad x_h | s \sim \mathcal{N}(s, \sigma_h^2). \quad (6.1)$$

先使用足够平坦的先验。后验正比于两条似然的乘积；取负对数、去掉与 s 无关的项，得到

$$-\log p(s | x_v, x_h) = \frac{(s - x_v)^2}{2\sigma_v^2} + \frac{(s - x_h)^2}{2\sigma_h^2} + \text{常数}. \quad (6.2)$$

对 s 求导并令其为零，就得到

$$\hat{s} = w_v x_v + w_h x_h, \quad w_v = \frac{1/\sigma_v^2}{1/\sigma_v^2 + 1/\sigma_h^2}, \quad w_h = 1 - w_v. \quad (6.3)$$

精度定义为方差的倒数。噪声越小，精度越大，权重越高。这个权重不是因为视觉在概念上“更高级”，而是因为在指定任务中它的测量更稳定。

若视觉报告 10，标准差为 2；触觉报告 14，标准差为 4，那么视觉权重为 0.8，整合估计为 10.8。整合方差为

$$\sigma_{vh}^2 = \left(\frac{1}{\sigma_v^2} + \frac{1}{\sigma_h^2} \right)^{-1} = 3.2, \quad (6.4)$$

小于两个单独方差。这个收益依赖独立噪声假设。若两条线索共享同一个误差源，重复计入信息会让模型过度自信。

实验解读 先测单通道，再预言双通道

Ernst 与 Banks 先测量视觉、触觉各自判断高度的变异，再据此预测双通道条件下的权重与精度。[11] 实验的说服力来自额外约束：整合模型不能在看到双通道结果后任意挑一个权重来贴合数据。

可以进一步人为模糊视觉线索，并让视觉与触觉给出轻微冲突。若权重随单通道可靠性系统变化，证据就比“两种感觉一起用比较好”更具体。




图 6.1 教学计算：两个单独似然的乘积得到更集中的后验。改变视觉噪声后，整合中心向更可靠的触觉线索移动。

6.2 先验怎样产生向平均值回归

加入高斯先验 $s \sim \mathcal{N}(\mu_0, \tau^2)$ ，对单一测量 $x | s \sim \mathcal{N}(s, \sigma^2)$ ，后验均值为

$$\hat{s} = \frac{\tau^2}{\tau^2 + \sigma^2} x + \frac{\sigma^2}{\tau^2 + \sigma^2} \mu_0. \quad (6.5)$$

感觉越不可靠，估计越接近先验均值。以时间间隔重现为例，被试先看到两个事件间的时间，再用动作重现。短间隔可能被估长，长间隔可能被估短；在模型中，这是噪声测量与时间分布先验结合的结果。

不要把所有“向平均值回归”都归于认知先验。重复测量的统计回归、记忆衰减、运动输出限制，也可能产生类似图形。实验可以改变被试经历的时间分布，检验偏移中心是否随之变化；还可以独立估计运动噪声，避免把输出的不稳定全算成感知不确定性。

6.3 共同原因推断：整合之前先问是不是一回事

设 $C = 1$ 表示声音与闪光来自同一位置， $C = 2$ 表示来自两个位置。共同原因模型中，两条线索共享一个潜变量 s ；分离原因模型中，它们分别由 s_a, s_v 生成。

共同原因的模型证据需要把未知位置积分掉：

$$p(x_a, x_v | C = 1) = \int p(x_a | s) p(x_v | s) p(s) ds, \quad (6.6)$$

$$p(x_a, x_v | C = 2) = \iint p(x_a | s_a) p(x_v | s_v) p(s_a) p(s_v) ds_a ds_v. \quad (6.7)$$

这一步叫边缘化。它比较的是整个模型生成当前数据的能力，而不是只找每个模型最能解释数据的一个参数点。再乘上 $p(C)$ 并归一化，得到共同原因后验 $q = p(C = 1 | x_a, x_v)$ 。

若视觉与听觉位置接近，共同原因通常比较容易解释；若差距很大，分离原因得到的支持可能增加。但“多远算远”取决于线索噪声与先验。噪声大的两条线索，即使差得较远，也不一定构成强烈冲突。




图 6.2 视听定位任务的教学图示。报告声音位置时，视觉可能将报告拉向闪光；距离变大后，观察者可能更倾向于分开处理。图示展示候选机制，不是确定的逐人行行为规律。

同样的后验，还可以产生不同的报告策略

设共同原因下的声音估计为 $\hat{s}_1$ ，分离原因下为 $\hat{s}_2$ 。模型平均报告 $q\hat{s}_1 + (1 - q)\hat{s}_2$ ，对应平方位置误差下对结构不确定性的整合。模型选择只采用后验更大的那个结构。概率匹配则以概率 q 采用第一种结构，以 $1 - q$ 采用第二种。

若 $q = 0.7, \hat{s}_1 = 6, \hat{s}_2 = 0$ ，模型平均每次给出的无输出噪声报告是 4.2；模型选择给出 6；概率匹配在 6 和 0 之间随机取值，平均仍为 4.2。**相同的平均报告，不等于相同的认知过程。**重复试次的分布形状可以区分“每次折中”与“有时整合、有时分开”。




图 6.3 课件展示的三种报告策略所产生的模拟分布。比较的不只是平均位置，还包括集中程度、多峰与条件变化。（课件 Bayesian observer，第 32 页）

Wozny 等人比较这些策略时，在其视听定位任务中发现很多观察者更符合概率匹配。[12] 这说明推断后验与如何使用后验需要分别建模，不能因模型含有贝叶斯公式，就自动宣称所有行为都达到了给定损失下的最优。

6.4 类别数未知时，怎样产生一个新类别

见到一种陌生动物，我们可能把它归为已知类别，也可能认为应该新建一类。如果模型预先只允许两类，它就无法解释第三类如何出现。中国餐馆过程（CRP）用一个简单先验描述“加入旧类还是开新类”。

已有 N 个对象，类别 j 中有 n_j 个，集中参数为 $\alpha_{\text{CRP}} > 0$ 。下一个对象的先验分配概率为

$$P(z_{N+1} = j) = \frac{n_j}{N + \alpha_{\text{CRP}}}, \quad P(\text{新类}) = \frac{\alpha_{\text{CRP}}}{N + \alpha_{\text{CRP}}}. \quad (6.8)$$

这里并不是因为餐桌有心理学意义，而是借它描述类别分配。已有大类更容易吸收新对象，新类仍保留非零概率；类别数量随数据增长，而不是预先写死。




图 6.4 中国餐馆过程用“加入已有桌子或开启新桌子”表示类别分配先验。真正做分类时，还必须乘上对象特征的似然。（课件 Bayesian observer，第 38 页）

只有人数先验还不够。一个新对象若和大类非常不相似，仍可能开启新类。后验分配应满足

$$P(z = j | x, \text{过去数据}) \propto P(z = j | \text{过去分配}) p(x | \text{类别 } j). \quad (6.9)$$

新类的似然来自对未知类参数的先验预测，不能随意设成常数 1，否则会不合理地偏爱开新类。

把二元特征的计算做一遍

设每个对象有五个取值为 0 或 1 的特征，各类中每个特征概率采用 Beta(1, 1) 先验。第一件对象是 (1, 1, 1, 1, 1)。观察后，这一类每个特征为 1 的后验预测概率是 2/3。

第二件对象是 $(1, 0, 1, 0, 1)$ 。设 $\alpha_{\text{CRP}} = 1$ ，加入旧类与开新类的先验都为 $1/2$ 。两种未归一化权重分别为

$$u_{\text{old}} = \frac{1}{2}(2/3)^3(1/3)^2 = \frac{4}{243}, \quad (6.10)$$

$$u_{\text{new}} = \frac{1}{2}(1/2)^5 = \frac{1}{64}. \quad (6.11)$$

旧类后验概率为 $u_{\text{old}}/(u_{\text{old}} + u_{\text{new}}) = 256/499 \approx 0.513$ 。虽然旧类略占优势，但远没有确定到可以忽略另一个可能性。

模型计算 计算一次类别分配

```
import numpy as np

x = np.array([1, 0, 1, 0, 1])
p_old = np.full(5, 2 / 3) # 已见一个全 1 对象
# 特征条件独立时，相乘得到该类的预测似然
lik_old = np.prod(p_old**x * (1 - p_old)**(1 - x))
weights = np.array([0.5 * lik_old, 0.5 * 0.5**5])
posterior = weights / weights.sum() # 旧类、新类
print(posterior) # 约为 [0.513, 0.487]
```

若每轮选概率最大的一类，选完就永不回头，这只是贪心近似。完整贝叶斯推断还需保留或积分许多可能的历史分配。粒子方法可以保留若干条类别历史，让新数据重新分配权重。两种方法对呈现顺序的敏感性可能不同，因而可以通过实验检验近似算法，而不仅检验抽象的贝叶斯原则。

第 7 章 结果与反事实：得到多少不是体验的全部

你买的彩票赢了 50 元，本来很高兴；随后知道另一张票会赢 200 元，心情可能改变。实际收入没有变化，变化的是比较对象。结果评价不仅涉及“发生了什么”，也涉及“如果当时换一种选择会怎样”。

反事实既可能帮助学习，也可能把一次独立的坏运气误当成策略错误。本章围绕这一张力，区分失望、后悔与有用的替代反馈。

7.1 先把比较对象说清楚

失望通常比较同一选择下本来可能发生的较好结果；后悔则比较没有采取的行动会带来的结果。为了避免只记两个名词，考虑图中的具体例子：选 A 后实际得到 -50，A 的另一个可能结果为 +50；未选的 B 此次实际结果为 +200。




图 7.1 教学示例：失望与后悔的比较基准不同。A 的另一个可能结果并未实现；B 的结果则在完整反馈条件下被揭示。

若用差值作最简单的量化，失望相关差距为 $50 - (-50) = 100$ ，后悔相关差距为 $200 - (-50) = 250$ 。差值只是候选计算量，不是情绪本身的定义；主观体验可能随差距非线性变化，也可能取决于责任归属、结果可控性和选择是否自愿。

7.2 怎样在实验中区分两种比较

Camille 等人的赌博任务使用部分反馈与完整反馈：前者不揭示未选彩票的实际结果，后者揭示。被试在结果后报告情绪，研究者比较获得结果与未获得结果对评分和之后选择的影响。[13]

这个设计的关键是让实际得失相似，但能进行的反事实比较不同。如果完整反馈下情绪更受未选结果影响，就不能仅用本人最终收入解释。与 OFC 病损患者的比较进一步约束了反事实评价的神经机制，但小样本、病损范围和一般任务能力都应纳入解释。




图 7.2 课件中的情绪评分结果。横轴是已获得结果，不同线区分未获得结果；上、下分别对应部分与完整反馈。阅读重点是同一已获结果下的评分差异。（课件 6 outcome, 第 19 页）

实验解读 不把“有图形差异”直接当成机制

如果两种反馈条件的视觉复杂度不同，注意与记忆负担也可能不同。可以在两组都显示相同位置与时长的信息，同时只改变是否揭示有意义的替代结果。若要研究预期后悔，还应分析作出选择时的可用信息，而不是把事后已经知道的两个结果塞回选择模型。

7.3 反事实怎样进入选择模型

一种教学性的结果效用为

$$U(a, r_a, r_b) = u(r_a) - \rho \max\{u(r_b) - u(r_a), 0\}, \quad \rho \geq 0. \quad (7.1)$$

第一项是实际结果的效用，第二项是没选方案更好时的惩罚。作出选择前尚不知道具体结果，因此应比较预期值：

$$\bar{U}(a) = \sum_{r_a, r_b} p(r_a, r_b | a) U(a, r_a, r_b). \quad (7.2)$$

这里需要两个结果的联合分布。只知道 A、B 各自的边际概率，并不总能计算预期后悔：两个结果是否相关会改变“B 比 A 好多少”的概率。

例如两种彩票总是同涨同跌，与一个涨时另一个跌，可以拥有相同边际分布，却产生不同替代比较。实验若只让被试看边际概率，就不应悄悄假定他们知道真实的相关结构。

7.4 替代反馈为什么可能加快学习

普通试错只告诉我们选中方案的结果。若完整反馈还揭示未选方案的结果，就能同时更新两种价值：

$$Q_{t+1}(a_t) = Q_t(a_t) + \alpha_{\text{chosen}}[r_{a,t+1} - Q_t(a_t)], \quad (7.3)$$

$$Q_{t+1}(b) = Q_t(b) + \alpha_{\text{cf}}[r_{b,t+1} - Q_t(b)]. \quad (7.4)$$

如果 B 的结果没有被揭示，第二行就没有真实观测可用。想象出来的结果属于额外模型推断，不能伪装成实验反馈。

设 A、B 初始价值都为 0.5，本轮选 A 并看到 A 得 0、B 得 1，两种学习率均为 0.2。完整反馈后价值为 (0.4, 0.6)；只有选中反馈时为 (0.4, 0.5)。后者知道 A 不太好，前者还学到了 B 较好，因此下一轮选择可能更快改变。

这不意味着每一份替代信息都值得学习。如果下一轮是同一未知稳定环境，反馈有助于估计长期规律；若每轮概率已知且相互独立，上一轮没有选中的大额奖金并不会让下一轮同一选项更容易中奖。反事实是否有用，取决于它是否提供了可迁移的信息。

7.5 有神经信号，不一定被行为利用

研究者可以先定义替代误差，例如“某个未选投资比例本可带来的收益，减去当前比例的收益”，再检验脑活动是否随之变化。还应另行检验该变量是否预测下一轮调整。Chiu 等人的研究之所以有启发，是因为神经层面出现相关信号，与行为是否使用该信息可以分离。^[14]

因此，“系统计算了某个量”与“这个量控制了行动”是不同命题。我们在多巴胺、社会学习和规划中都会遇到类似情况：一个计算变量可以被编码，却没有以相同方式进入最终策略。

动物的替代结果信号也不应直接等同于人类自述的后悔体验。可研究的是行为与神经指标是否符合反事实比较的操作定义。把机制问题说清楚，比把动物表现直接翻译成某种人类情绪更可靠。

第 8 章 从意外中学习：预测误差与多巴胺

铃声之后总有食物，动物逐渐在铃声响起时就开始期待。但如果灯光已经可靠地预告了食物，再把铃声与灯光一起呈现，动物未必同样学会铃声。两种情况下，铃声都与食物相邻。为什么结果不同？

这个问题推动学习理论从“共同出现”转向“是否带来了新的信息”。预测误差模型把学习写成对预期的修正，也为理解多巴胺响应提供了计算语言。

8.1 用一次更新理解学习率与误差

设 V_t 是当前对奖励的预期， r_{t+1} 是实际奖励。最简单的增量规则为

$$\delta_t = r_{t+1} - V_t, \quad V_{t+1} = V_t + \alpha \delta_t. \quad (8.1)$$

实际结果比预期好， $\delta_t > 0$ ，价值上升；比预期差，价值下降。学习率 α 控制改动幅度，不决定好坏方向。

若 $V_0 = 0, \alpha = 0.25$ ，每次奖励都为 1，前三次更新得到 0.25, 0.4375, 0.578125。它不会每次固定加 0.25，因为随着预期接近 1，误差越来越小。改写成

$$V_{t+1} = (1 - \alpha)V_t + \alpha r_{t+1} \quad (8.2)$$

可见新价值是旧估计与新结果的加权平均。展开递推后，较早结果的权重按 $(1 - \alpha)$ 的幂衰减。

若环境稳定，逐渐减小学习率可减少采样噪声；若环境一直变化，固定的非零学习率能保持适应能力，却会让估计在真值附近持续波动。因此“最后没有停在一个精确数字”不一定是算法失败。

8.2 阻断：为什么一起出现还不够

多个线索同时出现时，Rescorla-Wagner 型模型把总预测写为各线索贡献之和：

$$\hat{r}_t = \sum_i w_{i,t} x_{i,t}, \quad \delta_t = r_{t+1} - \hat{r}_t, \quad w_{i,t+1} = w_{i,t} + \alpha x_{i,t} \delta_t. \quad (8.3)$$

$x_i = 1$ 表示线索出现， $x_i = 0$ 表示未出现。共同误差决定这一轮还有多少奖励没有被解释。

在预训练后，若 $w_A \approx 1, w_B \approx 0$ ，A 与 B 一起出现并得到 1 单位奖励时，总预测已经约为 1，所以 $\delta \approx 0$ ，B 几乎不再增加价值。对照组没有 A 的强预测，联合训练会产生较大正误差，B 得到学习机会。

这一解释比“B 没被注意到”更具体，因为它预言：若联合阶段给出意外更多的奖励，原本被阻断的 B 可以获得关联，这叫解除阻断。不过刺激新奇性、注意和表征变化也可能影响结果；阻断现象并不只允许一种算法解释。




图 8.1 阻断实验的教学图示。两组都经历 A、B 联合呈现并获得奖励；关键差异是此前 A 是否已能预测奖励。正式实验还需匹配背景经验与刺激显著性。





图 8.2 教学模拟：预训练使 A 先吸收大部分预测，后来的 B 学得少。两组使用相同联合训练次数与学习率；图中曲线是模型权重。

8.3 经典多巴胺结果的逻辑

经典条件化记录中，未预料到的奖励可引起短暂响应；学会线索与奖励的关系后，响应出现在预测线索附近；预期奖励被省略时，在相应时刻可出现活动降低。这一组合模式与“比预期更好或更差”的计算相符。[15]

要解释响应为什么从结果转到更早的线索，还需要把时间状态放进模型。后面的 TD 学习将把误差写为 $r + \gamma V(\text{下一状态}) - V(\text{当前状态})$ ：即使当下没有食物，进入一个预示食物的新状态，也可以构成正误差。

预测误差不是奖励本身，也不是快乐程度的同义词。相同数量的奖励，在不同预期下可以产生不同误差；同样是正误差，也可能来自奖励时间提前或新的预测线索。神经细胞与投射通路还存在异质性，不能用单个标量解释所有多巴胺活动。



Fiorillo et al., *Science*, 2003

图 8.3 课件展示不同奖励概率下的响应。线索与结果附近的响应随预期而变。读图时要同时看奖励概率、事件时刻和放电基线，而不能只看峰值高低。（课件 7-8 model free RL，第 15 页）

8.4 怎样从相关走向教学信号的因果检验

阻断提供了一个有力测试：在奖励已被预料、通常缺少额外学习的时刻，若人为加入类似正误差的多巴胺活动，是否会使新线索获得预测作用？Steinberg 等人使用时间精确的光遗传操纵，对这种逻辑作了检验。[16]

Causal role of DA in learning




图 8.4 课件中的因果检验结果。比较与奖励配对的干预及相应对照，检验人为活动是否促成原本较弱的线索学习。（课件 7-8 model free RL，第 20 页）

实验解读 一个因果实验需要怎样的对照

除了有无刺激，还要比较刺激是否与奖励在时间上配对，以及控制动物是否具备相应光敏蛋白。若刺激只是让动物整体更活跃，可能提高靠近奖励口的次数，却未必形成对特定线索的持久学习。因此测试阶段的线索特异性与刺激撤去后的表现很重要。

这个推理支持特定活动在特定学习范式中的因果作用，不等于从此所有多巴胺信号都只能是同一种误差。记录对象是细胞放电还是末梢释放，任务中的状态如何表示，都会影响模型与数据的关系。

8.5 从被动预测到主动选择

条件化任务可以不要求选择；工具性学习则需要通过行动获得结果。对两个选项 A、B 分别保存价值，选择之后只更新被选项：

$$Q_{t+1}(a_t) = Q_t(a_t) + \alpha[r_{t+1} - Q_t(a_t)]. \quad (8.4)$$

要生成行为，还需要选择规则。最常用的 softmax 为

$$P_t(a) = \frac{e^{\beta Q_t(a)}}{\sum_b e^{\beta Q_t(b)}}. \quad (8.5)$$

两选项时，它就是价值差的 logistic 函数。 $\beta = 0$ 表示不根据当前价值区分选项； β 很大时，较小价值差也会引起明显偏好。 β 不等于“理性水平”：如果价值估计本身错误，坚定选择也可能一直选错。

模型计算 一次试次的正确顺序

```
import numpy as np

q = np.array([0.5, 0.5])
alpha, beta = 0.2, 4.0
logits = beta * q
p = np.exp(logits - logits.max()) # 防止指数溢出
p /= p.sum()
# 假设本轮实际选了 A, 随后得到 0 分
chosen, reward = 0, 0.0
choice_probability = p[chosen] # 先评价选择
error = reward - q[chosen]
q[chosen] += alpha * error # 后根据反馈更新
print(choice_probability, q) # 0.5, [0.4, 0.5]
```

这一小段顺序是后面模型拟合的基础。选择数据提供对 α, β 的约束，但二者都可能使行为看起来更随机。要区分它们，需要丰富的反馈历史与对时间变化的分析，而不仅是一张总选择率表。

8.6 经典模式也需要竞争解释

有些理论从奖励出现时向过去寻找可能原因，而不是从线索向未来预测奖励。两种过程在简单条件化中可能都产生“线索响应增强、熟悉奖励响应减弱”的模式，因此仅重复经典实验不一定能区分它们。

Jeong 等人提出并检验了回溯关联计算，对某些任务中的多巴胺释放给出不同于标准 RPE 的解释。[18] 可以直观区分两个条件量： $P(\text{奖励} | \text{线索})$ 问线索后多可能出现奖励； $P(\text{线索} | \text{奖励})$ 问奖励之前多可能有该线索。两者还依赖线索与奖励的基础发生率，不能简单互换。

实验可以分别操纵线索与奖励的关系、背景中奖励的频率和事件间隔，让竞争模型产生不同预测。这类研究的意义在于推进区分性检验；它不要求把所有已有 TD 证据一笔抹掉，也不允许仅凭相关结构就声称识别了真实因果机制。

第 9 章 探索、变化与注意：学习的不只是价值

一家新店只试过一次，味道很好；老店去过几十次，平均也不错。两者当前平均评价相近，但我们对新店更不确定。选择新店既可能是为了今天的饭，也可能是为了弄清它以后值不值得去。

与此同时，老店可能换了厨师。此时最近一次糟糕体验到底是随机波动，还是环境真的变了？本章讨论这些问题，并说明注意如何决定哪些特征进入学习。

9.1 随机探索与有目的的信息搜集

ϵ -greedy 规则以概率 $1 - \epsilon$ 选当前最好，以概率 ϵ 随机选。softmax 则让价值较差的选项更少被选。它们都能产生看似探索的行为，但没有明确计算一次选择能减少多少不确定性。

有目的的探索可以为不确定选项加入信息奖励，例如

$$\tilde{Q}_t(a) = \hat{\mu}_t(a) + \kappa s_t(a), \quad (9.1)$$

其中 $s_t(a)$ 是对平均收益估计的不确定程度。它不是奖励结果本身的方差。一个彩票的收益很不稳定，但如果概率已经完全知道，继续购买未必提供新的信息。

这种区别可用两种方差理解。结果噪声描述“即使知道环境，下一次结果仍不确定”；认识上的不确定性描述“还不知道环境参数”。探索主要利用后者可以被经验减少这一性质。

实验解读 怎样检验被试是不是为了信息而探索

先让两个选项有相似平均回报，但一个只被观察少数次，另一个被观察很多次。再操纵剩余选择次数：如果只剩最后一次，获得信息几乎不能改善未来收益；若还要选择很多次，信息更有用。

因此，少样本选项在长时间范围条件下变得更受偏爱，是有目的探索的候选证据。需要同时控制新奇偏好、记忆强度与强制采样经历，因为它们也会随样本数变化。

9.2 用 Beta 分布表示二元奖励的不确定性

某个选项每次得到奖励的概率为 p ，先验设为 $p \sim \text{Beta}(a, b)$ 。看见 n_1 次奖励和 n_0 次无奖励后，后验为

$$p \mid D \sim \text{Beta}(a + n_1, b + n_0). \quad (9.2)$$

记更新后的参数为 A, B ，则平均值为 $A/(A + B)$ ，方差为

$$\text{Var}(p \mid D) = \frac{AB}{(A + B)^2(A + B + 1)}. \quad (9.3)$$

同样平均为 0.5，Beta(2, 2) 比 Beta(20, 20) 更分散。后者经历更多信息，对平均值更有把握。

Thompson sampling 每轮从各选项的后验抽取一个可能的奖励概率，再选抽到值最高的选项。它将不确定性转化为探索机会：数据较少的选项仍有机会被抽到较高值。这是一个明确的算法，但是否贴合人的探索，需要与固定噪声和新奇偏好模型比较。

9.3 环境变化时，旧证据不一定仍然有用

固定环境中的 Beta 更新会不断累积样本。如果奖励概率已经反转，大量旧证据就可能使更新过慢。固定学习率的 delta rule 虽然不显式存储后验，却会逐渐遗忘旧信息，因而可能更快适应。




图 9.1 教学模拟：真实奖励概率在中途改变。小学习率更平稳，却调整较慢；大学习率反应较快，也更受单次随机反馈影响。两条曲线使用同一条反馈序列。

更系统的做法是给环境本身一个动态模型。在线性高斯模型中，潜在平均值按随机游走变化，过程方差为 q ，观察噪声方差为 r 。Kalman 更新先预测不确定性，再根据新证据修正：

$$P_t^- = P_{t-1} + q, \quad (9.4)$$

$$K_t = \frac{P_t^-}{P_t^- + r}, \quad (9.5)$$

$$\mu_t = \mu_{t-1} + K_t(y_t - \mu_{t-1}), \quad (9.6)$$

$$P_t = (1 - K_t)P_t^-. \quad (9.7)$$

K_t 看起来像学习率，但它由不确定性决定。若认为环境变化快， q 大，新观察更值得重视；若认为测量噪声大， r 大，同样的意外更可能被当作噪声。大预测误差并不总意味着应大幅学习。

高斯 Kalman 模型适合连续值的教学推导。二元奖励或突变环境可能需要非高斯、变点或隐状态模型，不能把所有任务都硬塞进同一公式。

9.4 隐状态推断：改变的是价值，还是“现在在哪种环境”

设环境只有两种隐藏状态：A 较好，或 B 较好；每轮有概率 h 切换。记当前相信 A 较好的概率为 b_t 。看到本轮结果前，先预测

$$b_t^- = (1 - h)b_{t-1} + h(1 - b_{t-1}). \quad (9.8)$$

随后按所选行动的结果更新：

$$b_t = \frac{p(r_t | a_{t-1}, A\text{好})b_t^-}{p(r_t | a_{t-1}, A\text{好})b_t^- + p(r_t | a_{t-1}, B\text{好})(1 - b_t^-)}. \quad (9.9)$$

一个坏结果不仅降低当前选项的价值，也可能让观察者认为整个状态已经切换。若两选项的好坏互补，关于 A 的反馈还会改变对 B 的判断，即使没有直接选择 B。

这给实验提供了区分方法：让两选项的奖励独立变化，或由同一个隐藏规则互补变化。只学被选项的简单模型不会自动把 A 的坏消息转移到 B；理解结构的模型会。观察到转移，才有机会讨论状态推断，而不是只把更快调整称作“学习率更高”。

9.5 注意决定学什么，学习也决定注意什么

若每个选项同时包含脸、物体和场景，奖励可能只由其中一个维度决定。对所有可见细节都建立独立价值，样本会被分得很薄。选择性注意可以缩小学习空间。

一种简化模型将特征价值整合为


$$Q_t(a) = \sum_d A_{d,t} w_{d,f_d(a),t}, \quad \sum_d A_{d,t} = 1. \quad (9.10)$$

$A_{d,t}$ 为对维度 d 的注意权重， $f_d(a)$ 是选项在该维度上的具体特征。更新可以也受注意调节：

$$w_{d,f_d(a_t),t+1} = w_{d,f_d(a_t),t} + \alpha A_{d,t} \delta_t. \quad (9.11)$$

注意在选择时加权，与注意在学习时调节更新，是两个不同假设。它们可以分别存在，也可以同时存在。

Learning to learn: which dimension is important?



Leong et al., *Neuron*, 2017

图 9.2 多维特征学习任务。每个选项包含不同维度的信息；要通过反馈发现当前真正预测奖励的维度。

(课件 7-8 model free RL, 第 70 页)

Leong 等人的研究结合行为、注意指标和神经数据，比较注意仅影响选择、仅影响学习或两者都影响的模型。[17] 独立注意测量很重要，否则模型可能只用一个自由权重吸收所有无法解释的行为。

另一类模型令可联结性随过去的绝对误差变化，例如 $A_{t+1} = (1 - \eta)A_t + \eta|\delta_t|$ 。出乎意料的线索因而获得更大学习机会。但“意外所以值得注意”与“可靠所以值得注意”是不同理论，适用任务和预测也不同。要根据实验区分它们，而不是把所有注意效应都归结为一个更大的 α 。

把注意权重代入一次更新

假设一个选项有“脸”和“物体”两个特征，当前价值分别为 0.6 和 0.2，注意权重分别为 0.75 和 0.25。这个选项的总价值为 $0.75 \times 0.6 + 0.25 \times 0.2 = 0.5$ 。如果随后得到 1 分，误差就是 0.5。

取基础学习率 $\alpha = 0.2$ ，注意调节后的两个更新量为

$$\Delta w_{\text{face}} = 0.2 \times 0.75 \times 0.5 = 0.075, \quad \Delta w_{\text{object}} = 0.2 \times 0.25 \times 0.5 = 0.025.$$

脸特征获得更多更新。若下一次选择仍使用同一注意权重，总价值变为 $0.75 \times 0.675 + 0.25 \times 0.225 = 0.5625$ 。被注意的特征既更影响当前判断，也更影响之后记住什么。

这个例子还揭示一个拟合问题：按上述规则，整体价值的更新幅度为 $\alpha \delta \sum_d A_d^2$ 。改变注意分配，也会改变总价值看起来的学习速度。若没有独立注意测量，模型可能把注意变化吸收到学习率参数里。实验中的眼动或特征操纵，正是为了给这些解释增加独立约束。

第 10 章 把未来接起来：Bellman 方程与时间差分学习

在最简单的学习任务里，按键后马上得到奖励。现实中往往要先做许多没有即时收益的事：找路线、经过路口、最后才到达餐厅。怎样把最后的结果归到前面的选择上，是序列决策的核心。

本章先规定时间与奖励，再从回报定义推出 Bellman 方程。这样，TD 更新就不再是一条需要硬记的规则，而是用真实经历近似一个期望关系。

10.1 状态、行动与奖励的时间顺序

在时间 t ，系统处于状态 s_t ，选择 a_t ，随后得到奖励 r_{t+1} 并进入 s_{t+1} 。折扣回报定义为

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \cdots, \quad 0 \leq \gamma < 1. \quad (10.1)$$

折扣因子以一个时间步为单位。如果改变时间步长，保留同一个 γ 未必代表相同时间偏好。有限回合也可以使用 $\gamma = 1$ ，但需要保证终止与回报的适当条件。

状态满足 Markov 性，意味着给定当前状态与行动后，预测下一步不再需要完整历史。它是对表示是否充分的要求，不是说世界没有历史。如果两个相同屏幕背后存在不同任务规则，屏幕本身就可能不是充分状态，需要加入记忆或对隐藏规则的信念。

策略 $\pi(a | s)$ 指定在状态下怎样选择行动。状态价值是遵循该策略的期望回报：

$$V^\pi(s) = \mathbb{E}_\pi[G_t | s_t = s]. \quad (10.2)$$

动作价值 $Q^\pi(s, a)$ 还规定第一步采取 a ，之后再遵循策略。价值依赖策略；“这条路值多少”也取决于走到下一路口后会怎样做。

10.2 Bellman 方程只是把第一步拆出来

由回报定义， $G_t = r_{t+1} + \gamma G_{t+1}$ 。给定当前状态、对随机行动与转移求期望：

$$V^\pi(s) = \sum_a \pi(a | s) \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^\pi(s') \right]. \quad (10.3)$$

$r(s, a)$ 是当前行动后奖励的条件期望。公式没有把未来删掉，而是把所有未来装进下一状态的价值。复杂的长期问题因此变成相互关联的一步方程。

固定策略后，记 P^π 为转移矩阵， r^π 为即时奖励向量，就有

$$V = r + \gamma P V, \quad (I - \gamma P) V = r. \quad (10.4)$$

实际计算通常解线性系统，不必显式求逆。对有限状态、合适的 P 与 $\gamma < 1$ ，也可以反复做 $V^{(k+1)} = r + \gamma P V^{(k)}$ 。以最大绝对差衡量，更新算子会把两组价值的距离至多缩小为原来的 γ 倍，因此逐渐接近唯一固定点。

数学直觉 固定点不是静止的世界

环境仍然可以随机跳转，奖励仍然可以波动。固定的是模型对长期平均回报的自洽估计：当前估计恰好等于即时期望加上折扣后的下一步估计。

10.3 一个两状态例子

考虑固定策略下两个状态的转移矩阵与奖励：

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix}, \quad r = \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \quad \gamma = 0.9. \quad (10.5)$$

从状态 1 出发，当步期望奖励为 1，以 0.8 的概率仍留在 1；状态 2 则有更高即时奖励。方程是

$$V_1 = 1 + 0.9(0.8V_1 + 0.2V_2), \quad (10.6)$$

$$V_2 = 3 + 0.9(0.3V_1 + 0.7V_2). \quad (10.7)$$

移项解得 $V_1 \approx 16.545$, $V_2 \approx 20.182$ 。状态 1 的价值远大于即时奖励 1，因为它未来还会持续产生奖励，并可能转到状态 2。

模型计算 求解与迭代两种算法

```
import numpy as np

P = np.array([[0.8, 0.2], [0.3, 0.7]])
r = np.array([1.0, 3.0])
gamma = 0.9
exact = np.linalg.solve(np.eye(2) - gamma * P, r)
v = np.zeros(2)
for _ in range(300):
    v = r + gamma * (P @ v) # 一次更新同时使用旧向量
print(exact, v) # 两者都接近 [16.545, 20.182]
```

10.4 不知道转移概率，怎样学习

现实中的被试并没有 P 矩阵，只经历一次次 (s_t, r_{t+1}, s_{t+1}) 。TD(0) 用一次经历的目标近似 Bellman 期望：

$$\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t), \quad (10.8)$$

$$V(s_t) \leftarrow V(s_t) + \alpha \delta_t. \quad (10.9)$$

在当前价值函数固定、样本确实来自指定转移过程的条件下，采样目标的条件均值等于 Bellman 更新目标。它不是对“真实最终价值”的无偏直接测量，因为目标中的 $V(s_{t+1})$ 也还在学习。这种使用自身估计更新自身的方式称为自举。

若下一状态终止，未来价值应为 0。不要把终点刚收到的奖励再次放进 $V(\text{终点})$ ，否则可能重复计数。对表格型、固定策略、充分访问和适当递减步长，TD 有收敛结果；固定步长一般保留波动，函数近似与离策略条件还会带来额外问题。

奖励怎样一步步向前传播

考虑 $S \rightarrow A \rightarrow B \rightarrow T$ ，三次转移奖励依次为 0, 0, 1，到达 T 后回合结束。初始化所有价值为 0， $\alpha = 1, \gamma = 0.9$ ，每轮按真实行走顺序在线更新。

完成的回合数	$V(S)$	$V(A)$	$V(B)$
0	0	0	0
1	0	0	1
2	0	0.9	1
3	0.81	0.9	1

第一轮到达 B 时才知道奖励，所以此前对 S、A 的更新没有获得新价值。第二轮 A 利用已学到的 B，第三轮 S 再利用 A。这解释了简单在线 TD 的逐步传播，也让我们看出它为什么可能不够灵活：若人能立即重新评价远处状态，就还需要规划、资格迹或重放等机制。




图 10.1 教学计算：沿三步路径在线学习时，价值逐回合向较早状态传播。这里每轮只按实际经历做一次前向 TD 更新，未使用重放或资格迹。

10.5 从预测价值到选择更好的行动

若目标是求最优策略，Bellman 最优方程将策略平均改为最大值：

$$Q^*(s, a) = \mathbb{E} \left[r_{t+1} + \gamma \max_b Q^*(s_{t+1}, b) \mid s, a \right]. \quad (10.10)$$

Q-learning 将右边的期望换成样本。它在目标里假定下一步选择当前看来最好的动作，即使实际探索时选择了别的动作。SARSA 则用实际下一动作 a_{t+1} 的价值作为目标，因此学习当前行为策略的后果。

这个差异有直观含义：若某条短路靠近危险区域，持续随机探索会带来风险。SARSA 的目标会考虑这种正在执行的探索策略；Q-learning 的目标更接近之后不再犯探索错误时的贪心路径价值。具体表现还取决于奖励与探索安排。

Actor-critic 将价值估计与策略分开。critic 用 TD 误差评价当前结果，actor 增加带来正误差的行动倾向。对 softmax 策略参数 h_a ，一个基础更新方向是

$$\Delta h_a \propto \delta_t [\mathbf{1}(a = a_t) - \pi(a | s_t)]. \quad (10.11)$$

$\mathbf{1}(\cdot)$ 是指示函数：括号内条件成立时取 1，否则取 0。不是给所有动作都加上同一个奖励，而是按所选行动的对数概率梯度调整。这个算法结构与神经环路可能有联系，但名称上的 actor、critic 并不自动对应两个互不重叠的解剖模块。

10.6 把逐试次计算带进神经分析

拟合行为后，可以按同一数据顺序计算每轮的价值与预测误差。在 fMRI 分析中，选择时刻放置价值调制事件，反馈时刻放置误差调制事件，再与血流动力学响应函数卷积。这一步将模型的离散计算映射到连续时间信号。

必须检查价值、奖励和误差之间的相关性。单步任务中 $\delta = r - Q$ ，三个量存在精确线性关系；若把它们在同一事件时刻、以相同卷积方式全部放进设计矩阵，就可能无法独立估计。一个区域与 δ 相关，也不能直接推断记录到了多巴胺。模型回归提供的是计算层面的相关证据，仍需其他实验支持。

第 11 章 不只记一个平均数：奖励分布与多时间尺度

两个选项平均都给 5 分，一个总给 5 分，另一个一半给 0、一半给 10。只记平均价值，就无法区分它们。类似地，同样平均价值的两个奖励过程，也可能一个马上兑现，另一个很久以后才兑现。

本章讨论如何把单个价值扩展成一组预测。这里的重点是：增加的表示保存了什么信息，怎样学习，以及神经实验怎样检验这些预测。

11.1 平均值由哪一种误差规则产生

用 $v \leftarrow v + \alpha(r - v)$ 更新，若达到平均更新为零的位置，则

$$\mathbb{E}[r - v] = 0 \implies v = \mathbb{E}[r]. \quad (11.1)$$

因此 delta rule 学平均值，并非偶然。它也可看作最小化平均平方误差的随机梯度步骤，因为 $(r - v)^2$ 对 v 的导数正比于 $v - r$ 。

若更新只看误差正负，不看差多少，即 $v \leftarrow v + \alpha \text{sign}(r - v)$ ，平衡要求高于与低于 v 的概率相等，对应中位数；存在概率质量集中在一点时，应使用相应的广义中位数条件。损失函数从平方误差变为绝对误差，所学统计量也随之改变。

11.2 分位数与期望分位数不能混为一谈

τ 分位数 q_τ 表示累计概率达到 τ 的位置。一个常用更新为

$$q_\tau \leftarrow q_\tau + \eta[\tau - \mathbf{1}(r < q_\tau)]. \quad (11.2)$$

当样本在当前估计上方时，往上走的幅度为 $\eta\tau$ ；在下方时，往下走的幅度为 $\eta(1 - \tau)$ 。更新幅度不随误差大小增加。连续分布下，平衡方程为 $P(r < q_\tau) = \tau$ 。

另一种不对称更新保留误差大小：

$$e_\tau \leftarrow e_\tau + \eta \begin{cases} \tau(r - e_\tau), & r \geq e_\tau, \\ (1 - \tau)(r - e_\tau), & r < e_\tau. \end{cases} \quad (11.3)$$

它学习的是期望分位数 (expectile)，不是一般意义下的分位数。其平衡条件比较的是两侧误差的总大小：

$$\tau \mathbb{E}[(r - e_\tau)_+] = (1 - \tau) \mathbb{E}[(e_\tau - r)_+]. \quad (11.4)$$

当 $\tau = 1/2$ 时得到平均数。较大的 τ 让正误差更新更强，因而收敛到更高的预测基准。

数学直觉 用一个两点分布看出差别

设 $r = 1$ 的概率为 0.2, $r = 0$ 的概率为 0.8。平均数为 0.2, 0.75 分位数是 0。对 0.75 expectile, 正误差平衡给出

$$0.75 \times 0.2(1 - e) = 0.25 \times 0.8e,$$

所以 $e = 3/7 \approx 0.429$ 。两个统计量有明显差异。看到“正负学习率不同”，必须继续问：更新有没有乘误差幅度？




图 11.1 教学计算：同一奖励分布可对应均值、分位数和 expectile 等不同预测。右图示意多个预测通道具有不同零交叉点，不能将它们全部当作同一个平均数加噪声。

11.3 为什么一群神经元的差异可能有计算意义

如果每个通道都学习同一平均值，只是响应增益不同，那么对同一奖励分布，误差从负变正的基准应该相近。分布式价值表示则预言不同通道可拥有不同基准，且基准与正负误差响应的不对称程度有关。


Dabney 等人在小鼠奖励任务中研究了这类预测。气味线索后，奖励量从若干可能值中抽取；同一种结果对不同细胞可能意味着高于或低于各自预期。研究中的关键不是单个细胞的噪声，而是跨试次可重复的零交叉差异及其与响应不对称性的关系。[19]

需要区分三个层次：算法能从多个不对称通道恢复奖励分布；神经数据符合其中一些预测；动物选择是否实际使用了这种分布信息。前两项成立，并不自动完成第三项。还可以通过操纵偏度、尾部风险或效用需求，让分布信息对行为产生可区分的价值。

11.4 未来的折扣也可以有不同时间尺度

离散时间的指数折扣为 $D(t) = \gamma^t$ ，连续时间可写为 $e^{-\lambda t}$ 。若将两个结果同时向未来平移 Δ ，它们的折扣比值不变。因此在其他条件固定时，纯指数折扣具有时间一致性。

双曲折扣 $D(t) = 1/(1 + kt)$ 的相对折扣会随起始时间变化。例如 $k = 0.2$ (天的倒数) 时，现在得 40 与 7 天后得 50，折扣价值为 40 与约 20.83；若两者都推迟 30 天，则为约 5.71 与 5.95。偏好发生逆转。这个教学例子演示函数性质，并不意味着每个人都拥有同一个 k 。



小鼠闻到气味线索后，会获得随机抽取的七种大小不等的奖励之一。气味本身不预测奖励大小，因此在奖励交付之前存在很大的不确定性

图 11.2 任务与群体平均响应。相同线索后出现不同奖励量，允许比较各奖励量引起的反应。（课件 9 model free RL extension, 第 36 页）




图 11.3 细胞之间的零交叉点差异，以及用不同数据子集估计时的一致性。可重复的异质性比一次响应的散乱更有理论信息。（课件 9 model free RL extension, 第 39 页）




图 11.4 教学计算：单一指数与双曲折扣具有不同形状。不同指数时间尺度的混合可以产生双曲形式；时间单位与参数单位必须一起说明。

多个指数怎样组成双曲线

假设不同通道的连续折扣率 λ 服从均值为 k 的指数分布，即 $p(\lambda) = k^{-1}e^{-\lambda/k}$ 。群体平均折扣为

$$\int_0^{\infty} e^{-\lambda t} \frac{1}{k} e^{-\lambda/k} d\lambda = \frac{1}{1 + kt}. \quad (11.5)$$

单个通道仍是指数形式，群体汇总却可以是双曲形式。这个数学结果提供一种可能的机制，不保证行为一定采用这种汇总方式。

折扣也可以与持续风险联系起来：若每一步独立地有固定概率失去未来奖励机会，生存概率随时间指数下降。但固定风险、独立性和时间齐次性是前提；不能说任何不确定性都必然导出指数折扣。

11.5 用一组价值保留奖励何时发生的信息

记 $\mu_k = \mathbb{E}[r_{t+k+1}]$ ，不同折扣通道得到

$$V_j = \sum_{k=0}^K \gamma_j^k \mu_k. \quad (11.6)$$

单个 V_j 把整条奖励时间序列压成一个数。多个不同 γ_j 提供多个加权投影，使时间结构有机会被恢复。矩阵形式为 $V = L\mu$ ，其中 $L_{jk} = \gamma_j^k$ 。

这与变换观点相通，但逆问题可能病态：几个相近折扣率产生的投影很相似，少量噪声就可能导致很不稳定的逆解。恢复奖励时间通常需要非负约束、正则化、足够通道与合理时间范围；不能仅凭一句“做逆变换”就宣称任意时间分布都能精确读取。

Masset 等人的研究通过不同奖励延迟的任务与导航任务，考察单个多巴胺神经元的时间尺度差异，并比较跨任务的一致性。[20] 这里有价值的设计是把奖励量与等待时间区分，再检查同一细胞的时间尺度是否具有稳定性。




图 11.5 不同神经元对奖励延迟的响应与折扣拟合。群体平均可能掩盖细胞间稳定的时间尺度差异。（课件 9 model free RL extension, 第 64 页）

从单个标量到一组预测，增加的不是形式上的复杂度，而是可供之后决策使用的信息：可能得到多少，以及可能何时得到。下一章将进一步把“环境怎样转移”也纳入表示。

第 12 章 知道路通向哪里：规划与两阶段任务

你知道常去的餐馆关门了，即使还没有重新走一遍路，也会改变今天的路线。简单缓存价值的学习器可能需要沿旧路重新经历坏结果；掌握环境结构的系统则可以先更新“餐馆是否营业”，再重新计算路线价值。

两种机制的区别不在于一个会学习、另一个不会，而在于存了什么信息，以及作决定时如何使用这些信息。

12.1 无模型与有模型：差别在于是否调用转移结构

无模型方法可以直接学习 $Q(s, a)$ ，而不显式保存 $P(s' | s, a)$ 与奖励模型。选择时查出动作价值即可。有模型方法学习转移与奖励，再利用它们计算未来后果：

$$Q_{\text{MB}}(s, a) = \hat{r}(s, a) + \gamma \sum_{s'} \hat{P}(s' | s, a) \max_b Q_{\text{MB}}(s', b). \quad (12.1)$$

帽子提醒我们：规划调用的是学到或假定的模型，可能不准确。拥有模型并不保证最优；搜索深度有限、转移记错或奖励估错，都可能导致系统性偏差。

缓存价值通常选择便宜，但环境改变后更新可能慢；规划更灵活，但耗费时间与计算。两者也不一定互斥：系统可以先通过模拟更新缓存，临到选择时再快速读取。

实验解读 结果贬值与潜在学习

训练动物某个动作可得到一种食物，随后在不执行该动作的情况下，降低这类食物当前的吸引力，再测试动作是否减少。若无须重新获得动作反馈就改变行为，说明控制过程使用了结果的当前价值，而不仅是旧动作价值。

潜在学习则询问：没有奖励时形成的环境知识，能否在奖励出现后用于导航？这类任务支持结构知识的作用，但需要排除新线索、一般活动变化以及测试阶段重新学习等解释。

12.2 两阶段任务到底让被试做什么

第一阶段选择 A 或 B。A 通常进入蓝房间，偶尔进入黄房间；B 的转移概率相反。到达房间后再选其中一个按钮，并收到奖励或无奖励。按钮的奖励概率缓慢变化，因此被试要持续学习，而第一阶段转移结构相对稳定。

使用典型的 70%/30% 转移作为示例。若蓝房间最佳按钮的估计奖励概率为 0.8，黄房间为 0.3，规划给出

$$Q_{\text{MB}}(A) = 0.7 \times 0.8 + 0.3 \times 0.3 = 0.65, \quad (12.2)$$

$$Q_{\text{MB}}(B) = 0.3 \times 0.8 + 0.7 \times 0.3 = 0.45. \quad (12.3)$$




图 12.1 两阶段任务的教学图示。两次选择之后是结果反馈。第一阶段选项决定进入哪个房间的概率，第二阶段按钮决定该房间内的奖励机会。

第一阶段本身不发奖励，但它控制了接触第二阶段奖励的机会。这一步期望计算就是规划最容易理解的核心。

12.3 为什么少见转移特别重要

假设本轮选 A。若经历常见转移进入蓝房间并得奖，缓存学习与规划都可能增加下次选 A 的倾向。但若 A 经少见转移进入黄房间并得奖，两种机制的预测开始分开。

缓存学习把这一串好结果归给刚才选过的 A。规划则认为这条新信息首先说明黄房间的按钮可能不错；因为 B 更容易通往黄房间，信息会相对提高 B 的第一阶段价值。不是因为少见事件本身“应该换”，而是因为要沿转移结构重新解释奖励。

上一轮经历	简单缓存价值的倾向	调用转移结构的倾向
得奖，常见转移	增加重复原选项	相对增加重复原选项
得奖，少见转移	增加重复原选项	相对增加转向另一选项
未得奖，常见转移	减少重复原选项	相对减少重复原选项
未得奖，少见转移	减少重复原选项	相对增加重复原选项

这里说的是其他因素相同时的更新方向，不是每一轮必然做某动作。若两房间价值已有巨大差距，一个新奖励可能不足以改变最终最优选项。

常见分析用是否重复第一阶段选择为因变量，以奖励 R_t 、转移类型 T_t 及其交互作 logistic 回归：

$$\text{logit } P(\text{stay}_{t+1}) = b_0 + b_R R_t + b_T T_t + b_{RT} R_t T_t. \quad (12.4)$$

用 $R, T \in \{-1, +1\}$ 编码时，经典模型无关模式主要表现为奖励主效应；典型规划模式包含奖励与转移交互。效应大小还受编码、历史范围与任务细节影响。




图 12.2 教学预测：左侧主要表现奖励主效应，右侧表现奖励与转移的交互。曲线来自明确指定的示意回归系数，用于解释分析逻辑，不是真实被试数据。

12.4 怎样写出能生成完整选择序列的模型

描述性回归之外，可以拟合混合学习模型。第二阶段价值按奖励误差更新：

$$\delta_2 = r - Q_2(s_2, a_2), \quad Q_2(s_2, a_2) \leftarrow Q_2(s_2, a_2) + \alpha_2 \delta_2. \quad (12.5)$$

第一阶段缓存价值先根据到达的第二阶段动作价值更新，再允许终末奖励通过资格迹直接影响第一阶段：

$$\delta_1 = Q_2^{\text{old}}(s_2, a_2) - Q_{\text{MF}}(a_1), \quad (12.6)$$

$$Q_{\text{MF}}(a_1) \leftarrow Q_{\text{MF}}(a_1) + \alpha_1 \delta_1 + \alpha_1 \lambda \delta_2. \quad (12.7)$$

这里两个阶段内折扣取 1； λ 控制较早动作保留多少获得终末误差的资格。上标 old 表示计算误差时使用更新前的第二阶段价值，避免把同一结果重复包含进目标。

有模型价值由转移矩阵与第二阶段价值重新计算，再按权重混合：

$$Q_{\text{mix}}(a) = w Q_{\text{MB}}(a) + (1 - w) Q_{\text{MF}}(a). \quad (12.8)$$

第一阶段选择还可以包含持续重复上次动作的倾向：

$$P(a) \propto \exp\{\beta_1 Q_{\text{mix}}(a) + \kappa \mathbf{1}(a = a_{\text{prev}})\}. \quad (12.9)$$

第二阶段使用自己的选择温度 β_2 。有了这些规则，才可以逐轮生成或评价选择，而不是只根据结果把一个人分进两个类别。

备注 权重 w 不是一个人有多少“理性”


w 只是指定模型下两种价值对行为的相对贡献。误解指导语、记错转移、过强的重复倾向、注意波动，以及模型遗漏的状态表示，都可能影响它。若候选模型中没有这些机制，拟合参数可能替它们承担解释。

Daw 等人的研究用多步任务区分有模型与无模型影响，并将二者与纹状体预测误差信号联系起来。[21] 它推动我们从“某脑区只属于某一种系统”的简单想法，转向更细的计算比较。不过单个奖励与转移交互本身并不是任何任务下规划机制的唯一标记。

12.5 认知资源、可靠性与规划证据

如果转移结构极不稳定，精细规划也可能调用错误模型；如果目标变化但路径稳定，旧缓存价值可能迅速过时，重新规划更有用。因此“环境越不稳定越有模型”不是无条件规律，必须说明不稳定的是奖励、转移还是隐藏规则。

Example: sequential two-choice MDP



Lee, et al., *Neuron*, 2014

图 12.3 通过目标是否具体、转移是否可预测，分别改变两种价值计算的适用性。关键是把奖励结构与转移不确定性分开。（课件 10 model based RL，第 18 页）

另一条证据是检验选择前是否出现对未来状态的表征。例如先用独立任务区分场景与身体图片的神经模式，再观察当前选择时是否重现与后续可达状态对应的模式。[22]




图 12.4 使用可区分的图片类别表示后续状态，使规划内容能够通过独立训练的神经模式解码器检验。
(课件 10 model based RL, 第 32 页)

解码到后续状态有助于约束表征内容，但仍要区分预期、注意、记忆检索与实际用于比较行动的模拟。最强的论证来自内容特异的神经预测、行为变化与任务操纵共同吻合，而不是仅仅看到“与未来有关”的活动。

第 13 章 没有行动时也在学习：重放与后继表示

走过一段路之后，我们可能在休息时回想路线，也可能在岔路前想象接下来会看到什么。对于学习算法，真实经验之外的这些内部计算可以很有用：最后的奖励不必等到下一次走完全程，才影响较早的选择。

本章连接三个想法。Dyna 用模型生成的经验训练价值；优先重放决定哪些经验值得先想；后继表示则预先保存未来状态的占用关系，让奖励变化时能够快速重算价值。

13.1 Dyna：把真实经历与内部模拟放进同一更新

真实经历 (s, a, r, s') 可以做一次 Q-learning 更新，同时用来学习环境模型。之后从记忆中选出一个状态与行动，调用模型产生模拟结果，再做同样的价值更新。

因此有两条信息路径：真实世界直接改变价值；真实世界先改变模型，模型再通过内部模拟改变价值。临到选择时仍然可以查表，所以行为看起来很快，并不意味着之前完全没有规划。

模型计算 Dyna 的最小结构

```
# 伪代码：真实奖励与模拟奖励采用同一套价值更新
for transition in real_experience:
    update_value(transition)
    update_world_model(transition)
    for _ in range(planning_budget):
        state, action = choose_memory()
        imagined = world_model(state, action)
        update_value(imagined)
```

内部模拟的价值取决于模型质量。错误模型被反复模拟，也会把错误放大。函数名表示所需模块，并不假定模拟结果必然正确。

回到 $S \rightarrow A \rightarrow B \rightarrow T$ 的三步链，首次拿到奖励后，若按 B, A, S 的逆序各备份一次，价值可在一次内部计算序列中传到 S。这里没有增加真实奖励经验，增加的是对已有经历的再利用。

13.2 怎样从神经活动识别重放

在动物实际探索时，先估计不同位置对应的群体放电模式。之后在休息或停顿中，观察活动是否按某种位置序列快速出现。若序列与曾走过或即将走的路径有关，就可以检验重放或预演的候选解释。

不能只凭几张细胞同时活动的图就说动物“梦见了这条路”。位置解码依赖训练数据、细胞选择和噪声模型；序列显著性需要与打乱时间或标签的对照比较。更进一步，若干预相应事件后，记忆或选择出现预期改变，功能解释会更有力。




图 13.1 课件中的三类内部序列：结果后的逆向传播、休息中的离线序列、选择前的前向序列。方向与发生时机为计算功能提供约束。（课件 11 model based extension, 第 35 页）

正向序列常被联系到前瞻规划，反向序列常被联系到价值传播，但两者不是严格的一对一标签。不同算法、行为策略与状态图都可能产生相同方向的序列，因此仍需要比较定量预测。

13.3 值得先回想什么：增益乘以需求

计算资源有限，不能把所有记忆无限遍历。Mattar 与 Daw 提出用一次价值备份能改善多少未来决策来安排记忆访问。[23] 在相应假设下，可以把价值写为类似

$$\text{EVB}(s, a) = \text{Gain}(s, a) \text{Need}(s). \quad (13.1)$$

Gain 描述这次更新在该处能让策略改善多少；Need 描述未来多可能用到该处的决定。预测误差大不一定 Gain 大：如果更新前后都会选择同一个动作，额外收益可能有限。

假设两个动作的真实后果相差很大，但旧估计刚好把它们排反，修正排序可以带来大 Gain。若错误发生在已经离开、以后也几乎不会到达的死胡同，Need 很小；若就在眼前路口，Need 可能很大。

一个近似增益表达为

$$\text{Gain}(s) \approx \sum_b [\pi_{\text{new}}(b | s) - \pi_{\text{old}}(b | s)] Q_{\text{new}}(s, b). \quad (13.2)$$

它衡量策略重新分配概率后，按更新后价值计算的局部收益变化。正式推导需说明后续策略、折扣及备份方式；这里的式子帮助理解“是否改变选择”为什么比绝对误差更关键。

需求可以写成预期折扣访问次数：

$$\text{Need}(s) = \mathbb{E} \left[\sum_{k=0}^{\infty} \gamma^k \mathbf{1}(s_{t+k} = s) \mid s_t \right]. \quad (13.3)$$

越近、越常访问的状态权重越高。这恰好引出后继表示。

13.4 后继表示：把路线结构与奖励分开保存

固定策略 π ，定义

$$M^\pi(s, s') = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k \mathbf{1}(s_{t+k} = s') \mid s_t = s \right]. \quad (13.4)$$

$M(s, s')$ 回答：从 s 出发，以后会以多大折扣权重访问 s' ？它不是一步转移概率。由于同一状态可被访问多次，数值也不必小于 1。

令 $r^\pi(s)$ 是处于 s 时下一次转移带来的期望即时奖励，则

$$V^\pi(s) = \sum_{s'} M^\pi(s, s') r^\pi(s'), \quad V = Mr. \quad (13.5)$$

M 保存“以后会去哪里”， r 保存“在那里会发生什么奖励”。只改变奖励时，可以保持 M 不变，快速重新乘一次；若路径结构或策略改变， M 也需要改变。

矩阵形式为

$$M = I + \gamma PM = (I - \gamma P)^{-1}. \quad (13.6)$$

每一项 P^k 是 k 步转移，因此 $M = I + \gamma P + \gamma^2 P^2 + \dots$ 。单位矩阵 I 记录当前就处于出发状态，不能漏掉。

四状态链的完整例子

仍用 $S \rightarrow A \rightarrow B \rightarrow T$ ，到达 T 后结束。用零行表示终止后不再转移， $\gamma = 0.9$ ，得到

$$M = \begin{pmatrix} 1 & 0.9 & 0.81 & 0.729 \\ 0 & 1 & 0.9 & 0.81 \\ 0 & 0 & 1 & 0.9 \\ 0 & 0 & 0 & 1 \end{pmatrix}. \quad (13.7)$$

奖励在 $B \rightarrow T$ 时收到，所以 $r = (0, 0, 1, 0)^\top$ ，不是把奖励再放到终止后的 T 。于是 $V = (0.81, 0.9, 1, 0)^\top$ ，与前面 TD 例子一致。若该次转移奖励变成 2，只要已知这个变化，立刻有 $V = (1.62, 1.8, 2, 0)^\top$ 。

模型计算 不枚举所有未来路径，也能学后继矩阵

```
# M 的每一行是一组未来状态占用预测
indicator = np.zeros(n_states)
indicator[state] = 1.0 # 当前状态计入一次
if done:
    # 进入终点：终点仍访问一次，此后不再继续
    future = np.eye(n_states)[next_state]
else:
    future = M[next_state]
target = indicator + gamma * future
M[state] += alpha * (target - M[state])
```




图 13.2 教学计算：后继矩阵显示从每个出发状态预计访问哪些状态。奖励向量改变时，用同一矩阵即可重新计算价值；转移改变则不能照搬旧矩阵。

这里 `done` 表示刚进入终点；终点计入一次占用，但不再有更远的未来。将终点行固定为它自身的单位向量，其他行由经验更新，就与上面的矩阵约定一致。固定策略时，这相当于对各状态的占用分别做 TD 预测。

13.5 用重新评价实验区分几种表示

可以先训练一张路线图，再只改变终点奖励，或只改变中间转移。缓存标量价值通常需要传播新经验；保存后继表示的系统容易应对奖励重新评价，却可能对未重新体验的转移改变不够灵活；完整且准确的转移模型可以在重新规划后处理两者。

不过这不是给人贴三个标签的测验。后继表示可以通过离线重放更新，规划也可能因计算成本而失败。实验应明确改变发生在哪里、被试经历过哪些局部信息、测试前允许多少时间。能否立即重新评价，只是约束表示与计算过程的一部分。

13.6 从位置细胞到预测地图

位置细胞在动物处于某些位置时更容易放电；网格细胞则可以在多个位置形成近似周期性的放电场。研究者把每个空间小格中的放电次数除以动物在该处的停留时间，得到空间发放率图。否则动物只是某处待得久，也可能被误认为该处放电更强。

几何距离很近的两个位置，可能被墙隔开，实际上很难互相到达。后继表示不仅关心直线距离，还关心按当前策略会怎样移动。改变障碍或运动习惯，预测地图因此可能改变；这提供了区




图 13.3 课件中的轨迹、空间放电图与六角结构示意。轨迹上的放电点需要结合占用时间，才能转成比较的空间发放率。（课件 11 model based extension, 第 52 页）

别纯几何编码与预测编码的实验方向。Stachenfeld 等人将这种观点系统化为海马预测地图假说。[\[24\]](#)

用线性代数还能理解压缩表示。若 $Pu = \lambda u$ ，则

$$Mu = (I - \gamma P)^{-1}u = \frac{1}{1 - \gamma\lambda}u.$$

因此 P 与 M 共享相应特征方向，只是不同模式得到不同放大。对于具有适当谱结构的转移图，少量平滑模式可以近似较大的预测矩阵。在二维规则环境中，这类分解与周期空间图样产生联系，但图样相似本身不足以证明网格细胞就是在做这一分解。

状态也可以是概念、人物或事件，而不必是物理位置。如果人只学过 A 与 B 、 B 与 C 的关系，却能推断 A 与 C ，研究者便可比较逐对记忆、关系结构和几何嵌入等机制。关键仍是设计未直接训练的关系测试，使不同表示产生不同的迁移预测。

第 14 章 对手也在思考：社会价值、信念与博弈

与老虎机不同，人会对你的行为作出反应。一次慷慨既可能表达关心，也可能是为了建立信誉；一次拒绝既可能来自对不公平的反感，也可能是在影响之后的谈判。只看自己最后拿了多少钱，很难理解这些选择。

社会决策需要分清两个问题：我在乎什么，以及我认为别人会做什么。前者是价值或动机，后者是信念与策略推断。本章先用几个简单博弈建立这一区分，再讨论学习和递归推理。

14.1 独裁者、最后通牒与信任任务各在测什么

独裁者任务中，一人决定怎样分配资源，另一人没有否决权。它能观察没有即时策略回应时的分配倾向，但仍会受匿名程度、规范、实验需求特征等影响，因此不是对纯粹利他性的无条件测量。

最后通牒任务增加了接收者的接受或拒绝：接受则按提议分配，拒绝则双方都得不到这笔资源。提议者给得更多，可能因为更重视公平，也可能因为担心低报价被拒绝。独裁者与最后通牒的差别提供了一个切入点，却不能靠一次跨任务差值把所有动机精确拆开。

信任任务又不同。投资者转出一部分禀赋，实验者将其放大，受托者决定返还多少。投资有机会提高总收益，但回报取决于另一个人。

若投资者初始有 e ，转出 x ，乘数为 m ，返还为 y ，则两人最终收入为 $e - x + y$ 与 $mx - y$ 。投资者需要预期 y ，受托者还可能考虑对方期待、公平与未来互动。重复博弈中的投资不只测一次性信任，也包含声誉建立和战略试探。

14.2 公平怎样变成可检验的效用

一个常用不平等厌恶模型把处于劣势和优势的差距分开：

$$U_i = x_i - \alpha_{\text{ineq}} \max(x_j - x_i, 0) - \beta_{\text{ineq}} \max(x_i - x_j, 0). \quad (14.1)$$

α_{ineq} 衡量自己比别人少时的差距成本， β_{ineq} 衡量自己比别人多时的差距成本。它们与强化学习的学习率、选择逆温度没有关系，只是传统记号恰好相同。

在最后通牒任务中，若对方提议自己拿 80、给你 20，接受时你的效用为 $20 - 60\alpha_{\text{ineq}}$ ，拒绝为 0。在这个最小模型中， $\alpha_{\text{ineq}} > 1/3$ 时拒绝更有利。拒绝并不一定没有考虑收益，而可能是效用函数包含了差距。

同样，模型不能因为能解释拒绝就被视作唯一机制。愤怒、对意图的判断、规范执行、惩罚他人的愿望，都可能产生类似选择。若同样不平等的结果由对手主动决定或由随机装置决定，意图敏感模型与只看结果差距的模型可能给出不同预测。

信任博弈：先投资，再决定回报




图 14.1 信任博弈的一轮教学示例。投资者转出 4 元，受托者收到 12 元并自主返还 6 元。数字用于说明支付规则，不能被当作典型行为比例。

14.3 均衡是互相一致的最佳回应

设自己选 a ，对方选 b ，自己的收益为 $u(a,b)$ 。如果相信对方行动分布为 $q(b)$ ，应比较

$$Q(a) = \sum_b q(b)u(a,b). \tag{14.2}$$

Nash 均衡要求各自策略都是对他人策略的最佳回应。它是策略彼此一致的条件，不是说现实中的每个被试都已经知道均衡，也不保证均衡唯一或达到集体最优。

以匹配硬币为例，双方同时选正或反，相同则行玩家得 1、列玩家得 -1，不同则相反：

	对方正	对方反
自己正	(1, -1)	(-1, 1)
自己反	(-1, 1)	(1, -1)

若行玩家以概率 p 选正，列玩家选择正时行玩家期望收益为 $2p - 1$ ，选择反时为 $1 - 2p$ 。令两者相等得 $p = 1/2$ ，使对方无法利用一个确定性偏向获利。只考虑纯策略的“最坏情况”会遗漏这种随机化。

备注 同时行动不能随意改画成轮流行动

若用一棵树让对方在看到你的实际动作后再选择，会改变对方的信息条件。完全信息、轮流行动博弈可以自底向上做 minimax；同时行动矩阵博弈则通常需要考虑混合策略。二者不能仅因都叫博弈而使用同一棵可见行动树。

在轮流行动、零和且终局收益已知的树中，自己的节点取子节点最大值，对手节点取最小值。Alpha-beta 剪枝跳不会影响根节点选择的分支，不改变完整搜索的 minimax 答案。人的搜索还可能受到深度、记忆、启发式与表征成本限制，不能把搜索最优性直接当成心理过程的事实。

14.4 从奖励学习转向对手信念学习

无模型社会学习直接更新自己行动的回报，形式与老虎机相同。信念学习则先估计对手的行动概率，再用收益矩阵计算自己每个行动的价值。对两个行动的对手，记其选择左的概率为 q_t ，可用

$$q_{t+1} = q_t + \eta[1(b_t = \text{左}) - q_t] \quad (14.3)$$

更新，再计算 $Q_t(a) = q_t u(a, \text{左}) + (1 - q_t) u(a, \text{右})$ 。

为什么值得分开？看到对手一次行动后，信念模型可以更新自己所有动作的预期回报，因为知道“如果我刚才选另一个会怎样”。只有选中反馈的价值模型通常只更新实际行动。若改变收益矩阵但保留对手习惯，信念模型也能较快重新计算。

模型计算 一次对手信念更新

```
import numpy as np

payoff = np.array([[3.0, 0.0], [1.0, 2.0]])
q, eta = 0.6, 0.2 # q 表示对手选择左的概率
opponent_left = 0.0 # 本轮实际观察到对手选择右
q += eta * (opponent_left - q)
# 每行是自己的一个行动，每列是对手的行动
values = payoff @ np.array([q, 1 - q])
print(q, values) # 0.48, [1.44, 1.52]
```

更进一步，对手也可能在根据你的选择学习。此时 q_t 不只由他过去选了多少次决定，还取决于你认为他怎样理解你。递归信念使模型更强，也带来参数可辨识性和计算负担。需要设计能区分层级的任务，而不是在任何行为上都加入无限层推理。

14.5 选美博弈：多想一层会怎样

考虑人数较多的群体，每人报一个 0 到 100 之间的数，最接近全体平均数的 $2/3$ 者获胜。若先把别人看作均匀随机，平均数约为 50，一层回应约为 33.3。若相信别人都这样想，再乘 $2/3$ ，两层回应约为 22.2。这些数忽略了单个参与者对群体均值的微小影响，是层级推理的教学近似。

持续迭代消除高数值，在这个允许 0 的连续版本中指向全报 0 的均衡。若任务限制为 1 到 100 的整数，边界与精确最佳回应要按实际规则处理，不能照搬 0。

level- k 模型通常让第 k 层回应第 $k-1$ 层；认知层级模型则让较高层回应若干较低层的混合。二者对同一任务可能有不同预测。“层级高”还依赖对 level-0 的假设：若最初的随机或显著性假设变了，同一个报告数对应的层级也会变。





图 14.2 层级推理的教学近似：从假定平均数 50 开始，反复乘 $2/3$ 。这条曲线是计算过程，不是人群选择频率。

14.6 心理理论与神经证据

错误信念任务让研究者区分真实世界状态与另一个人相信的状态。例如物品已被移走，但某人未看到移动；预测其行动需要使用他的旧信念，而不是自己的当前知识。控制条件应匹配故事记忆、语言和难度，才能更具体地检验对他人信念的表征。



Jamali et. al., *Nature*, 2021

图 14.3 课件中的人类单细胞结果示例，比较关于他人信念与物理状态的问题。曲线和放电栅格提供时间信息；并非所有细胞都具有同样选择性。（课件 12 games, 第 13 页）

Jamali 等人的研究在特定记录与任务条件下提供了与他人信念有关的单神经元证据。^[25] 这不能推出某个脑区只负责心理理论。更有信息的后续问题是：活动区分的是信念内容、真假关系、推理难度，还是需要抑制自己的知识？

博弈任务让社会计算可以被精确检验。结论应在支付规则、信息条件与互动历史下解释，不宜直接外推为稳定的人格标签。

第 15 章 从解释到证据：参数估计与模型比较

一个模型能画出像样的学习曲线，离解释真实行为还差一步。我们需要问：数据支持哪些参数？别的模型能否同样解释？如果理论是错的，当前实验有没有能力发现？

本章用两臂学习模型贯穿参数估计、恢复、预测检查和神经回归。重点是理解每一步在排除什么问题，而不是把优化器返回的数字当成心理属性的直接测量。

15.1 似然评价的是已发生选择的概率

数据包含一串行动 $a_1, \dots, a_T$ 与每轮行动之后的反馈 r_{t+1} 。记 $\mathcal{H}_t$ 为第 t 轮选择前可用的历史，含以往行动与截至 r_t 的反馈。给定参数 $\theta = (\alpha, \beta)$ ，模型按真实历史逐轮更新价值，给每轮实际选择分配一个概率。

在固定任务规则下，行动与反馈的联合概率可分解为

$$p_\theta(a_{1:T}, r_{2:T+1}) = \prod_{t=1}^T p_\theta(a_t | \mathcal{H}_t) p_{\text{env}}(r_{t+1} | \mathcal{H}_t, a_t). \quad (15.1)$$

这里暂略了已知刺激与初始条件。若实验环境的奖励机制不含待估认知参数，参数比较时可略去环境反馈因子，只评价条件选择概率的乘积。这样做没有把未来反馈泄露给当前选择；第 t 轮只使用 $\mathcal{H}_t$ 。

若同时估计环境生成参数，或反馈机制也由待比较模型决定，就需要保留相应的联合概率。不能在奖励受到行动影响时，随意将完整反馈序列当作独立于行动的固定条件。

取负对数后，乘积变成求和：

$$\mathcal{L}(\theta) = - \sum_t \log P_\theta(a_t | \mathcal{H}_t). \quad (15.2)$$

模型给实际选择较高概率时惩罚小，较低概率时惩罚大。它不要求每次都猜中。例如模型认为两个选项几乎一样好，分配 0.5/0.5 比毫无根据地给出 0.999/0.001 更诚实；后者一旦遇到少数选择，会受到很大惩罚。

手算三轮，检查时间顺序

令两价值初始均为 0.5， $\alpha = 0.2, \beta = 4$ 。第一轮选 A 并得奖，选择概率为 0.5，更新后 $Q = (0.6, 0.5)$ 。第二轮仍选 A 但没得奖，选择概率为 $\sigma(0.4) \approx 0.599$ ，更新后 $Q = (0.48, 0.5)$ 。第三轮选 B，其反馈前概率为 $\sigma(0.08) \approx 0.520$ 。

这三轮选择的联合评分约为 $0.5 \times 0.599 \times 0.520 = 0.156$ ，负对数似然约为 1.86。第三轮之后得到什么奖励，不应该回头改变第三轮自己的选择概率。

15.2 优化只是找参数，不是完成解释

为了保证 $0 < \alpha < 1, \beta > 0$ ，可以直接用带边界的优化器，也可以设 $\alpha = \sigma(u)$ 、 $\beta = e^v$ ，优化无约束的 u 、 v 。后者在边界附近仍可能数值困难，不能代替检查。

优化需要多个起点，因为目标可能存在平坦方向或局部极值。也要画出小模型的似然曲面。若最佳点附近是一条长谷，说明许多参数组合产生相似行为；只报告一个小数点后三位的估计会掩盖不确定性。




图 15.1 教学数据的负对数似然曲面。标记区分生成参数与拟合最优点；有限样本下二者不必重合。等高线的形状帮助判断参数之间能否互相补偿。

初始价值也是模型的一部分。将它固定为 0.5、设为待估参数，或让被试先接受练习，会改变早期试次的解释。不同被试和独立区块何时重置价值，也必须与任务经历一致。

模型计算 稳定地计算两选项负对数似然

```
def nll(params, actions, rewards):
    alpha, beta = params
    q = np.array([0.5, 0.5])
    loss = 0.0
    for a, r in zip(actions, rewards):
        z = beta * (q[1] - q[0]) # 行动 1 的对数赔率
        loss += np.logaddexp(0.0, z) - a * z
        q[a] += alpha * (r - q[a]) # 当前选择评分后更新
    return loss
```

这里 actions 用 0、1 编码，rewards 与同轮行动后的结果一一对应。logaddexp 实现 $\log(1+e^z)$ 的稳定计算，避免先算极小概率再取对数。

15.3 参数可辨识：数据是否真的包含答案

若被试几乎总选 A，B 的价值很少获得反馈，学习率与温度可能难以分开。若奖励只变化一点，许多学习率产生近似相同曲线。增加参数前，应先判断当前任务能否约束它们。

尺度问题更是结构性的：把所有奖励和价值乘以 c ，同时把 β 除以 c ，softmax 预测不变。如果两者都自由，单靠选择无法确定尺度。DDM 也有类似性质，因此常固定扩散噪声尺度，再解释其他参数。

参数恢复检验的是测量工具有没有辨别力。从已知参数生成模拟被试，再用相同流程拟合，观察能否恢复。如果 $\alpha = 0.1$ 与 0.6 经常被估到相似位置，就不应立即用该任务研究细小的组间学习率差异。




图 15.2 教学模拟的参数恢复。每个点是一条独立生成的行为序列，横轴是真参数，纵轴是估计参数；虚线为完全恢复。离散程度反映指定任务长度与参数范围下的信息限制。

恢复不能只测试一个“好看”的参数点。应覆盖实际关注的范围，包含极端策略、有限试次数与可能的缺失机制。高总体相关也不等于每个人估计准确，偏差、边界堆积和置信区间覆盖率都值得检查。

15.4 模型恢复：实验能否分出不同机制

参数恢复假设模型家族正确。模型恢复更进一步：分别用模型 A、B 生成数据，再让所有候选模型竞争。若来自 A 的数据经常被判成 B，真实数据中“B 获胜”就不能被过度解释。

以两类学习规则为例，RW-softmax 用完整反馈历史逐渐积累价值；概率型赢留输换只根据上一轮结果决定是否重复。后者用 p_{win} 与 p_{loss} 控制得奖、未得奖后的重复概率。两者都有两个参数，但对更早历史的依赖不同。

真实实验设计应在收集数据前就做这一步。若竞争模型区分不开，可以改变反馈噪声、区块长度或操纵方式，而不是等收集完才增加一串无法识别的参数。[26]




图 15.3 教学模拟的模型恢复示例。行是生成模型，列是拟合后选择的模型；每行 12 条序列，按同参数数目的 AIC 比较。此例的区分能力不能外推为所有任务与参数下都可完美区分。

15.5 拟合得更好，不等于预测得更好

更多参数通常能降低训练集误差，但可能在解释噪声。AIC 与 BIC 都在拟合与复杂度之间折中：

$$\text{AIC} = 2k - 2\hat{\ell}, \quad \text{BIC} = k \log T - 2\hat{\ell}. \quad (15.3)$$

k 是自由参数数， $\hat{\ell}$ 是最大对数似然， T 是相应数据量。较小值更好。它们有各自近似条件；层级模型、强相关数据与边界参数不一定符合简单推导，不能把所有评分都混在同一张表里直接比较。

留出预测更直接，但序列任务必须保留历史。若以前 350 轮拟合参数、预测后 150 轮，测试开始时的价值应由前 350 轮经历推进得到。在测试过程中，若评价一步预测，可以用已经发生的真实反馈更新，但不能用未来试次估计参数。

这与从头自由生成整段测试行为不同。后者的行动会改变后续可见反馈，必须重新模拟环境。两种检验回答不同问题：一步预测测试已知历史下的选择概率，自由生成测试模型能否重现整个行为过程。

15.6 看模型能否重现真正关心的现象

一个模型的总似然不错，却可能完全错过反转后的适应速度、少见转移后的选择变化或反应时长尾。预测检查应围绕研究问题，比较数据与模型生成数据的同类统计量。

如果模型遗漏持续重复动作的倾向，可能用很低学习率解释；如果遗漏偶发走神，可能用很低 β 解释。可以加入带有明确含义的候选机制，例如 lapse 混合

$$P(a) = (1 - \epsilon)P_{\text{model}}(a) + \epsilon/K, \quad (15.4)$$

但每增加一个自由度，都要重新检查恢复与预测。遗漏反应也需要按规则处理：若被试看到反馈，内部状态可能继续更新；直接删掉这一轮而假装什么都没发生，会改变历史。




图 15.4 教学数据的预测检查：比较反转前后不同时间位置的较优选项选择率。模拟带显示重复生成中的变异；不应只检查一条平均学习曲线。

15.7 个体差异与神经回归的最后一段距离

少试次的单独拟合容易给出极端参数。层级模型让个体参数来自群体分布，例如

$$\text{logit}(\alpha_i) \sim \mathcal{N}(\mu_\alpha, \tau_\alpha^2). \quad (15.5)$$

信息少的个体估计会向群体适度收缩，信息多的个体更多由自身数据决定。收缩不是把所有人强行变一样，而是在共享结构与个体证据之间折中。研究组间差异时，应同时处理个体估计的不确定性。

将拟合参数生成的价值、误差放进神经回归，也不是完全无误差的解释变量。行为参数不确定、模型选择不确定和回归变量相关，都可能影响神经结论。区域选择若依据同一待检验效应，再在该区域证明效应显著，会产生循环分析。

对计算神经科学而言，一套可靠结论应同时经得起行为预测、参数恢复、竞争模型和独立神经检验。优化器成功返回，只完成了其中很小的一步。

第 16 章 把实验与模型连成一项研究

假设我们想研究：“环境经常变化时，人是否会提高学习率？”看起来只要安排一个变化环境，再拟合出较大的 α 即可。但这样的结论有几个漏洞：行为变得不稳定，可能来自选择噪声；被试也可能在推断隐藏规则，而不是连续调大同一个学习率。

这一章用一个完整的教学设计，把问题、任务、竞争模型、数据检查和神经预测接在一起。目标不是规定所有研究都走同一条流程，而是看清每一步为什么必要。

16.1 先把问题缩小到可操作的差别

考虑两个选项，较好选项以 0.8 概率奖励，较差选项以 0.2 概率奖励。被试每轮选择一个，只看到所选项的结果。两种条件使用相同高低概率，但改变哪一个选项较好的切换频率。

稳定条件长期保持同一较好选项；变化条件在若干未告知时刻切换。被试应知道奖励具有随机性，但不预先知道具体切换点。条件顺序与较好选项身份需要平衡，按键位置也要控制。若使用不同符号表示两个区块，应保证视觉显著性没有系统差异。

随机奖励意味着：即使较好选项仍然较好，也会偶尔给 0。这个任务迫使被试区分偶然失利与规则变化。研究者真正关心的不是“看到 0 后换不换”，而是过去多长的证据以及环境历史如何改变调整幅度。

实验解读 学习率假说的可观察预测

如果变化条件下学习率更高，那么在价值明确的阶段仍可保持稳定偏好，但在切换后应该更快反向调整。若主要是选择温度降低，则未切换阶段也会持续出现更多低价值选择。若依靠隐状态推断，一串足够异常的反馈可能触发较突然的切换，并同时改变对未选项的估计。这些不是完全互斥的现实机制，而是候选模型可以争论的具体行为特征。实验需要提供足够的稳定阶段和切换后试次，才能看到它们。

16.2 先看原始行为，避免模型遮住问题

将每轮保存为一行，包括被试、条件、区块、试次、两个选项的位置、选择、反应时、反馈、实际奖励概率与事件时刻。实际概率是研究者知道的生成规则，不能作为被试已经知道的输入直接传给认知模型。

先画选择率随时间变化的曲线，并对齐切换点。再检查反应时分布、遗漏、长期只按同一键、是否理解反馈。如果某人根本没有掌握任务，把他拟合为“低学习率”只会给任务失败披上一个参数名称。

排除规则应明确且尽量独立于想得到的结果。若按“模型拟合得不好”排除人，可能系统删掉最需要解释的行为。可以分别报告包含与不包含合理质量控制对象的敏感性分析。

16.3 竞争解释如何落实为模型

从最小 RW-softmax 开始，比较以下约束：

候选解释	学习率	逆温度
M1：机制相同	两条件共享	两条件共享
M2：学习调整	条件间不同	共享
M3：选择调整	共享	条件间不同
M4：两者都变	条件间不同	条件间不同

这些模型检验的是同一家族中的参数约束。还需要一个不同机制的竞争者，例如第九章的隐状态模型，或仅用上一轮结果的赢留输换模型。否则最多只能说“在 RW 家族内，允许学习率变化有帮助”，不能说真实心理过程已经被唯一识别。

持续重复与 lapse 可以作为有理论动机的扩展，但不要一次把所有参数都加满。先检查较简单解释在哪里失败，再增加能产生新预测的机制。每个区块重置、延续或迁移哪些内部变量，应由被试实际接受的指导和经验决定。

16.4 在招募之前，先让模拟被试做任务

用一组可能的参数生成数据，例如稳定条件 $\alpha = 0.1$ 、变化条件 $\alpha = 0.3$ ，逆温度均为 4；再用四个模型拟合。另生成“学习率不变、温度改变”的数据，看模型会不会误判成学习率变化。

如果两种机制频繁混淆，可以增加切换次数、延长切换前后的观察窗口，或加入强制采样来减少未选项的信息缺失。增加被试数与增加每人试次数解决不同问题：前者有助于群体效应，后者可能改善个体参数识别。样本量应围绕关心的效应和恢复结果决定，不能把一次成功的模拟当作充分保证。

模型计算 从生成到留出预测的最小调用

```
from numpy.random import default_rng
from models import reward_schedule, simulate_rw, fit_rw, rw_nll

rng = default_rng(2025)
probs = reward_schedule(n=500, period=100)
a, r, _ = simulate_rw(probs, alpha=0.25, beta=4.0, rng=rng)
fit = fit_rw(a[:350], r[:350]) # 参数只由前段数据估计
# 仍按完整历史推进价值，只给后 150 轮计算预测分数
test_loss = rw_nll(fit.x, a, r, start=350)
print(fit.x, test_loss / 150)
```

完整程序在配套 examples 目录中。预期看到估计参数围绕生成参数波动；有限数据不会精确复原输入数字。每轮平均负对数似然可与两选项随机基线 $\log 2 \approx 0.693$ 比较。

16.5 如果加入神经测量，问题要更具体

可以把当前所选价值放在选择时刻，把预测误差放在反馈时刻。对 fMRI，先构造带幅度的事件序列，再与血流动力学响应函数 h 卷积：

$$x_{\delta}(t) = h * \sum_j \delta_j \delta_{\text{Dirac}}(t - t_j^{\text{feedback}}). \quad (16.1)$$

这里 δ_j 是学习误差，而 δ_{Dirac} 是表示事件时刻的脉冲，二者只是符号相似。对单细胞数据，则可以使用事件对齐的放电率或合适的点过程模型，不能直接套用 BOLD 的时间过程。




图 16.1 教学示意：离散反馈事件经过响应函数卷积后形成缓慢且重叠的信号。时间间隔过于固定或事件过近，会降低不同计算变量的可分辨性。

若研究问题是环境变化如何调节学习，应比较哪些信号解释状态切换概率、哪些解释带符号误差或绝对意外程度。不能发现一处“正误差相关”就宣称识别了变化推断；几个候选量在切换附近往往高度相关，需要通过设计拉开。

感兴趣区域可依据独立定位或事前定义；多重比较与时间自相关需要纳入统计方法。最终的因果解释还要依赖适当操纵，而不是靠更复杂的回归式替代。

16.6 怎样写出与证据匹配的结论

如果行为更快适应、M2 的留出预测优于共享参数模型、参数恢复支持区分、关键预测检查也吻合，可以说：“在这项任务和所比较模型下，条件差异更符合学习更新幅度改变。”若隐状态模型同样好，则应保留“规则推断”这一解释。

同样，如果某脑区活动与模型预测误差相关，可以说数据支持它与该计算量的联系；不能直接把拟合参数称为某种递质水平。模型的价值在于缩小解释空间，而不是消除所有不确定性。

一项自洽研究最终要接通同一条链：任务创造什么信息，被试可以利用什么信息，模型如何处理这些信息，数据又在哪些地方支持或限制模型。把这条链讲清楚，往往比再增加一个模型名字更重要。

附录 A 概率与计算的几块基石

正文的模型并不需要很多彼此孤立的数学技巧。条件概率、期望、对数概率和递推，已经支撑了大部分推导。本附录把容易卡住的几个环节用短例子串起来。

A.1 期望不是最常见的那一次结果

奖励为 0 的概率是 0.8，为 10 的概率是 0.2，期望为 2。系统从来不发 2 分，并不妨碍 2 成为正确的长期平均预测。众数为 0，中位数也可以为 0；它们回答的不是同一个问题。

条件期望还指定了已知信息。 $\mathbb{E}[r \mid a = A]$ 与 $\mathbb{E}[r]$ 不同，因为不同行动可以改变结果分布。强化学习中的价值通常是条件于状态、行动与策略的期望，不能直接用整段所有奖励的平均代替。

A.2 边缘化就是把没有观察到的可能性都算进去

设奖励由隐藏状态 z 决定， $P(z = 1) = 0.3$ ， $P(r = 1 \mid z = 1) = 0.9$ ， $P(r = 1 \mid z = 0) = 0.2$ 。不知道 z 时，奖励概率为

$$P(r = 1) = 0.3 \times 0.9 + 0.7 \times 0.2 = 0.41.$$

这不是先选择更可能的状态再预测，而是把两种状态都按信念加权。若观察到奖励，反向更新得到 $P(z = 1 \mid r = 1) = 0.27/0.41 \approx 0.659$ 。

层级模型中，“积分掉”潜变量执行同一思想，只是从有限求和变成积分。把潜变量直接替换成最可能的一个值通常是一种近似，需要知道它丢掉了不确定性。

A.3 高斯乘积为什么还是高斯

两个关于同一未知量 s 的高斯因子，其指数分别包含 $(s - \mu_1)^2/(2\sigma_1^2)$ 与 $(s - \mu_2)^2/(2\sigma_2^2)$ 。展开后， s^2 的系数为 $\frac{1}{2}(\sigma_1^{-2} + \sigma_2^{-2})$ ， s 的系数为 $-(\mu_1\sigma_1^{-2} + \mu_2\sigma_2^{-2})$ 。

将二次式配方，就得到新的精度为两精度之和，新的均值为精度加权平均。这个技巧解释了高斯先验结合高斯似然、多感觉线索融合与 Kalman 更新中的权重形式。

A.4 指数函数很容易溢出，但 softmax 不需要溢出

对任意常数 c ，

$$\frac{e^{z_i}}{\sum_j e^{z_j}} = \frac{e^{z_i - c}}{\sum_j e^{z_j - c}}.$$

选 $c = \max_j z_j$ ，所有指数输入都不为正，避免大数溢出。相应的 log-sum-exp 为

$$\log \sum_j e^{z_j} = c + \log \sum_j e^{z_j - c}.$$

概率很小时，最好直接在对数空间评价似然。随意把所有小概率截成同一个值，会改变优化目标，尤其影响极端选择的惩罚。

A.5 一段能独立运行的拟合示例

下面的程序只依赖 NumPy 与 SciPy，数据在程序内部生成。它将“价值怎样更新”与“怎样评价一串选择”写在同一个清晰的时间约定下。模型越复杂，越应该先用这种小规模例子检查顺序。

```
import numpy as np
from scipy.optimize import minimize
from scipy.special import expit

rng = np.random.default_rng(7)
q = np.full(2, 0.5)
actions, rewards = [], []
for t in range(400):
    # 中途交换好、坏选项；真实概率不传给拟合函数
    probs = [0.8, 0.2] if t < 200 else [0.2, 0.8]
    p1 = expit(4.0 * (q[1] - q[0]))
    action = int(rng.random() < p1)
    reward = float(rng.random() < probs[action])
    actions.append(action)
    rewards.append(reward)
    q[action] += 0.25 * (reward - q[action])

def loss(theta):
    alpha, beta = theta
    values = np.full(2, 0.5) # 每次评价参数都重置内部状态
    total = 0.0
    for action, reward in zip(actions, rewards):
        z = beta * (values[1] - values[0])
        total += np.logaddexp(0.0, z) - action * z
        values[action] += alpha * (reward - values[action])
    return total

fits = [minimize(loss, start, method='L-BFGS-B',
                 bounds=[(0.001, 0.999), (0.05, 15)])
        for start in [(0.1, 1), (0.4, 4), (0.8, 8)]]
# 多起点减少只找到局部较优解的风险
converged = [f for f in fits if f.success]
if not converged:
    raise RuntimeError('请检查数据、目标函数与优化设置')
best = min(converged, key=lambda f: f.fun)
print('alpha, beta =', best.x)
print('negative log likelihood =', best.fun)
```

预期输出是一组接近生成值、但不完全相同的估计，以及一个有限的负对数似然。若增加试次数，恢复通常会改善；若选择几乎完全随机或只偏向一个选项，参数仍可能难以识别。改变随机种子是在检查结果的变异，不是寻找最漂亮的那一次结果。

附录 B 几个值得自己推一遍的问题

这些问题不要求背公式。先想清楚实验提供的信息，再决定哪个计算量应该改变。

B.1 同一个错误率，可能有不同的原因

两个检测条件正确率相同，能否说明感觉敏感性相同？不能。信号比例、准则与敏感性共同影响正确率。至少需要分别观察命中与虚警，再在适当分布假设下估计敏感性；最好通过多个准则或置信评分检查 ROC。

B.2 奖励总是出现，为什么还会有负误差

如果预期 10 分，实际得到 5 分，虽然有正奖励，误差仍为 -5。在 TD 中，即使即时奖励为正，若下一状态比预期差很多，也可能产生负误差。误差评价的是“相对于预测好还是差”，不是结果本身是否大于零。

B.3 归一化一定产生诱饵效应吗

不一定。所有价值除以同一个正数，并不会改变确定性排序。若希望预测概率变化，必须说明噪声与读出；若希望解释特定方向的诱饵效应，还要检查属性结构、权重与选择集。一个解释部分情境效应的机制，不必解释所有现象。

B.4 少见转移后得奖，为什么规划者可能换选项

因为奖励首先改善了到达状态的评价。若另一第一阶段选项更容易到达这个状态，它可能因此增加价值。规划不是机械执行“少见就换”，而是把奖励通过已知转移结构传回前一步。

B.5 重放误差最大的经验一定最好吗

不一定。误差虽大，但若不改变行动排序，策略增益可能小；若发生在未来几乎不会遇到的状态，需求也小。优先重放需要考虑更新对未来行为的影响，而不只看误差幅度。

B.6 后继表示知道了新奖励，为什么还可能走错路

因为它缓存的是特定策略与转移下的未来状态占用。奖励改变时，旧占用关系仍可能有效；道路被阻断、策略大幅改变时，旧占用预测就可能过时。快速奖励重新评价不等于拥有可处理所有结构变化的完整世界模型。

B.7 赢留输换与价值学习都能解释，下一步做什么

设计两种规则预言不同的历史。例如保持上一轮结果相同，但改变更早多轮的奖励历史。只依赖上一轮的规则给出相同预测，持续积累价值的模型可能不同。也可以在保持平均奖励接近时改变噪声与反转频率，再通过模型恢复检查辨别力。

B.8 神经解码成功，能否说明脑在用这个信息做决定

解码成功说明记录中含有可被指定解码器利用的信息。要说明信息被行为使用，还需要它与选择的关系、时间顺序和干预等证据。相关信息可能是输入、结果、副产物或旁路表示；仅能解码不足以在这些解释中作决定。

B.9 两个时间尺度能还原多少未来信息

假设只可能在当前与下一时间步获得奖励，其期望分别为 μ_0, μ_1 。两个折扣通道的因子为 0.5 与 0.9，价值分别为 1.5 与 1.9，则

$$\mu_0 + 0.5\mu_1 = 1.5, \quad \mu_0 + 0.9\mu_1 = 1.9.$$

两式相减得到 $\mu_1 = 1$ ，再代回得 $\mu_0 = 1$ 。如果还可能在第三、第四个时间步出现奖励，两个方程就不能唯一确定所有未知量。加入更多时间尺度可以增加约束，但还要检查噪声与矩阵条件数；这说明“群体包含时间信息”与“能精确还原任意时间序列”之间仍有距离。

参考文献

- [1] 朱露莎, 张航。决策的认知神经计算, 北京大学 2025 秋课程课件。包括价值、情境、行动、结果、贝叶斯观察者、无模型学习及其扩展、有模型学习及其扩展、博弈等专题。
- [2] Padoa-Schioppa, C., & Assad, J. A. (2006). Neurons in the orbitofrontal cortex encode economic value. *Nature*, 441, 223–226. doi:10.1038/nature04676.
- [3] Chib, V. S., et al. (2009). Evidence for a common representation of decision values for dissimilar goods in human ventromedial prefrontal cortex. *Journal of Neuroscience*, 29, 12315–12320. doi:10.1523/JNEUROSCI.2575-09.2009.
- [4] Ballesta, S., et al. (2020). Values encoded in orbitofrontal cortex are causally related to economic choices. *Nature*, 588, 450–453. doi:10.1038/s41586-020-2880-x.
- [5] Louie, K., Khaw, M. W., & Glimcher, P. W. (2013). Normalization is a general neural mechanism for context-dependent decision making. *PNAS*, 110, 6139–6144. doi:10.1073/pnas.1217854110.
- [6] Krajbich, I., et al. (2015). Rethinking fast and slow based on a critique of reaction-time reverse inference. *Nature Communications*, 6, 7455. doi:10.1038/ncomms8455.
- [7] Hare, T. A., Camerer, C. F., & Rangel, A. (2009). Self-control in decision-making involves modulation of the vmPFC valuation system. *Science*, 324, 646–648. doi:10.1126/science.1168450.
- [8] Zhu, L., et al. (2014). Damage to dorsolateral prefrontal cortex affects tradeoffs between honesty and self-interest. *Nature Neuroscience*, 17, 1319–1321. doi:10.1038/nn.3798.
- [9] Koenigs, M., et al. (2007). Damage to the prefrontal cortex increases utilitarian moral judgments. *Nature*, 446, 908–911. doi:10.1038/nature05631.
- [10] Maréchal, M. A., et al. (2017). Increasing honesty in humans with noninvasive brain stimulation. *PNAS*, 114, 4360–4364. doi:10.1073/pnas.1614912114.
- [11] Ernst, M. O., & Banks, M. S. (2002). Humans integrate visual and haptic information in a statistically optimal fashion. *Nature*, 415, 429–433. doi:10.1038/415429a.
- [12] Wozny, D. R., Beierholm, U. R., & Shams, L. (2010). Probability matching as a computational strategy used in perception. *PLOS Computational Biology*, 6, e1000871. doi:10.1371/journal.pcbi.1000871.
- [13] Camille, N., et al. (2004). The involvement of the orbitofrontal cortex in the experience of regret. *Science*, 304, 1167–1170. doi:10.1126/science.1094550.

-
- [14] Chiu, P. H., Lohrenz, T. M., & Montague, P. R. (2008). Smokers' brains compute, but ignore, a fictive error signal in a sequential investment task. *Nature Neuroscience*, 11, 514–520. doi:10.1038/nn2067.
- [15] Schultz, W., Dayan, P., & Montague, P. R. (1997). A neural substrate of prediction and reward. *Science*, 275, 1593–1599. doi:10.1126/science.275.5306.1593.
- [16] Steinberg, E. E., et al. (2013). A causal link between prediction errors, dopamine neurons and learning. *Nature Neuroscience*, 16, 966–973. doi:10.1038/nn.3413.
- [17] Leong, Y. C., et al. (2017). Dynamic interaction between reinforcement learning and attention in multidimensional environments. *Neuron*, 93, 451–463. doi:10.1016/j.neuron.2016.12.040.
- [18] Jeong, H., et al. (2022). Mesolimbic dopamine release conveys causal associations. *Science*, 378, eabq6740. doi:10.1126/science.abq6740.
- [19] Dabney, W., et al. (2020). A distributional code for value in dopamine-based reinforcement learning. *Nature*, 577, 671–675. doi:10.1038/s41586-019-1924-6.
- [20] Masset, P., et al. (2025). Multi-timescale reinforcement learning in the brain. *Nature*, 642, 682–690. doi:10.1038/s41586-025-08929-9.
- [21] Daw, N. D., et al. (2011). Model-based influences on humans' choices and striatal prediction errors. *Neuron*, 69, 1204–1215. doi:10.1016/j.neuron.2011.02.027.
- [22] Doll, B. B., et al. (2015). Model-based choices involve prospective neural activity. *Nature Neuroscience*, 18, 767–772. doi:10.1038/nn.3981.
- [23] Mattar, M. G., & Daw, N. D. (2018). Prioritized memory access explains planning and hippocampal replay. *Nature Neuroscience*, 21, 1609–1617. doi:10.1038/s41593-018-0232-z.
- [24] Stachenfeld, K. L., Botvinick, M. M., & Gershman, S. J. (2017). The hippocampus as a predictive map. *Nature Neuroscience*, 20, 1643–1653. doi:10.1038/nn.4650.
- [25] Jamali, M., et al. (2021). Single-neuronal predictions of others' beliefs in humans. *Nature*, 591, 610–614. doi:10.1038/s41586-021-03184-0.
- [26] Wilson, R. C., & Collins, A. G. E. (2019). Ten simple rules for the computational modeling of behavioral data. *eLife*, 8, e49547. doi:10.7554/eLife.49547.