

NUMERICAL ANALYSIS

数值分析

课程讲义

VON

2026 春 数值分析

余肇飞

目录

第 1 章 数值分析概述	1
1.1 数值分析的研究对象	1
1.2 数值计算的基本思想	1
1.3 数值算法的评价	2
第 2 章 数值计算的误差	3
2.1 误差的来源	3
2.2 绝对误差、相对误差和有效数字	3
2.3 运算误差分析	4
2.4 病态问题与数值稳定性	5
2.5 数值计算的基本原则	6
第 3 章 函数的多项式插值	8
3.1 引言	8
3.2 多项式插值	8
3.3 Lagrange 插值多项式	9
3.4 牛顿插值多项式	10
3.5 Hermite 插值多项式	12
3.6 分段低次插值	13
3.7 三次样条插值	15
第 4 章 函数逼近	19
4.1 引言	19
4.2 正交多项式	19
4.3 连续函数的最佳逼近	22
4.4 离散数据的曲线拟合	25
4.5 三角多项式逼近与快速傅里叶变换	27
第 5 章 数值积分与数值微分	30
5.1 引言	30
5.2 Newton-Cotes 求积公式	30
5.3 复化求积公式	32
5.4 外推原理与 Romberg 求积法	34
5.5 Gauss 求积公式	35
5.6 数值微分	36
第 6 章 线性方程组直接解法	40
6.1 引言	40

6.2	Gauss 消去法	40
6.3	直接三角分解法	42
6.4	向量和矩阵的范数	43
6.5	方程组的性态与误差分析	44
第 7 章 线性方程组的迭代解法		47
7.1	引言	47
7.2	基本迭代方法	47
7.3	迭代法的收敛性	48
7.4	超松弛迭代法	50
第 8 章 非线性方程的数值解法		52
8.1	引言	52
8.2	方程求根的二分法	52
8.3	一元方程的不动点迭代法	53
8.4	一元方程的常用迭代法	55
第 9 章 矩阵特征值问题的数值解法		59
9.1	引言	59
9.2	特征值的性质与估计	59
9.3	幂法与反幂法	61
9.4	Jacobi 方法	62
9.5	QR 方法	63
第 10 章 常微分方程的数值解法		65
10.1	引言	65
10.2	简单数值方法	65
10.3	龙格-库塔方法	67
10.4	线性多步法	71

第 1 章 数值分析概述

1.1 数值分析的研究对象

许多数学问题能够写出严格的表达式，却不能靠有限步符号运算得到所需的数值。例如，定积分 $\int_0^1 e^{-x^2} dx$ 没有初等原函数，但它代表的面积仍然确定；高次方程的根未必有方便的根式表达；由几千个未知量组成的线性方程组，理论上可以用行列式公式求解，实际却需要更有效的组织方式。

数值分析研究怎样把这些问题转化为可执行的有限运算，并分析计算结果与精确解之间的关系。这里既有构造算法的问题，也有证明算法可靠的问题。一条公式即使在实数运算中恒等成立，到了有限精度的计算机上，也可能与另一条等价公式表现不同。

定义 1.1 (数值问题、数值方法与数值算法) 数值问题是在给定数据下，求某个数学量的值。数值方法用有限维近似或迭代过程描述求解思路；数值算法进一步规定运算顺序、数据存储和停止条件，使这一思路可以实际执行。

例如，求 $\sqrt{a}$ 是一个问题；把它改写为 $x^2 - a = 0$ 并作 Newton 迭代是一种方法；规定初值、逐步更新式、误差阈值和异常情况的处理，才形成完整算法。这三个层次相互联系，但不能混在一起评价。

数值方法不只用于“算不出解析解”的情形。有时解析式虽然存在，却很难稳定地求值；有时需要对大量输入反复计算，较便宜且误差可控的近似反而更实用。我们关心的是怎样得到符合任务精度要求的结果，而不是把小数位数写得越多越好。

1.2 数值计算的基本思想

用简单对象逼近复杂对象

最基本的做法是选择容易计算的函数。例如，在一点附近用 Taylor 多项式表示局部变化；在多个节点之间用插值多项式连接数据；在整个区间上用最小二乘选择总体误差较小的函数。它们都用有限个系数描述近似，但系数的确定条件不同。

例 1.1 (用有限项近似指数函数) 用二次多项式 $1 + x + x^2/2$ 近似 e^x 。在 $0 \leq x \leq 0.1$ 上，怎样保证误差不超过一个明确的数值？

解 Taylor 定理给出

$$e^x = 1 + x + \frac{x^2}{2} + \frac{e^\xi}{6}x^3, \quad 0 \leq \xi \leq x.$$

所以全区间上有

$$\left| e^x - \left(1 + x + \frac{x^2}{2} \right) \right| \leq \frac{e^{0.1}}{6} (0.1)^3 < 1.85 \times 10^{-4}.$$

多项式提供可计算的值，余项提供适用区间和误差保证。若把同一公式用于很大的 x ，上面的保证就不再适用。

化整为零与逐次逼近

复杂函数在一个大区间上可能很难逼近，在足够小的区间上却近似为直线。复化求积和分段插值因此先划分网格，再拼合局部结果。这里必须继续检查：局部误差累加以后有多大，相邻分段的连接是否满足要求。

另一条路线是迭代。先给出一个容易得到的近似，再根据方程残差修正它。迭代不是单纯“重复算很多次”：更新规则必须让误差趋于零，停止条件也必须与所需精度对应。线性迭代、非线性求根以及特征值计算都会使用这种思想。

外推则利用误差的规律。如果已知两个步长下的近似含有同一类主误差项，就可以适当组合，消掉该项。它比“取两次结果的平均”更有针对性，因为组合系数来自误差展开。

1.3 数值算法的评价

定义 1.2 (收敛性与计算效率) 对依赖网格宽度 h 的近似 Q_h ，若 $h \rightarrow 0$ 时 $Q_h \rightarrow Q$ ，称该近似收敛。对迭代序列 x_k ，若 $k \rightarrow \infty$ 时趋于目标解，也称迭代收敛。计算效率则衡量达到规定精度所需的运算、存储或函数求值成本。

收敛只描述极限，不自动说明实际计算多快。一个误差按 $1/k$ 下降的迭代和一个按 2^{-k} 下降的迭代都收敛，但达到同一精度所需的步数相差很大。同样，单步计算便宜的方法也可能需要更多步，应该比较总成本。

误差阶常用 O 记号描述。写 $E(h) = O(h^p)$ ，意思是存在与充分小的 h 无关的常数 C ，使 $|E(h)| \leq Ch^p$ 。它描述误差随网格变化的尺度，没有直接给出误差常数；只有进入相应的渐近范围，减半步长才会表现出接近 2^p 的改善。

除了收敛和效率，还要考察稳定性。输入和每次运算都可能有微小误差，如果算法把它们不断放大，再高的形式精度也可能失去意义。下一章从误差的来源、度量和传播开始，为这些判断建立具体工具。

第 2 章 数值计算的误差

一个计算结果有两种不同的“不准确”。第一种来自数学近似，例如用有限项 Taylor 展开代替指数函数；第二种来自计算机只能保存有限位数字。前者可以通过提高阶数或细化网格减小，后者却可能随着运算次数增加而累积。只有把两者分开，才能理解为什么一个看起来更精细的计算反而更差。

2.1 误差的来源

同样一个“数值不准”，可能来自完全不同的环节。要改进结果，首先应明确计算链条：实际现象给出数学模型，观测给出输入数据，离散方法把连续问题变成有限计算，计算机再执行有限精度运算。各环节的误差不能一概归咎于最后一个公式。

定义 2.1 (数值计算中的主要误差) 模型误差是数学模型与实际对象之间的差异；数据误差来自观测、测量或输入数据的近似；截断误差来自以有限过程代替无限或连续过程；舍入误差来自把不能精确表示的数存入有限位表示，以及对运算结果作舍入。

用有限项级数近似函数，遗漏的尾项属于截断误差；把 π 存成有限位小数属于舍入；半径由仪器测得而有误差，属于数据误差。提高级数项数只直接影响第一种，不会自动改进仪器读数。

这些误差进入后续计算后，还可能受到问题本身和运算方式的放大。因此，区分来源只是第一步，还要建立能比较大小的尺度。

浮点数与舍入

二进制浮点数由符号、有效位和指数构成。在常见的 binary64 格式中，有效二进制位数为 53。采用舍入到最近值、且结果没有溢出或进入导致相对模型失效的下溢区域时，可以用

$$\text{fl}(a \circ b) = (a \circ b)(1 + \delta), \quad |\delta| \leq u, \quad u = 2^{-53} \quad (2.1)$$

分析一次基本四则运算。式中 $\circ$ 表示相应运算。Python 中常见的 `eps` 是 1 与下一个可表示数的间距 2^{-52} ，等于这里的 $2u$ 。

这个模型有两层含义。首先，单次舍入误差很小；其次，后续运算可能把这点误差放大。数值稳定性主要关注第二层，而不只是浮点格式有多少位。

2.2 绝对误差、相对误差和有效数字

所谓“误差”，首先要相对于一个明确的精确对象来定义。设这个对象的真值为 x ，算法或测量给出的近似值为 $\hat{x}$ 。后面讨论误差时，默认真值由数学问题确定，即使实际并不知道它。

定义 2.2 (绝对误差、相对误差与误差限) 误差为 $e = \hat{x} - x$ ，其绝对值 $|e|$ 衡量偏离真值的距离。当 $x \neq 0$ 时，相对误差为 $e_r = (\hat{x} - x)/x$ 。若已知 $|e| \leq \varepsilon$ 或 $|e_r| \leq \varepsilon_r$ ，则称 ε 或 ε_r 为相应的误差限。

误差本身通常未知，误差限却可能由仪器精度、余项定理或算法分析获得。数值分析的大部分保证，实际是在估计误差限，而不是提前知道真值后再作比较。

两种误差尺度各有用途。“误差不超过 10^{-3} ”必须配合量的尺度理解：测量一条千米长的公路与一个微米尺度的结构，意义完全不同。相对误差把误差除以真值，说明它占结果的多大比例；真值为零或非常接近零时，则应使用绝对误差或混合尺度。

真值未知时，可以由 $|\hat{x} - x| \leq \varepsilon < |\hat{x}|$ 得到

$$|x| \geq |\hat{x}| - \varepsilon, \quad |e_r| \leq \frac{\varepsilon}{|\hat{x}| - \varepsilon}.$$

这里分母不能直接当成 $|\hat{x}|$ ；用近似值代替真值是一阶估计，不是无条件的严格上界。

定义 2.3 (有效数字) 若近似数写为 $\hat{x} = \pm 0.a_1a_2 \cdots a_n \times 10^m$ ，其中 $a_1 \neq 0$ ，采用通常的误差界约定：当

$$|\hat{x} - x| \leq \frac{1}{2} 10^{m-n}$$

时，称它至少有 n 位有效数字。

末位所在数位的半个单位，就是这一约定的核心。它不等价于把两串十进制字符逐个比较；进位附近尤其如此。

例 2.1 (从误差要求选择保留位数) 以 3.1416 近似 π ，判断其有效数字；若用它计算圆面积，半径已有 10^{-3} 的相对误差，应怎样看待继续提高 π 的精度？

解 计算得误差约为 7.35×10^{-6} 。五位有效数字的阈值是 0.5×10^{-4} ，因此该近似至少有五位有效数字。若要求计算 πr^2 ，且半径测量已有 10^{-3} 的相对误差，继续把 π 保存到几十位，并不会消除半径测量带来的主误差。

2.3 运算误差分析

输入有误差以后，函数求值会怎样改变误差？先不考虑运算中的新舍入，只研究精确函数对输入扰动的响应。这样可以把“问题的敏感性”从具体实现中分离出来。

定义 2.4 (绝对条件数与相对条件数) 对标量函数 $y = f(x)$ ，绝对条件数衡量小的绝对输入扰动可能造成的输出变化率；可微时为 $|f'(x)|$ 。若 $x \neq 0$ 且 $f(x) \neq 0$ ，相对条件数为

$$\kappa_f(x) = \left| \frac{x f'(x)}{f(x)} \right|.$$

它比较输出的相对变化和输入的相对变化，是关于问题和当前输入点的量。

例如， $f(x) = x^m$ 在非零点处的相对条件数为 $|m|$ 。如果输入有约 10^{-5} 的相对误差， $m = 3$ 时输出的一阶相对误差约为 3×10^{-5} 。这个估计由函数的局部斜率决定，尚未涉及用何种代码计算幂。

现在暂时假设运算完全精确，只让输入 x 有扰动 Δx 。若 $y = f(x)$ 且 f 在附近有连续二阶导数，Taylor 展开给出

$$f(x + \Delta x) - f(x) = f'(x)\Delta x + O(\Delta x^2).$$

因此 $|f'(x)|$ 衡量绝对误差的一阶放大；当 $x \neq 0$ 、 $f(x) \neq 0$ 时，

$$\frac{|\Delta y|}{|y|} \approx \underbrace{\left| \frac{xf'(x)}{f(x)} \right|}_{\kappa_f(x)} \frac{|\Delta x|}{|x|}. \quad (2.2)$$

$\kappa_f(x)$ 称为相对条件数。它描述数学问题本身对相对扰动的敏感程度。一个函数在不同输入点的条件数可以相差很大。

对多元函数 $f(x_1, \dots, x_n)$ ，一阶传播式为

$$\Delta f \approx \sum_{j=1}^n \frac{\partial f}{\partial x_j} \Delta x_j, \quad |\Delta f| \lesssim \sum_{j=1}^n \left| \frac{\partial f}{\partial x_j} \right| \varepsilon_j.$$

若需要严格界，可以在连接输入与扰动输入的线段上，对各偏导数取上界，再应用多元积分形式的中值公式。不能把一阶近似中的 $\approx$ 直接换成无条件等号。

例 2.2 (相减问题为何可能病态) 设 $f(a, b) = a - b$ 且 $a \neq b$ ，两个输入的相对扰动均不超过 η 。估计输出的相对扰动，并说明相近量相减的敏感性。

解 由三角不等式，

$$|\Delta f| \leq \eta(|a| + |b|), \quad \frac{|\Delta f|}{|a - b|} \leq \frac{|a| + |b|}{|a - b|} \eta.$$

当 a, b 接近时，这个问题对独立输入扰动敏感。后面将看到，某些相近量由同一个输入按确定关系产生，此时可以通过代数改写改善算法。是否出现减法，并不能单独决定原问题的病态程度。

一个更有代表性的例子是求 $\sqrt{x}$ 。对 $x > 0$ ，相对条件数恒为 $1/2$ ，因此它通常是良态问题。但如果用很差的迭代公式计算，仍然可能失败。条件数不评价具体算法。

2.4 病态问题与数值稳定性

有了误差传播的尺度，才可以区分两种失败。第一种是输入已经不足以确定高精度结果；第二种是输入本来足够准确，算法却在中间步骤额外丢失了信息。病态性描述前者，数值稳定性描述后者。

定义 2.5 (病态问题与数值稳定性) 相对于所选输入、输出尺度，若微小数据扰动可能引起很大的解扰动，则称问题在该数据附近病态。数值稳定性讨论算法中输入误差和舍入误差的传播是否受到合理控制。条件数是量化病态程度的常用工具。

病态不是一个只由题目名字决定的标签。同一个函数在不同输入位置可能具有不同条件数；同一个线性方程组在不同尺度和扰动方式下，也应使用相应的误差描述。评价算法之前，应先问期望得到的精度是否由数据本身允许。

定义 2.6 (前向误差与后向误差) 前向误差比较计算结果与原问题精确解的差异。后向误差则寻找一个尽量小的数据扰动，使计算结果恰好成为扰动后问题的精确解。若所需相对数据扰动仅与舍入误差同量级，算法通常称为后向稳定。

设任务是解 $F(d) = x$ ， d 表示输入数据。计算结果 $\hat{x}$ 的前向误差就是它与真解 x 的距离。后向误差则反过来问：能否找到一个很小的数据扰动 Δd ，使

$$\hat{x} = F(d + \Delta d)?$$

如果算法所得结果恰是邻近问题的精确解，且相对后向误差与单位舍入误差同量级或仅差温和的维数因子，就称算法具有后向稳定性。

局部一阶分析把两者联系起来：

$$\text{相对前向误差} \lesssim \text{条件数} \times \text{相对后向误差}. \quad (2.3)$$

这不是所有问题的精确等式，而是一条重要的分析路线：先控制算法引入的扰动，再评估问题会把扰动放大多少。

稳定算法的能力边界。后向稳定算法能尽量避免额外损失信息，但不能恢复输入中已经失去的信息。病态问题即使用稳定算法，也可能有很大的前向误差；良态问题使用不稳定算法，也可能得出很差的结果。

例 2.3 (递推方向决定误差增长) 设 $I_n = \int_0^1 x^n/(x+5) dx$ 。推导相邻积分的递推关系，并比较正向与反向计算的误差传播。

解 由 $x^n/(x+5) = x^{n-1} - 5x^{n-1}/(x+5)$ 得

$$I_n = \frac{1}{n} - 5I_{n-1}, \quad I_0 = \log(6/5).$$

若忽略每步新舍入，仅看初值误差 e_0 ，则 $e_n = -5e_{n-1} = (-5)^n e_0$ 。而 $0 < I_n < 1/[5(n+1)]$ ，真值越来越小，误差却几何增长。

反向递推为 $I_{n-1} = (1/n - I_n)/5$ ，已有误差每步缩小到原来的 $1/5$ 。从较大的 N 开始，用 $I_N \approx 0$ ，回推到较小的 n ，初始近似误差满足

$$|e_n| \leq 5^{-(N-n)} \frac{1}{5(N+1)}.$$

实际还要累加各步舍入影响，但它们同样受到后续反向递推的衰减。相同的数学恒等式，沿不同方向计算，数值行为可以完全不同。

2.5 数值计算的基本原则

选择计算公式时，除了实数范围内的代数正确性，还要观察中间量的尺度与误差传播。常见原则包括：避免不必要的相近量相减；尽量不把很大的数与很小的数反复累加；在合理范围内缩放变量；复用可靠的分解或中间结果；让递推沿误差衰减的方向进行。

这些原则并非要求禁用某一类运算。减法和递推本身都是必要工具，关键是判断正在减去的量已经带有多少误差，以及结果的尺度有多小。

对多项式 $p(x) = a_0 + a_1x + \cdots + a_nx^n$ ，Horner 嵌套形式

$$p(x) = a_0 + x(a_1 + x(a_2 + \cdots + xa_n))$$

减少了重复计算幂的成本。它通常是良好的求值方式，但在多项式值接近零、系数存在强烈抵消的点附近，问题本身仍可能敏感。减少运算次数有帮助，却不能代替条件分析。

例如计算 $x > 0$ 很小时的 $\sqrt{1+x} - 1$ 。两项都接近 1，它们各自很小的绝对误差，相对于约为 $x/2$ 的结果却可能很大。利用代数恒等式可改写为

$$\sqrt{1+x} - 1 = \frac{x}{\sqrt{1+x} + 1}. \quad (2.4)$$

右式的分母约为 2，没有相近量相减。若 $x = 10^{-16}$ ，浮点加法甚至可能把 $1 + x$ 舍入为 1，左式返回零，右式仍能给出约 5×10^{-17} 。

消去的究竟是什么。相近浮点数相减本身不一定产生很大的舍入误差。真正危险的是：前面计算或数据中的误差已经存在，而相减使有效结果变得很小，留下的误差相对于结果就变大了。分析时应沿着整条计算链追踪误差。

求二次方程 $ax^2 + bx + c = 0$ 也有同样问题。若 $b^2 \gg 4ac$ ，一个根的分母 $-b \pm \sqrt{b^2 - 4ac}$ 会发生消去。对非零 a 、实根和 $b \neq 0$ ，可先算

$$q = -\frac{1}{2} \left(b + \text{sign}(b) \sqrt{b^2 - 4ac} \right), \quad x_1 = \frac{q}{a}, \quad x_2 = \frac{c}{q}.$$

两个根的乘积为 c/a ，因此第二个根无需再次作危险的减法。实现仍要单独处理 $q = 0$ 、 $b = 0$ 以及判别式溢出等情况。

用前向差商近似 $f'(x)$ ：

$$D_h f(x) = \frac{f(x+h) - f(x)}{h}.$$

若 $f \in C^2$ ，Taylor 展开产生 $O(h)$ 截断误差；若两个函数值各有不超过 ε 的绝对误差，作差后除以 h ，额外误差至多 $2\varepsilon/h$ 。因此

$$|D_h f(x) - f'(x)| \lesssim C_1 h + \frac{2\varepsilon}{h}.$$

减小 h 只降低第一项，却增大第二项。使右侧近似最小的步长为 $h \approx \sqrt{2\varepsilon/C_1}$ 。数值微分一节将把这个思路推广到中心差分和外推。

实际工作中，误差预算应把模型误差、数据误差、离散误差、迭代误差与舍入误差分开。例如测量数据只有四位有效数字，通常没有必要把迭代残差压到几百位精度。另一方面，即使数据很精确，低阶离散也可能主导总误差。**应优先减小当前最大的误差来源。**

第 3 章 函数的多项式插值

3.1 引言

如果只知道温度在若干时刻的读数，怎样估计中间时刻的温度？一个自然做法是寻找一条通过所有数据点的曲线。曲线的选择有无限多种，插值方法通过预先指定函数空间，把问题变成一个有限维问题。

本章采用多项式作为插值函数，依次讨论插值条件能否确定唯一解、怎样表示和计算这个解，以及节点选择怎样影响误差。

需要先说清楚的是：离散数据只规定了若干点上的函数值，并不唯一确定点与点之间的曲线。因此，插值包含两项选择：给定数据的约束，以及允许使用的函数类型。函数类型一旦固定，才有可能讨论存在性、唯一性和误差。

定义 3.1 (插值与插值节点) 给定互异点 $x_0, \dots, x_n$ 和对应数据 $y_0, \dots, y_n$ ，在指定函数空间中寻找 p ，使 $p(x_i) = y_i$ ，称为插值。 x_i 称为插值节点，等式称为插值条件。若 $y_i = f(x_i)$ ，则称 p 为 f 在这些节点上的插值函数。

在节点范围内求值称为内插，范围外求值称为外推。外推虽然仍可代入同一个多项式，但节点对远处行为的约束更弱，不能把区间内的误差经验直接搬到外部。

3.2 多项式插值

定义 3.2 (多项式空间与基) $\mathcal{P}_n$ 表示次数不超过 n 的实多项式组成的线性空间，包括零多项式。它的维数为 $n+1$ ，一组基为 $1, x, \dots, x^n$ 。多项式插值就是在 $\mathcal{P}_n$ 中满足 $n+1$ 个节点条件。

维数与条件数相等提示我们可能得到唯一解，但仅靠计数还不够：条件之间可能相关。例如，把同一个节点重复写两遍，并不会增加一条独立的函数值约束。互异节点的作用需要在证明中体现。

给定互异节点 $x_0, \dots, x_n$ 及数据 $y_0, \dots, y_n$ ，寻找 $p_n \in \mathcal{P}_n$ 满足

$$p_n(x_i) = y_i, \quad i = 0, \dots, n.$$

若把 p_n 写成单项式之和，插值条件变成 Vandermonde 线性方程组。但这个表示在高次或节点聚集时可能很不稳定；存在唯一解不意味着任意求解方式都合适。

具体写成 $p_n(x) = a_0 + a_1x + \dots + a_nx^n$ ，插值条件为

$$\begin{pmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & & \vdots \\ 1 & x_n & \cdots & x_n^n \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

系数矩阵的行列式为 $\prod_{0 \leq i < j \leq n} (x_j - x_i)$, 互异节点保证它非零。这是唯一性的线性代数解释。下面给出另一种更直接的构造证明, 它同时产生方便使用的插值公式。

定理 3.3 (多项式插值的存在唯一性) 对 $n+1$ 个互异实节点和任意实数据, 存在唯一的 $p_n \in \mathcal{P}_n$ 满足插值条件。

证明. 先构造

$$\ell_i(x) = \prod_{\substack{0 \leq j \leq n \\ j \neq i}} \frac{x - x_j}{x_i - x_j}.$$

由于节点互异, 分母非零; 且 $\ell_i(x_j) = \delta_{ij}$ 。因此

$$p_n(x) = \sum_{i=0}^n y_i \ell_i(x) \quad (3.1)$$

满足要求, 证明了存在性。如果 p_n, q_n 都满足条件, 则 $p_n - q_n$ 是次数至多 n 的多项式, 却有 $n+1$ 个不同零点, 只能恒为零。□

3.3 Lagrange 插值多项式

ℓ_i 就像针对第 i 个读数设计的开关: 在自己的节点上取 1, 在其他节点上取 0。特别地, 常函数 1 的插值仍为 1, 由唯一性有 $\sum_i \ell_i(x) = 1$ 。这个关系以后也会出现在求积权重的推导中。

例 3.1 (三点插值) 求通过 $(0, 1), (1, 2), (2, 5)$ 的二次插值多项式, 并估计 $x = 1/2$ 处的函数值。

解 Lagrange 公式给出

$$p_2(x) = \frac{(x-1)(x-2)}{2} - 2x(x-2) + \frac{5}{2}x(x-1) = 1 + x^2.$$

在 $x = 1/2$ 处得到 1.25。如果真实函数并不是 $1 + x^2$, 这个值仍然是插值值, 但未必是真值。插值条件只约束节点上的行为。

插值余项

设数据来自一个光滑函数 f 。定义节点多项式

$$\omega_{n+1}(t) = \prod_{i=0}^n (t - x_i).$$

它在所有节点上消失, 因此它最适合用来表达插值误差的形状。

定理 3.4 (Lagrange 插值余项) 若 $f \in C^{n+1}[a, b]$, 节点和待估点 x 均在 $[a, b]$ 中, 则存在位于这些点最小包含区间内的 ξ , 使

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x). \quad (3.2)$$

在节点处, 等式两端均为零。

证明. 设 x 不是节点, 并记

$$c = \frac{f(x) - p_n(x)}{\omega_{n+1}(x)}, \quad g(t) = f(t) - p_n(t) - c\omega_{n+1}(t).$$

g 在 $n+1$ 个节点及 x 处均为零, 共有 $n+2$ 个不同零点. 反复应用 Rolle 定理, $g^{(n+1)}$ 至少有一个零点 ξ . 因为 $p_n^{(n+1)} = 0$, 而首一多项式 ω_{n+1} 的 $n+1$ 阶导数为 $(n+1)!$, 于是

$$0 = f^{(n+1)}(\xi) - c(n+1)!.$$

代回 c 的定义即得结论. □

证明中的 x 是固定的, ξ 依赖于它. 因此**不能把余项中的 ξ 当作常数, 对整个等式随意求导或积分**. 求导误差和求积误差需要各自的推导.

对两端点的线性插值, 若 $|f''| \leq M_2$, 则

$$|f(x) - p_1(x)| \leq \frac{M_2}{2} |(x-a)(x-b)| \leq \frac{M_2(b-a)^2}{8}.$$

这条界把“曲率越大, 直线近似越差”变成了明确的数量关系.

例 3.2 (用误差界决定节点间距) 在 $[1, 2]$ 上用分段线性插值近似 $\sqrt{x}$. 若误差要求不超过 10^{-4} , 等距网格至少应取多少个子区间才能由余项界保证?

解 因 $|f''(x)| = 1/(4x^{3/2}) \leq 1/4$, 最大网格宽度为 h 时, 误差不超过 $h^2/32$. 若要求不超过 10^{-4} , 只需 $h \leq \sqrt{0.0032} \approx 0.05657$. 取 18 个等长子区间即可满足这条充分条件.

余项估计在使用时有两个独立步骤. 先从函数的光滑性得到高阶导数的界, 再根据节点位置估计节点多项式 ω_{n+1} . 如果导数界很大、节点分布不合理, 或者待估点远离节点区间, 即使公式中存在 $(n+1)!$, 也不能保证误差很小.

这里 $C^k[a, b]$ 表示在该闭区间上具有 k 阶连续导数的函数. 要求 $f \in C^{n+1}$, 是为了反复使用 Rolle 定理并控制余项; 它不是插值多项式存在的条件. 只要节点互异, 任意数据都可以插值, 哪怕这些数据并非来自一个光滑函数.

3.4 牛顿插值多项式

Lagrange 公式直接给出答案, 却没有保留“从少量节点逐步增加信息”的计算过程. 若新增一个节点后重新计算全部基函数, 会重复很多工作. Newton 形式通过更换基, 保留已经确定的低阶部分, 只增加一个在旧节点处为零的新项.

定义 3.5 (差商) 零阶差商就是函数值 $f[x_i] = f(x_i)$. 对互异节点, 一阶差商是割线斜率

$$f[x_i, x_j] = \frac{f(x_j) - f(x_i)}{x_j - x_i}.$$

更高阶差商通过相邻低阶差商的差再除以端点间距得到; 它描述已有低阶变化仍未解释的部分.

Lagrange 形式对所有节点一视同仁, 但每加一个节点, 全部基函数都要改变. Newton 形式使用逐次增加零点的基:

$$1, \quad (x - x_0), \quad (x - x_0)(x - x_1), \quad \dots$$

新增的高次项在旧节点上自动为零，因此不会破坏已有插值条件。

差商也称均差，其递推定义为

$$f[x_i] = f(x_i), \quad f[x_i, \dots, x_{i+k}] = \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i}.$$

由逐次满足节点条件可得到

$$p_n(x) = f[x_0] + \sum_{k=1}^n f[x_0, \dots, x_k] \prod_{j=0}^{k-1} (x - x_j). \quad (3.3)$$

为什么系数恰好是差商？设 $p_{i:j}$ 是节点 $x_i, \dots, x_j$ 上的插值多项式，直接验证可得递推

$$p_{i:j}(x) = \frac{(x - x_i)p_{i+1:j}(x) - (x - x_j)p_{i:j-1}(x)}{x_j - x_i}.$$

右式在两端节点和所有中间节点都满足插值条件，所以由唯一性等于左式。比较最高次项的系数，恰好得到差商的递推。这也解释了 Aitken–Neville 逐次插值：在一个指定 x 上递推这些数值，无需先求全部多项式系数。

差商虽然递推时有节点顺序，但最高次系数由插值多项式唯一决定，所以对节点置换对称。若 $f \in C^k$ ，则

$$f[x_0, \dots, x_k] = \frac{f^{(k)}(\xi)}{k!}.$$

证明可对 $f - p_k$ 反复使用 Rolle 定理，再比较 $p_k^{(k)}$ 。特别地，多项式的差商具有“高阶归零”性质：对次数小于 k 的多项式， k 阶差商为零。

例 3.3 (把差商表真正算一遍) 对数据 $(0, 1), (1, 2), (2, 5)$ 构造差商表与 Newton 插值多项式，再分析加入 $(3, 10)$ 后的变化。

解 零阶差商为 1, 2, 5，一阶差商为 1, 3，二阶差商为 $(3 - 1)/(2 - 0) = 1$ 。因此

$$p_2(x) = 1 + x + x(x - 1) = 1 + x^2.$$

如果再加入 $(3, 10)$ ，新的三阶差商为零，原多项式无需改变。这是用新观测检验已有模型的一个简单方式。

Newton 形式可用嵌套乘法在 $O(n)$ 次运算内求值：

```
def evaluate_newton(nodes, coeff, t):
    value = coeff[-1]
    for k in range(len(coeff) - 2, -1, -1):
        # 把上一层乘积包进当前一层，避免重复乘法。
        value = coeff[k] + (t - nodes[k]) * value
    return value
```

差商表通常需要 $O(n^2)$ 次运算，可原位保存为长度 $n + 1$ 的数组。求系数与在多个点求值是两个不同阶段，复杂度也应分开计算。

差分与等距节点

对等距节点 $x_i = x_0 + ih$ ，定义前向差分 $\Delta f_i = f_{i+1} - f_i$ 。因为每次差商的分母依次为 $h, 2h, \dots, kh$ ，归纳得到

$$f[x_0, \dots, x_k] = \frac{\Delta^k f_0}{k! h^k}.$$

令 $s = (x - x_0)/h$, 则 Newton 前向公式变成

$$p_n(x) = f_0 + s\Delta f_0 + \frac{s(s-1)}{2!}\Delta^2 f_0 + \cdots + \frac{s(s-1)\cdots(s-n+1)}{n!}\Delta^n f_0.$$

在右端附近, 用 $t = (x - x_n)/h$ 和后向差分 $\nabla f_i = f_i - f_{i-1}$, 可写成

$$p_n(x) = f_n + t\nabla f_n + \frac{t(t+1)}{2!}\nabla^2 f_n + \cdots.$$

两式表示同一个多项式, 区别在于数据组织与计算位置。高阶差分会放大噪声, 因此差分表中后面几列异常抖动时, 不能只把它看成函数的高阶变化。

3.5 Hermite 插值多项式

函数值只能决定曲线经过哪里, 导数还规定它以怎样的方向经过。例如连接两段运动轨迹时, 仅匹配位置可能留下速度突变; 同时匹配位置和速度, 就需要把导数作为独立数据。

定义 3.6 (Hermite 插值) 在若干节点上, 同时给定函数值与一定阶数的导数值, 要求插值多项式逐项满足这些条件, 称为 Hermite 插值。对每个节点同时给定函数值和一阶导数时, 总共 $2n + 2$ 个条件对应空间 $\mathcal{P}_{2n+1}$ 。

这里重复出现的节点代表不同阶的导数信息, 而不是把同一个函数值条件重复使用。重节点差商正是把这两种信息统一写入 Newton 形式的办法。

有些问题不仅知道函数值, 还知道斜率。例如轨迹在两端的位置和速度都已给定。此时要求

$$H(x_i) = f(x_i), \quad H'(x_i) = f'(x_i), \quad i = 0, \dots, n.$$

共有 $2n + 2$ 个条件, 恰好对应 $\mathcal{P}_{2n+1}$ 的维数。若两个解存在, 其差在每个节点有至少二重零点, 而次数不超过 $2n + 1$, 因此解唯一。

记 Lagrange 基为 ℓ_i , 可构造

$$A_i(x) = [1 - 2\ell'_i(x_i)(x - x_i)]\ell_i(x)^2, \quad B_i(x) = (x - x_i)\ell_i(x)^2.$$

逐个代入可验证 $A_i(x_j) = \delta_{ij}$, $A'_i(x_j) = 0$, 而 $B_i(x_j) = 0$, $B'_i(x_j) = \delta_{ij}$ 。于是

$$H(x) = \sum_{i=0}^n [f(x_i)A_i(x) + f'(x_i)B_i(x)].$$

若 $f \in C^{2n+2}[a, b]$, 重复零点版本的 Rolle 论证给出

$$f(x) - H(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \prod_{i=0}^n (x - x_i)^2. \quad (3.4)$$

具体做法与插值余项证明相同, 只是辅助函数在每个节点同时为零且导数为零。

重节点差商提供了统一记号: $f[x_i, x_i] = f'(x_i)$, 一般有 $f[\underbrace{x_i, \dots, x_i}_{k+1}] = f^{(k)}(x_i)/k!$ 。当所有

节点合并到同一点时, Newton 形式退化为 Taylor 多项式。Taylor 展开因此可以看成所有信息集中在一个节点的极端插值。

3.6 分段低次插值

余项 (3.2) 有两个相乘因素：高阶导数与节点多项式。增加次数既改变 $f^{(n+1)}$ ，也改变节点乘积，所以不能仅凭分母有阶乘就断言误差趋于零。

经典例子是 $f(x) = 1/(1 + 25x^2)$ 在 $[-1, 1]$ 上的等距插值。虽然 f 很光滑，端点附近的高次插值仍可能剧烈振荡，这就是 Runge 现象。应对它有两条路线：保留全局多项式但改善节点分布，或改用局部低次插值。




图 3.1 同一个函数、同样数量的节点。等距高次插值在端点附近振荡；Chebyshev 节点向两端聚集，明显改善近似。图中采用 17 个节点，两幅图的纵轴尺度不同。

第二类误差来自数据扰动。若每个数据有 $|\Delta y_i| \leq \varepsilon$ ，则

$$|\Delta p_n(x)| \leq \varepsilon \sum_{i=0}^n |\ell_i(x)|.$$

定义 Lebesgue 常数

$$\Lambda_n = \max_{x \in [a, b]} \sum_{i=0}^n |\ell_i(x)|.$$

它控制插值算子对数据误差的最坏放大。设 I_n 为插值算子，任取 $q \in \mathcal{P}_n$ ，利用 $I_n q = q$ 得

$$f - I_n f = (f - q) - I_n(f - q),$$

因此

$$\|f - I_n f\|_\infty \leq (1 + \Lambda_n) \inf_{q \in \mathcal{P}_n} \|f - q\|_\infty. \quad (3.5)$$

这条不等式清楚地分开了“函数能否被低次多项式逼近”和“所选节点是否把误差放大”。

在 $[-1, 1]$ 上常用 Chebyshev 零点

$$x_i = \cos \frac{(2i+1)\pi}{2(n+1)}, \quad i = 0, \dots, n.$$

其节点多项式与 $T_{n+1}(x) = \cos((n+1) \arccos x)$ 成比例。函数逼近一章将解释它为何在首一多项式中具有最小的最大绝对值。

最后，好的节点也需要好的求值公式。令

$$w_i = \frac{1}{\prod_{j \neq i} (x_i - x_j)}.$$

把 Lagrange 公式的分子、分母同时除以节点多项式，得到重心公式

$$p_n(x) = \frac{\sum_{i=0}^n \frac{w_i y_i}{x - x_i}}{\sum_{i=0}^n \frac{w_i}{x - x_i}}, \quad x \neq x_i. \quad (3.6)$$

在节点上直接返回相应 y_i 。全部 w_i 乘同一个非零常数不改变结果，可据此缩放，减少溢出风险。一般节点的朴素权重计算仍可能不稳；对结构化节点宜使用相应的显式权重。

前面的失败来自让一个高次多项式同时负责整个区间。分段方法先划分网格，各段只负责局部数据，再通过连接条件得到全局函数。增加节点时，可以保持每段次数固定，因此不再要求越来越高阶的导数。

定义 3.7 (分段插值与光滑连接) 在划分 $a = x_0 < \cdots < x_n = b$ 上，若 p 在每个小区间都是某个低次多项式，并在节点满足给定数据条件，则称为分段多项式插值。 $p \in C^r[a, b]$ 表示函数及直到 r 阶的导数在内部节点左右相接。

连续性是全局要求，低次性是局部要求。分段线性函数虽然每段都可微，但连接处左右斜率可能不同，因而通常只是 C^0 。共享同一组节点斜率的分段三次 Hermite 则为 C^1 ，但二阶导数仍可能跳变。

设 $a = x_0 < x_1 < \cdots < x_n = b$ ， $h_i = x_{i+1} - x_i$ 。在 $[x_i, x_{i+1}]$ 上，线性插值为

$$L(x) = \frac{x_{i+1} - x}{h_i} y_i + \frac{x - x_i}{h_i} y_{i+1}.$$

若 $f \in C^2[a, b]$ ，令 $h = \max h_i$ ，Lagrange 余项立即给出

$$\|f - L\|_\infty \leq \frac{1}{8} h^2 \|f''\|_\infty.$$

这条误差界只需要二阶导数，不随节点总数要求越来越高的光滑性。它也是分段方法可靠的重要原因。

线性插值在节点处通常有折角。如果已知每个节点的斜率 m_i ，令 $t = (x - x_i)/h_i$ ，可用三次 Hermite 多项式

$$H_i(x) = (2t^3 - 3t^2 + 1)y_i + (-2t^3 + 3t^2)y_{i+1} + h_i(t^3 - 2t^2 + t)m_i + h_i(t^3 - t^2)m_{i+1}. \quad (3.7)$$

四个基函数分别控制左端值、右端值、左端斜率和右端斜率。斜率项前的 h_i 不能省略，因为 $d/dx = h_i^{-1}d/dt$ 。

若 $m_i = f'(x_i)$ 且 $f \in C^4$ ，由 (3.4) 有

$$|f(x) - H_i(x)| \leq \frac{\|f^{(4)}\|_\infty}{4!} (x - x_i)^2 (x - x_{i+1})^2 \leq \frac{h_i^4}{384} \|f^{(4)}\|_\infty.$$

因此全局函数值误差为 $O(h^4)$ 。如果斜率只是近似值，其误差还要乘以 h_i 后加入函数误差：要保留四阶精度，通常需要节点斜率误差达到 $O(h^3)$ 。随使用一个一阶差商代替斜率，不会自动得到四阶精度。

3.7 三次样条插值

高次多项式把整个区间绑在一起：改变一个节点，远处的曲线也可能变化。分段方法换了一种思路，先把大区间拆小，再在每段使用低次多项式。这样，精度主要通过网格变细来提高，而不必让次数不断增加。

但分段之后又产生一个新问题：小段在连接处应当多光滑？线性插值只保证函数连续，Hermite 插值可以保证一阶导数连续，三次样条则进一步要求二阶导数连续。

定义 3.8 (三次样条插值函数) 对划分 $a = x_0 < \cdots < x_n = b$ ，若 $S \in C^2[a, b]$ ，每个限制 $S|_{[x_i, x_{i+1}]} \in \mathcal{P}_3$ ，且 $S(x_i) = y_i$ ，则称 S 为三次样条插值函数。要唯一确定它，还需要两条合适的边界条件。

与一般分段三次 Hermite 相比，样条不预先指定所有节点斜率，而是让二阶导数连续这一条件协调相邻区间。这样得到的曲线有更高的整体光滑性，但各段也因此通过一个线性系统相互联系。

三次样条 S 满足：每个小区间上是次数至多 3 的多项式， $S(x_i) = y_i$ ，并且 $S \in C^2[a, b]$ 。

共有 n 段，每段四个系数，总计 $4n$ 个未知量。各段两端函数值共给出 $2n$ 个条件，内部 $n-1$ 个节点的一、二阶导数连续各给 $n-1$ 个条件，一共 $4n-2$ 个。还缺两条边界条件。

常见选择为：给定两端一阶导数的固支样条；给定两端二阶导数的样条；以及 $y_0 = y_n$ 时，使一、二阶导数首尾相等的周期样条。自然样条采用

$$S''(a) = S''(b) = 0.$$

这是一种边界模型，而不是所有函数都满足的真理。若真实端点曲率并不为零，自然边界会引入端点附近的偏差。




图 3.2 同一组离散值的分段线性插值与自然三次样条。上图比较曲线，下图比较导数：线性插值的斜率在节点处跳变，样条斜率连续。

三弯矩方程

令 $M_i = S''(x_i)$ 。由于每段 S_i 为三次，其二阶导数是一次函数；又因两端值已知，必有

$$S_i''(x) = M_i \frac{x_{i+1} - x}{h_i} + M_{i+1} \frac{x - x_i}{h_i}.$$

积分两次，再用 $S_i(x_i) = y_i, S_i(x_{i+1}) = y_{i+1}$ 确定两个积分常数，得到

$$S_i(x) = \frac{M_i(x_{i+1} - x)^3}{6h_i} + \frac{M_{i+1}(x - x_i)^3}{6h_i} \quad (3.8)$$

$$+ \left(y_i - \frac{M_i h_i^2}{6} \right) \frac{x_{i+1} - x}{h_i} + \left(y_{i+1} - \frac{M_{i+1} h_i^2}{6} \right) \frac{x - x_i}{h_i}. \quad (3.9)$$

这一形式已经满足函数值插值和二阶导数连接。剩下的条件是内部节点的一阶导数连续。

记 $d_i = (y_{i+1} - y_i)/h_i$ 。对 (3.9) 求导，分别在两端取值：

$$S_i'(x_i) = d_i - \frac{h_i}{6}(2M_i + M_{i+1}), \quad S_i'(x_{i+1}) = d_i + \frac{h_i}{6}(M_i + 2M_{i+1}).$$

在节点 x_i ，令左段右端导数等于右段左端导数，整理得

$$h_{i-1}M_{i-1} + 2(h_{i-1} + h_i)M_i + h_iM_{i+1} = 6(d_i - d_{i-1}), \quad 1 \leq i \leq n-1. \quad (3.10)$$

每个方程只联系三个相邻弯矩，因此称为三弯矩方程。

自然边界直接给出 $M_0 = M_n = 0$ ；固支边界 $S'(a) = s_a, S'(b) = s_b$ 则给出

$$2h_0M_0 + h_0M_1 = 6(d_0 - s_a),$$

$$h_{n-1}M_{n-1} + 2h_{n-1}M_n = 6(s_b - d_{n-1}).$$

这些系数形成三对角系统，后面可用 $O(n)$ 的追赶法求解。

定理 3.9 (自然三次样条的存在唯一性) 对严格递增节点和任意数据，自然三次样条存在且唯一。

证明. 把 $M_0 = M_n = 0$ 代入内部方程。剩下矩阵的对角元为 $2(h_{i-1} + h_i)$ ，每行非对角元绝对值之和不超过 $h_{i-1} + h_i$ ，故严格对角占优。

若该矩阵存在非零零空间向量 v ，取 $|v_k| = \max_i |v_i| > 0$ ，由第 k 行可得

$$|a_{kk}||v_k| \leq \sum_{j \neq k} |a_{kj}||v_j| \leq \left(\sum_{j \neq k} |a_{kj}| \right) |v_k| < |a_{kk}||v_k|,$$

矛盾。因此弯矩唯一可解，再由 (3.9) 唯一确定每段。构造本身保证所有样条条件。 $\square$

例 3.4 (三个节点的自然样条) 求通过 $(0,0), (1,1), (2,0)$ 的自然三次样条，并计算 $S(1/2)$ 和 $S'(1)$ 。

解 自然边界给出 $M_0 = M_2 = 0$ ，内部方程为 $4M_1 = 6(-1 - 1) = -12$ ，所以 $M_1 = -3$ 。代入分段公式，在 $[0,1]$ 上得到

$$S_0(x) = \frac{3}{2}x - \frac{1}{2}x^3.$$

对称性给出 $S_1(x) = S_0(2-x)$ 。特别地 $S(1/2) = 11/16$ ，且 $S'(1) = 0$ 。三个数据点并没有直接指定中点斜率，光滑连接条件把它确定了。

三转角方程与弯曲能量

也可以把节点斜率 $m_i = S'(x_i)$ 作为未知量, 先用三次 Hermite 公式表示每段, 再令二阶导数连续。计算可得

$$h_i m_{i-1} + 2(h_{i-1} + h_i) m_i + h_{i-1} m_{i+1} = 3(h_i d_{i-1} + h_{i-1} d_i). \quad (3.11)$$

这里的左右系数次序与三弯矩方程不同, 不能凭外形照搬。自然边界在斜率形式下为 $2m_0 + m_1 = 3d_0$ 和 $m_{n-1} + 2m_n = 3d_{n-1}$; 固支边界则直接给定 m_0, m_n 。

样条的光滑性还有一个变分解释。设 g 是任何满足相同节点值、且有平方可积二阶导数的足够光滑函数。用

$$J(g) = \int_a^b [g''(x)]^2 dx$$

衡量弯曲能量。在小斜率近似下, 它对应薄弹性梁的弯曲代价。

定理 3.10 (自然样条的最小弯曲性质) 自然三次样条 S 在所有具有相同节点值的 $C^2[a, b]$ 函数中唯一最小化 $J(g)$ 。

证明. 写 $g = S + v$, 其中 $v(x_i) = 0$ 。则

$$J(g) = J(S) + 2 \int_a^b S'' v'' dx + J(v).$$

对交叉项在每段分部积分两次。每段内 $S'''' = 0$; 涉及 v 的端点项因节点值为零而消失; 涉及 v' 的内部项因 S'' 连续而相互抵消; 区间两端项因 $S''(a) = S''(b) = 0$ 而消失。因此交叉项为零, $J(g) = J(S) + J(v) \geq J(S)$ 。

等号要求 $v'' = 0$, 故 v 是一次函数; 它在至少两个不同节点为零, 故恒为零。□

样条的平滑来自哪里。自然样条在必须穿过所有节点的前提下, 选择总弯曲最小的曲线。它仍然是插值: 数据若含噪声, 样条也会穿过噪声。若希望平滑噪声, 应引入数据拟合项与弯曲惩罚之间的权衡, 而不是仅更换边界条件。

几种插值方法的比较

方法	所需数据	主要特点	使用时的条件
Lagrange 与 Newton	节点函数值	同一个全局多项式的不同表示	节点互异，注意高次振荡
Hermite	函数值与导数	同时匹配位置和局部变化	导数数据精度影响结果
分段线性	节点函数值	局部、连续，通常二阶	节点处斜率一般不连续
分段三次 Hermite	函数值与节点斜率	一阶导数连续	准确斜率下函数值四阶
三次样条	函数值与边界条件	二阶导数连续，解三对角系统	边界条件影响端点精度

表 3.1 插值表示、所需信息与光滑性。误差阶均须结合相应的函数光滑性理解。

边界条件与误差

对 $f \in C^4[a, b]$ ，使用真实端点一阶导数的固支三次样条，在常用的规则网格条件下，具有 $O(h^4)$ 的函数误差、 $O(h^3)$ 的一阶导数误差和 $O(h^2)$ 的二阶导数误差。这里的规则网格可取等距网格，或最大最小步长比一致有界的网格族。

自然样条若与真实端点二阶导数相容，也具有相应的高阶精度；若 $f''(a)$ 或 $f''(b)$ 非零，则不能不加条件地声称全区间仍四阶收敛。例如 $f(x) = x^2$ 的端点曲率恒为 2，自然边界却强制曲率为零，端点附近会产生边界误差，函数最大误差一般只有二阶量级。对导数与误差阶的判断必须把边界条件一起写出。

数值上还要区分光滑性与保形性。普通三次样条即使在单调数据上也可能过冲。若任务要求浓度或概率始终非负、曲线严格单调，就需要额外限制斜率的保形插值方法。 C^2 光滑并不自动包含这些约束。

第 4 章 函数逼近

4.1 引言

插值要求每个节点都准确通过，但这未必是最合适的目标。如果数据有噪声，或者要在整个区间上控制误差，我们更关心一条曲线总体上是否接近目标函数。“接近”必须由一个明确的误差度量定义。

平方误差把所有位置的偏差累加，适合用内积和正交投影分析；最大误差关注最坏位置，引出一致逼近和等幅交错。两者都叫“最佳”，但最优解通常不同。

假设实验数据在一条直线附近上下波动。严格插值会把每个测量误差都当作必须满足的约束，导致曲线追着噪声变化。如果只希望描述总体趋势，就应允许部分点存在偏差，再规定怎样比较这些偏差。函数逼近从这里出发：先选择近似空间，再选择误差度量，最后在空间内寻找误差最小者。

定义 4.1 (逼近空间与最佳逼近) 给定目标函数 f 、允许的函数集合 V 及误差度量 $\|\cdot\|$ ，若 $p_* \in V$ 满足

$$\|f - p_*\| = \inf_{p \in V} \|f - p\|,$$

则称 p_* 是该度量下的最佳逼近。不同的空间或度量，通常产生不同的最佳函数。

例如，同样用一次多项式逼近 x^2 ，最小化误差平方的积分与最小化最大误差，会给出不同常数。没有说明“在哪个空间、用什么误差”，单独说某个近似“最好”没有确定含义。

4.2 正交多项式

为了把函数逼近转成几何问题，需要先把向量的内积推广到函数。对于离散向量，内积把对应分量的乘积相加；对于连续函数，自然的对应操作是把乘积积分。权函数用来调节不同位置的贡献。

定义 4.2 (实内积、正交与正交归一) 实线性空间中的内积 $\langle u, v \rangle$ 对第一个变量线性，满足对称性 $\langle u, v \rangle = \langle v, u \rangle$ ，以及 $\langle u, u \rangle \geq 0$ ，等号仅在 $u = 0$ 时成立。若 $\langle u, v \rangle = 0$ ，称 u, v 正交；一组向量或函数两两正交且各自范数为 1，称为正交归一组。

函数空间中，零函数应按所选内积的意义理解。例如连续正权积分下，平方范数为零的连续函数处处为零；对于平方可积函数，则把几乎处处相等的函数视为同一个元素。离散采样内积只观察节点值，若空间太大，可能存在非零函数在所有节点上都为零，此时它在整个函数空间上只是半内积。

设权函数 $w(x) > 0$ 几乎处处成立，且相关积分有限。定义

$$\langle f, g \rangle_w = \int_a^b w(x) f(x) g(x) dx, \quad \|f\|_w^2 = \langle f, f \rangle_w.$$

权越大的位置, 对总误差的贡献越大。离散数据也可以定义 $\langle u, v \rangle_w = \sum_i w_i u(x_i) v(x_i)$, 其中 $w_i > 0$; 此时需注意, 内积对所选函数空间是否正定取决于采样是否足够。

定义 4.3 (正交多项式序列) 若 $\deg \pi_k = k$, 且 $\langle \pi_k, \pi_j \rangle_w = 0$ 对所有 $j \neq k$ 成立, 则称 $\{\pi_k\}$ 是对应权与区间上的正交多项式序列。若最高次项系数取 1, 称为首一正交多项式; 若平方范数取 1, 称为正交归一多项式。

性质 4.4 (正交多项式的张成空间) 非零正交函数线性无关。对次数依次为 $0, \dots, n$ 的正交多项式, 前 $n+1$ 项构成 $\mathcal{P}_n$ 的一组基; 因此 π_n 与任意次数小于 n 的多项式正交。

证明. 若 $\sum_{j=0}^n c_j \pi_j = 0$, 与 π_k 取内积, 得 $c_k \|\pi_k\|_w^2 = 0$, 故所有系数为零。它们共有 $n+1$ 个, 等于 $\mathcal{P}_n$ 的维数, 所以构成一组基。任何低次多项式都能用前面的基展开, 再利用两两正交即可。□

正交多项式并不是另一类逼近空间: 它们仍然张成普通多项式空间。改变的是坐标, 目的是避免单项式基中不同方向的强烈相关, 使系数和误差更容易分析。

三项递推

从 $1, x, x^2, \dots$ 出发, 逐步减去在已有空间中的投影, 即可得到正交多项式。让每个多项式的最高次系数等于 1, 记为 π_k 。首一化使递推系数更容易比较。

因为 $x\pi_k$ 的次数为 $k+1$, 可以在 $\pi_0, \dots, \pi_{k+1}$ 上展开。而当 $j \leq k-2$ 时,

$$\langle x\pi_k, \pi_j \rangle_w = \langle \pi_k, x\pi_j \rangle_w = 0,$$

因为 $x\pi_j$ 的次数至多为 $k-1$ 。所以展开只剩下三个相邻次数:

$$\pi_{k+1}(x) = (x - \alpha_k)\pi_k(x) - \beta_k\pi_{k-1}(x), \quad (4.1)$$

其中

$$\alpha_k = \frac{\langle x\pi_k, \pi_k \rangle_w}{\|\pi_k\|_w^2}, \quad \beta_k = \frac{\|\pi_k\|_w^2}{\|\pi_{k-1}\|_w^2} > 0.$$

第二式可由 $\langle x\pi_k, \pi_{k-1} \rangle_w = \langle \pi_k, x\pi_{k-1} \rangle_w = \|\pi_k\|_w^2$ 得到。初值为 $\pi_0 = 1$ 、 $\pi_1 = x - \alpha_0$, $k=0$ 时省略最后一项。

例 4.1 (在 $[-1, 1]$ 上构造前三个首一正交多项式) 在 $[-1, 1]$ 上取权函数 $w = 1$, 构造次数为 $0, 1, 2$ 的首一正交多项式。

解 对称性使 $\alpha_0 = \alpha_1 = 0$ 。有 $\pi_0 = 1$ 、 $\pi_1 = x$, 且

$$\beta_1 = \frac{\int_{-1}^1 x^2 dx}{\int_{-1}^1 1 dx} = \frac{1}{3}, \quad \pi_2 = x^2 - \frac{1}{3}.$$

二次项减去均值后, 与常数正交; 它又是偶函数, 所以自动与奇函数 x 正交。

定理 4.5 (零点全部位于区间内部) 设 $w > 0$ 几乎处处, π_n 是 $[a, b]$ 上的 n 次正交多项式, 则它在 (a, b) 中有 n 个互异实零点。

证明. 把 π_n 在 (a, b) 中所有变号零点记为 $t_1, \dots, t_m$, 令 $q(x) = \prod_{j=1}^m (x - t_j)$. 乘积 $\pi_n q$ 在整个区间不变号, 且并非恒零, 所以 $\langle \pi_n, q \rangle_w \neq 0$. 若 $m < n$, 正交性却要求该内积为零, 矛盾. 因此 $m \geq n$. 次数只有 n , 故恰有 n 个变号零点, 且均为单根, 也不可能再有端点、区间外或非实零点. $\square$

相邻次数的零点还会交错. 理由可以从 (4.1) 看出: 在 π_k 的零点处, $\pi_{k+1} = -\beta_k \pi_{k-1}$, 而 $\beta_k > 0$. 由低次情形开始归纳, 相邻零点处符号交替, 介值定理保证中间出现新零点; 结合两端的最高次项符号, 可确定最外侧两个零点. 这种结构使正交多项式非常适合作为求积节点的来源.

常用正交多项式

Legendre 多项式对应区间 $[-1, 1]$ 和权 1, 通常采用 $P_n(1) = 1$ 的归一化, 而非首一归一化. Rodrigues 公式为

$$P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} (x^2 - 1)^n.$$

对任意 $q \in \mathcal{P}_{n-1}$, 分部积分 n 次, 边界项因 $(x^2 - 1)^n$ 在两端有 n 重零点而消失, 最后出现 $q^{(n)} = 0$, 因此 P_n 与全部低次多项式正交. 这给出了 Rodrigues 公式与正交性的直接联系.

前几项及递推关系为

$$P_0 = 1, \quad P_1 = x, \quad P_2 = \frac{1}{2}(3x^2 - 1), \quad P_3 = \frac{1}{2}(5x^3 - 3x),$$

$$(n+1)P_{n+1} = (2n+1)xP_n - nP_{n-1}, \quad \int_{-1}^1 P_n^2 dx = \frac{2}{2n+1}.$$

Chebyshev 多项式定义为

$$T_n(\cos \theta) = \cos(n\theta).$$

余弦加法公式给出 $T_{n+1} = 2xT_n - T_{n-1}$, 其中 $T_0 = 1, T_1 = x$. 代换 $x = \cos \theta$ 后,

$$\int_{-1}^1 \frac{T_m(x)T_n(x)}{\sqrt{1-x^2}} dx = \int_0^\pi \cos(m\theta) \cos(n\theta) d\theta.$$

因此它们在权 $w(x) = (1-x^2)^{-1/2}$ 下正交. $n \geq 1$ 时平方范数为 $\pi/2$, $n = 0$ 时为 π . 权在端点发散, 但积分仍然有限.




图 4.1 Legendre 多项式与 Chebyshev 多项式的前几项. 它们使用不同权函数, 因而“正交”对应不同的误差度量.

无界区间上也有相应的正交多项式。标准 Laguerre 多项式 L_n 对应 $[0, \infty)$ 与权 e^{-x} ，可由

$$L_n(x) = \frac{e^x}{n!} \frac{d^n}{dx^n} (e^{-x} x^n)$$

构造。物理学约定的 Hermite 多项式 H_n 对应 $\mathbb{R}$ 与权 e^{-x^2} ，定义为

$$H_n(x) = (-1)^n e^{x^2} \frac{d^n}{dx^n} e^{-x^2}.$$

它与概率论中使用权 $e^{-x^2/2}$ 的另一套 Hermite 归一化不同。使用公式时必须核对权与缩放。此处的 Hermite 多项式是一族正交多项式，与上一章利用导数数据的 Hermite 插值是不同概念。

4.3 连续函数的最佳逼近

上一节准备了正交基，现在用它寻找最佳函数。平方误差的关键优点是展开后只有二次项和交叉项，交叉项能否消失，恰好由内积和正交性控制。

定义 4.6 (最佳平方逼近与最佳一致逼近) 在有限维空间 V 中，使

$$\int_a^b w(x) [f(x) - p(x)]^2 dx$$

最小的 p 称为最佳平方逼近。若 f, p 连续，使 $\max_{[a,b]} |f - p|$ 最小的 p 称为最佳一致逼近。前者控制总体平方误差，后者控制最坏位置的误差。

先处理平方逼近。把近似函数沿空间中的任一方向微调，如果误差已经最小，一阶变化率就必须为零。这条最优性条件将转化为“残差与空间正交”。它不仅是一组求系数的方程，还解释了为什么解是全局最优而不是某个偶然驻点。

给定线性无关函数 $\phi_0, \dots, \phi_n$ ，令 $V = \text{span}\{\phi_0, \dots, \phi_n\}$ 。我们寻找 $p_* \in V$ ，使 $\|f - p_*\|_w$ 最小。

定理 4.7 (有限维正交投影) 若内积在 V 上正定，则最佳平方逼近 p_* 存在唯一，且等价地满足

$$\langle f - p_*, v \rangle_w = 0, \quad \forall v \in V. \quad (4.2)$$

证明. 写 $p = \sum_j c_j \phi_j$ 。误差平方是关于 c 的二次函数，其一阶导数为零的条件为

$$\sum_{j=0}^n \langle \phi_j, \phi_i \rangle_w c_j = \langle f, \phi_i \rangle_w.$$

记 Gram 矩阵 $G_{ij} = \langle \phi_j, \phi_i \rangle_w$ 。对非零向量 z ,

$$z^T G z = \left\| \sum_j z_j \phi_j \right\|_w^2 > 0,$$

故 G 正定，方程有唯一解 c_* 。它给出的残差与每个基函数正交，因此满足 (4.2)。

反过来，对任意 $p = p_* + v$ ，正交性使交叉项消失：

$$\|f - p\|_w^2 = \|f - p_*\|_w^2 + \|v\|_w^2.$$

所以 p_* 是唯一最小点。最后这个等式比只说“导数为零”更强：它直接给出全局最优性。 $\square$

若基函数两两正交, Gram 矩阵就是对角阵, 系数可逐个求出:

$$c_j = \frac{\langle f, \phi_j \rangle_w}{\langle \phi_j, \phi_j \rangle_w}, \quad \|f - p_*\|_w^2 = \|f\|_w^2 - \sum_{j=0}^n \frac{\langle f, \phi_j \rangle_w^2}{\langle \phi_j, \phi_j \rangle_w}.$$

选好坐标系使耦合消失, 这正是正交基的计算价值。

最佳平方逼近的计算

例 4.2 (用一次多项式逼近 x^2) 在 $[-1, 1]$ 、权 $w = 1$ 下, 求 x^2 的最佳平方一次多项式逼近及最小误差平方。

解 设 $p = a + bx$ 。正交条件为

$$\int_{-1}^1 (x^2 - a - bx) dx = 0, \quad \int_{-1}^1 x(x^2 - a - bx) dx = 0.$$

奇函数积分为零, 所以 $a = 1/3, b = 0$ 。最佳平方逼近是常数 $1/3$, 最小误差平方为

$$\int_{-1}^1 (x^2 - 1/3)^2 dx = \frac{8}{45}.$$

注意误差的积分等于零, 并不意味着误差处处为零; 正负误差在内积中抵消了。

对一般 f , Legendre 展开的前 $n+1$ 项就是 $\mathcal{P}_n$ 中的最佳平方逼近:

$$p_n(x) = \sum_{k=0}^n a_k P_k(x), \quad a_k = \frac{2k+1}{2} \int_{-1}^1 f(x) P_k(x) dx.$$

增加一项不会改变旧系数, 因为新方向与旧空间正交。误差平方恰好减少 $a_{n+1}^2 \|P_{n+1}\|^2$ 。这给出一个清晰的逐阶改进过程。

有限阶投影的存在不要求 f 能展开成处处收敛的无穷级数。讨论无穷展开时, 还要指明采用平方平均收敛、逐点收敛还是一致收敛。这些结论需要不同条件。

最佳一致逼近

现在改用 $\|f - p\|_\infty = \max_{x \in [a, b]} |f(x) - p(x)|$ 。我们要让最坏位置的误差尽量小。这里没有二次函数和正交方程, 最优条件变成误差峰值的排列。

先记录一条用于计数零点的事实。

引理 4.8 (等幅交错导致多个零点) 若连续函数 g 在递增点 $t_0, \dots, t_m$ 上非零且符号交替, 则每个 (t_i, t_{i+1}) 内至少有一个零点, 因而至少有 m 个不同零点。

证明. 每个相邻区间的端点异号, 由介值定理可得一个内部零点。各个开区间互不相交, 所以这些零点互异。□

定理 4.9 (Chebyshev 交错定理) 设 $f \in C[a, b]$ 且 $f \notin \mathcal{P}_n$ 。 $p_* \in \mathcal{P}_n$ 是最佳一致逼近的充要条件是: 存在 $n+2$ 个递增点 $t_0 < \dots < t_{n+1}$, 使

$$f(t_i) - p_*(t_i) = \sigma(-1)^i E, \quad E = \|f - p_*\|_\infty > 0, \quad \sigma \in \{1, -1\}.$$

最佳一致逼近存在且唯一。若 $f \in \mathcal{P}_n$, 最佳逼近就是 f 本身。

证明. 先证充分性. 若另有 q 的最大误差小于 E , 则在 t_i 处, $q - p_*$ 必须与 $f - p_*$ 同号. 因此 $q - p_*$ 在相邻 t_i 之间至少有一个零点, 共至少 $n + 1$ 个, 而其次数至多为 n , 矛盾.

再说明必要性. 记极值集合 $K = \{x : |f(x) - p_*(x)| = E\}$. 正、负极值集合都是紧集, 且由于 $E > 0$ 而彼此分离. 如果没有 $n + 2$ 个交错极值点, 沿区间从左到右, K 可分成至多 $n + 1$ 个符号交替的块. 在相邻块的空隙中各选一点作零点, 可构造一个次数至多为 n 的多项式 q , 其符号在 K 上与误差一致, 且在 K 上不为零.

对足够小的 $\epsilon > 0$, 把 p_* 改成 $p_* + \epsilon q$. 在 K 的某个邻域, 误差绝对值被一致压低; 在剩余紧集, 原误差已比 E 小一个固定余量, 足够小的扰动不会超过 E . 这样得到更小的最大误差, 矛盾.

存在性可由有限维紧性证明: 取误差有界的极小化序列, 在固定 $n + 1$ 个节点上的多项式值有界, Vandermonde 矩阵可逆, 故系数有界, 存在收敛子列. 极限仍达到下确界.

最后, 若 p, q 都最佳, 则 $(p + q)/2$ 也是最佳. 对这个平均多项式使用交错条件, 在其 $n + 2$ 个极值点, $f - p$ 与 $f - q$ 必须同为相应的 $\pm E$, 否则平均达不到该极值. 故 $p - q$ 在这些点全为零, 只能恒为零. $\square$

例 4.3 (平方最佳与一致最佳的区别) 求 x^2 在 $[-1, 1]$ 上的最佳一致一次多项式逼近, 并与最佳平方逼近比较.

解 取 $p_* = 1/2$. 误差在 $-1, 0, 1$ 依次为 $1/2, -1/2, 1/2$, 有三个交错点, 故是最佳一致逼近. 前面最佳平方逼近是 $1/3$. 两者都正确, 只是优化的目标不同.




图 4.2 用一次多项式逼近 x^2 : 平方最佳为 $1/3$, 一致最佳为 $1/2$. 后者让端点与中点的最大误差等幅交错.

对 $n \geq 1$, T_n 的最高次系数为 2^{n-1} , 故 $2^{1-n}T_n$ 是首一多项式, 且在 $n + 1$ 个极值点交错取值 $\pm 2^{1-n}$. 如果另一个首一 n 次多项式具有更小的最大绝对值, 两者之差至多 $n - 1$ 次, 却被迫在 n 个间隔内变号, 矛盾. 因此

$$\min_{q \text{ 为首一 } n \text{ 次多项式}} \|q\|_{\infty} = 2^{1-n}.$$

这正是 Chebyshev 零点能减小插值节点乘积最大值的原因。

实际寻找一般函数的最佳一致逼近时, Remez 思路是先猜 $n + 2$ 个交错点, 联立求出多项式系数与共同误差 E , 再寻找真实误差的极值并更新点组. 它把无限多个不等式约束暂时压缩成有限组等幅条件, 但需要可靠的极值搜索与点组更新, 不能只解一次线性方程就结束.

交错条件同时解释了为什么一致最佳逼近的误差不倾向于集中在一个位置。如果一个正峰值明显高于其他负峰值，通常可以把多项式略向上移动，在不制造更大反向误差的情况下压低最坏值。到达最佳状态时，必须有足够多个正负峰值互相制约，次数为 n 的扰动多项式才无法同时改善它们。

交错定理的充分性证明正是把这一事实用于两个逼近多项式之差，再与“非零 n 次多项式至多有 n 个零点”比较。它体现了一条常用证明路线：先把误差大小要求变成符号约束，再把符号约束变成零点计数。

4.4 离散数据的曲线拟合

连续投影假设知道整个函数，实验数据却通常只提供有限个样本。此时把积分内积换成离散内积，平方逼近就转化为一个矩阵问题。

连续函数的平方逼近把整个区间上的误差积分；只有观测样本时，就把积分换成加权求和。权的选择应与数据含义对应：更可靠的观测通常应受到更大重视，但权不是用来事后迁就拟合结果的任意旋钮。

定义 4.10 (最小二乘拟合与残差) 给定观测 y_i 和模型值 $p(x_i; c)$, 定义残差 $r_i = y_i - p(x_i; c)$ 。最小化 $\sum_i w_i r_i^2$ ($w_i > 0$) 称为加权最小二乘拟合。若模型对参数 c 线性，则是线性最小二乘；模型对自变量 x 不必是一次函数。

例如 $p(x) = c_0 + c_1x + c_2x^2$ 是关于 x 的二次函数，却仍是线性最小二乘模型，因为每个未知系数都以一次形式出现。相反， ae^{bx} 对参数 b 非线性，不能仅凭“只有两个参数”就按线性方程处理。

给定样本 (x_i, y_i) , $i = 1, \dots, m$, 选择 $n+1$ 个基函数，通常 $m > n+1$ 。令

$$p(x) = \sum_{j=0}^n c_j \phi_j(x), \quad A_{ij} = \phi_j(x_i), \quad W = \text{diag}(w_1, \dots, w_m), \quad w_i > 0.$$

加权最小二乘问题是

$$\min_c J(c), \quad J(c) = (Ac - y)^T W (Ac - y).$$

对系数求导，得到正规方程

$$A^T W A c = A^T W y. \quad (4.3)$$

若 A 列满秩，则 $z^T A^T W A z = \|W^{1/2} A z\|_2^2 > 0$ ，所以系数唯一。若不满秩，拟合出的投影向量仍唯一，但表达它的系数未必唯一。

残差 $r = y - Ac$ 满足 $A^T W r = 0$ 。这不是说每个残差为零，而是说它无法再通过改变模型系数而一阶减小。几何上，拟合向量是数据向量在设计矩阵列空间上的加权正交投影。

例 4.4 (拟合直线) 对数据 $(0, 1), (1, 2), (2, 2)$ 作等权最小二乘直线拟合，并验证残差的正交性。

解 设拟合直线为 $a + bx$ 。正规方程为

$$\begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}, \quad a = \frac{7}{6}, \quad b = \frac{1}{2}.$$

残差依次为 $-1/6, 1/3, -1/6$ ，其和为零，与横坐标的内积也为零。最小残差平方和为 $1/6$ 。

拟合次数提高，训练样本上的最小平方误差不会增大，因为允许的空间变大了。但这不保证对新位置的预测更好。模型也可能把噪声拟合成剧烈的曲线；是否采用更高次数，需要结合数据精度与用途判断。




图 4.3 含噪声样本上的低次最小二乘与严格插值。插值必须穿过每个噪声点，低次拟合则允许局部残差，以换取较稳定的整体趋势。

正规方程的求解

设 $\tilde{A} = W^{1/2}A$, $\tilde{y} = W^{1/2}y$ 。列满秩时，2-范数条件数满足

$$\kappa_2(\tilde{A}^T \tilde{A}) = \kappa_2(\tilde{A})^2,$$

因为 $\tilde{A}^T \tilde{A}$ 的特征值是 $\tilde{A}$ 奇异值的平方。因此显式形成正规方程可能额外损失精度。

作薄 QR 分解 $\tilde{A} = QR$ ，其中 $Q^T Q = I$, R 为上三角阵。把残差分成列空间内与正交补上的分量：

$$\|\tilde{A}c - \tilde{y}\|_2^2 = \|Rc - Q^T \tilde{y}\|_2^2 + \|(I - QQ^T)\tilde{y}\|_2^2.$$

第二项与 c 无关，所以只需求解

$$Rc = Q^T \tilde{y}.$$

正交变换保持 2-范数，是 QR 稳定性分析的核心。出现近似秩亏时，应进一步使用带列主元的 QR 或 SVD 分析有效秩。

```
import numpy as np

# A 的每一列是一种基函数在样本上的取值。
A = np.column_stack([np.ones_like(x), x, x*x])
Aw = np.sqrt(w)[: , None] * A
bw = np.sqrt(w) * y
# 用最小二乘求解器，避免手工形成 A.T @ A。
coef, _, rank, singular_values = np.linalg.lstsq(Aw, bw, rcond=None)
```

这是调用片段， x, y, w 是事先准备好的等长一维数组。返回的奇异值和秩提供了设计矩阵的信息，而不只是给出一组系数。

若 x 的尺度很大，先中心化并缩放到适当区间，或直接使用正交多项式基，通常更易计算。换基不改变理想精确算术下的拟合空间，却会改变矩阵的条件。

模型的线性化

有时拟合模型写为 $y = ae^{bx}$ 。取对数后得到 $\log y = \log a + bx$ ，看起来可以用线性最小二乘。但原来的目标

$$\sum_i (y_i - ae^{bx_i})^2$$

与变换后的目标

$$\sum_i (\log y_i - \log a - bx_i)^2$$

并不相同。小扰动下， $\Delta \log y \approx \Delta y/y$ ，后一个目标更接近关注相对误差。若 $y_i \leq 0$ ，变换甚至无定义。

因此线性化可以简化计算，但必须说明接受了什么误差度量。若原问题要求最小化原尺度上的残差，就应直接处理非线性最小二乘，或把线性化结果作为初值。

4.5 三角多项式逼近与快速傅里叶变换

多项式适合描述区间上的平滑趋势，周期现象则具有另一种自然结构：一个周期结束后，函数应与下一个周期衔接。正弦和余弦自动满足周期条件，还能按频率把慢变化与快变化分开，因此适合作为周期逼近的基。

定义 4.11 (三角多项式与频率) 形如

$$p_n(x) = \frac{a_0}{2} + \sum_{k=1}^n [a_k \cos(kx) + b_k \sin(kx)]$$

的函数称为最高频率不超过 n 的 2π 周期三角多项式。整数 k 表示一个基本周期内的振荡次数，系数确定该频率分量的幅度与相位。

一组 Fourier 系数描述函数在这些方向上的投影。有限项的投影问题只需要有限维正交性；把项数趋于无穷以后，还要单独讨论级数在何种意义下趋于原函数。尤其不能把平方平均收敛直接读成每个位置的误差都很小。

对 2π 周期实函数，在 $[-\pi, \pi]$ 上考虑

$$p_n(x) = \frac{a_0}{2} + \sum_{k=1}^n [a_k \cos(kx) + b_k \sin(kx)].$$

三角函数间的正交关系可由积化和差公式推出。例如 $k \neq l$ 时

$$\int_{-\pi}^{\pi} \cos(kx) \cos(lx) dx = 0,$$

而正整数 k 的 $\cos^2(kx)$ 与 $\sin^2(kx)$ 积分均为 π 。应用投影定理，

$$a_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \cos(kx) dx, \quad b_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \sin(kx) dx.$$

a_0 按同一公式取 $k = 0$ 。常数项写成 $a_0/2$ ，是为了统一系数表达式。

对分段光滑的周期函数，Fourier 部分和在连续点趋于 $f(x)$ ，在跳跃点趋于左右极限的平均。这是逐点结论。跳跃附近会出现 Gibbs 振荡，增大截断阶数会压缩振荡区域，却不会使最大过冲简单消失。误差在平方平均意义下趋于零，与局部仍存在过冲并不矛盾。




图 4.4 方波的 Fourier 部分和。增加项数使远离跳跃的位置更准确，但跳跃附近仍有过冲，说明不同收敛概念不能混用。

复指数形式更加紧凑：

$$c_k = \frac{1}{2\pi} \int_{-\pi}^{\pi} f(x) e^{-ikx} dx, \quad p_n(x) = \sum_{k=-n}^n c_k e^{ikx}.$$

对实函数， $c_{-k} = \overline{c_k}$ ；并且 $c_k = (a_k - ib_k)/2$ ， $k > 0$ 。复数表达没有增加额外信息，只是把正弦与余弦合并。

离散傅里叶变换

令样本位于 $x_j = 2\pi j/N$ 。不同整数频率满足

$$\sum_{j=0}^{N-1} e^{2\pi i(k-l)j/N} = \begin{cases} N, & k \equiv l \pmod{N}, \\ 0, & \text{否则}. \end{cases}$$

证明只需有限等比数列公式：当比值不是 1 时，分子为 $1 - e^{2\pi i(k-l)} = 0$ 。

采用常见的未归一化正变换约定，

$$Y_k = \sum_{j=0}^{N-1} y_j e^{-2\pi ijk/N}, \quad y_j = \frac{1}{N} \sum_{k=0}^{N-1} Y_k e^{2\pi ijk/N}. \quad (4.4)$$

把第一式代入第二式，再交换求和顺序，用上面的离散正交关系，即可验证逆变换。归一化系数必须与所用库的约定一致。

DFT 不能区分相差 N 的频率，因为它们在这些节点上的值完全相同，这就是混叠。数据是有限采样时，不能把频谱中的一个峰无条件解释为真实连续信号的唯一频率。对偶数 N ，频率 $N/2$ 的样本为 $(-1)^j$ ，它与 $-N/2$ 是同一模式，不能重复计数。

快速傅里叶变换

直接计算 (4.4) 需要 $O(N^2)$ 次运算。若 N 为偶数，分别把偶数下标与奇数下标取出：

$$Y_k = \sum_{r=0}^{N/2-1} y_{2r} e^{-2\pi irk/(N/2)} + e^{-2\pi ik/N} \sum_{r=0}^{N/2-1} y_{2r+1} e^{-2\pi irk/(N/2)}.$$

把两项中的短变换记为 E_k, O_k ，令 $\omega_N = e^{-2\pi i/N}$ ，便得到

$$Y_k = E_k + \omega_N^k O_k, \quad Y_{k+N/2} = E_k - \omega_N^k O_k, \quad 0 \leq k < N/2.$$

一个长度 N 的问题被拆成两个长度 $N/2$ 的问题，再用 $O(N)$ 次运算组合。若 $N = 2^m$ ，

$$T(N) = 2T(N/2) + O(N) = O(N \log N).$$

FFT 是计算 DFT 的快速算法，不是一种新的变换，也不是对原 DFT 的截断近似。

三类逼近目标的比较

方法	要求或最小化的量	最优条件或特点
插值	指定节点上误差为零	先选函数空间，节点条件决定系数
最佳平方逼近	误差平方的积分或加权和	残差与逼近空间正交
最佳一致逼近	整个区间的最大绝对误差	多项式情形满足等幅交错条件

表 4.1 “最佳” 依赖于误差度量。Fourier 有限部分和属于相应三角空间中的最佳平方逼近。

第 5 章 数值积分与数值微分

5.1 引言

许多积分没有方便的原函数，或者被积函数本身就是一个昂贵的程序。数值积分要在有限次函数求值的预算内，尽量准确地估计面积。选择哪些点、给每个点多大权重，决定了一个求积公式的精度与稳定性。

本章先固定节点，用插值导出求积；再通过复化与外推改善精度；最后让节点也参与设计，得到 Gauss 求积。

数值积分与数值微分都可以借助插值构造：先用简单函数近似 f ，再对近似函数积分或求导。但两种运算的误差传播不同。积分把局部贡献累加，常有平均作用；求导依赖相邻值的差，再除以小步长，容易放大扰动。因此，本章不仅推导公式，也比较它们对数据精度和光滑性的要求。

一个求积问题通常先给定积分区间和可获得的函数信息。如果节点位置可以自由选择，就有优化节点的余地；如果只能使用已有等距采样，方法选择会受到限制。固定节点的 Newton-Cotes 与自由选点的 Gauss，正好对应这两种情况。

5.2 Newton-Cotes 求积公式

定义 5.1 (求积节点、权重与代数精度) 用有限和 $Q_m(f) = \sum_{i=1}^m A_i f(x_i)$ 近似积分，称为数值求积公式； x_i 是求积节点， A_i 是求积权重。若公式对所有 $p \in \mathcal{P}_d$ 精确，而并非对所有 $p \in \mathcal{P}_{d+1}$ 精确，则代数精度恰为 d 。

代数精度之所以容易检验，是因为积分和加权求和都是线性操作。只要对基函数 $1, x, \dots, x^d$ 一一精确，就对它们的任意线性组合精确。这把一个涉及无穷多个多项式的条件，转成了有限组矩条件。

一般加权求积写为

$$I(f) = \int_a^b w(x)f(x) dx \approx Q_m(f) = \sum_{i=1}^m A_i f(x_i).$$

若它对 $1, x, \dots, x^d$ 全部精确，而对至少一个 $d+1$ 次多项式不精确，则称代数精度为 d 。这是对多项式的精确性指标，并不直接等于某个任意函数上的误差大小。

固定 m 个互异节点，插值 f 后积分，得

$$A_i = \int_a^b w(x)\ell_i(x) dx.$$

因为对次数至多 $m-1$ 的多项式，插值完全恢复原函数，所以这种插值型求积至少具有 $m-1$ 次代数精度。反过来，若固定节点的求积对 $\mathcal{P}_{m-1}$ 精确，把各个 ℓ_i 代入就会唯一确定上述权重。

也可以通过矩条件设计公式：

$$\sum_{i=1}^m A_i x_i^k = \int_a^b w(x)x^k dx, \quad k = 0, 1, \dots, d.$$

这是把“对所有低次多项式精确”转成有限方程组的标准方法。

例 5.1 (对称二点公式) 在 $[-1, 1]$ 上构造 $Q(f) = A[f(-c) + f(c)]$, 使代数精度尽可能高, 并说明其精度恰为多少。

解 由常数精确得 $2A = 2$, 故 $A = 1$; 奇次矩因对称性自动为零; 二次矩要求 $2c^2 = 2/3$, 故 $c = 1/\sqrt{3}$ 。对 x^4 , 公式给 $2/9$, 而积分为 $2/5$, 所以代数精度恰为 3。

收敛性与稳定性

定义 5.2 (求积公式的收敛性与稳定性) 对一系列求积公式 Q_m , 若节点逐渐加密或阶数增加时 $Q_m(f) \rightarrow I(f)$, 称其对 f 收敛。若节点函数值的小扰动只造成一致受控的求积扰动, 则称该公式族对这类数据扰动稳定。

性质 5.3 (权重绝对值之和控制扰动) 若各节点数据误差不超过 ε , 则

$$|\Delta Q_m| \leq \varepsilon \sum_{i=1}^m |A_i|.$$

因此, $\sum_i |A_i|$ 随节点数一致有界, 是对最大范数数据误差稳定的直接保证。

证明. 由 $\Delta Q_m = \sum_i A_i \Delta f_i$, 使用三角不等式并代入 $|\Delta f_i| \leq \varepsilon$ 即得。若扰动符号恰与权重符号相同, 这一上界还可以达到。□

具有高代数精度只说明公式能消去低次多项式误差, 不限制权重绝对值之和。因此, “次数更高”和“对数据更稳定”是两个需要分别检验的性质。

Newton-Cotes 公式与误差

等距节点上的插值求积称为 Newton-Cotes 公式。最常用的三个低阶公式是中点、梯形与 Simpson:

$$\begin{aligned} M(f) &= (b-a)f\left(\frac{a+b}{2}\right), \\ T(f) &= \frac{b-a}{2}[f(a) + f(b)], \\ S(f) &= \frac{b-a}{6}\left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right]. \end{aligned}$$

中点公式使用一个内部节点。梯形公式来自线性插值的积分。Simpson 公式来自三个节点的二次插值, 但因对称性使三次项误差也消失, 代数精度达到 3。

梯形余项可从线性插值误差得到。因 $(x-a)(x-b) \leq 0$, 若 f'' 连续, 利用加权积分中值思想可得

$$I(f) - T(f) = -\frac{(b-a)^3}{12} f''(\xi).$$

严格地说, 不需要先假设插值余项中 $\xi(x)$ 连续: 用 f'' 的最小、最大值把积分误差夹住, 再用 f'' 的介值性即可。类似地, 中点误差为

$$I(f) - M(f) = \frac{(b-a)^3}{24} f''(\eta).$$




图 5.1 同一区间上的中点、梯形与 Simpson 近似。它们分别用常数、直线和二次曲线替代被积函数；图形解释构造，误差阶仍需由余项证明。

对凸函数，梯形高估面积，中点低估面积，符号与几何直觉一致。

Simpson 的四阶导数余项值得单独说明，避免把三次插值余项中的未知点直接移出积分。先在 $[-1, 1]$ 上定义误差泛函

$$E(f) = \int_{-1}^1 f(x) dx - \frac{f(-1) + 4f(0) + f(1)}{3}.$$

由于 E 消去 $\mathcal{P}_3$ ，将带积分余项的 Taylor 公式代入并交换积分，得到

$$E(f) = \int_{-1}^1 K(t) f^{(4)}(t) dt,$$

其中

$$K(t) = E_x \left(\frac{(x-t)_+^3}{6} \right) = -\frac{(1-|t|)^3(1+3|t|)}{72} \leq 0.$$

这里 $(z)_+ = \max(z, 0)$ 。直接积分有 $\int_{-1}^1 K = -1/90$ ，故

$$E(f) = -\frac{1}{90} f^{(4)}(\xi).$$

把区间仿射映射回 $[a, b]$ ，得到

$$I(f) - S(f) = -\frac{(b-a)^5}{2880} f^{(4)}(\xi). \quad (5.1)$$

负号可用 $f(x) = x^4$ 核对：Simpson 对它高估。

高次等距 Newton-Cotes 并不总是更好。部分权重变成负数后，数据误差的放大会变大；高次插值也可能振荡。通常更可靠的路线是在很多小区间重复使用低阶公式。

5.3 复化求积公式

单面板公式只用少量节点，在很长的区间上可能无法反映函数变化。提高单个插值多项式的次数是一种办法，但也会引入高次振荡。复化法保留低阶公式，只缩短每次近似负责的区间。

定义 5.4 (复化求积) 把积分区间划分成多个小区间，在每个小区间使用同一种低阶求积规则，再将所有近似相加，称为复化求积。全局误差是各个面板误差之和。

估计时要同时计算两件事：一个面板的误差随 h 怎样变化，以及面板数量随 h 怎样变化。固定区间长度下，面板数约为 $1/h$ ；所以局部 $O(h^{p+1})$ 的误差通常累积成全局 $O(h^p)$ ，这一规律还会在时间积分中再次出现。

把 $[a, b]$ 分成 N 个等长子区间， $h = (b - a)/N$ ， $x_i = a + ih$ 。复化梯形为

$$T_h = h \left[\frac{f(x_0) + f(x_N)}{2} + \sum_{i=1}^{N-1} f(x_i) \right].$$

每段局部误差为 $O(h^3)$ ，一共约 $1/h$ 段，因此总误差为 $O(h^2)$ 。更严格地，在 $f \in C^2$ 下，

$$I - T_h = -\frac{b-a}{12} h^2 f''(\xi), \quad |I - T_h| \leq \frac{b-a}{12} h^2 \|f''\|_{\infty}.$$

这里又使用了各段导数值加权平均后的介值性。

若 N 为偶数，复化 Simpson 每两个小区间组成一个面板：

$$S_h = \frac{h}{3} \left[f(x_0) + f(x_N) + 4 \sum_{\substack{1 \leq i \leq N-1 \\ i \text{ 奇}}} f(x_i) + 2 \sum_{\substack{2 \leq i \leq N-2 \\ i \text{ 偶}}} f(x_i) \right].$$

由 (5.1)，面板宽为 $2h$ ，总误差为

$$I - S_h = -\frac{b-a}{180} h^4 f^{(4)}(\xi). \quad (5.2)$$

h 指小区间宽度，而不是面板宽度。混淆这两个长度会带来 2^4 倍的常数错误。

例 5.2 (从容许误差选取子区间数) 用复化梯形和复化 Simpson 计算 $\int_0^1 e^x dx$ 。若要求误差不超过 10^{-6} ，分别给出满足余项界的子区间数。

解 被积函数的各阶导数均为 e^x ，在区间上的上界为 e 。梯形界要求 $e/(12N^2) \leq 10^{-6}$ ，取 $N \geq 476$ 即可。Simpson 界要求 $e/(180N^4) \leq 10^{-6}$ ，取正偶数 $N = 12$ 即可。这比较的是导数界给出的充分保证，不表示每个实际函数都需要这么多节点。




图 5.2 计算 $\int_0^1 e^x dx$ 的实际误差。双对数图中，复化梯形与 Simpson 的渐近斜率分别对应二阶与四阶；误差接近浮点精度后不再遵循无限精度模型。

自适应划分

当曲率集中在少数位置时, 统一细网格会浪费计算。自适应 Simpson 在一个面板上计算粗值 S 和分成两半后的 S_2 。在四阶主误差模型成立时, 精细值的误差近似为

$$I - S_2 \approx \frac{S_2 - S}{15}, \quad I \approx S_2 + \frac{S_2 - S}{15}.$$

若估计不满足该区间的误差预算, 就继续二分, 并给子区间分配预算。实际程序还应设置深度与求值次数上限, 避免在不光滑点附近无限递归。少量采样也可能完全错过狭窄尖峰; 相邻公式一致只是基于当前采样信息的判断。

5.4 外推原理与 Romberg 求积法

假设粗网格与细网格结果都已经进入同一种误差展开范围。它们的差主要来自那个尚未消失的低阶项, 因此可以用这个差估计主误差, 再把它扣掉。这是外推能提高阶数的原因。

定义 5.5 (Richardson 外推) 若近似 $Q(h)$ 具有已知主阶 p 的误差展开, 通过不同步长的线性组合消去 h^p 项, 称为 Richardson 外推。系数的选择依赖误差阶, 而不是任意取平均。

例如, 若两次结果只差 10^{-5} , 仅凭这个差无法知道误差本身是 10^{-5} 、 10^{-3} , 还是两者恰好发生了抵消。只有先建立 $Q(h) = I + ch^p + \dots$ 的关系, 才能把结果差转成误差估计。

假设已有近似 $Q(h) = I + ch^p + O(h^{p+q})$, 其中 $p, q > 0$ 。步长减半后

$$Q(h/2) = I + \frac{c}{2^p} h^p + O(h^{p+q}).$$

两式消去未知 c :

$$\hat{Q} = \frac{2^p Q(h/2) - Q(h)}{2^p - 1} = I + O(h^{p+q}). \quad (5.3)$$

外推并没有新测量误差, 而是在已知主误差模型下, 用两次近似估计并消除主项。

对足够光滑的函数, 复化梯形具有偶次幂展开

$$T_h = I + c_2 h^2 + c_4 h^4 + c_6 h^6 + \dots$$

例如 $c_2 = [f'(b) - f'(a)]/12$ 。若函数端点不光滑, 或存在奇异性, 就不能直接假定这个展开成立。

令 $R_{k,0} = T_{(b-a)/2^k}$, 逐列外推:

$$R_{k,j} = R_{k,j-1} + \frac{R_{k,j-1} - R_{k-1,j-1}}{4^j - 1}, \quad 1 \leq j \leq k. \quad (5.4)$$

第一列消去 h^2 项, 第二列消去 h^4 项, 依次进行, 这就是 Romberg 积分。对固定列 j , 在相应光滑性和渐近展开成立时, 其误差为 $O(h^{2j+2})$ 。

梯形加密时已有节点可以复用:

$$T_{h/2} = \frac{1}{2} T_h + \frac{h}{2} \sum_{i=0}^{N-1} f(x_i + h/2).$$

只计算新插入的中点即可。外推表中系数很小的差值还可能受到舍入或噪声影响, 不能无限加列。

外推与“多算一次”的区别。如果不知道误差随 h 怎样变化, 两次近似接近并不能自动给出可靠误差。外推的力量来自误差展开, 而不只是数字相近。误差估计通常要先确认已进入渐近区间。

5.5 Gauss 求积公式

固定 m 个节点时, 只有 m 个权重可调, 通常只能保证到 $m-1$ 次。若连节点也一起设计, 就多出 m 个自由参数。我们希望把这些自由度用在消去更高次误差上, 而不是仅把已有节点移动得更均匀。

定义 5.6 (Gauss 型求积公式) 对给定区间与正权函数, 使用 m 个互异节点, 并达到最大可能代数精度 $2m-1$ 的求积公式, 称为 m 点 Gauss 型求积公式。

正交多项式在这里重新出现, 是因为求积误差需要同时消去一整族乘积 $q(x)\pi_m(x)$ 。它不是凭经验挑选出的一组“好看节点”, 而是由精确性条件必然导出的节点结构。

用 m 个节点时, 节点与权重共提供 $2m$ 个参数。能否让公式对 $2m$ 个单项式精确, 即达到 $2m-1$ 次代数精度? 正交多项式给出一个完整答案。

定理 5.7 (Gauss 节点的刻画) 设 $w > 0$ 几乎处处, π_m 是对应权下的首一 m 次正交多项式。以它的 m 个零点为节点, 采用插值型权重, 求积公式恰有 $2m-1$ 次代数精度。反之, 具有此精度的 m 点公式, 其节点多项式必与 P_{m-1} 正交。

证明. 对任意 $p \in \mathcal{P}_{2m-1}$, 作多项式除法

$$p = q\pi_m + r, \quad q, r \in \mathcal{P}_{m-1}.$$

由正交性, $\int wq\pi_m = 0$ 。在所有节点上 $\pi_m = 0$, 故求积值也只保留 r 。而插值型公式对 r 精确, 因此对 p 精确。

反过来, 设节点多项式为 ω_m , 对任意 $q \in \mathcal{P}_{m-1}$, $q\omega_m$ 的次数至多 $2m-1$ 。其求积值为零, 所以精确性要求 $\int wq\omega_m = 0$, 即所需正交性。

最后, 任何 m 点公式都不可能对 ω_m^2 精确: 求积值为零, 但 $\int w\omega_m^2 > 0$ 。该多项式次数为 $2m$, 所以 $2m-1$ 已是上限。□

定理 5.8 (Gauss 权重为正及余项) Gauss 求积的每个权重 $A_i > 0$, 且若 $f \in C^{2m}[a, b]$, 则

$$I(f) - Q_m(f) = \frac{f^{(2m)}(\xi)}{(2m)!} \int_a^b w(x)\pi_m(x)^2 dx. \quad (5.5)$$

证明. 对节点 i 的 Lagrange 基 ℓ_i , ℓ_i^2 的次数为 $2m-2$, 公式精确。因此

$$A_i = \sum_j A_j \ell_i(x_j)^2 = \int_a^b w(x)\ell_i(x)^2 dx > 0.$$

余项用 m 个节点上的 Hermite 插值 $H \in \mathcal{P}_{2m-1}$ 。它与 f 在节点上函数值、导数值都一致, 所以 $Q(f) = Q(H) = I(H)$ 。Hermite 余项含有 π_m^2 , 始终非负; 用 $f^{(2m)}$ 的上下界夹逼积分并应用介值性, 即得结论。□

Gauss-Legendre 使用 $[-1, 1]$ 、权 1。二点规则已在前面得到; 三点规则为

$$\int_{-1}^1 f(x) dx \approx \frac{5}{9}f\left(-\sqrt{\frac{3}{5}}\right) + \frac{8}{9}f(0) + \frac{5}{9}f\left(\sqrt{\frac{3}{5}}\right).$$

映射到一般区间时, 令 $x = (a+b)/2 + (b-a)t/2$, 每个权重还要乘 $(b-a)/2$ 。

Gauss-Chebyshev 对应的是带权积分

$$\int_{-1}^1 \frac{f(x)}{\sqrt{1-x^2}} dx \approx \frac{\pi}{m} \sum_{i=1}^m f\left(\cos \frac{(2i-1)\pi}{2m}\right).$$

它不是普通无权积分的现成替代式。若把权混入 f , 必须检查变换后的函数光滑性。

正权公式的收敛性

若节点数据各有不超过 ε 的绝对误差, 则求积误差的扰动满足

$$|\Delta Q| \leq \varepsilon \sum_i |A_i|.$$

正权公式对常数精确时, $\sum_i |A_i| = \sum_i A_i = \int w$, 因此数据噪声不会因权重正负抵消而额外放大。

正权与不断提高的多项式精度还给出收敛性。对连续 f 和任意 $\epsilon > 0$, 由多项式一致逼近定理选 p 使 $\|f-p\|_\infty < \epsilon$ 。当公式精度足够高时 $Q(p) = I(p)$, 所以

$$|I(f) - Q(f)| \leq |I(f-p)| + |Q(f-p)| \leq 2\epsilon \int_a^b w(x) dx.$$

这说明 Gauss 公式随节点数增加对连续函数收敛。这里使用的是有限总权重与正性, 不要求 f 有任意高阶导数。

5.6 数值微分

积分把很多函数值平均起来, 微分却试图从很小的函数差中恢复局部变化率。这使微分更容易放大数据噪声。同样的插值思想可以构造两类公式, 但它们面对误差时的行为很不相同。

定义 5.9 (差分近似与截断误差) 用有限个函数值的线性组合近似某点的导数, 称为差分近似。把精确函数值代入差分公式后, 与精确导数之间的差称为该公式的截断误差; 输入函数值本身的误差应另外计入。

讨论求导公式时, 需要明确三个对象: 求导位置、可用节点以及目标导数的阶数。例如, 中心差分在 x 两侧取值, 而边界点可能只有单侧数据; 同样的节点组合, 也可能分别用于一阶或二阶导数。不能仅根据“用了三个点”判断公式精度。

中点方法与误差分析

在点 x 展开 $f(x \pm h)$:

$$f(x \pm h) = f(x) \pm hf'(x) + \frac{h^2}{2}f''(x) \pm \frac{h^3}{6}f'''(x) + \cdots.$$

作差可消去偶次项, 因此

$$\frac{f(x+h) - f(x-h)}{2h} = f'(x) + \frac{h^2}{6}f'''(x) + O(h^4). \quad (5.6)$$

这里完整到 $O(h^4)$ 的展开可在足够高阶连续导数条件下成立; 若仅有 $f \in C^3$, 仍有二阶误差界。

同理，作和并减去 $2f(x)$ 得

$$\frac{f(x+h) - 2f(x) + f(x-h)}{h^2} = f''(x) + \frac{h^2}{12}f^{(4)}(x) + O(h^4).$$

中心公式的高阶精度来自对称性。区间端点无法取到两侧值时，可以用单侧三点公式

$$f'(x) \approx \frac{-3f(x) + 4f(x+h) - f(x+2h)}{2h},$$

其主误差为 $-h^2 f'''(x)/3$ ，仍为二阶，但误差常数与噪声放大都不同。

插值型求导公式

设要设计

$$D_h f(x) = \frac{1}{h} \sum_{j=1}^m c_j f(x + \alpha_j h).$$

代入 Taylor 展开后，为使它近似一阶导数且误差为 $O(h^p)$ ，要求

$$\sum_j c_j = 0, \quad \sum_j c_j \alpha_j = 1, \quad \sum_j c_j \alpha_j^k = 0 \quad (2 \leq k \leq p).$$

常数项消失，一阶项保留，更高低阶项消失。把同一条件解释成“该公式对低次多项式求导精确”，便与插值多项式求导完全一致。

例 5.3 (四点中心公式) 使用 $x-2h, x-h, x+h, x+2h$ 四个节点构造 $f'(x)$ 的四阶差分，并给出主截断误差。

解 要求对 $\mathcal{P}_4$ 求导精确，得到

$$D_h^{(4)} f(x) = \frac{f(x-2h) - 8f(x-h) + 8f(x+h) - f(x+2h)}{12h}.$$

Taylor 展开给出

$$D_h^{(4)} f(x) = f'(x) - \frac{h^4}{30} f^{(5)}(x) + O(h^6).$$

它的截断误差优于二点中心公式，但使用更多采样，且噪声放大系数也有所增加。

对非等距节点，直接对 Lagrange 基求导，得到 $p'_n(x) = \sum_i y_i \ell'_i(x)$ 。这样可统一构造边界与不规则网格公式，但大规模高阶权重计算需要注意条件数。

舍入误差与步长

若各函数值有独立但只知道绝对界的误差 $|\delta f_i| \leq \varepsilon$ ，则

$$|\delta D_h| \leq \frac{\varepsilon}{h} \sum_j |c_j|.$$

对于二点中心差分，系数绝对值之和为 1，噪声误差界为 ε/h 。若 $|f'''| \leq M_3$ ，总误差可界为

$$|D_h f - f'| \leq \frac{M_3 h^2}{6} + \frac{\varepsilon}{h}.$$

最小化右端，得到

$$h_{\text{opt}} = \left(\frac{3\varepsilon}{M_3} \right)^{1/3}.$$




图 5.3 对 e^x 在 $x = 1$ 处求导。步长较大时截断误差占主导，步长很小时消去与舍入影响占主导；实际曲线在理论包络附近波动。

一般 p 阶一阶差分有误差模型 $C_T h^p + C_R \varepsilon/h$ ，最优步长尺度为 $\varepsilon^{1/(p+1)}$ 。二阶导数还要除以 h^2 ，因此对噪声更敏感。

为什么“采样更密”仍可能求不好导数。噪声大小如果没有同步减小，相邻采样值越来越接近，真实差值会缩小，噪声差却未必缩小。除以更小的步长后，导数估计反而更抖。此时需要利用平滑性或统计假设，而不是盲目缩短间隔。

局部低次多项式拟合后再求导，可以利用多点平均缓解噪声。它改变了问题：我们先选一个局部函数模型，再估计模型导数。窗口过大造成平滑偏差，窗口过小又无法抑制噪声，仍然存在偏差与噪声之间的权衡。

求积与求导公式的比较

公式	典型误差阶	信息要求	主要限制
复化梯形	全局 $O(h^2)$	函数值，二阶光滑	局部误差累加
复化 Simpson	全局 $O(h^4)$	偶数网格，四阶光滑	节点与面板宽度须区分
m 点 Gauss	代数精度 $2m - 1$	可自由选择节点	区间与权必须匹配
中心一阶差分	截断 $O(h^2)$	两侧函数值	数据误差按 $1/h$ 放大
中心二阶差分	截断 $O(h^2)$	三个函数值	数据误差按 $1/h^2$ 放大

表 5.1 求积的全局阶、求导的截断阶和代数精度是不同概念，应按各自定义比较。

外推与三次样条求导

中心差分具有偶次幂误差，记 $D(h) = f'(x) + c_2h^2 + c_4h^4 + \dots$ 。使用 Richardson 外推，

$$D_{\text{ext}} = \frac{4D(h/2) - D(h)}{3} = f'(x) + O(h^4).$$

把它展开，会得到使用偏移 $\pm h/2, \pm h$ 的四点公式。它与前面四点中心公式仅相差步长记法。这说明“提高精度”的代数操作可以有两种解释：消去 Taylor 误差项，或把不同网格的近似组合起来。

但外推也线性组合了噪声。若输入函数值本身不精确，高阶外推列可能越来越不稳定。判断停止时，应同时观察步长变化、误差估计趋势以及数据精度。

样条求导则先构造光滑曲线 S ，然后解析计算 S' 或 S'' 。这样不同位置的导数由同一条曲线给出，连接关系更一致。但普通插值样条仍会穿过全部噪声点；只有明确加入平滑机制时，才真正进行噪声抑制。

第 6 章 线性方程组直接解法

6.1 引言

插值系数、样条弯矩、最小二乘和微分方程离散，最终常常要求解 $Ax = b$ 。在精确算术中，非奇异矩阵保证唯一解；在数值计算中，还要考虑怎样组织消元、何时交换行，以及残差多小才有意义。

直接法在有限次算术操作后给出结果。这个“有限次”是数学算法意义上的描述，并不表示结果没有舍入误差。

先把问题的代数前提说清楚。这里主要考虑 n 个未知量、 n 个方程组成的方阵系统。矩阵非奇异时，任意右端都有唯一解；矩阵奇异时，可能无解，也可能有无穷多解，需要另外讨论相容性。

定义 6.1 (非奇异矩阵与直接法) 方阵 A 若存在逆矩阵，称为非奇异矩阵；等价地，齐次系统 $Ax = 0$ 只有零解。直接法通过有限次消元或分解，把原系统化成为可直接前代、回代的形式。

理论上可以写 $x = A^{-1}b$ ，但这个表达只说明解如何由数据决定，并不规定最好怎样计算。数值算法通常先分解矩阵，再求解三角系统。这样既减少无用运算，也便于处理多个不同右端。

6.2 Gauss 消去法

消元的目标是把一个变量从其余方程中逐个消去，同时不改变解集。若两个方程都含 x_1 ，可以用第一个方程的合适倍数减去第二个方程，使第二式的 x_1 系数成为零。对剩余变量重复这一过程，就得到按顺序可解的上三角系统。

定义 6.2 (主元、消元乘子与三角系统) 一次消元中用来消去同列其他元素的基准元素称为主元；相应行倍数称为消元乘子。上三角系统满足 $u_{ij} = 0$ ($i > j$)，可由最后一个方程向前回代；下三角系统则由第一个方程向后前代。

引理 6.3 (初等行变换保持解集) 交换两个方程、将一个方程乘非零常数、把一个方程的倍数加到另一个方程，都不改变线性系统的解集。

证明. 每种变换都可逆：交换可以再次交换，非零缩放可以除回原数，加上某行的倍数可以减去同样的倍数。因此原系统与变换后系统能够相互推出，解集相同。□

这一结论解释消元在精确算术中的正确性。舍入误差不会出现在这个代数证明中，必须等到讨论主元大小和中间量增长时再单独分析。

在第 k 步, 若主元 $a_{kk}^{(k)} \neq 0$, 对 $i > k$ 定义乘子

$$l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}},$$

把第 i 行减去第 k 行的 l_{ik} 倍, 使第 k 列主元下方归零。最终得到上三角系统 $Ux = c$, 通过回代求解

$$x_i = \frac{c_i - \sum_{j=i+1}^n u_{ij}x_j}{u_{ii}}, \quad i = n, n-1, \dots, 1.$$

每次行变换都是左乘一个可逆消元矩阵。把它们移到另一侧, 就得到 $A = LU$, 其中 L 是单位下三角阵, 保存消元乘子, U 是最终的上三角阵。对多个不同右端, 只需一次分解, 之后分别作 $Ly = b$ 的前代与 $Ux = y$ 的回代。

定理 6.4 (不选主元的 LU 分解) 对非奇异矩阵 A , 存在 L 单位下三角、 U 非奇异上三角的分解, 当且仅当所有前 $n-1$ 个顺序主子式非零; 此时分解唯一。

证明. 若 $A = LU$, 其前 k 阶顺序主子式等于 $u_{11} \cdots u_{kk}$, 均非零。反过来, 消元到第 k 步时, 前 k 阶主子式等于此前主元之积再乘当前主元; 非零条件保证每一步可进行。

若 $L_1 U_1 = L_2 U_2$, 则 $L_2^{-1} L_1 = U_2 U_1^{-1}$ 同时为单位下三角和上三角, 只能是单位阵, 故两分解相同。□

列主元消去法

非零主元仍可能太小。例如

$$\begin{pmatrix} 10^{-20} & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

若第一步不交换行, 乘子为 10^{20} , 更新中会出现很大的中间量, 并把有效信息丢在相减中。交换两行后, 乘子变为 10^{-20} , 计算就合理得多。

列主元消元在当前第 k 列的剩余行中选绝对值最大者, 交换到主元位置。这里“列主元”表示在列中搜索, 实际交换的是行。最终有 $PA = LU$, 其中 P 是累计行置换。求解时必须对右端作同样置换: 先解 $Ly = Pb$, 再解 $Ux = y$ 。若已经存储了 L 的旧列, 后续换行也必须同步交换相应历史乘子。

列主元使消元乘子满足 $|l_{ik}| \leq 1$, 有助于控制误差, 但并不保证所有中间元素都不增长。舍入误差分析还依赖消元过程的增长因子。极端矩阵上增长可能很大, 因此不能把“选了列主元”当作无条件前向高精度保证。实践中它通常是可靠的通用选择, 仍应结合残差与条件估计检验结果。

例 6.1 (带行交换的两步计算) 用列主元消去法求解 $\begin{pmatrix} 0 & 2 \\ 1 & 3 \end{pmatrix} x = (4, 7)^T$, 说明首元素为零时应怎样处理。

解 首元素为零, 但矩阵可逆。交换两行后, 上三角系统为 $x_1 + 3x_2 = 7$ 、 $2x_2 = 4$, 所以 $x_2 = 2$, $x_1 = 1$ 。不能把“当前消元主元为零”直接判断为原矩阵奇异。

6.3 直接三角分解法

一般矩阵的直接三角分解

通过直接比较 $A = LU$ 的元素，可以按行计算 Doolittle 分解：

$$u_{kj} = a_{kj} - \sum_{s < k} l_{ks} u_{sj} \quad (j \geq k),$$

$$l_{ik} = \frac{a_{ik} - \sum_{s < k} l_{is} u_{sk}}{u_{kk}} \quad (i > k).$$

这与消元保存乘子的算法是同一件事，只是表达方式不同。若改令 U 的对角元为 1，则得到另一种归一化的三角分解。

稠密消元的主计算量约为 $2n^3/3$ 次浮点加乘，前代与回代各为 $O(n^2)$ 。计算 A^{-1} 再乘 b 通常增加工作量与误差途径，没有必要。Gauss-Jordan 消元进一步把主元上方也消为零，可用于小规模手算、求逆或理解行变换，但不是一般求解器的首选组织方式。

分解与求解是两个不同阶段。 $A = LU$ 的系数只由 A 决定，不随右端 b 改变；每次新的右端只需完成 $Ly = b$ 与 $Ux = y$ 。因此，当同一矩阵对应很多载荷、时间步或观测向量时，复用分解能节省大量工作。

定义 6.5 (对称正定矩阵) 实矩阵 A 若满足 $A^T = A$ ，且对任意非零实向量 z 都有 $z^T A z > 0$ ，称为对称正定矩阵。 $z^T A z$ 是对应的二次型；正定性表示它在任何非零方向都严格为正。

对称性允许只存储一半矩阵，正定性进一步保证 Cholesky 分解中的平方根参数为正。这两个条件提供了通用消元所没有的结构信息，因此值得在求解前检查，而不必所有矩阵都使用同一套算法。

三对角方程组与平方根法

三对角系统写为

$$a_i x_{i-1} + b_i x_i + c_i x_{i+1} = d_i.$$

边界处不存在的项省略。消去左下对角元时，不会产生更远的非零项，因而只需保存三条对角线。令

$$\tilde{b}_1 = b_1, \quad \tilde{d}_1 = d_1,$$

$$m_i = \frac{a_i}{\tilde{b}_{i-1}}, \quad \tilde{b}_i = b_i - m_i c_{i-1}, \quad \tilde{d}_i = d_i - m_i \tilde{d}_{i-1}.$$

回代为 $x_n = \tilde{d}_n / \tilde{b}_n$, $x_i = (\tilde{d}_i - c_i x_{i+1}) / \tilde{b}_i$ 。这就是追赶法，时间和存储均为 $O(n)$ 。

一般三对角矩阵仍可能出现零或危险的小主元。严格对角占优、对称正定等结构可提供保证；不能只因矩阵有三条对角线就省去所有适用性判断。

对实对称正定矩阵，可使用 Cholesky 分解

$$A = LL^T, \quad l_{ii} > 0.$$

系数由

$$l_{kk} = \sqrt{a_{kk} - \sum_{j < k} l_{kj}^2}, \quad l_{ik} = \frac{a_{ik} - \sum_{j < k} l_{ij} l_{kj}}{l_{kk}}$$

计算。它利用对称性将计算与存储大致减半。

定理 6.6 (Cholesky 分解的存在唯一性) 每个实对称正定矩阵都有唯一的正对角 Cholesky 分解。

证明. 分块写成

$$A = \begin{pmatrix} a & r^T \\ r & B \end{pmatrix}, \quad a > 0.$$

首列应取 $\sqrt{a}$ 和 $r/\sqrt{a}$, 剩余矩阵为 Schur 补 $S = B - rr^T/a$ 。对非零 z , 取 $v = (-r^T z/a, z)^T$, 有 $z^T S z = v^T A v > 0$, 所以 S 仍正定。递归即可完成分解。每步的正平方根与后续元素都被唯一确定, 故分解唯一。□

LDL^T 形式把平方根放入对角矩阵 D , 也是平方根法的一种常见组织方式。对正定矩阵, D 对角元为正; 对一般对称不定矩阵, 通常需要更谨慎的对称主元策略与可能的 2×2 块。

6.4 向量和矩阵的范数

单个数的误差可以用绝对值衡量, 但线性方程组的误差是一个向量。某些分量可能大、某些分量可能小, 需要一个一致的规则把整个向量的大小变成一个非负数。范数就是满足基本代数要求的这种大小度量。

定义 6.7 (向量范数) 实或复向量空间上的函数 $\|x\|$ 若满足正定性、齐次性与三角不等式, 即

$$\begin{aligned} \|x\| &\geq 0, \quad \|x\| = 0 \iff x = 0, \quad \|\alpha x\| = |\alpha| \|x\|, \\ \|x + y\| &\leq \|x\| + \|y\|, \end{aligned}$$

则称为向量范数。

三角不等式保证把不同来源的误差相加时, 可以用各自误差界的和来控制总误差。不同范数强调不同方面: 无穷范数观察最大分量, 1-范数累加全部分量, 2-范数与欧氏几何和正交变换相容。

常用向量范数为

$$\|x\|_1 = \sum_i |x_i|, \quad \|x\|_2 = \sqrt{\sum_i |x_i|^2}, \quad \|x\|_\infty = \max_i |x_i|.$$

诱导矩阵范数定义为

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

由定义立即有 $\|Ax\| \leq \|A\| \|x\|$ 和 $\|AB\| \leq \|A\| \|B\|$ 。对三种常见范数,

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \quad \|A\|_\infty = \max_i \sum_j |a_{ij}|, \quad \|A\|_2 = \sqrt{\lambda_{\max}(A^* A)}.$$

注意 2-范数一般不是 $\rho(A)$; 只有实对称、Hermitian 或更一般的正规矩阵等特殊情况下, 两者才相等。Frobenius 范数 $\|A\|_F = (\sum_{ij} |a_{ij}|^2)^{1/2}$ 也很有用, 但它不是向量 2-范数的诱导范数。

性质 6.8 (诱导范数的基本不等式) 对同一向量范数诱导的矩阵范数, 有

$$\|Ax\| \leq \|A\| \|x\|, \quad \|AB\| \leq \|A\| \|B\|, \quad \|I\| = 1.$$

证明. 第一式来自上确界的定义. 将第一式连续用于 ABx , 得 $\|ABx\| \leq \|A\| \|B\| \|x\|$, 再对非零 x 取比值上确界, 便得第二式. $Ix = x$ 直接给出第三式. $\square$

对无穷范数, $|(Ax)_i| \leq \sum_j |a_{ij}| \|x\|_\infty$, 所以最大行绝对值和是一个上界. 取达到最大行和的那一行, 并使 x_j 的符号或相位与该行系数配合, 就能达到这个界. 这说明矩阵无穷范数的行和公式不仅是估计, 而且是精确表达.

引理 6.9 (Neumann 级数) 若某个诱导范数下 $\|E\| < 1$, 则 $I - E$ 可逆, 且

$$(I - E)^{-1} = \sum_{k=0}^{\infty} E^k, \quad \|(I - E)^{-1}\| \leq \frac{1}{1 - \|E\|}.$$

证明. 由次乘性, 级数在范数意义下被几何级数控制, 因而收敛. 有限和满足 $(I - E) \sum_{k=0}^m E^k = I - E^{m+1}$, 令 $m \rightarrow \infty$ 即得逆矩阵关系; 对级数取范数得到上界. $\square$

这个引理说明, 离单位阵足够小的扰动不会立即造成奇异. 后面的矩阵扰动界中出现 $1 - \|A^{-1}\Delta A\|$ 一类分母, 正是同一个几何级数机制.

6.5 方程组的性态与误差分析

计算完成后, 即使残差很小, 还需要知道这个残差对应多大的解误差. 这取决于 A 是否把某些方向压得很小: 如果大误差恰好落在这样的方向上, 乘以 A 后就可能几乎看不见.

定义 6.10 (矩阵条件数) 对非奇异矩阵和指定的诱导范数, 定义

$$\kappa(A) = \|A\| \|A^{-1}\|.$$

它衡量线性方程组解对相对数据扰动的最坏放大程度. $\kappa(A) \geq 1$; 条件数很大时, 方程组在相应意义下病态.

性质 6.11 (2-范数条件数与奇异值) 若 A 非奇异, 最大、最小奇异值分别为 $\sigma_{\max}, \sigma_{\min}$, 则 $\kappa_2(A) = \sigma_{\max}/\sigma_{\min}$. 对实对称正定矩阵, 该比值等于最大特征值与最小特征值之比.

奇异值描述矩阵在不同单位方向上的伸缩尺度. 比值很大时, 矩阵同时保留很大的尺度和很小的尺度; 输入扰动经过逆变换后, 沿小尺度方向容易被大幅放大.

对非奇异 A , 定义 $\kappa(A) = \|A\| \|A^{-1}\| \geq 1$. 若只有右端有扰动,

$$A(x + \Delta x) = b + \Delta b \implies \Delta x = A^{-1}\Delta b.$$

又由 $\|b\| \leq \|A\| \|x\|$, 得到

$$\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\Delta b\|}{\|b\|}. \quad (6.1)$$

这里假设 $b \neq 0$ ；这是最坏情况界，不是说每个扰动方向都会达到如此大的放大。

若 A 与 b 同时扰动，记

$$\epsilon_A = \frac{\|\Delta A\|}{\|A\|}, \quad \epsilon_b = \frac{\|\Delta b\|}{\|b\|}.$$

由 $(A + \Delta A)(x + \Delta x) = b + \Delta b$ 得

$$\Delta x = A^{-1}(\Delta b - \Delta A x - \Delta A \Delta x).$$

取范数并移项，在 $\kappa(A)\epsilon_A < 1$ 时得到

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A)\epsilon_A}(\epsilon_A + \epsilon_b). \quad (6.2)$$

分母条件保证扰动足够小，使问题没有靠近奇异边界。这一步不能省略。

例 6.2 (几乎平行的两个方程) 设 $A = \begin{pmatrix} 1 & 1 \\ 1 & 1 + \epsilon \end{pmatrix}$ 、 $b = (2, 2 + \epsilon)^T$ ， $\epsilon > 0$ 。若只把右端第二项增加 δ ，求解的变化。

解 原解为 $x = (1, 1)^T$ 。将右端第二项改为 $2 + \epsilon + \delta$ ，两方程相减得 $\epsilon x_2 = \epsilon + \delta$ ，所以

$$x_2 = 1 + \frac{\delta}{\epsilon}, \quad x_1 = 1 - \frac{\delta}{\epsilon}.$$

当 ϵ 很小时，微小右端扰动也会使交点移动很远。这是问题本身的敏感性，不是消元方法制造的。




图 6.1 两条几乎平行的直线定义一个病态线性方程组。右端的小变化使交点显著移动。图中为了可读性使用较温和的参数。

残差与误差估计

计算出 $\hat{x}$ 后，容易得到的是残差 $r = b - A\hat{x}$ 。由于

$$A(x - \hat{x}) = r,$$

有

$$\frac{\|x - \hat{x}\|}{\|x\|} \leq \kappa(A) \frac{\|r\|}{\|b\|}. \quad (6.3)$$

所以小相对残差在良态问题中很有意义，在病态问题中却未必代表小前向误差。

常用的尺度化后向误差指标为

$$\eta = \frac{\|b - A\hat{x}\|}{\|A\| \|\hat{x}\| + \|b\|}.$$

分母同时计入矩阵作用和右端尺度，避免对不同单位或整体缩放的问题采用同一个无量纲解释错误的阈值。

若有可复用的分解，可通过残差继续校正。先计算 $r_k = b - Ax_k$ ，再利用已有分解近似解 $Ad_k = r_k$ ，最后令 $x_{k+1} = x_k + d_k$ 。因为精确误差满足 $A(x_* - x_k) = r_k$ ，修正量 d_k 正是在估计尚未消除的解误差。

在精确算术中，这个修正一步就应到达真解；实际修正方程也有舍入误差，因此可能需要重复。残差最好用更高精度或更准确的累加方式计算，避免 b 与 Ax_k 接近时再次丢失信息。方法的效果仍依赖条件数与已有分解的质量。

第 7 章 线性方程组的迭代解法

7.1 引言

大规模稀疏矩阵的直接分解可能产生很多填充，消耗大量存储。迭代法每次只作便宜的更新，希望逐步逼近真解。它的核心问题不再是“有限次消元是否可行”，而是“误差经过一次更新后会怎样变化”。

直接法把工作集中在一次分解中，迭代法则把求解过程拆成很多轮简单更新。对于非零元素很少的稀疏矩阵，一次矩阵向量乘法可能很便宜，而直接分解会产生许多原来没有的非零元素。此时，迭代法在时间和存储上都有吸引力。

但它必须回答两个额外问题：初值是否会影响最终结果，迭代多少次才能达到精度。一个更新式能够执行，并不代表它收敛；一串数值看起来暂时变化很小，也不代表已经接近真解。

7.2 基本迭代方法

定义 7.1 (定常线性迭代) 形如 $x^{(k+1)} = Bx^{(k)} + c$ ，且矩阵 B 与向量 c 不随迭代次数改变的过程，称为定常线性迭代。 B 称为迭代矩阵。用于求解 $Ax = b$ 时，需要保证原方程的解同时是该更新的不动点。

构造迭代矩阵不能随意进行。矩阵分裂 $A = M - N$ 提供了一种系统办法：把容易求解的部分留在新时刻，把其余部分放到旧时刻。不同分裂决定了每一步的成本，也决定了误差的传播矩阵。

把 $A = M - N$ ，其中 M 易于求解，写成

$$x^{(k+1)} = M^{-1}Nx^{(k)} + M^{-1}b = Bx^{(k)} + c.$$

这只是公式写法，实际通常通过解 M 系统计算，而不显式求逆。精确解 x_* 也满足 $x_* = Bx_* + c$ ，故误差

$$e^{(k+1)} = Be^{(k)}, \quad e^{(k)} = B^k e^{(0)}.$$

迭代收敛完全由矩阵幂 B^k 的行为决定。

固定符号约定

$$A = D + L + U,$$

其中 D 为对角部分， L, U 为实际的严格下、上三角部分，不额外带负号。假设对角元都非零。

Jacobi 迭代为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right), \quad B_J = -D^{-1}(L + U).$$

所有新分量只使用旧值，可以并行计算。Gauss-Seidel 则立即使用已经更新的分量：

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right),$$

$$B_{GS} = -(D + L)^{-1}U.$$

后者相当于每次解一个下三角系统；变量的排列顺序会影响其迭代矩阵和速度。

例 7.1 (一个可以手算谱半径的系统) 对 $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$ 、 $b = (1, 2)^T$ ，写出 Jacobi 和 GS 迭代矩阵，并判断收敛性。

解 真解为 $(1/10, 3/5)^T$ 。迭代矩阵分别为

$$B_J = \begin{pmatrix} 0 & -1/4 \\ -2/3 & 0 \end{pmatrix}, \quad B_{GS} = \begin{pmatrix} 0 & -1/4 \\ 0 & 1/6 \end{pmatrix}.$$

因此 $\rho(B_J) = 1/\sqrt{6}$ ， $\rho(B_{GS}) = 1/6$ 。这个例子中 GS 渐近更快，但不能由一个例子推断所有矩阵都如此。

7.3 迭代法的收敛性

定义 7.2 (谱半径与迭代收敛) 矩阵 B 的谱半径定义为 $\rho(B) = \max_{\lambda \in \sigma(B)} |\lambda|$ ，其中 $\sigma(B)$ 为全部特征值。这里说迭代收敛，是指对任意初始向量，迭代都趋于同一个解，而不是仅对某个特殊初值成功。

误差满足 $e^{(k)} = B^k e^{(0)}$ ，因此考察收敛就是考察矩阵幂能否把所有方向都压向零。在某个特征方向上，误差每步乘以对应特征值；最大模特征值由此成为关键。但非对角化情形还含有 Jordan 块带来的多项式因子，所以完整证明需要同时处理它们。

定理 7.3 (定常迭代的收敛充要条件) 对任意初值， $x^{(k+1)} = Bx^{(k)} + c$ 都收敛到唯一不动点，当且仅当 $\rho(B) < 1$ 。

证明. 若对任意初始误差都有 $B^k e^{(0)} \rightarrow 0$ ，则对每个坐标基向量都成立，故 $B^k \rightarrow 0$ 。任一特征值 λ 和相应特征向量满足 $B^k v = \lambda^k v$ ，所以必须 $|\lambda| < 1$ 。

反之，考虑复 Jordan 分解。每个 Jordan 块的 k 次幂由有限个“关于 k 的多项式乘以 λ^{k-j} ”组成。若 $|\lambda| < 1$ ，指数衰减快于任何固定次多项式增长；零特征值的块则最终归零。因此 $B^k \rightarrow 0$ 。同时 1 不是特征值， $I - B$ 可逆，不动点唯一。□

若某个诱导范数满足 $\|B\| = q < 1$ ，则这是更容易验证的充分条件，并有

$$\|e^{(k)}\| \leq q^k \|e^{(0)}\|.$$

因为相邻增量也按 B 传播，可将未来增量相加，得到后验界

$$\|x_* - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\|. \quad (7.1)$$

只有在已知 $q < 1$ 且 q 不太接近 1 时，相邻两次接近才是有力的停止依据。

$\rho(B) < 1$ 并不要求某个预先指定的范数 $\|B\| < 1$ ，也不保证每一步误差都下降。非正规矩阵可能有明显的暂态增长，然后才进入渐近衰减。谱半径描述最终行为，范数界则能控制每一步。

定义 7.4 (对角占优与不可约性) 若每行均有 $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$, 称为严格对角占优; 若将 $>$ 换成 $\geq$, 称为弱对角占优。若不存在同时置换行列的方法把矩阵变成两个非空方块组成的上块三角形, 则称矩阵不可约。

对角占优是逐行可检查的代数条件, 谱半径则依赖整个矩阵。前者的价值在于: 不必先算出特征值, 就能获得后者所需的收敛保证。不可约性进一步保证不同分量之间的信息可以传递; 如果方程分成互不影响的子系统, 某一行的严格不等式未必能够控制另一个子系统。

对于正定矩阵, GS 的收敛还可以从能量下降理解。逐坐标求解相当于沿一个坐标方向精确最小化二次能量; 每轮更新消除一些误差能量, 最终只能停在唯一最小点。这条思路将在 SOR 的证明中给出更一般的表达。

定理 7.5 (严格对角占优) 若 $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$ 对所有行成立, 则 Jacobi 和 Gauss-Seidel 均收敛。

证明. Jacobi 满足

$$\|B_J\|_\infty = \max_i \frac{\sum_{j \neq i} |a_{ij}|}{|a_{ii}|} < 1.$$

对 GS, 设 $B_{GS}v = \lambda v$, 取 $|v_i| = \max_j |v_j| > 0$. 特征方程的第 i 行为

$$\lambda a_{ii} v_i = -\lambda \sum_{j < i} a_{ij} v_j - \sum_{j > i} a_{ij} v_j.$$

若 $|\lambda| \geq 1$, 取绝对值并除以 $|\lambda|$, 得到

$$|a_{ii}| |v_i| \leq \sum_{j \neq i} |a_{ij}| |v_i|,$$

与严格对角占优矛盾, 故所有 $|\lambda| < 1$. □

弱对角占优只要求 $|a_{ii}| \geq \sum_{j \neq i} |a_{ij}|$. 如果矩阵不可约, 且至少一行严格不等式成立, 则上述两方法也收敛。不可约的图像是: 把非零 a_{ij} 看成从 i 指向 j 的边, 整个有向图强连通。证明沿最大模特征向量分量传播等号条件; 若有模至少为 1 的特征值, 连通性会把等号传到严格占优行, 从而矛盾。“不可约”和“至少一行严格”都不能省略。

对实对称正定 A , Gauss-Seidel 一定收敛, 但 Jacobi 未必。因为

$$D^{1/2} B_J D^{-1/2} = I - D^{-1/2} A D^{-1/2},$$

右侧对称, 且 $D^{-1/2} A D^{-1/2}$ 正定。故 $\rho(B_J) < 1$ 当且仅当该正定矩阵的全部特征值小于 2, 等价于 $2D - A$ 正定。

例 7.2 (正定并不保证 Jacobi 收敛) 三阶矩阵 A 的对角元均为 1, 非对角元均为 $3/4$ 。证明 A 正定, 但 Jacobi 迭代不能对任意初值收敛。

解 其特征值为 $5/2, 1/4, 1/4$, 所以正定。Jacobi 迭代矩阵为 $I - A$, 特征值为 $-3/2, 3/4, 3/4$, 谱半径 $3/2 > 1$, 因而不能对任意初值收敛。GS 却由正定性保证收敛。

误差估计与停止条件

最直接的停止条件是尺度化残差

$$\eta_k = \frac{\|b - Ax^{(k)}\|}{\|A\| \|x^{(k)}\| + \|b\|} \leq \text{tol.}$$

若还有可靠条件估计, 就可以把它转换为前向误差判断。若用相邻两次的差停止, 应同时具备 (7.1) 那样的收敛率界; 否则很小的步长也可能只是迭代停滞。

实现应区分 GS 的新旧数组。Jacobi 必须整体使用旧向量; 如果原位更新, 就会无意间改变算法。GS 与 SOR 恰恰要按顺序利用新分量。对稀疏矩阵, 应尽量只访问非零元素, 单步成本才能与非零元个数相称。

从矩阵分裂看, 选取容易求解且接近 A 的 M , 是在重新组织方程的误差传播。这也是预条件思想的起点。更先进的 Krylov 方法会利用多个历史方向, 但其数学主线仍然是: 用便宜的矩阵作用构造有信息的修正, 再控制残差与误差。

7.4 超松弛迭代法

GS 使用某个坐标方程给出的完整修正, 但完整修正未必是迭代速度最好的选择。可以只走修正的一部分, 也可以适当多走一点, 以改变不同误差模式的衰减速度。这就是松弛参数的作用。

定义 7.6 (松弛迭代) 把旧值与一次基本更新值作加权组合 $x_{\text{new}} = (1 - \omega)x_{\text{old}} + \omega x_{\text{basic}}$, 称为松弛。 $0 < \omega < 1$ 为欠松弛, $\omega > 1$ 为超松弛; 对 GS 的逐坐标更新作这种处理, 得到 SOR 方法。

“多走一点”可能加速, 也可能把原本衰减的误差变成增长。参数范围必须由收敛分析给出, 而不能把超松弛理解成无条件更快。

GS 给出一个坐标修正, SOR 再乘松弛因子 ω :

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij}x_j^{(k+1)} - \sum_{j > i} a_{ij}x_j^{(k)} \right).$$

$\omega = 1$ 恢复 GS; $0 < \omega < 1$ 是欠松弛; $\omega > 1$ 是超松弛。矩阵形式为

$$B_\omega = (D + \omega L)^{-1}[(1 - \omega)D - \omega U].$$

因两侧矩阵分别为三角阵,

$$\det B_\omega = (1 - \omega)^n.$$

如果迭代收敛, 则所有特征值模小于 1, 所以 $|1 - \omega| < 1$, 即 $0 < \omega < 2$ 。这是一般情况下的必要条件, 单独并不充分。

定理 7.7 (正定情形的 SOR 收敛) 若 A 实对称正定且 $0 < \omega < 2$, 则 SOR 收敛。因此 GS 是其中 $\omega = 1$ 的特例。

证明. 考虑二次能量 $F(x) = \frac{1}{2}x^T Ax - b^T x$, 其唯一最小点是 $x_* = A^{-1}b$ 。在更新第 i 个坐标前, 记当前残差分量为 $r_i = b_i - (Ax)_i$ 。SOR 沿坐标方向取 $s = \omega r_i / a_{ii}$, 因此

$$F(x + se_i) - F(x) = -sr_i + \frac{1}{2}a_{ii}s^2 = -\frac{\omega(2 - \omega)}{2a_{ii}}r_i^2 \leq 0.$$

若一整轮没有严格下降，则每个坐标更新时的残差都为零，所有更新都为零，故起始点已满足 $Ax = b$ 。所以对每个非零误差，一整轮都使能量范数 $\|e\|_A^2 = e^T Ae$ 严格下降。

一整轮是线性映射。在紧的单位能量球面上，连续比值 $\|B_\omega e\|_A / \|e\|_A$ 达到最大值，且处处小于 1，因此最大值也小于 1。由收缩性即得收敛。□

适当 ω 可以加速，但最佳值依赖矩阵与排序。某些特殊结构有显式最优公式，不能把它们直接用于任意矩阵。下图展示一个三对角正定问题的实际差异。




图 7.1 三对角正定系统上 Jacobi、Gauss–Seidel 与一个给定松弛参数的 SOR。纵轴是尺度化残差。这里 SOR 更快是此矩阵和参数下的表现。

基本迭代方法的比较

方法	一轮中使用的数据	常见收敛保证	计算特点
Jacobi	全部使用上一轮值	严格对角占优；一般判据为 $\rho(B_J) < 1$	各分量可并行
Gauss–Seidel	已更新分量立即使用	严格对角占优，或实对称正定	依赖更新顺序
SOR	GS 修正乘以 ω	正定情形 $0 < \omega < 2$	参数影响速度；一般情形仍需另验收敛

表 7.1 充分条件不能当作必要条件；不同方法的迭代轮数还需结合单轮成本比较。

第 8 章 非线性方程的数值解法

8.1 引言

对 $f(x) = 0$ ，通常没有一个适用于所有函数的显式解法。我们需要根据连续性、单调性和局部导数信息，逐步缩小可能的根位置。二分法提供可靠的范围保证，Newton 与割线法提供更快的局部修正；把两者结合，往往比只追求某一种收敛阶更实用。

定义 8.1 (方程的根、单根与重根) 若 $f(\alpha) = 0$ ，称 α 为根。若 $f'(\alpha) \neq 0$ ，称为单根。若在根附近 $f(x) = (x - \alpha)^m g(x)$ ，其中 $g(\alpha) \neq 0$ ，则称 α 为 m 重根。

求根任务不仅是得到一个使 $f(x)$ 很小的数，还要判断它对应哪一个根，以及位置误差是否符合要求。函数有多个根时，需要先给出初始区间或其他先验信息，把希望求的根与其他根区分开。

若 α 是单根， $f(\alpha) = 0, f'(\alpha) \neq 0$ 。给函数值加入小扰动 δ ，新的根满足 $f(\alpha + \Delta\alpha) + \delta = 0$ ，一阶展开给出

$$\Delta\alpha \approx -\frac{\delta}{f'(\alpha)}.$$

根附近曲线越平，函数值误差越容易变成较大的位置误差。多重根处 $f'(\alpha) = 0$ ，敏感性通常更严重。例如 $x^2 = 0$ 改为 $x^2 = \delta$ ，根的变化是 $\sqrt{\delta}$ 量级，而非 δ 量级。

8.2 方程求根的二分法

二分法利用的是连续性。它不预测曲线的形状，只维护一段确定含根的区间。每次判断中点的符号，就能排除一半区间，因此计算过程有明确的范围保证。

定理 8.2 (异号区间内的根) 若 $f \in C[a, b]$ 且 $f(a)f(b) < 0$ ，则 (a, b) 中至少有一个零点。若进一步 f 在区间内严格单调，则零点唯一。

证明. 存在性来自介值定理。若严格单调函数有两个不同零点，则这两个点的函数值应严格有序，与二者都为零矛盾。□

若 f 在 $[a, b]$ 连续且 $f(a)f(b) < 0$ ，介值定理保证至少有一个根。二分法取中点 $m = (a+b)/2$ ，保留仍然异号的半区间。每次保留根，区间长度减半。

经过 k 次二分后，新区间长度为 $(b-a)/2^k$ ，返回该区间的中点 m_k ，则对区间中的某个根有

$$|m_k - \alpha| \leq \frac{b-a}{2^{k+1}}.$$

若要求位置误差不超过 ε ，只需选取满足该不等式的非负整数 k 。不同教材把第一次中点计算计为第 0 或第 1 次，公式因此可能差一个 2；应先核对迭代计数。

二分只需要连续性和异号区间，不需要导数。但偶数重根两侧可能同号，因此“没有异号”不等于“没有根”。浮点实现也宜比较两个函数值的符号，避免直接相乘导致溢出。

可以把一次更新明确写成三个步骤：先计算中点及其函数值；若函数值恰为零则结束；否则用它替换与其同号的端点。更新后两端仍异号，所以含根不变量一直保持。

例 8.1 (用二分法预先确定工作量) 对 $f(x) = x^3 - x - 1$, 从 $[1, 2]$ 开始, 要求最终返回区间中点的误差不超过 10^{-6} , 至少应作多少次二分?

解 有 $f(1) = -1$ 、 $f(2) = 5$, 且 $f'(x) = 3x^2 - 1 > 0$, 所以区间内有唯一根。按“二分 k 次后返回新区间中点”的计数, 误差界为 $2^{-(k+1)}$ 。要求 $2^{-(k+1)} \leq 10^{-6}$, 最小整数为 $k = 19$ 。

第一次中点为 1.5, 其函数值为 $0.875 > 0$, 所以保留 $[1, 1.5]$ 。下一次中点 1.25 的函数值为 $-0.296875 < 0$, 保留 $[1.25, 1.5]$ 。每一步只需要新增一次函数求值。

8.3 一元方程的不动点迭代法

定义 8.3 (不动点与压缩映射) 若 $\varphi(\alpha) = \alpha$, 称 α 为映射 φ 的不动点。若对某集中的任意 x, y , 存在统一常数 $0 \leq q < 1$ 使 $|\varphi(x) - \varphi(y)| \leq q|x - y|$, 则称该映射在集合上具有压缩性。

不动点方程表达“更新以后不再改变”。压缩性更进一步, 表达两条从不同初值出发的轨迹会相互靠近。把方程写成不动点形式只是代数步骤, 是否压缩则是新的分析问题; 并非所有等价改写都会保留良好的迭代行为。

把方程改写为 $x = \varphi(x)$, 迭代

$$x_{k+1} = \varphi(x_k).$$

代数上等价的改写, 收敛性质可能完全不同。例如 $x^2 - a = 0$ 可以写成 $x = a/x$, 也可写成 $x = (x + a/x)/2$ 。前一种在正根处导数为 -1 , 可能来回循环; 后一种在根处导数为零, 误差衰减更快。

定理 8.4 (区间上的压缩映射定理) 若 $\varphi: [a, b] \rightarrow [a, b]$, 且存在 $0 \leq q < 1$ 使

$$|\varphi(x) - \varphi(y)| \leq q|x - y| \quad \forall x, y \in [a, b],$$

则区间中有唯一不动点 α , 任意 $x_0 \in [a, b]$ 的迭代均收敛到它, 且

$$|x_k - \alpha| \leq \frac{q^k}{1 - q}|x_1 - x_0|, \quad |x_k - \alpha| \leq \frac{q}{1 - q}|x_k - x_{k-1}|.$$

证明. 自映射条件保证全部迭代点留在区间内。相邻差满足 $|x_{k+1} - x_k| \leq q^k|x_1 - x_0|$ 。对 $m > k$,

$$|x_m - x_k| \leq \sum_{j=k}^{m-1} |x_{j+1} - x_j| \leq \frac{q^k}{1 - q}|x_1 - x_0|.$$

因此序列是 Cauchy 序列, 在闭区间内收敛到某个 α 。由 Lipschitz 条件连续, 取极限得 $\alpha = \varphi(\alpha)$ 。若还有 β , 则 $|\alpha - \beta| \leq q|\alpha - \beta|$, 故两者相同。让上面不等式中 $m \rightarrow \infty$ 得先验界, 从第 k 步后的相邻差求和得后验界。□

若 φ 可微, $\max|\varphi'| \leq q < 1$ 是压缩条件的常用充分条件, 但仍须验证 $\varphi([a, b]) \subset [a, b]$ 。只在一个区间估计导数, 却让迭代跑出区间, 证明就失去了基础。

局部结论更弱也更灵活: 若 $\varphi(\alpha) = \alpha$ 、 φ' 在附近连续且 $|\varphi'(\alpha)| < 1$, 则可以找到足够小的邻域, 使它自映射并压缩, 因此足够近的初值收敛。若 $|\varphi'(\alpha)| > 1$, 根附近通常排斥; 等于 1 时, 一阶分析不能判断, 必须看更高阶项。




图 8.1 不动点迭代 $x_{k+1} = \cos x_k$ 的蛛网图。曲线与直线 $y = x$ 的交点是不动点；反复的竖直与水平移动表示一次函数求值和一次坐标传递。

局部收敛性与加速

只知道收敛还不够。对于相同的初始误差，有的方法每一步只按固定比例改进，有的方法在接近根以后会突然变得非常快。收敛阶用相邻误差之间的幂次关系区分这些速度。

定义 8.5 (线性、超线性与二阶收敛) 设 $x_k \rightarrow \alpha$, $e_k = x_k - \alpha$ 。若 $|e_{k+1}|/|e_k| \rightarrow q$ 且 $0 < q < 1$, 称为线性收敛；若该比值趋于零, 称为超线性收敛。若 $|e_{k+1}|/|e_k|^2$ 趋于有限正数, 则称为二阶收敛。

当主误差常数约为 1 时, 二阶收敛意味着误差从 10^{-3} 降到约 10^{-6} , 再降到约 10^{-12} 。这只是进入局部范围后的尺度说明, 不保证从任意初值就按这个速度前进。

设 $e_k = x_k - \alpha$ 。若

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^p} = C, \quad 0 < C < \infty,$$

则称收敛阶为 p 。 $p = 1$ 时还需 $C < 1$ 才称线性收敛； $p > 1$ 为超线性， $p = 2$ 为二阶收敛。

若 φ 在根附近足够光滑，且

$$\varphi'(\alpha) = \cdots = \varphi^{(p-1)}(\alpha) = 0, \quad \varphi^{(p)}(\alpha) \neq 0,$$

Taylor 展开给出 $e_{k+1} = \varphi^{(p)}(\alpha)e_k^p/p! + o(e_k^p)$ 。高阶收敛的本质是低阶误差项消失。

对近似几何误差 $e_{k+1} \approx \lambda e_k$, 有

$$x_{k+1} - x_k \approx (\lambda - 1)e_k, \quad x_{k+2} - 2x_{k+1} + x_k \approx (\lambda - 1)^2 e_k.$$

消去 λ 和 e_k , 得到 Aitken Δ^2 外推

$$\hat{x}_k = x_k - \frac{(x_{k+1} - x_k)^2}{x_{k+2} - 2x_{k+1} + x_k}.$$

它对严格几何误差一步消去主项。分母很小时会放大误差，需要防护。

Steffensen 方法把这一外推重新作为下一次迭代：先算 $y = \varphi(x)$ 、 $z = \varphi(y)$ ，再取

$$x_{\text{new}} = x - \frac{(y - x)^2}{z - 2y + x}.$$

在简单不动点附近，若 φ 足够光滑且 $\varphi'(\alpha) \neq 1$ ，Taylor 展开显示一阶误差被消去，可获得至少局部二阶行为；在根处出现的 $0/0$ 按连续延拓或已经收敛处理。它不自动提供全局收敛保证。

8.4 一元方程的常用迭代法

Newton 迭代法

二分法每步只保留范围，不使用当前曲线的斜率。不动点方法利用一个人为设计的更新映射，速度也依赖该映射。Newton 法则直接从原方程的局部线性模型产生修正：当前函数值告诉我们偏离横轴多少，导数把这个竖直偏差换算成水平位移。

要使用这种换算，导数必须非零；要让局部线性模型有效，当前点还应处在目标根的合适邻域。先说明这两个条件，再看它为何能得到二阶收敛。

在 x_k 附近线性化 f ：

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k).$$

令右侧为零，得到

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}. \quad (8.1)$$

几何上，这是切线与横轴的交点。算法用当前切线代替真实曲线，因此它需要初值已经足够接近目标根，或额外的全局保护。




图 8.2 对 $x^2 - 2 = 0$ 作 Newton 迭代。每次用当前点的切线求交点；靠近根后，切线近似迅速改善。

定理 8.6 (简单根处的局部二阶收敛) 设 $f \in C^2$ 在简单根 α 的某邻域内成立， $f'(\alpha) \neq 0$ 。则足够近的初值使 Newton 迭代有定义并收敛，且

$$e_{k+1} = \frac{f''(\alpha)}{2f'(\alpha)}e_k^2 + o(e_k^2).$$

若 $f''(\alpha) = 0$ ，收敛可能更高阶，不能据此断言恰为二阶。

证明. 以 x_k 为展开点, 有

$$0 = f(\alpha) = f(x_k) + f'(x_k)(\alpha - x_k) + \frac{1}{2}f''(\xi_k)(\alpha - x_k)^2.$$

整理并代入 Newton 公式, 得

$$e_{k+1} = \frac{f''(\xi_k)}{2f'(x_k)}e_k^2.$$

选取小邻域, 使 $|f'| \geq m > 0$, $|f''| \leq M$. 于是 $|e_{k+1}| \leq C|e_k|^2$, $C = M/(2m)$. 进一步取邻域半径 r 使 $Cr < 1$, 便保证迭代留在邻域且误差收缩. 取极限得到主误差常数. $\square$

例 8.2 (平方根迭代及其全局单调性) 对 $a > 0$, 推导计算 $\sqrt{a}$ 的 Newton 迭代, 并证明任意正初值都收敛到 $\sqrt{a}$.

解 对方程 $x^2 - a = 0$, Newton 迭代为

$$x_{k+1} = \frac{1}{2} \left(x_k + \frac{a}{x_k} \right).$$

任取 $x_0 > 0$, 由算术几何平均不等式有 $x_1 \geq \sqrt{a}$. 当 $x_k \geq \sqrt{a}$, 又有 $x_{k+1} \leq x_k$. 所以从第一步起序列有下界且单调下降, 其极限必须满足 $x = a/x$, 因此等于 $\sqrt{a}$.

更直接地,

$$x_{k+1} - \sqrt{a} = \frac{(x_k - \sqrt{a})^2}{2x_k}.$$

这一个等式同时说明不越过根、误差非负与局部二阶收敛. 取 $a = 2, x_0 = 1$, 前几步为 1.5, 1.416666..., 1.414215686....

类似地, 若在异号区间内 $f' > 0, f'' \geq 0$, 从右端 b 且 $f(b) > 0$ 出发, 切线交点位于根与当前点之间: 凸性给出不越过根, $f/f' > 0$ 给出向左移动. 因此得到单调收敛. 这类全局结论依赖具体符号条件, 不是 Newton 法的一般属性.

重根、阻尼与割线法

若 $f(x) = (x - \alpha)^m g(x)$, 其中 $g(\alpha) \neq 0, m > 1$, 则

$$\frac{f(x)}{f'(x)} = \frac{x - \alpha}{m} + O((x - \alpha)^2),$$

普通 Newton 只有 $e_{k+1} = (1 - 1/m)e_k + O(e_k^2)$, 即线性收敛. 若重数已知, 改用

$$x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)}$$

可消去一阶项. 若重数未知, 可对 $g_1 = f/f'$ 作 Newton, 得到

$$x_{k+1} = x_k - \frac{f(x_k)f'(x_k)}{[f'(x_k)]^2 - f(x_k)f''(x_k)}.$$

它需要二阶导数, 且分母在数值上可能敏感, 不能无条件替代普通方法.

远离根时, 可尝试阻尼步 $x_{k+1} = x_k - \lambda_k f/f'$, 其中 $0 < \lambda_k \leq 1$. 逐次减半寻找使 $|f|$ 下降的步长, 能抑制某些过大的跳跃, 但“函数值下降”本身不保证一定到达根. 若已有连续异号区间, 更可靠的做法是保留区间, 只接受落在内部且有足够缩减作用的 Newton 步, 否则回退到二分.

不便计算导数时，以差商替代 $f'(x_k)$ ，得到割线法

$$x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}.$$

它每步只增加一次函数求值。在简单根附近、光滑性与非退化条件成立时，误差满足

$$e_{k+1} \sim C e_k e_{k-1}, \quad C = \frac{f''(\alpha)}{2f'(\alpha)}.$$

若设 $|e_{k+1}|$ 近似为 $|e_k|^p$ ，则右边尺度为 $|e_k|^{1+1/p}$ ，故 $p = 1 + 1/p$ ，解得

$$p = \frac{1 + \sqrt{5}}{2} \approx 1.618.$$

这解释了黄金分割阶的来源。若 $f''(\alpha) = 0$ 等特殊情况使主项消失，实际阶数可能不同。割线法也不自动保留异号区间。

抛物线法

Müller 方法用三点二次插值代替切线。记连续间隔为 $h_0 = x_1 - x_0, h_1 = x_2 - x_1$ ，差商为

$$\delta_0 = \frac{f_1 - f_0}{h_0}, \quad \delta_1 = \frac{f_2 - f_1}{h_1}.$$

以 $s = x - x_2$ 为变量，插值多项式写为 $as^2 + bs + c$ ，其中

$$a = \frac{\delta_1 - \delta_0}{h_0 + h_1}, \quad b = \delta_1 + ah_1, \quad c = f_2.$$

为避免根公式相近项相减，使用

$$s = -\frac{2c}{b \pm \sqrt{b^2 - 4ac}},$$

并选择模较大的分母，再取 $x_3 = x_2 + s$ 。若判别式为负，迭代可能进入复数域；对只寻找实根的任务应明确处理策略。简单非退化根附近的典型局部阶约为 1.839，但它并不因此在所有任务上优于有保护的 Newton 或割线方法。

常用求根方法的比较

方法	所用信息	典型速度	适用条件与限制
二分法	连续函数的异号区间	区间宽度每次减半	有范围保证；不能靠异号检测所有重根
不动点法	更新函数 φ	常见为线性	需验证自映射和压缩或局部条件
Newton 法	函数值与一阶导数	单根附近二阶	初值足够近，导数不为零
割线法	两个近期函数值	典型阶约 1.618	不保区间；需处理近零差商
Müller 法	三个近期函数值	典型阶约 1.839	可能进入复数域

表 8.1 局部阶数是在相应光滑性和非退化条件下的结论，不直接代表全局可靠性。

停止时可以同时检查区间宽度、步长和残差。如果在根附近有 $|f'| \geq m > 0$ ，中值定理给出

$$|x - \alpha| \leq \frac{|f(x)|}{m}.$$

没有导数下界时，小残差不一定对应小根误差；一个整体乘以 10^{-20} 的函数，残差天然很小，根的位置却没有变得更准确。

第 9 章 矩阵特征值问题的数值解法

9.1 引言

线性方程组求某个输入的响应，特征值问题则寻找矩阵自身的基本作用方向。振动系统的频率、迭代法的收敛率、二次型的曲率都与它有关。数值上通常不直接展开特征多项式求根，而是利用矩阵乘法和相似变换保留结构。

定义 9.1 (特征值、特征向量与谱) 对方阵 A ，若存在非零向量 v 使 $Av = \lambda v$ ，则称 λ 为特征值， v 为对应特征向量。全部特征值组成的集合称为谱，记为 $\sigma(A)$ ；特征多项式为 $\det(\lambda I - A)$ 。

特征向量描述矩阵作用后方向保持不变的模式。它的长度没有唯一标准，因为任意非零倍数仍是特征向量；计算时通常规定范数为 1。同一个特征值还可能对应多个线性无关方向，所以讨论向量的精度时，有时应关注整个特征子空间。

若 A 有 n 个线性无关特征向量，将其组成可逆矩阵 V ，便有 $AV = V\Lambda$ ，即 $A = V\Lambda V^{-1}$ ，称为可对角化。不是所有矩阵都能这样分解。实对称矩阵则具有更强的性质：可以选择正交归一特征向量，使 $A = Q\Lambda Q^T$ 。

9.2 特征值的性质与估计

性质 9.2 (相似变换、移位与求逆) 若 $B = S^{-1}AS$ 且 S 可逆，则 A, B 有相同特征多项式。若 $Av = \lambda v$ ，则 $(A - \mu I)v = (\lambda - \mu)v$ ；若 A 非奇异，则 $A^{-1}v = \lambda^{-1}v$ 。

证明. 有 $\det(zI - B) = \det[S^{-1}(zI - A)S] = \det(zI - A)$ ，故相似变换保持特征值及其代数重数。移位结论由直接展开得到；对 $Av = \lambda v$ 左乘 A^{-1} ，并使用 $\lambda \neq 0$ ，即得求逆结论。□

这三条性质分别支撑后面的 QR 相似迭代、移位加速与反幂法。它们改变矩阵的计算形式或特征值位置，却保留了可追踪的谱关系。选择变换的目的，是使目标模式更容易分离，或使矩阵结构更简单。

在真正迭代之前，先给特征值一个粗略范围很有用。它能帮助选择移位，也能排查明显不合理的计算结果。Gershgorin 圆盘只需要逐行求绝对值和，成本远小于完整求谱。

定理 9.3 (Gershgorin 圆盘定理) 矩阵 $A \in \mathbb{C}^{n \times n}$ 的全部特征值都落在

$$\bigcup_{i=1}^n D_i, \quad D_i = \left\{ z \in \mathbb{C} : |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \right\}$$

中。若其中 m 个圆盘组成的并集与其他圆盘分离，则该并集内恰有 m 个特征值，按代数重数计。

证明. 特征值满足 $Av = \lambda v$ 、 $v \neq 0$ 。取 $|v_i| = \max_j |v_j|$ ，则

$$(\lambda - a_{ii})v_i = \sum_{j \neq i} a_{ij}v_j.$$

取绝对值并约去 $|v_i|$ ，得到 $|\lambda - a_{ii}| \leq \sum_{j \neq i} |a_{ij}|$ 。

第二部分可以考虑连续变形 $A(t) = D + t(A - D)$ ， $0 \leq t \leq 1$ 。特征值作为多重集合连续变化；所有缩小的圆盘都包含在原来的相应圆盘中，特征值不能跨过两组之间的空隙。在 $t = 0$ 时，它们就是对角元，每组数量明确，因此到 $t = 1$ 数量不变。□

对实对称矩阵，特征值全部为实数，可把圆盘与实轴相交成区间，进一步简化范围估计。行圆盘与对转置矩阵所得的列圆盘都有效，也可以结合使用。




图 9.1 一个实对称矩阵的 Gershgorin 圆盘与实际特征值。圆盘用于包围谱的位置；当一组圆盘与其余圆盘分离时，还能数出其中的特征值个数。

Rayleigh 商

定义 9.4 (Rayleigh 商) 对实对称矩阵 A 和非零向量 x ， $R_A(x) = x^T A x / (x^T x)$ 称为 Rayleigh 商。它是沿方向 x 的二次型值经过长度归一化后的结果，因此不随 x 的非零倍数缩放而改变。

如果 x 恰好是特征向量，Rayleigh 商就等于对应特征值；如果只是接近特征方向，它仍可作为自然的特征值估计。关键是弄清楚：方向误差会以什么阶进入这个估计，以及怎样用可计算的残差检验它。

对实对称 A ，定义

$$R_A(x) = \frac{x^T A x}{x^T x}, \quad x \neq 0.$$

写正交特征分解 $A = Q \Lambda Q^T$ ，令 $x = \sum_i c_i q_i$ ，则

$$R_A(x) = \frac{\sum_i \lambda_i c_i^2}{\sum_i c_i^2}.$$

它是特征值的加权平均，所以

$$\lambda_{\min} \leq R_A(x) \leq \lambda_{\max},$$

并且在相应特征向量上取到端点。等价地，它是二次型在单位球面上的极值问题。

若单位向量 $x = q_j \cos \theta + w \sin \theta$ ，其中 $w \perp q_j$ 、 $\|w\| = 1$ ，正交性给出

$$R_A(x) - \lambda_j = (w^T A w - \lambda_j) \sin^2 \theta.$$

因此向量方向有一阶小误差时，Rayleigh 商的特征值误差是二阶小量。这个结论依赖对称性。

对近似特征对 (μ, v) ，取 $\|v\|_2 = 1$ ，定义残差 $r = Av - \mu v$ 。在正交特征基下，

$$\|r\|_2^2 = \sum_i |\lambda_i - \mu|^2 |c_i|^2 \geq \min_i |\lambda_i - \mu|^2,$$

故至少有一个特征值满足 $|\lambda_i - \mu| \leq \|r\|_2$ 。要保证向量接近某一个指定的特征向量，还需要谱间隙；特征值聚集时，小残差可能只说明它接近一个特征子空间。

9.3 幂法与反幂法

最简单的特征值算法只重复作矩阵向量乘法。其直觉是：把一个向量分解到不同特征方向后，每乘一次 A ，第 i 个方向就再乘一次 λ_i 。重复很多次，模较大的特征值会逐渐占据主导。

这个解释同时揭示了限制。若初值根本没有目标方向的分量，精确运算不会凭空生成它；若两个特征值的模相同，也就没有一个模式能仅靠模的差异压过另一个模式。因此必须把初值和谱分离条件写进收敛结论。

假设 A 可对角化，特征值按模排序满足 $|\lambda_1| > |\lambda_2| \geq \dots$ ，且初值在主特征方向上的系数 $c_1 \neq 0$ 。展开

$$A^k x_0 = c_1 \lambda_1^k \left[v_1 + \sum_{j=2}^n \frac{c_j}{c_1} \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \right].$$

括号内其余方向逐步衰减，因此归一化后的方向趋于主特征方向，典型渐近速度由 $|\lambda_2/\lambda_1|$ 控制。

为避免长度溢出或下溢，每步计算

$$y_{k+1} = Ax_k, \quad x_{k+1} = \frac{y_{k+1}}{\|y_{k+1}\|_2}.$$

对称问题可用 $\mu_k = x_k^T A x_k$ 估计特征值，并用特征对残差停止。若主特征值为负，归一化向量可能正负交替；复特征值还可能带相位变化。因此严格地说，是方向或一维子空间收敛，不一定是原向量序列逐项收敛。

例 9.1 (初值不能遗漏目标方向) 对 $A = \text{diag}(3, 2, 1)$ ，比较从 $(1, 1, 1)^T$ 和 $(0, 1, 1)^T$ 出发的幂法极限方向。

解 如果 $x_0 = (1, 1, 1)^T$ ，幂法会突出第一坐标，速度受 $2/3$ 控制；如果 $x_0 = (0, 1, 1)^T$ ，精确算术中第一坐标永远为零，算法只能看到特征值 2。所以“任取非零初值”不是充分条件。

若主次特征值模很接近，幂法会慢；若最大模特征值不唯一，则可能振荡或停留在更高维不变子空间。移位 $A - \sigma I$ 会改变模的排序，有时可改善比例，但也可能把目标变成非主特征值，因此必须先分析谱位置。

反幂法与原点移位

要寻找靠近给定 σ 的特征值，可以对 $(A - \sigma I)^{-1}$ 应用幂法，其特征值为 $1/(\lambda_i - \sigma)$ 。离 σ 最近者的倒数模最大。

实际每步求解

$$(A - \sigma I)y_{k+1} = x_k, \quad x_{k+1} = y_{k+1} / \|y_{k+1}\|.$$

不需要显式形成逆矩阵。固定移位时，可以复用一次 LU 分解。若 λ_j 是唯一最近的特征值，次近者为 λ_l ，典型收敛因子为 $|\lambda_j - \sigma|/|\lambda_l - \sigma|$ 。




图 9.2 对角对称矩阵的幂法。方向误差约按主次特征值模比衰减，Rayleigh 商的误差通常衰减得更快；曲线末端受到浮点精度限制。

令每步移位取 Rayleigh 商，得到 Rayleigh 商迭代。对实对称矩阵、简单特征值以及足够好的初始方向，局部可达到很快的三阶方向收敛。这个高阶性质需要对称性和局部条件；一般非对称矩阵不能直接套用。

当移位接近特征值，线性系统变得近奇异，这恰好强化目标方向，但也要求可靠的线性求解与残差检查。已经达到特征对精度时，应先停止，避免继续求一个实际已奇异的系统。

9.4 Jacobi 方法

幂法适合提取少数模式。如果希望得到实对称矩阵的全部特征值与正交特征向量，可以换一种目标：逐步消掉非对角项，把矩阵变得接近对角阵。此时对角元直接给出特征值，而累计变换记录特征方向。

定义 9.5 (平面旋转矩阵) 在两个坐标方向上作二维旋转、在其余坐标方向上保持不变的矩阵，称为平面旋转矩阵。它满足 $G^T G = I$ ，因此保持向量的欧氏长度和夹角。

左右两侧配套使用 G^T 与 G ，既保持对称性，又保持特征值。若只从一侧消元，得到的一般只是与原矩阵等价的线性系统，并不自动与原矩阵同谱。这是特征值算法与线性方程组消元的重要区别。

本节的 Jacobi 方法用于特征值，与第七章求线性方程组的 Jacobi 迭代不同。它只针对实对称矩阵，通过正交相似变换不断减小非对角元素。

在坐标 p, q 平面上取旋转块

$$G_{pq} = \begin{pmatrix} c & s \\ -s & c \end{pmatrix}, \quad c^2 + s^2 = 1,$$

其他坐标保持不动。令 $B = G^T A G$ ，则

$$b_{pq} = (a_{pp} - a_{qq})cs + a_{pq}(c^2 - s^2).$$

选角度使它为零。为避免角度公式中的消去，可令

$$\tau = \frac{a_{qq} - a_{pp}}{2a_{pq}}, \quad t = \frac{\text{sign}(\tau)}{|\tau| + \sqrt{1 + \tau^2}}, \quad c = \frac{1}{\sqrt{1 + t^2}}, \quad s = tc.$$

$\tau = 0$ 时可取 $t = 1$; $a_{pq} = 0$ 时无需旋转。不同教材采用不同旋转块符号, t 的公式应与之匹配。

令 $\text{off}(A)^2 = \sum_{i \neq j} a_{ij}^2$ 。正交变换保持 Frobenius 范数, 而且本次消去使对角平方和增加 $2a_{pq}^2$, 因此

$$\text{off}(B)^2 = \text{off}(A)^2 - 2a_{pq}^2.$$

若每次选绝对值最大的非对角元, 则

$$a_{pq}^2 \geq \frac{\text{off}(A)^2}{n(n-1)},$$

所以

$$\text{off}(B)^2 \leq \left(1 - \frac{2}{n(n-1)}\right) \text{off}(A)^2.$$

非对角量几何趋零。累计旋转矩阵的列给出对应的正交特征向量近似; 存在重特征值时, 其内部基的选择不唯一。

9.5 QR 方法

定义 9.6 (正交相似变换与 QR 分解) 若 $Q^T Q = I$, 称 Q 为正交矩阵, $Q^T A Q$ 称为正交相似变换。将矩阵写成正交矩阵与上三角矩阵的乘积 $A = QR$, 称为 QR 分解。

正交变换保持 2-范数, 使计算不因坐标变换本身产生很大的长度伸缩。这种数值性质加上相似变换的保谱性质, 使正交相似变换成为特征值计算的基本工具。

平面旋转一次处理一对坐标, Householder 反射则可以一次把一个向量的很多分量消为零。因此, 反射适合先把稠密矩阵整理为更稀疏的结构, 再进行重复的 QR 迭代。

Householder 矩阵定义为

$$H = I - 2vv^T, \quad \|v\|_2 = 1.$$

直接计算得 $H^T = H$ 、 $H^T H = I$ 。几何上, 它翻转沿 v 的分量, 保持与 v 正交的分量。

性质 9.7 (Householder 反射的几何性质) 设 $\|v\|_2 = 1$ 、 $H = I - 2vv^T$ 。则 $H^T = H$ 、 $H^2 = I$; $Hv = -v$, 而对任意 $z \perp v$ 有 $Hv = z$ 。

证明. vv^T 对称, 所以 H 对称。展开平方并用 $v^T v = 1$, 得 $H^2 = I - 4vv^T + 4v(v^T v)v^T = I$ 。另外 $Hv = v - 2v = -v$; 若 $v^T z = 0$, 则 $Hv = z$ 。□

若要把非零向量 x 变到第一坐标轴, 取 $\alpha = -\text{sign}(x_1) \|x\|_2$, $x_1 = 0$ 时约定符号为 1, 令 $u = x - \alpha e_1$ 、 $v = u / \|u\|$, 便有 $Hx = \alpha e_1$ 。这样的符号选择让 $x_1 - \alpha$ 发生同号相加, 减少消去。

逐列反射可以构造 QR 分解; 对矩阵两侧作配套反射, 可以先将一般矩阵化成上 Hessenberg 形, 对称矩阵化成三对角形, 减少后续特征值迭代的成本。

QR 迭代写为

$$A_k = Q_k R_k, \quad A_{k+1} = R_k Q_k.$$

因 Q_k 正交,

$$A_{k+1} = Q_k^T A_k Q_k,$$

所以每一步都是相似变换, 特征值不变。加移位时先分解 $A_k - \mu_k I = Q_k R_k$, 再令 $A_{k+1} = R_k Q_k + \mu_k I$, 同样保持相似性。

对一般实矩阵, 理想终点是实 Schur 形, 可能含代表复共轭特征值的 2×2 对角块, 而不一定是实对角阵。对称矩阵则可趋于对角形式。实际算法还需要合适的移位、降阶判断和稳定的 Hessenberg 更新。

对称矩阵经过正交相似变换仍对称; 若同时已成为上 Hessenberg 形, 对称性就强制它为三对角形。这样, 后续每次更新不再需要按原稠密矩阵的方式处理所有元素。QR 方法的效率不仅来自迭代公式, 也依赖前面的结构化简。

第 10 章 常微分方程的数值解法

10.1 引言

前面的求值、积分与线性求解通常针对一个固定问题。常微分方程则要求连续推进：当前近似成为下一步的输入，每一步误差都会影响后面。这使“单步很准确”与“整条轨迹可靠”之间多出一层稳定性问题。

考虑初值问题

$$y'(t) = f(t, y(t)), \quad y(t_0) = y_0.$$

以下先用标量记号，向量系统可用同样方式书写。若 f 连续，并对 y 局部 Lipschitz，则初值问题有局部唯一解；要在整个给定区间上使用数值方法，还需解在该区间存在，且相关光滑性与界成立。局部存在不自动保证任意长时间不爆破。

定义 10.1 (初值问题与离散解) 给定微分方程 $y' = f(t, y)$ 和起点值 $y(t_0) = y_0$ ，求满足二者的函数，称为初值问题。选择离散时刻 $t_0 < t_1 < \dots$ ，以 y_n 近似 $y(t_n)$ ，得到数值离散解；相邻时刻之差称为步长。

数值解通常只提供网格时刻的近似值。若需要中间时刻，还须使用与方法相容的插值或连续扩展。 y_n 中的下标表示时间步，不是向量分量；对向量方程，一个 y_n 本身就包含多个分量。

定义 10.2 (对状态变量的 Lipschitz 条件) 若在所考虑的区域存在与 t, y, z 无关的常数 L ，使 $\|f(t, y) - f(t, z)\| \leq L \|y - z\|$ ，称 f 对状态变量满足 Lipschitz 条件。

它限制的是两条接近状态所受到的斜率差异，因此既用于保证解的唯一性，也用于分析数值误差的传播。在有界区域内，连续且有界的状态导数 f_y 能给出这样的常数；但要覆盖整个计算区间，还需保证真解和数值轨迹处在相应区域中。

10.2 简单数值方法

从积分恒等式出发：

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y(t)) dt.$$

用左端矩形近似积分，得到显式 Euler：

$$y_{n+1} = y_n + hf(t_n, y_n).$$

它也可以解释为沿当前切线走一步。用右端矩形得到隐式 Euler：

$$y_{n+1} = y_n + hf(t_{n+1}, y_{n+1}).$$

右侧含新值，每一步要解一个代数方程。用梯形积分则得到

$$y_{n+1} = y_n + \frac{h}{2}[f(t_n, y_n) + f(t_{n+1}, y_{n+1})].$$

前者用一个斜率，后者平均两端斜率。阶数改善来自对积分的更准确近似，但隐式方程的求解也进入了算法成本。

设 f 对 y 的 Lipschitz 常数为 L 。用不动点方式解隐式 Euler 时，迭代函数 $z \mapsto y_n + hf(t_{n+1}, z)$ 的 Lipschitz 常数为 hL 。因此 $hL < 1$ 是该内迭代收敛的充分条件；这不是隐式 Euler 本身的绝对稳定步长限制。对于刚性问题，常用 Newton 法求隐式方程。

例 10.1 (同一个指数衰减方程) 对 $y' = -2y$, $y(0) = 1$ ，分别写出显式 Euler、隐式 Euler 与隐式梯形的更新式，并比较 $h = 0.1$ 时的第一步。

解 对 $y' = -2y$, $y(0) = 1$ ，精确解为 e^{-2t} 。步长 h 下，三种更新分别为

$$y_{n+1} = (1 - 2h)y_n, \quad y_{n+1} = \frac{y_n}{1 + 2h}, \quad y_{n+1} = \frac{1 - h}{1 + h}y_n.$$

取 $h = 0.1$ ，第一步得到 $0.8, 0.833333\dots, 0.818181\dots$ ，真值为 $0.818730\dots$ 。这也预示了隐式梯形法的二阶精度。

定义 10.3 (显式方法、隐式方法与单步方法) 若新值可以直接由已知数据算出，称为显式方法；若新值同时出现在待求方程两侧，需要解代数方程，称为隐式方法。只依赖当前一步的状态推进到下一步，称为单步方法。

显式与隐式描述每一步怎样计算，单步与多步描述使用多少历史信息。这是两个不同维度。例如隐式 Euler 仍是单步方法，因为它只把当前状态推进到下一状态，不需要更早时刻的数值解。

定义 10.4 (局部误差与整体误差) 假设某一步的起点取精确值，只观察这一数值步产生的误差，称为局部一步误差。实际从初值连续推进以后， $y(t_n) - y_n$ 称为整体误差，它同时包含当前误差和历史误差的传播。

区分二者是理解方法阶数的起点。局部分析可以把旧误差暂时清零，从 Taylor 展开得到简洁公式；整体分析则必须把各步重新连起来，不能把最后一步的局部界直接当成终点总误差。

局部误差和方法的阶

把一次数值更新写为 $y_{n+1} = \Psi_h(t_n, y_n)$ 。局部一步误差定义为从准确起点出发后的误差：

$$\delta_{n+1} = y(t_{n+1}) - \Psi_h(t_n, y(t_n)).$$

若在固定区间上一致有 $\delta_{n+1} = O(h^{p+1})$ ，称方法具有 p 阶局部一致精度。整体误差 $e_n = y(t_n) - y_n$ 还包含以前各步传下来的误差。

有些教材把 δ_{n+1}/h 叫局部截断误差，于是它记为 $O(h^p)$ 。两种记法都可用，关键是明确是否除以 h 。对隐式方法，还常把真解代入离散方程后的残差称为局部缺陷，它与解出隐式方程后的实际一步误差应区分。

例如显式 Euler 的一步误差由 Taylor 公式直接得到

$$\delta_{n+1} = \frac{h^2}{2}y''(t_n) + O(h^3).$$

隐式 Euler 与梯形法代入真解后的方程缺陷分别为

$$d_{n+1}^{BE} = -\frac{h^2}{2}y''(t_n) + O(h^3), \quad d_{n+1}^{TR} = -\frac{h^3}{12}y'''(t_n) + O(h^4).$$

在小步长下隐式求解映射良好时，对缺陷的响应因子有界，故它们分别是一阶和二阶方法。

定理 10.5 (单步方法的整体误差界) 假设 $t_n \leq T$ ，数值单步映射满足

$$|\Psi_h(t, u) - \Psi_h(t, v)| \leq (1 + Lh)|u - v|,$$

且局部误差 $|\delta_{n+1}| \leq Ch^{p+1}$ 。则 $L > 0$ 时

$$|e_n| \leq e^{L(t_n - t_0)}|e_0| + \frac{C}{L} \left(e^{L(t_n - t_0)} - 1 \right) h^p.$$

当 $L = 0$ 时，第二项按极限理解为 $C(t_n - t_0)h^p$ 。

证明. 加减从准确起点得到的数值一步值，得

$$|e_{n+1}| \leq (1 + Lh)|e_n| + Ch^{p+1}.$$

递推展开：

$$|e_n| \leq (1 + Lh)^n |e_0| + Ch^{p+1} \sum_{j=0}^{n-1} (1 + Lh)^j.$$

对几何级数求和，再用 $(1 + Lh)^n \leq e^{Ln h}$ ，便得结论。□

因此，在稳定传播条件下，局部一步 $O(h^{p+1})$ 通常累计成固定时间区间上的整体 $O(h^p)$ 。少一阶不是神秘现象，而是总步数约为 $1/h$ 。证明同时说明初值误差也会传播，并不会因方法阶数提高而自动消失。

两步 Euler 公式

在区间 $[t_{n-1}, t_{n+1}]$ 上积分，并用中点 t_n 的斜率近似，得到

$$y_{n+1} = y_{n-1} + 2hf(t_n, y_n).$$

它也称显式中点多步公式。这里一次更新跨越两个小区间，所以前面的系数是 $2h$ ；它与在一个时间步内部评估中点斜率的 Runge-Kutta 中点法不同。

将真解在 t_n 两侧展开，得

$$y(t_n + h) - y(t_n - h) - 2hy'(t_n) = \frac{h^3}{3} y'''(t_n) + O(h^5).$$

因此该格式的代数阶为二阶。但它需要两个启动值，并含有一个交替符号的历史模式；是否适合具体问题，还需看多步稳定性，不能只按局部余项选择。

10.3 龙格-库塔方法

Euler 方法只观察起点斜率，相当于假设整个小区间内变化率不变。想提高精度，就应补充区间内部的变化信息。直接计算 y'' 、 y''' 是一种途径，但对复杂的 $f(t, y)$ ，展开这些导数很麻烦。

定义 10.6 (Runge-Kutta 阶段与级数) 在同一时间步内，用若干中间状态计算斜率 k_i ，再将这些斜率加权组合完成更新，称为 Runge-Kutta 方法。斜率求值次数称为级数，整体误差的渐近阶称为阶数，两者不是同一概念。

中间状态通常不是精确轨迹上的点，而是由已知阶段构造的预测。系数必须同时补偿时间位置和状态预测的误差。下面从最简单的二级形式逐项匹配 Taylor 展开，再看四阶公式怎样延续这一路线。

高阶 Taylor 法需要计算 $y'', y''', \dots$ 。由微分方程， $y'' = f_t + f_y f$ ，更高导数会迅速变复杂。Runge-Kutta 用同一步内多个斜率取代显式高阶求导。

考虑二级显式形式

$$k_1 = f(t_n, y_n), \quad k_2 = f(t_n + ch, y_n + ahk_1),$$

$$y_{n+1} = y_n + h(b_1 k_1 + b_2 k_2).$$

在准确起点展开 $k_2 = f + h(cf_t + af_y f) + O(h^2)$ ，于是数值更新为

$$y + h(b_1 + b_2)f + h^2 b_2 (cf_t + af_y f) + O(h^3).$$

真解展开为

$$y(t+h) = y + hf + \frac{h^2}{2}(f_t + f_y f) + O(h^3).$$

匹配独立项，得到

$$b_1 + b_2 = 1, \quad b_2 c = \frac{1}{2}, \quad b_2 a = \frac{1}{2}.$$

所以必须 $a = c \neq 0$ ， $b_2 = 1/(2c)$ 、 $b_1 = 1 - 1/(2c)$ 。常见两种选择是：

取 $c = 1$ ，得到改进 Euler (Heun) 法

$$k_1 = f(t_n, y_n), \quad k_2 = f(t_n + h, y_n + hk_1), \quad y_{n+1} = y_n + \frac{h}{2}(k_1 + k_2).$$

取 $c = 1/2$ ，得到显式中点法

$$y_{n+1} = y_n + hf\left(t_n + \frac{h}{2}, y_n + \frac{h}{2}f(t_n, y_n)\right).$$

两者都二阶，但对非线性问题通常给出不同结果。改进 Euler 只是用一次预测值替代了隐式梯形公式中的新值，并不等于把隐式梯形方程解到收敛，因此稳定性也不同。

四阶龙格-库塔公式

经典四级四阶 Runge-Kutta (RK4) 为

$$\begin{aligned} k_1 &= f(t_n, y_n), \\ k_2 &= f(t_n + h/2, y_n + hk_1/2), \\ k_3 &= f(t_n + h/2, y_n + hk_2/2), \\ k_4 &= f(t_n + h, y_n + hk_3), \\ y_{n+1} &= y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \end{aligned}$$

第二、三阶段虽然同在半步时刻，却使用不同的状态预测，不能随意合并。

用 Butcher 系数矩阵 A 、权向量 b 与时刻向量 $c = A\mathbf{1}$ 统一表示。经典 RK4 的表为

0	0	0	0	0
1/2	1/2	0	0	0
1/2	0	1/2	0	0
1	0	0	1	0
	1/6	1/3	1/3	1/6

在足够光滑条件下，四阶匹配要求

$$\begin{aligned} b^T \mathbf{1} &= 1, & b^T c &= \frac{1}{2}, \\ b^T c^{\circ 2} &= \frac{1}{3}, & b^T A c &= \frac{1}{6}, \\ b^T c^{\circ 3} &= \frac{1}{4}, & b^T \text{diag}(c) A c &= \frac{1}{8}, \\ b^T A c^{\circ 2} &= \frac{1}{12}, & b^T A^2 c &= \frac{1}{24}. \end{aligned}$$

$c^{\circ q}$ 表示逐分量 q 次幂。这些条件分别匹配不同的导数组合，而不只是 f 本身的幂。例如 $b^T c^{\circ 2} = 1/3$ 对应二阶时刻效应， $b^T A c = 1/6$ 对应阶段状态的嵌套影响。将上表代入可逐项验证。

对测试方程 $y' = \lambda y$ ，RK4 给出乘子

$$R(z) = 1 + z + \frac{z^2}{2} + \frac{z^3}{6} + \frac{z^4}{24}, \quad z = h\lambda.$$

它与 e^z 的前五项一致，但仅核对这个线性测试方程不足以证明一般非线性问题的四阶精度：其他导数组合仍需上面的条件。




图 10.1 求解 $y' = y, y(0) = 1$ 到 $t = 1$ 的整体误差。Euler、改进 Euler 与 RK4 分别呈现一阶、二阶与四阶下降。比较计算成本时，还应计入每步函数求值次数。

变步长龙格-库塔方法

从同一个准确或当前数值起点出发，用步长 h 走一步得到 Y_c ，用 $h/2$ 走两步得到 Y_f 。对 p 阶方法，在光滑且主误差模型成立时，粗步局部误差与细步累计局部误差之比约为 2^p 。因此

$$y(t+h) - Y_f \approx \frac{Y_f - Y_c}{2^p - 1}.$$

这个估计反映当前一步的误差，不能直接当作整个积分区间最终误差的严格上界。

若误差估计为 E ，局部容许值为 τ ，由于一步误差按 h^{p+1} 变化，可建议

$$h_{\text{new}} = s h \left(\frac{\tau}{E} \right)^{1/(p+1)}, \quad 0 < s < 1.$$

s 是安全因子；还应限制单次增长或缩减倍数。对不同尺度的分量，常以

$$\frac{|E_i|}{\text{atol}_i + \text{rtol}_i \max(|y_{n,i}|, |y_{n+1,i}|)}$$

归一化后再决定接受或拒绝。这避免某个绝对量很大的分量支配所有误差判断。

嵌入式 Runge-Kutta 通过共享阶段、使用两套权重得到不同阶的近似，减少重复求值。它的步长指数取决于被估计误差的主阶，不能只看高阶方法的名字来填写。

稳定性与步长

精度分析让 h 趋于零，而实际计算使用一个固定的有限步长。一个形式上高阶的方法，在当前步长下仍可能把应衰减的模式放大。因此还需要检验方法对最基本的线性模式有什么作用。

定义 10.7 (稳定函数与绝对稳定域) 对测试方程 $y' = \lambda y$ ，若一步更新为 $y_{n+1} = R(z)y_n$ ， $z = h\lambda$ ，称 R 为稳定函数。集合 $\{z \in \mathbb{C} : |R(z)| \leq 1\}$ 称为绝对稳定域；内部点对应衰减，边界点只保证不放大。

测试方程虽然简单，却对应一般线性系统分解后的单个特征模式。它不能替代所有非线性稳定性分析，但能清楚展示步长、特征值位置与数值增长之间的联系。

考虑 $y' = \lambda y$ ， $\text{Re } \lambda < 0$ ，真解应衰减。如果数值方法给出 $y_{n+1} = R(h\lambda)y_n$ ，则当 $|R(h\lambda)| \leq 1$ 时，扰动不会逐步放大，称该点处绝对稳定。

显式 Euler 的 $R(z) = 1 + z$ ，稳定域是圆盘 $|1 + z| \leq 1$ 。对实负 λ ，要求 $0 \leq h \leq 2/|\lambda|$ ；在右端边界上乘子为 -1 ，只保证不增长，并不衰减。

隐式 Euler 的 $R(z) = 1/(1 - z)$ ，左半平面全部稳定，而且 $z \rightarrow -\infty$ 时 $R(z) \rightarrow 0$ 。梯形法的

$$R(z) = \frac{1 + z/2}{1 - z/2}$$

也覆盖左半平面，但 $z \rightarrow -\infty$ 时趋于 -1 ，极快衰减模式可能留下缓慢衰减的交替振荡。覆盖整个左半平面称为 A 稳定；进一步把无限刚性极限的放大因子压到零，则涉及 L 稳定性。

刚性的一种典型表现是：真解已经变化很慢，但显式方法仍必须用很小步长，才能压住方程中快速衰减的模式。例子为

$$y' = -1000(y - \cos t) - \sin t,$$

其通解为 $y(t) = \cos t + (y(0) - 1)e^{-1000t}$ 。快速暂态消失后，主轨迹接近 $\cos t$ ，变化尺度约为 1，显式 Euler 却仍受到 $h \lesssim 0.002$ 的稳定限制。隐式法能用更大稳定步长，但准确性仍然需要控制。

三个不同的问题。一致性问单步离散能否逼近微分方程；收敛性问固定时间区间内、步长趋零时整体误差是否趋零；绝对稳定性问给定步长下某种衰减模式是否被错误放大。高阶精度不能自动代替稳定性。




图 10.2 复平面上的绝对稳定域：显式 Euler、改进 Euler、RK4 与隐式 Euler。阴影表示 $|R(z)| \leq 1$ ；隐式 Euler 的稳定域向左无限延伸，图中只显示有限窗口。

10.4 线性多步法

定义 10.8 (线性多步方法) 若新状态与以前若干状态及其斜率满足固定系数的线性关系

$$\sum_{j=0}^s \alpha_j y_{n+j} = h \sum_{j=0}^s \beta_j f(t_{n+j}, y_{n+j}), \quad \alpha_s \neq 0,$$

则称为 s 步线性多步方法。 $\beta_s = 0$ 时为显式，否则通常为隐式。

与 Runge-Kutta 的区别在于信息来自哪里：前者复用过去时间步已经得到的值，后者主要在当前一步内构造新阶段。多步法可减少每步新增函数求值，但必须提供足够准确的启动值，改变步长时也要重新处理历史信息与系数。

Runge-Kutta 每步在内部重新采样多个斜率；多步方法复用过去若干步的斜率。仍从积分恒等式出发，在 $[t_n, t_{n+1}]$ 上，用历史数据插值 $g(t) = f(t, y(t))$ 。

用 g_n, g_{n-1} 作线性外推, 令 $s = (t - t_n)/h$, 则 $g(t) \approx g_n + s(g_n - g_{n-1})$ 。对 $s \in [0, 1]$ 积分, 得 Adams-Bashforth 二步法

$$y_{n+1} = y_n + \frac{h}{2}(3f_n - f_{n-1}).$$

继续使用四个历史斜率, 得到四步四阶公式

$$y_{n+1} = y_n + \frac{h}{24}(55f_n - 59f_{n-1} + 37f_{n-2} - 9f_{n-3}).$$

若把未来的 f_{n+1} 纳入插值, 便得到 Adams-Moulton 隐式公式。例如常用四阶式为

$$y_{n+1} = y_n + \frac{h}{24}(9f_{n+1} + 19f_n - 5f_{n-1} + f_{n-2}).$$

“步数”按需要覆盖的历史间隔计, “阶数”按误差阶计; 不同命名习惯可能把同一公式按节点数或历史步数编号, 应以公式为准。

可以先用显式公式预测, 再代入隐式公式校正。但只校正一次与将隐式方程解到指定容差并非同一算法, 稳定域也不一定相同。多步法还需要启动值; 若主方法四阶, 启动误差通常也需与四阶整体误差相容, 可用合适的 RK 方法生成。

Milne 型公式也可由积分构造。例如

$$y_{n+1} = y_{n-3} + \frac{4h}{3}(2f_n - f_{n-1} + 2f_{n-2})$$

是一个四步四阶显式公式, 而

$$y_{n+1} = y_{n-1} + \frac{h}{3}(f_{n+1} + 4f_n + f_{n-1})$$

来自跨两个小区间的 Simpson 积分。这些公式虽然有较高代数阶, 仍须分析多步误差传播, 不能只根据插值次数作选择。

待定系数法与收敛条件

一般常步长线性多步法写为

$$\sum_{j=0}^s \alpha_j y_{n+j} = h \sum_{j=0}^s \beta_j f_{n+j}, \quad \alpha_s \neq 0.$$

将真解代入, 在 t_n 展开。 $h^q y^{(q)}(t_n)$ 的系数为

$$C_0 = \sum_j \alpha_j, \quad C_q = \frac{1}{q!} \sum_j \alpha_j j^q - \frac{1}{(q-1)!} \sum_j \beta_j j^{q-1} \quad (q \geq 1).$$

若 $C_0 = \cdots = C_p = 0$ 而 $C_{p+1} \neq 0$, 则未除以 h 的方程缺陷为 $O(h^{p+1})$, 方法代数阶为 p 。这是待定系数法构造多步公式的系统办法。

定义

$$\rho(\zeta) = \sum_{j=0}^s \alpha_j \zeta^j, \quad \sigma(\zeta) = \sum_{j=0}^s \beta_j \zeta^j.$$

至少一阶一致性要求 $\rho(1) = 0, \rho'(1) = \sigma(1)$ 。然而消去局部低阶误差并不足以保证收敛, 还必须控制历史值误差的递推。

令 $f = 0$ ，扰动满足 $\sum_j \alpha_j e_{n+j} = 0$ 。若 ρ 有根 $|\zeta| > 1$ ，对应误差按 ζ^n 增长；若单位圆上的根有重数，则出现 $n\zeta^n$ 等多项式增长。因固定时间内 $n \sim 1/h$ ，这些增长会破坏 $h \rightarrow 0$ 时的稳定性。

定理 10.9 (零稳定性的根条件) 对固定系数、常步长线性多步法，零稳定性等价于： ρ 的全部根满足 $|\zeta| \leq 1$ ，且单位圆上的根均为单根。在标准 Lipschitz 条件、适当的隐式可解性及收敛启动值下，一致性与零稳定性共同保证收敛；对一般初值问题，二者也是收敛所必需的条件。

证明思路。根条件保证齐次递推的基本解一致有界。把局部缺陷作为非齐次项加入误差递推，再用 Lipschitz 条件和离散 Gronwall 型估计控制累积误差，即可从一致性得到整体收敛。

例 10.2 (一致但不收敛的多步格式) 检验 $y_{n+2} - 3y_{n+1} + 2y_n = -hf_n$ 的一致性和零稳定性，说明二者的区别。

解 其 $\rho(\zeta) = \zeta^2 - 3\zeta + 2$, $\sigma(\zeta) = -1$ 。有 $\rho(1) = 0$ 、 $\rho'(1) = -1 = \sigma(1)$ ，所以一致。但 ρ 的另一个根为 2，启动误差中若含有这一模式，会按 2^n 放大，方法不零稳定，因此不能保证收敛。

时间离散方法的比较

方法	阶数	每步主要工作	历史信息	稳定性特点
显式 Euler	1	一次斜率	当前状态	稳定步长受限制
隐式 Euler	1	解隐式方程	当前状态	左半平面稳定，强衰减模式可压低
隐式梯形	2	解隐式方程	当前状态	A 稳定，强衰减模式可能振荡
改进 Euler	2	两次斜率	当前状态	显式稳定域有限
经典 RK4	4	四次斜率	当前状态	高阶不等于无步长限制
Adams 多步法	依公式而定	复用历史斜率	多个历史点	需启动值与根条件分析

表 10.1 方法阶数描述光滑解上的误差尺度；工作量和稳定性还须单独比较。