NUMERICAL ANALYSIS

数值分析

课程讲义

VON

2026 春　数值分析

余肇飞

目录

第 1 章 数值分析概述 **1**
1.1 数值分析的研究对象 1
1.2 数值计算的基本思想 1
1.3 数值算法的评价 2

第 2 章 数值计算的误差 **3**
2.1 误差的来源 3
2.2 绝对误差、相对误差和有效数字 3
2.3 运算误差分析 4
2.4 病态问题与数值稳定性 5
2.5 数值计算的基本原则 7

第 3 章 函数的多项式插值 **9**
3.1 引言 9
3.2 多项式插值 9
3.3 Lagrange 插值多项式 10
3.4 牛顿插值多项式 12
3.5 Hermite 插值多项式 15
3.6 分段低次插值 17
3.7 三次样条插值 20

第 4 章 函数逼近 **25**
4.1 引言 25
4.2 正交多项式 25
4.3 连续函数的最佳逼近 29
4.4 离散数据的曲线拟合 34
4.5 三角多项式逼近与快速傅里叶变换 37

第 5 章 数值积分与数值微分 **42**
5.1 引言 42
5.2 Newton-Cotes 求积公式 42
5.3 复化求积公式 46
5.4 外推原理与 Romberg 求积法 50
5.5 Gauss 求积公式 52
5.6 数值微分 55

第 6 章 线性方程组直接解法 **61**
6.1 引言 61

6.2 Gauss 消去法 61
6.3 直接三角分解法 64
6.4 向量和矩阵的范数 66
6.5 方程组的性态与误差分析 68

第 7 章 线性方程组的迭代解法 72
7.1 引言 72
7.2 基本迭代方法 72
7.3 迭代法的收敛性 74
7.4 超松弛迭代法 77

第 8 章 非线性方程的数值解法 80
8.1 引言 80
8.2 方程求根的二分法 80
8.3 一元方程的不动点迭代法 81
8.4 一元方程的常用迭代法 83

第 9 章 矩阵特征值问题的数值解法 90
9.1 引言 90
9.2 特征值的性质与估计 90
9.3 幂法与反幂法 93
9.4 Jacobi 方法 95
9.5 QR 方法 97

第 10 章 常微分方程的数值解法 100
10.1 引言 100
10.2 简单数值方法 101
10.3 龙格-库塔方法 104
10.4 线性多步法 113

第 1 章　数值分析概述

1.1　数值分析的研究对象

许多数学问题能够写出严格的表达式，却不能靠有限步符号运算得到所需的数值。例如，定积分 $\int_0^1 e^{-x^2}\,\mathrm{d}x$ 没有初等原函数，但它代表的面积仍然确定；高次方程的根未必有方便的根式表达；由几千个未知量组成的线性方程组，理论上可以用行列式公式求解，实际却需要更有效的组织方式。

数值分析研究怎样把这些问题转化为可执行的有限运算，并分析计算结果与精确解之间的关系。这里既有构造算法的问题，也有证明算法可靠的问题。一条公式即使在实数运算中恒等成立，到了有限精度的计算机上，也可能与另一条等价公式表现不同。

定义 1.1 (数值问题、数值方法与数值算法)　数值问题是在给定数据下，求某个数学量的值。数值方法用有限维近似或迭代过程描述求解思路；数值算法进一步规定运算顺序、数据存储和停止条件，使这一思路可以实际执行。

例如，求 $\sqrt{a}$ 是一个问题；把它改写为 $x^2-a=0$ 并作 Newton 迭代是一种方法；规定初值、逐步更新式、误差阈值和异常情况的处理，才形成完整算法。这三个层次相互联系，但不能混在一起评价。

数值方法不只用于“算不出解析解”的情形。有时解析式虽然存在，却很难稳定地求值；有时需要对大量输入反复计算，较便宜且误差可控的近似反而更有用。我们关心的是怎样得到符合任务精度要求的结果，而不是把小数位数写得越多越好。

1.2　数值计算的基本思想

用简单对象逼近复杂对象

最基本的做法是选择容易计算的函数。例如，在一点附近用 Taylor 多项式表示局部变化；在多个节点之间用插值多项式连接数据；在整个区间上用最小二乘选择总体误差较小的函数。它们都用有限个系数描述近似，但系数的确定条件不同。

例 1.1 (用有限项近似指数函数)　用二次多项式 $1+x+x^2/2$ 近似 e^x。在 $0\le x\le 0.1$ 上，怎样保证误差不超过一个明确的数值?

解　Taylor 定理给出

$$e^x=1+x+\frac{x^2}{2}+\frac{e^{\xi}}{6}x^3,\qquad 0\le\xi\le x.$$

所以全区间上有

$$\left|e^x-\left(1+x+\frac{x^2}{2}\right)\right|\le\frac{e^{0.1}}{6}(0.1)^3<1.85\times10^{-4}.$$

多项式提供可计算的值，余项提供适用区间和误差保证。若把同一公式用于很大的 x，上面的保证就不再适用。

化整为零与逐次逼近

复杂函数在一个大区间上可能很难逼近，在足够小的区间上却近似为直线。复化求积和分段插值因此先划分网格，再拼合局部结果。这里必须继续检查：局部误差累加以后有多大，相邻分段的连接是否满足要求。

另一条路线是迭代。先给出一个容易得到的近似，再根据方程残差修正它。迭代不是单纯“重复算很多次”：更新规则必须让误差趋于零，停止条件也必须与所需精度对应。线性迭代、非线性求根以及特征值计算都会使用这种思想。

外推则利用误差的规律。如果已知两个步长下的近似含有同一类主误差项，就可以适当组合，消掉该项。它比“取两次结果的平均”更有针对性，因为组合系数来自误差展开。

1.3 数值算法的评价

定义 1.2 (收敛性与计算效率) 对依赖网格宽度 h 的近似 Q_h，若 $h \to 0$ 时 $Q_h \to Q$，称该近似收敛。对迭代序列 x_k，若 $k \to \infty$ 时趋于目标解，也称迭代收敛。计算效率则衡量达到规定精度所需的运算、存储或函数求值成本。

收敛只描述极限，不自动说明实际计算多快。一个误差按 $1/k$ 下降的迭代和一个按 2^{-k} 下降的迭代都收敛，但达到同一精度所需的步数相差很大。同样，单步计算便宜的方法也可能需要更多步，应该比较总成本。

误差阶常用 O 记号描述。写 $E(h) = O(h^p)$，意思是存在与充分小的 h 无关的常数 C，使 $|E(h)| \le C h^p$。它描述误差随网格变化的尺度，没有直接给出误差常数；只有进入相应的渐近范围，减半步长才会表现出接近 2^p 的改善。

除了收敛和效率，还要考察稳定性。输入和每次运算都可能有微小误差，如果算法把它们不断放大，再高的形式精度也可能失去意义。下一章从误差的来源、度量和传播开始，为这些判断建立具体工具。

第 2 章　数值计算的误差

一个计算结果有两种不同的“不准确”。第一种来自数学近似，例如用有限项 Taylor 展开代替指数函数；第二种来自计算机只能保存有限位数字。前者可以通过提高阶数或细化网格减小，后者却可能随着运算次数增加而累积。只有把两者分开，才能理解为什么一个看起来更精细的计算反而更差。

2.1　误差的来源

同样一个“数值不准”，可能来自完全不同的环节。要改进结果，首先应明确计算链条：实际现象给出数学模型，观测给出输入数据，离散方法把连续问题变成有限计算，计算机再执行有限精度运算。各环节的误差不能一概归咎于最后一个公式。

定义 2.1 (数值计算中的主要误差)　模型误差是数学模型与实际对象之间的差异；数据误差来自观测、测量或输入数据的近似；截断误差来自以有限过程代替无限或连续过程；舍入误差来自把不能精确表示的数存入有限位表示，以及对运算结果作舍入。

用有限项级数近似函数，遗漏的尾项属于截断误差；把 π 存成有限位小数属于舍入；半径由仪器测得而有误差，属于数据误差。提高级数项数只直接影响第一种，不会自动改进仪器读数。

这些误差进入后续计算后，还可能受到问题本身和运算方式的放大。因此，区分来源只是第一步，还要建立能比较大小的尺度。

浮点数与舍入

二进制浮点数由符号、有效位和指数构成。在常见的 binary64 格式中，有效二进制位数为 53。采用舍入到最近值、且结果没有溢出或进入导致相对模型失效的下溢区域时，可以用

$$\mathrm{fl}(a \circ b) = (a \circ b)(1+\delta), \qquad |\delta| \le u, \quad u = 2^{-53} \tag{2.1}$$

分析一次基本四则运算。式中 $\circ$ 表示相应运算。Python 中常见的 `eps` 是 1 与下一个可表示数的间距 2^{-52}，等于这里的 $2u$。

这个模型有两层含义。首先，单次舍入误差很小；其次，后续运算可能把这点误差放大。数值稳定性主要关注第二层，而不只是浮点格式有多少位。

2.2　绝对误差、相对误差和有效数字

所谓“误差”，首先要相对于一个明确的精确对象来定义。设这个对象的真值为 x，算法或测量给出的近似值为 $\widehat{x}$。后面讨论误差时，默认真值由数学问题确定，即使实际并不知道它。

定义 2.2 (绝对误差、相对误差与误差限)　误差为 $e = \widehat{x} - x$，其绝对值 $|e|$ 衡量偏离真值的距离。当 $x \neq 0$ 时，相对误差为 $e_r = (\widehat{x} - x)/x$。若已知 $|e| \le \varepsilon$ 或 $|e_r| \le \varepsilon_r$，则称 ε 或 ε_r 为相应的误差限。

误差本身通常未知，误差限却可能由仪器精度、余项定理或算法分析获得。数值分析的大部分保证，实际是在估计误差限，而不是提前知道真值后再作比较。

两种误差尺度各有用途。“误差不超过 10^{-3}”必须配合量的尺度理解：测量一条千米长的公路与一个微米尺度的结构，意义完全不同。相对误差把误差除以真值，说明它占结果的多大比例；真值为零或非常接近零时，则应使用绝对误差或混合尺度。

真值未知时，可以由 $|\widehat{x}-x|\le\varepsilon<|\widehat{x}|$ 得到

$$|x|\ge|\widehat{x}|-\varepsilon,\qquad |e_r|\le\frac{\varepsilon}{|\widehat{x}|-\varepsilon}.$$

这里分母不能直接当成 $|\widehat{x}|$；用近似值代替真值是一阶估计，不是无条件的严格上界。

这里先用反三角不等式 $|x|\ge|\widehat{x}|-|\widehat{x}-x|$，再使用已知误差界，得到 $|x|\ge|\widehat{x}|-\varepsilon>0$。所以

$$\frac{|\widehat{x}-x|}{|x|}\le\frac{\varepsilon}{|x|}\le\frac{\varepsilon}{|\widehat{x}|-\varepsilon}.$$

第二步的方向来自“正分母越小，分数越大”。条件 $\varepsilon<|\widehat{x}|$ 正是为了保证这个替代分母为正。

定义 2.3 (有效数字)　若近似数写为 $\widehat{x}=\pm0.a_1a_2\cdots a_n\times10^m$，其中 $a_1\neq0$，采用通常的误差界约定：当

$$|\widehat{x}-x|\le\frac{1}{2}\,10^{m-n}$$

时，称它至少有 n 位有效数字。

末位所在数位的半个单位，就是这一约定的核心。它不等价于把两串十进制字符逐个比较；进位附近尤其如此。

例 2.1 (从误差要求选择保留位数)　以 3.1416 近似 π，判断其有效数字；若用它计算圆面积，半径已有 10^{-3} 的相对误差，应怎样看待继续提高 π 的精度?

解　计算得误差约为 7.35×10^{-6}。五位有效数字的阈值是 0.5×10^{-4}，因此该近似至少有五位有效数字。若要求计算 πr^2，且半径测量已有 10^{-3} 的相对误差，继续把 π 保存到几十位，并不会消除半径测量带来的主误差。

2.3　运算误差分析

输入有误差以后，函数求值会怎样改变误差？先不考虑运算中的新舍入，只研究精确函数对输入扰动的响应。这样可以把“问题的敏感性”从具体实现中分离出来。

定义 2.4 (绝对条件数与相对条件数)　对标量函数 $y=f(x)$，绝对条件数衡量小的绝对输入扰动可能造成的输出变化率；可微时为 $|f'(x)|$。若 $x\neq0$ 且 $f(x)\neq0$，相对条件数为

$$\kappa_f(x)=\left|\frac{xf'(x)}{f(x)}\right|.$$

它比较输出的相对变化和输入的相对变化，是关于问题和当前输入点的量。

例如，$f(x)=x^m$ 在非零点处的相对条件数为 $|m|$。如果输入有约 10^{-5} 的相对误差，$m=3$ 时输出的一阶相对误差约为 3×10^{-5}。这个估计由函数的局部斜率决定，尚未涉及用何种代码计算幂。

现在暂时假设运算完全精确，只让输入 x 有扰动 Δx。若 $y=f(x)$ 且 f 在附近有连续二阶导数，Taylor 展开给出

$$f(x+\Delta x)-f(x)=f'(x)\Delta x+O(\Delta x^2).$$

因此 $|f'(x)|$ 衡量绝对误差的一阶放大；当 $x\neq 0$、$f(x)\neq 0$ 时，

$$\frac{|\Delta y|}{|y|}\approx \underbrace{\left|\frac{xf'(x)}{f(x)}\right|}_{\kappa_f(x)}\frac{|\Delta x|}{|x|}. \tag{2.2}$$

$\kappa_f(x)$ 称为相对条件数。它描述**数学问题本身**对相对扰动的敏感程度。一个函数在不同输入点的条件数可以相差很大。

对多元函数 $f(x_1,\dots,x_n)$，一阶传播式为

$$\Delta f\approx\sum_{j=1}^{n}\frac{\partial f}{\partial x_j}\Delta x_j,\qquad |\Delta f|\lesssim\sum_{j=1}^{n}\left|\frac{\partial f}{\partial x_j}\right|\varepsilon_j.$$

若希望将一阶估计换成严格上界，可以只用一元微积分来建立。记扰动向量为 d，沿连接两次输入的线段定义 $g(t)=f(x+td)$，$0\le t\le 1$。链式法则与微积分基本定理给出

$$g'(t)=\sum_j \partial_j f(x+td)d_j,\qquad f(x+d)-f(x)=\int_0^1 g'(t)\,\mathrm{d}t.$$

如果整条线段上 $|\partial_j f|\le M_j$，那么

$$|f(x+d)-f(x)|\le\int_0^1\sum_j M_j|d_j|\,\mathrm{d}t=\sum_j M_j|d_j|.$$

这里始终在对实际经过的输入区域取界；只知道起点处的导数，通常只能得到一阶近似。

例 2.2（相减问题为何可能病态） 设 $f(a,b)=a-b$ 且 $a\neq b$，两个输入的相对扰动均不超过 η。估计输出的相对扰动，并说明相近量相减的敏感性。

解 由三角不等式，

$$|\Delta f|\le\eta(|a|+|b|),\qquad \frac{|\Delta f|}{|a-b|}\le\frac{|a|+|b|}{|a-b|}\eta.$$

当 a,b 接近时，这个问题对独立输入扰动敏感。后面将看到，某些相近量由同一个输入按确定关系产生，此时可以通过代数改写改善算法。是否出现减法，并不能单独决定原问题的病态程度。

一个更有代表性的例子是求 $\sqrt{x}$。对 $x>0$，相对条件数恒为 $1/2$，因此它通常是良态问题。但如果用很差的迭代公式计算，仍然可能失败。条件数不评价具体算法。

2.4 病态问题与数值稳定性

有了误差传播的尺度，才可以区分两种失败。第一种是输入已经不足以确定高精度结果；第二种是输入本来足够准确，算法却在中间步骤额外丢失了信息。病态性描述前者，数值稳定性描述后者。

> **定义 2.5**（病态问题与数值稳定性） 相对于所选输入、输出尺度，若微小数据扰动可能引起很大的解扰动，则称问题在该数据附近病态。数值稳定性讨论算法中输入误差和舍入误差的传播是否受到合理控制。条件数是量化病态程度的常用工具。

病态不是一个只由题目名字决定的标签。同一个函数在不同输入位置可能具有不同条件数；同一个线性方程组在不同尺度和扰动方式下，也应使用相应的误差描述。评价算法之前，应先问期望得到的精度是否由数据本身允许。

定义 2.6 (前向误差与后向误差) 前向误差比较计算结果与原问题精确解的差异。后向误差则寻找一个尽量小的数据扰动，使计算结果恰好成为扰动后问题的精确解。若所需相对数据扰动仅与舍入误差同量级，算法通常称为后向稳定。

设任务是解 $F(d)=x$，d 表示输入数据。计算结果 $\widehat{x}$ 的前向误差就是它与真解 x 的距离。后向误差则反过来问：能否找到一个很小的数据扰动 Δd，使

$$\widehat{x}=F(d+\Delta d)?$$

如果算法所得结果恰是邻近问题的精确解，且相对后向误差与单位舍入误差同量级或仅差温和的维数因子，就称算法具有后向稳定性。

局部一阶分析把两者联系起来：

$$\text{相对前向误差} \lesssim \text{条件数}\times\text{相对后向误差}. \tag{2.3}$$

这不是所有问题的精确等式，而是一条重要的分析路线：先控制算法引入的扰动，再评估问题会把扰动放大多少。

稳定算法的能力边界。后向稳定算法能尽量避免额外损失信息，但不能恢复输入中已经失去的信息。病态问题即使用稳定算法，也可能有很大的前向误差；良态问题使用不稳定算法，也可能得出很差的结果。

例 2.3 (递推方向决定误差增长) 设 $I_n=\int_0^1 x^n/(x+5)\,\mathrm{d}x$。推导相邻积分的递推关系，并比较正向与反向计算的误差传播。

解 由 $x^n/(x+5)=x^{n-1}-5x^{n-1}/(x+5)$ 得

$$I_n=\frac{1}{n}-5I_{n-1},\qquad I_0=\log(6/5).$$

若忽略每步新舍入，仅看初值误差 e_0，则 $e_n=-5e_{n-1}=(-5)^n e_0$。而 $0<I_n<1/[5(n+1)]$，真值越来越小，误差却几何增长。

这里的积分上界来自 $0<x^n/(x+5)<x^n/5$ $(0<x<1)$，所以

$$0<I_n<\frac{1}{5}\int_0^1 x^n\,\mathrm{d}x=\frac{1}{5(n+1)}.$$

两次正向计算各满足同一个递推，相减后常数 $1/n$ 抵消，才得到 $e_n=-5e_{n-1}$。反向计算也一样：相减后得到 $e_{n-1}=-e_n/5$，连续回推 $N-n$ 次就乘 $5^{-(N-n)}$。

反向递推为 $I_{n-1}=(1/n-I_n)/5$，已有误差每步缩小到原来的 $1/5$。从较大的 N 开始，用 $I_N\approx 0$，回推到较小的 n，初始近似误差满足

$$|e_n|\le 5^{-(N-n)}\frac{1}{5(N+1)}.$$

实际还要累加各步舍入影响，但它们同样受到后续反向递推的衰减。相同的数学恒等式，沿不同方向计算，数值行为可以完全不同。

2.5 数值计算的基本原则

选择计算公式时，除了实数范围内的代数正确性，还要观察中间量的尺度与误差传播。常见原则包括：避免不必要的相近量相减；尽量不把很大的数与很小的数反复累加；在合理范围内缩放变量；复用可靠的分解或中间结果；让递推沿误差衰减的方向进行。

这些原则并非要求禁用某一类运算。减法和递推本身都是必要工具，关键是判断正在减去的量已经带有多少误差，以及结果的尺度有多小。

对多项式 $p(x) = a_0 + a_1x + \cdots + a_nx^n$，Horner 嵌套形式

$$p(x) = a_0 + x\left(a_1 + x(a_2 + \cdots + xa_n)\right)$$

减少了重复计算幂的成本。它通常是良好的求值方式，但在多项式值接近零、系数存在强烈抵消的点附近，问题本身仍可能敏感。减少运算次数有帮助，却不能代替条件分析。

舍入误差的积累也可以从两步运算开始看。若两个阶段分别产生因子 $1+\delta_1, 1+\delta_2$，则合并因子为

$$(1+\delta_1)(1+\delta_2) = 1 + \delta_1 + \delta_2 + \delta_1\delta_2.$$

当 $|\delta_i| \le u \ll 1$ 时，前两项给出约 $2u$ 的误差尺度，乘积项只有 u^2。连续多步仍要检查中间量是否相消：单次相对误差小，并不意味着相对于最终很小的结果仍然小。分析一个公式时，应先写出中间量的误差，再带进下一步，而不是直接把“机器精度”当作最终误差。

例如计算 $x > 0$ 很小时的 $\sqrt{1+x} - 1$。两项都接近 1，它们各自很小的绝对误差，相对于约为 $x/2$ 的结果却可能很大。利用代数恒等式可改写为

$$\sqrt{1+x} - 1 = \frac{x}{\sqrt{1+x}+1}. \tag{2.4}$$

右式的分母约为 2，没有相近量相减。

具体的有理化步骤是把左式乘以 $[\sqrt{1+x}+1]/[\sqrt{1+x}+1]$，分子按平方差变成 $(1+x)-1 = x$。分母在 $x \to 0$ 时趋于 2，也就说明结果为何约为 $x/2$。若 $x = 10^{-16}$，浮点加法甚至可能把 $1+x$ 舍入为 1，左式返回零，右式仍能给出约 5×10^{-17}。

消去的究竟是什么。相近浮点数相减本身不一定产生很大的舍入误差。真正危险的是：前面计算或数据中的误差已经存在，而相减使有效结果变得很小，留下的误差相对于结果就变大了。分析时应沿着整条计算链追踪误差。

求二次方程 $ax^2 + bx + c = 0$ 也有同样问题。若 $b^2 \gg 4ac$，一个根的分子 $-b \pm \sqrt{b^2 - 4ac}$ 会发生消去。对非零 a、实根和 $b \neq 0$，可先算

$$q = -\frac{1}{2}\left(b + \operatorname{sign}(b)\sqrt{b^2 - 4ac}\right), \qquad x_1 = \frac{q}{a}, \qquad x_2 = \frac{c}{q}.$$

两个根的乘积为 c/a，因此第二个根无需再次作危险的减法。实现仍要单独处理 $q = 0$、$b = 0$ 以及判别式溢出等情况。

用前向差商近似 $f'(x)$：

$$D_h f(x) = \frac{f(x+h) - f(x)}{h}.$$

把 $f(x+h)$ 在 x 处展开到一次，保留二阶余项：

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(\xi).$$

两边减去 $f(x)$、除以 h，差商与导数相差 $hf''(\xi)/2$。若计算机实际拿到的是 $f(x+h)+\eta_1$ 与 $f(x)+\eta_0$，则又多出 $(\eta_1-\eta_0)/h$。由 $|\eta_0|,|\eta_1|\le\varepsilon$，这一项的绝对值不超过 $2\varepsilon/h$，这才得到下面的两项误差模型。

若 $f\in C^2$，Taylor 展开产生 $O(h)$ 截断误差；若两个函数值各有不超过 ε 的绝对误差，作差后除以 h，额外误差至多 $2\varepsilon/h$。因此

$$|D_hf(x)-f'(x)|\lesssim C_1h+\frac{2\varepsilon}{h}.$$

减小 h 只降低第一项，却增大第二项。使右侧近似最小的步长为 $h\approx\sqrt{2\varepsilon/C_1}$。数值微分一节将把这个思路推广到中心差分和外推。

对上界模型 $E(h)=C_1h+2\varepsilon/h$，令 $h>0$。求导得 $E'(h)=C_1-2\varepsilon/h^2$，驻点满足 $h^2=2\varepsilon/C_1$。又有 $E''(h)=4\varepsilon/h^3>0$，所以驻点确为最小点。这里优化的是误差上界的模型，不是声称每次实际浮点误差都恰好在该步长达到最小。

实际工作中，误差预算应把模型误差、数据误差、离散误差、迭代误差与舍入误差分开。例如测量数据只有四位有效数字，通常没有必要把迭代残差压到几百位精度。另一方面，即使数据很精确，低阶离散也可能主导总误差。**应优先减小当前最大的误差来源**。

第 3 章　函数的多项式插值

3.1　引言

如果只知道温度在若干时刻的读数，怎样估计中间时刻的温度？一个自然做法是寻找一条通过所有数据点的曲线。曲线的选择有无限多种，插值方法通过预先指定函数空间，把问题变成一个有限维问题。

本章采用多项式作为插值函数，依次讨论插值条件能否确定唯一解、怎样表示和计算这个解，以及节点选择怎样影响误差。

需要先说清楚的是：离散数据只规定了若干点上的函数值，并不唯一确定点与点之间的曲线。因此，插值包含两项选择：给定数据的约束，以及允许使用的函数类型。函数类型一旦固定，才有可能讨论存在性、唯一性和误差。

定义 3.1（插值与插值节点）　给定互异点 $x_0,\dots,x_n$ 和对应数据 $y_0,\dots,y_n$，在指定函数空间中寻找 p，使 $p(x_i)=y_i$，称为插值。x_i 称为插值节点，等式称为插值条件。若 $y_i=f(x_i)$，则称 p 为 f 在这些节点上的插值函数。

在节点范围内求值称为内插，范围外求值称为外推。外推虽然仍可代入同一个多项式，但节点对远处行为的约束更弱，不能把区间内的误差经验直接搬到外部。

3.2　多项式插值

定义 3.2（多项式空间与基）　$\mathcal{P}_n$ 表示次数不超过 n 的实多项式组成的线性空间，包括零多项式。它的维数为 $n+1$，一组基为 $1,x,\dots,x^n$。多项式插值就是在 $\mathcal{P}_n$ 中满足 $n+1$ 个节点条件。

维数与条件数相等提示我们可能得到唯一解，但仅靠计数还不够：条件之间可能相关。例如，把同一个节点重复写两遍，并不会增加一条独立的函数值约束。互异节点的作用需要在证明中体现。

给定互异节点 $x_0,\dots,x_n$ 及数据 $y_0,\dots,y_n$，寻找 $p_n\in\mathcal{P}_n$ 满足

$$p_n(x_i)=y_i,\qquad i=0,\dots,n.$$

若把 p_n 写成单项式之和，插值条件变成 Vandermonde 线性方程组。但这个表示在高次或节点聚集时可能很不稳定；存在唯一解不意味着任意求解方式都合适。

具体写成 $p_n(x)=a_0+a_1x+\cdots+a_nx^n$，插值条件为

$$\begin{pmatrix}1 & x_0 & \cdots & x_0^n\\ 1 & x_1 & \cdots & x_1^n\\ \vdots & \vdots & & \vdots\\ 1 & x_n & \cdots & x_n^n\end{pmatrix}\begin{pmatrix}a_0\\ a_1\\ \vdots\\ a_n\end{pmatrix}=\begin{pmatrix}y_0\\ y_1\\ \vdots\\ y_n\end{pmatrix}.$$

系数矩阵的行列式为 $\prod_{0\le i<j\le n}(x_j-x_i)$，互异节点保证它非零。这是唯一性的线性代数解释。下面给出另一种更直接的构造证明，它同时产生方便使用的插值公式。

这个行列式公式可以按最后一个节点归纳。把 $n+1$ 阶行列式记为 $D_n(x_0,\dots,x_n)$，暂时把 $x_0,\dots,x_{n-1}$ 固定。最后一行是 $1, x_n, \dots, x_n^n$，所以 D_n 是关于 x_n 的至多 n 次多项式。当 $x_n = x_i$ 时两行相同，故它在 $x_0,\dots,x_{n-1}$ 处都为零，只能写成

$$D_n = C\prod_{i=0}^{n-1}(x_n - x_i).$$

按最后一行展开，x_n^n 的系数恰为左上角的 n 阶行列式 D_{n-1}，所以 $C = D_{n-1}$。从 $D_0 = 1$ 开始反复使用这一关系，就得到 $\prod_{i<j}(x_j-x_i)$。互异节点使每一个因子都非零。

定理 3.3（多项式插值的存在唯一性） 对 $n+1$ 个互异实节点和任意实数据，存在唯一的 $p_n \in \mathcal{P}_n$ 满足插值条件。

证明. 先构造

$$\ell_i(x) = \prod_{\substack{0\le j\le n\\ j\ne i}} \frac{x - x_j}{x_i - x_j}.$$

由于节点互异，分母非零；且 $\ell_i(x_j) = \delta_{ij}$。因此

$$p_n(x) = \sum_{i=0}^{n} y_i \ell_i(x) \tag{3.1}$$

满足要求，证明了存在性。如果 p_n, q_n 都满足条件，则 $p_n - q_n$ 是次数至多 n 的多项式，却有 $n+1$ 个不同零点，只能恒为零。 □

3.3 Lagrange 插值多项式

ℓ_i 就像针对第 i 个读数设计的开关：在自己的节点上取 1，在其他节点上取 0。特别地，常函数 1 的插值仍为 1，由唯一性有 $\sum_i \ell_i(x) = 1$。这个关系以后也会出现在求积权重的推导中。

例 3.1（三点插值） 求通过 $(0,1),(1,2),(2,5)$ 的二次插值多项式，并估计 $x = 1/2$ 处的函数值。

解 Lagrange 公式给出

$$p_2(x) = \frac{(x-1)(x-2)}{2} - 2x(x-2) + \frac{5}{2}x(x-1) = 1 + x^2.$$

在 $x = 1/2$ 处得到 1.25。如果真实函数并不是 $1+x^2$，这个值仍然是插值值，但未必是真值。插值条件只约束节点上的行为。

将三点插值的构造拆开看，节点 $0,1,2$ 对应三个基函数。先分别画出 ℓ_i，再乘以对应数据 $1,2,5$，最后逐点相加，就得到 $p_2 = 1 + x^2$。中间的单项可以为负，只有它们的和需要通过全部数据点。

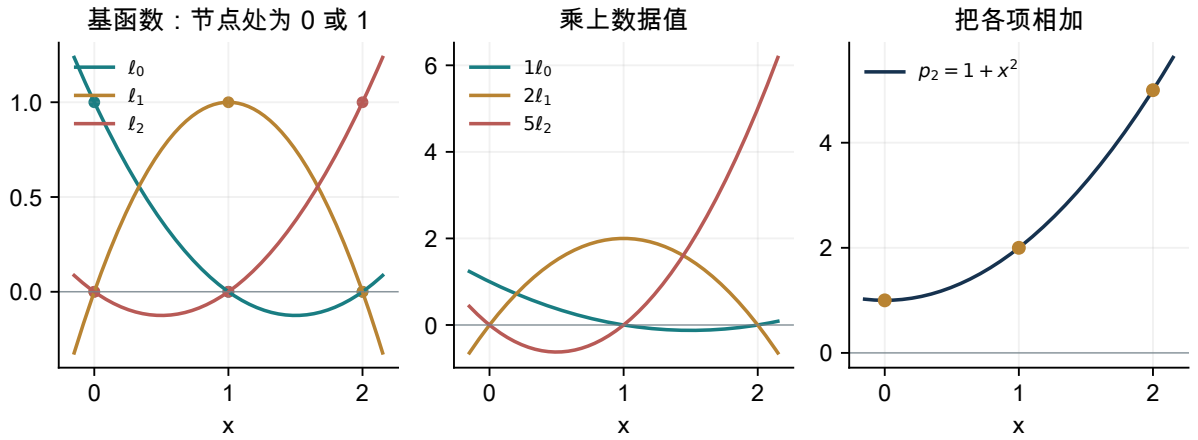


图 3.1 Lagrange 插值的三个计算环节。相同颜色始终表示同一个节点的贡献；右图的金色点是原始数据。

插值余项

设数据来自一个光滑函数 f。定义节点多项式

$$\omega_{n+1}(t) = \prod_{i=0}^{n} (t - x_i).$$

它在所有节点上消失，因此它最适合用来表达插值误差的形状。

定理 3.4 (Lagrange 插值余项) 若 $f \in C^{n+1}[a,b]$，节点和待估点 x 均在 $[a,b]$ 中，则存在位于这些点最小包含区间内的 ξ，使

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}\omega_{n+1}(x). \tag{3.2}$$

在节点处，等式两端均为零。

证明. 设 x 不是节点，并记

$$c = \frac{f(x) - p_n(x)}{\omega_{n+1}(x)}, \qquad g(t) = f(t) - p_n(t) - c\omega_{n+1}(t).$$

g 在 $n+1$ 个节点及 x 处均为零，共有 $n+2$ 个不同零点。反复应用 Rolle 定理，$g^{(n+1)}$ 至少有一个零点 ξ。因为 $p_n^{(n+1)} = 0$，而首一多项式 ω_{n+1} 的 $n+1$ 阶导数为 $(n+1)!$，于是

$$0 = f^{(n+1)}(\xi) - c(n+1)!.$$

代回 c 的定义即得结论。 □

证明中的 x 是固定的，ξ 依赖于它。因此**不能把余项中的 ξ 当作常数，对整个等式随意求导或积分**。求导误差和求积误差需要各自的推导。

对两端点的线性插值，若 $|f''| \le M_2$，则

$$|f(x) - p_1(x)| \le \frac{M_2}{2}|(x-a)(x-b)| \le \frac{M_2(b-a)^2}{8}.$$

这个常数可以直接算。令 $h=b-a$、$t=(x-a)/h$，则 $0\le t\le 1$，并且

$$|(x-a)(x-b)| = h^2 t(1-t) = h^2\left[\frac{1}{4}-\left(t-\frac{1}{2}\right)^2\right] \le \frac{h^2}{4}.$$

再乘余项中的 $M_2/2$，得到 $M_2h^2/8$；最坏的节点乘积出现在区间中点。误差常数因此来自一个明确的最大值问题。

这条界把“曲率越大，直线近似越差”变成了明确的数量关系。

例 3.2 (用误差界决定节点间距) 在 $[1,2]$ 上用分段线性插值近似 $\sqrt{x}$。若误差要求不超过 10^{-4}，等距网格至少应取多少个子区间才能由余项界保证?

解 因 $|f''(x)| = 1/(4x^{3/2}) \le 1/4$，最大网格宽度为 h 时，误差不超过 $h^2/32$。若要求不超过 10^{-4}，只需 $h\le\sqrt{0.0032}\approx 0.05657$。取 18 个等长子区间即可满足这条充分条件。

余项估计在使用时有两个独立步骤。先从函数的光滑性得到高阶导数的界，再根据节点位置估计节点多项式 ω_{n+1}。如果导数界很大、节点分布不合理，或者待估点远离节点区间，即使公式中存在 $(n+1)!$，也不能保证误差很小。

这里 $C^k[a,b]$ 表示在该闭区间上具有 k 阶连续导数的函数。要求 $f\in C^{n+1}$，是为了反复使用 Rolle 定理并控制余项；它不是插值多项式存在的条件。只要节点互异，任意数据都可以插值，哪怕这些数据并非来自一个光滑函数。

3.4 牛顿插值多项式

Lagrange 公式直接给出答案，却没有保留“从少量节点逐步增加信息”的计算过程。若新增一个节点后重新计算全部基函数，会重复很多工作。Newton 形式通过更换基，保留已经确定的低阶部分，只增加一个在旧节点处为零的新项。

定义 3.5 (差商) 零阶差商就是函数值 $f[x_i]=f(x_i)$。对互异节点，一阶差商是割线斜率

$$f[x_i,x_j]=\frac{f(x_j)-f(x_i)}{x_j-x_i}.$$

更高阶差商通过相邻低阶差商的差再除以端点间距得到；它描述已有低阶变化仍未解释的部分。

Lagrange 形式对所有节点一视同仁，但每加一个节点，全部基函数都要改变。Newton 形式使用逐次增加零点的基：

$$1,\quad (x-x_0),\quad (x-x_0)(x-x_1),\quad \dots.$$

新增的高次项在旧节点上自动为零，因此不会破坏已有插值条件。

差商也称均差，其递推定义为

$$f[x_i]=f(x_i),\qquad f[x_i,\dots,x_{i+k}]=\frac{f[x_{i+1},\dots,x_{i+k}]-f[x_i,\dots,x_{i+k-1}]}{x_{i+k}-x_i}.$$

先只看增加一个节点会发生什么。p_k-p_{k-1} 在 $x_0,\dots,x_{k-1}$ 上都为零，次数至多为 k，所以必有

$$p_k(x)-p_{k-1}(x)=c_k\prod_{j=0}^{k-1}(x-x_j).$$

在 $x = x_k$ 处代入新条件，便得到

$$c_k = \frac{f(x_k) - p_{k-1}(x_k)}{\prod_{j=0}^{k-1}(x_k - x_j)}.$$

因此新增系数衡量的是：旧插值在新节点上还差多少，再除以新基函数在该节点上的值。下面通过最高次系数的递推，识别这个 c_k 恰好就是 k 阶差商。

由逐次满足节点条件可得到

$$p_n(x) = f[x_0] + \sum_{k=1}^{n} f[x_0, \ldots, x_k] \prod_{j=0}^{k-1}(x - x_j). \tag{3.3}$$

为什么系数恰好是差商？设 $p_{i:j}$ 是节点 $x_i, \ldots, x_j$ 上的插值多项式，直接验证可得递推

$$p_{i:j}(x) = \frac{(x - x_i)p_{i+1:j}(x) - (x - x_j)p_{i:j-1}(x)}{x_j - x_i}.$$

为核对这个递推，不必先展开所有系数。在左端节点 x_i，第一项消失，第二项变成 $p_{i:j-1}(x_i)$；在右端节点 x_j，第二项消失，第一项变成 $p_{i+1:j}(x_j)$。若 x_l 是中间节点，两个低阶多项式在此处都等于 $f(x_l)$，所以右侧为

$$\frac{(x_l - x_i) - (x_l - x_j)}{x_j - x_i} f(x_l) = f(x_l).$$

右侧次数至多为 $j - i$，又满足全部 $j - i + 1$ 个插值条件，因此由唯一性等于 $p_{i:j}$。设 $a_{i:j}$ 表示其最高次系数，比较递推中的最高次项便有

$$a_{i:j} = \frac{a_{i+1:j} - a_{i:j-1}}{x_j - x_i}, \qquad a_{i:i} = f(x_i).$$

这与差商的定义及初值完全相同，所以 $a_{i:j} = f[x_i, \ldots, x_j]$。在 Newton 的逐次生成中，新添项是唯一的 k 次项，故其系数 c_k 也等于这个最高次系数。

差商虽然递推时有节点顺序，但最高次系数由插值多项式唯一决定，所以对节点置换对称。若 $f \in C^k$，则

$$f[x_0, \ldots, x_k] = \frac{f^{(k)}(\xi)}{k!}.$$

差商与导数的关系也可逐步核对。$g = f - p_k$ 有 $k + 1$ 个不同零点；对相邻零点之间应用 Rolle 定理，g' 至少有 k 个零点。继续做下去，$g^{(k)}$ 至少在某处 ξ 为零。由于 p_k 的最高次系数是 $f[x_0, \ldots, x_k]$，

$$p_k^{(k)}(x) = k! f[x_0, \ldots, x_k], \qquad 0 = g^{(k)}(\xi) = f^{(k)}(\xi) - k! f[x_0, \ldots, x_k].$$

这就给出差商公式中的 $k!$。对次数小于 k 的多项式，k 阶导数恒为零，因而差商也为零。

例 3.3 (把差商表真正算一遍)　对数据 $(0,1),(1,2),(2,5)$ 构造差商表与 Newton 插值多项式，再分析加入 $(3,10)$ 后的变化。

解　将新增节点 $(3,10)$ 一并放入表中，可以同时看清递推和系数读取。

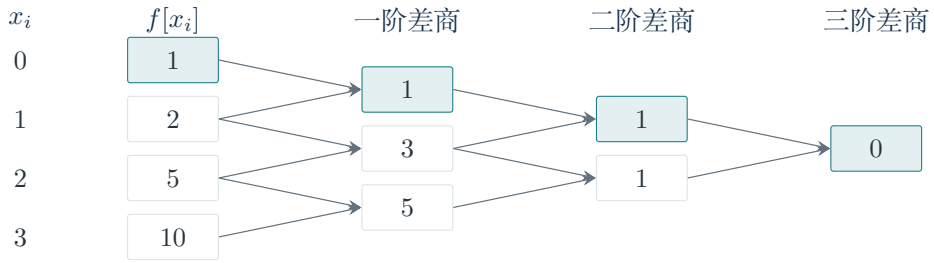


表 3.1　差商表的递推依赖。着色单元格为 $f[x_0], f[x_0,x_1], f[x_0,x_1,x_2], f[x_0,x_1,x_2,x_3]$。

每个箭头都表示对相邻两项作差，再除以对应节点的跨度。例如

$$f[x_0,x_1,x_2]=\frac{3-1}{2-0}=1,\qquad f[x_0,x_1,x_2,x_3]=\frac{1-1}{3-0}=0.$$

沿表中着色的上边缘读取 $1,1,1,0$，依次作为 Newton 基 $1, x, x(x-1), x(x-1)(x-2)$ 的系数。

零阶差商为 $1,2,5$，一阶差商为 $1,3$，二阶差商为 $(3-1)/(2-0)=1$。因此

$$p_2(x)=1+x+x(x-1)=1+x^2.$$

如果再加入 $(3,10)$，新的三阶差商为零，原多项式无需改变。这是用新观测检验已有模型的一个简单方式。

Newton 形式可用嵌套乘法在 $O(n)$ 次运算内求值：

```
def evaluate_newton(nodes, coeff, t):
    value = coeff[-1]
    for k in range(len(coeff) - 2, -1, -1):
        # 把上一层乘积包进当前一层，避免重复乘法。
        value = coeff[k] + (t - nodes[k]) * value
    return value
```

差商表通常需要 $O(n^2)$ 次运算，可原位保存为长度 $n+1$ 的数组。求系数与在多个点求值是两个不同阶段，复杂度也应分开计算。

差分与等距节点

对等距节点 $x_i = x_0 + ih$，定义前向差分 $\Delta f_i = f_{i+1} - f_i$。因为每次差商的分母依次为 $h, 2h, \dots, kh$，归纳得到

$$f[x_0,\dots,x_k]=\frac{\Delta^k f_0}{k!\,h^k}.$$

归纳中的分母不能省略。假设 $k-1$ 阶关系已经成立，则

$$f[x_i,\dots,x_{i+k}]=\frac{\Delta^{k-1}f_{i+1}-\Delta^{k-1}f_i}{(k-1)!\,h^{k-1}\cdot kh}=\frac{\Delta^k f_i}{k!\,h^k}.$$

其中 $x_{i+k}-x_i=kh$。当 $k=1$ 时，这就是一阶差商的定义，故归纳从这里开始。再把 $x-x_j=h(s-j)$ 代入 Newton 乘积，k 个 h 与分母中的 h^k 抵消，才得到前向差分插值公式。

令 $s=(x-x_0)/h$，则 Newton 前向公式变成

$$p_n(x)=f_0+s\Delta f_0+\frac{s(s-1)}{2!}\Delta^2 f_0+\cdots+\frac{s(s-1)\cdots(s-n+1)}{n!}\Delta^n f_0.$$

在右端附近，用 $t=(x-x_n)/h$ 和后向差分 $\nabla f_i=f_i-f_{i-1}$，可写成

$$p_n(x)=f_n+t\nabla f_n+\frac{t(t+1)}{2!}\nabla^2 f_n+\cdots.$$

两式表示同一个多项式，区别在于数据组织与计算位置。高阶差分会放大噪声，因此差分表中后面几列异常抖动时，不能只把它看成函数的高阶变化。

同一组数据还可以列成前向差分表。这里节点间隔为 $h=1$，差分只作相减；二阶差商还要除以 2!，因此表中二阶差分 2 对应二阶差商 1。

x_i	f_i	Δf_i	$\Delta^2 f_i$	$\Delta^3 f_i$
0	1	1	2	0
1	2	3	2	
2	5	5		
3	10			

表 3.2 同一组等距数据的前向差分表。空白处表示现有数据不足以继续计算。

这两张表的数字不能逐列直接混用。非等距节点时，差商分母还会随起止节点变化，等距差分公式便不再直接适用。

3.5 Hermite 插值多项式

函数值只能决定曲线经过哪里，导数还规定它以怎样的方向经过。例如连接两段运动轨迹时，仅匹配位置可能留下速度突变；同时匹配位置和速度，就需要把导数作为独立数据。

定义 3.6 (Hermite 插值) 在若干节点上，同时给定函数值与一定阶数的导数值，要求插值多项式逐项满足这些条件，称为 Hermite 插值。对每个节点同时给定函数值和一阶导数时，总共 $2n+2$ 个条件对应空间 $\mathcal{P}_{2n+1}$。

这里重复出现的节点代表不同阶的导数信息，而不是把同一个函数值条件重复使用。重节点差商正是把这两种信息统一写入 Newton 形式的办法。

有些问题不仅知道函数值，还知道斜率。例如轨迹在两端的位置和速度都已给定。此时要求

$$H(x_i)=f(x_i),\qquad H'(x_i)=f'(x_i),\quad i=0,\dots,n.$$

共有 $2n+2$ 个条件，恰好对应 $\mathcal{P}_{2n+1}$ 的维数。若两个解存在，其差在每个节点有至少二重零点，而次数不超过 $2n+1$，因此解唯一。

记 Lagrange 基为 ℓ_i，可构造

$$A_i(x)=[1-2\ell_i'(x_i)(x-x_i)]\ell_i(x)^2,\qquad B_i(x)=(x-x_i)\ell_i(x)^2.$$

先验证最容易忽略的导数条件。若 $j\neq i$，ℓ_i 在 x_j 有因子 $x-x_j$，所以 ℓ_i^2 在那里有二重零点，它本身和一阶导数都为零。故 A_i,B_i 在别的节点上都不会改变函数值和斜率。

在自己的节点，记 $a=\ell_i'(x_i)$，且 $\ell_i(x_i)=1$。对 A_i 求导：

$$A_i'(x)=-2a\ell_i(x)^2+[1-2a(x-x_i)]\,2\ell_i(x)\ell_i'(x).$$

代入 x_i 得 $A_i'(x_i)=-2a+2a=0$，同时 $A_i(x_i)=1$。类似地，

$$B_i'(x)=\ell_i(x)^2+(x-x_i)2\ell_i(x)\ell_i'(x),$$

故 $B_i(x_i)=0$、$B_i'(x_i)=1$。因此，A_i 只负责第 i 个函数值，B_i 只负责第 i 个导数值。

因此插值多项式为

$$H(x)=\sum_{i=0}^{n}[f(x_i)A_i(x)+f'(x_i)B_i(x)].$$

若 $f\in C^{2n+2}[a,b]$，重复零点版本的 Rolle 论证给出

$$f(x)-H(x)=\frac{f^{(2n+2)}(\xi)}{(2n+2)!}\prod_{i=0}^{n}(x-x_i)^2. \tag{3.4}$$

这个余项仍可从辅助函数得到，而不需要猜测。对不是节点的固定 x，令

$$c=\frac{f(x)-H(x)}{\prod_i(x-x_i)^2},\qquad g(t)=f(t)-H(t)-c\prod_i(t-x_i)^2.$$

每个节点既满足 $g(x_i)=0$，又满足 $g'(x_i)=0$；加上 $g(x)=0$，总共给出按重数计的 $2n+3$ 个零点条件。

带重数的 Rolle 计数可以这样理解：一个 r 重零点求导后仍留下至少 $r-1$ 重；每对相邻不同零点之间又产生至少一个新零点。因此每求导一次，零点条件总数至少只减少一个。连续求 $2n+2$ 次导数，仍有一个零点 ξ。此时 $H^{(2n+2)}=0$，首一 $2n+2$ 次节点乘积的导数为 $(2n+2)!$，于是

$$0=f^{(2n+2)}(\xi)-c(2n+2)!.$$

解出 c，正好得到上述余项。重节点差商的定义也与这个极限相容：当节点都趋于 x_i，差商的导数表达式趋于 $f^{(k)}(x_i)/k!$。

下面固定 $H(0)=0,H(1)=1$，只改变两端导数 m_0,m_1。零斜率使曲线在端点变平；两端斜率都为 1 时，曲线恰好是一条直线；较大的起始斜率和负的终止斜率会形成拱起。

重节点差商提供了统一记号：$f[x_i,x_i]=f'(x_i)$，一般有 $f[\underbrace{x_i,\dots,x_i}_{k+1}]=f^{(k)}(x_i)/k!$。当所有节点合并到同一点时，Newton 形式退化为 Taylor 多项式。Taylor 展开因此可以看成所有信息集中在一个节点的极端插值。

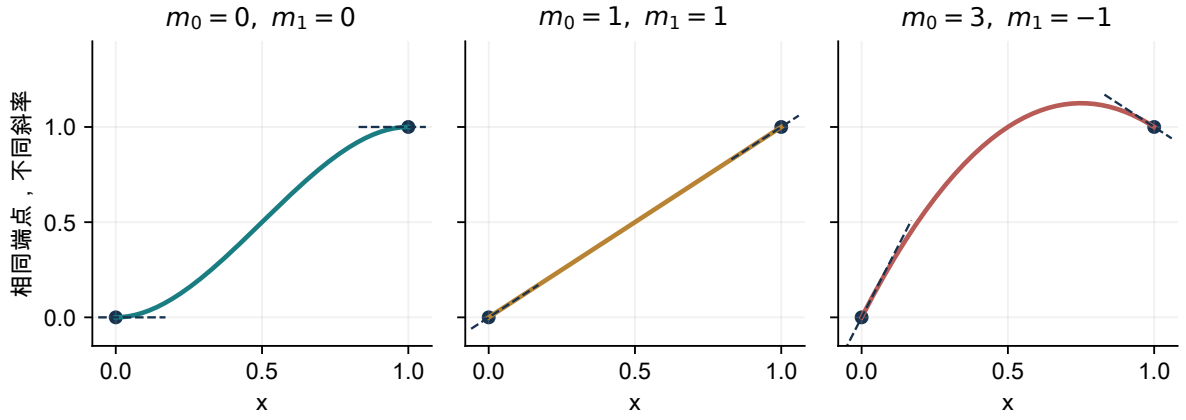


图 3.2 相同函数值约束下，导数改变三次 Hermite 曲线的形状。深色虚线是端点处的切线，彩色曲线在端点与切线相切。

3.6 分段低次插值

余项 (3.2) 有两个相乘因素：高阶导数与节点多项式。增加次数既改变 $f^{(n+1)}$，也改变节点乘积，所以不能仅凭分母有阶乘就断言误差趋于零。

经典例子是 $f(x) = 1/(1+25x^2)$ 在 $[-1,1]$ 上的等距插值。虽然 f 很光滑，端点附近的高次插值仍可能剧烈振荡，这就是 Runge 现象。应对它有两条路线：保留全局多项式但改善节点分布，或改用局部低次插值。

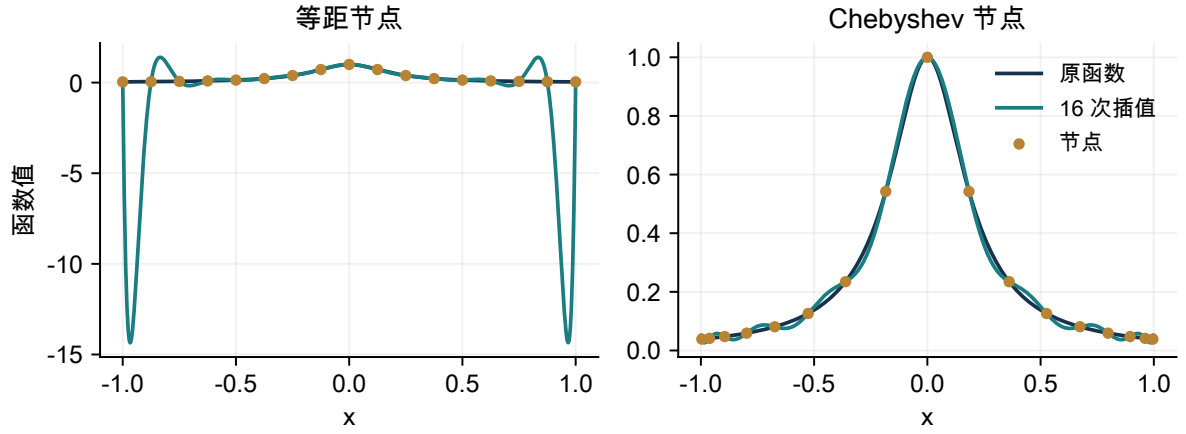


图 3.3 同一个函数、同样数量的节点。等距高次插值在端点附近振荡；Chebyshev 节点向两端聚集，明显改善近似。图中采用 17 个节点，两幅图的纵轴尺度不同。

第二类误差来自数据扰动。若每个数据有 $|\Delta y_i| \le \varepsilon$，则

$$|\Delta p_n(x)| \le \varepsilon \sum_{i=0}^{n} |\ell_i(x)|.$$

定义 Lebesgue 常数

$$\Lambda_n = \max_{x\in[a,b]} \sum_{i=0}^{n} |\ell_i(x)|.$$

它控制插值算子对数据误差的最坏放大。设 I_n 为插值算子，任取 $q \in \mathcal{P}_n$，利用 $I_n q = q$ 得

$$f - I_n f = (f - q) - I_n(f - q),$$

因此

$$\|f - I_n f\|_\infty \le (1 + \Lambda_n) \inf_{q \in \mathcal{P}_n} \|f - q\|_\infty . \tag{3.5}$$

这条不等式清楚地分开了“函数能否被低次多项式逼近”和“所选节点是否把误差放大”。

中间的范数估计是：对任意函数 g，

$$|I_n g(x)| = \left| \sum_i g(x_i)\ell_i(x) \right| \le \|g\|_\infty \sum_i |\ell_i(x)|, \qquad \|I_n g\|_\infty \le \Lambda_n \|g\|_\infty .$$

在前面的恒等式中取 $g = f - q$，再用三角不等式，便得到对每个 q 都成立的 $\|f - I_n f\|_\infty \le (1 + \Lambda_n)\|f - q\|_\infty$。左边与 q 无关，因此右边可以取下确界。

在 $[-1, 1]$ 上常用 Chebyshev 零点

$$x_i = \cos \frac{(2i+1)\pi}{2(n+1)}, \qquad i = 0, \dots, n.$$

其节点多项式与 $T_{n+1}(x) = \cos((n+1)\arccos x)$ 成比例。函数逼近一章将解释它为何在首一多项式中具有最小的最大绝对值。

最后，好的节点也需要好的求值公式。令

$$w_i = \frac{1}{\prod_{j \ne i}(x_i - x_j)}.$$

利用 Lagrange 基函数之和为 1，消去公共的节点多项式，得到重心公式

$$p_n(x) = \frac{\displaystyle\sum_{i=0}^{n} \frac{w_i y_i}{x - x_i}}{\displaystyle\sum_{i=0}^{n} \frac{w_i}{x - x_i}}, \qquad x \ne x_i. \tag{3.6}$$

重心公式的分母来自恒等式 $\sum_i \ell_i(x) = 1$，不能只从原来的分子凭空加出。

这个恒等式本身来自插值唯一性：左边次数至多为 n，在每个节点都等于 1，因此它就是常函数 1 的插值多项式，必恒等于 1。对非节点 x，

$$\ell_i(x) = \frac{\omega_{n+1}(x)}{x - x_i} \frac{1}{\prod_{j \ne i}(x_i - x_j)} = \omega_{n+1}(x) \frac{w_i}{x - x_i}.$$

所以 $p_n(x) = \omega_{n+1}(x) \sum_i w_i y_i/(x - x_i)$，而 $1 = \omega_{n+1}(x) \sum_i w_i/(x - x_i)$。两式相除，公共节点乘积消去，即得重心表示。

在节点上直接返回相应 y_i。全部 w_i 乘同一个非零常数不改变结果，可据此缩放，减少溢出风险。一般节点的朴素权重计算仍可能不稳；对结构化节点宜使用相应的显式权重。

前面的失败来自让一个高次多项式同时负责整个区间。分段方法先划分网格，各段只负责局部数据，再通过连接条件得到全局函数。增加节点时，可以保持每段次数固定，因此不再要求越来越高阶的导数。

定义 3.7（分段插值与光滑连接） 在划分 $a = x_0 < \cdots < x_n = b$ 上，若 p 在每个小区间都是某个低次多项式，并在节点满足给定数据条件，则称为分段多项式插值。$p \in C^r[a, b]$ 表示函数及直到 r 阶的导数在内部节点左右相接。

连续性是全局要求，低次性是局部要求。分段线性函数虽然每段都可微，但连接处左右斜率可能不同，因而通常只是 C^0。共享同一组节点斜率的分段三次 Hermite 则为 C^1，但二阶导数仍可能跳变。

设 $a=x_0<x_1<\cdots<x_n=b$，$h_i=x_{i+1}-x_i$。在 $[x_i,x_{i+1}]$ 上，线性插值为

$$L(x)=\frac{x_{i+1}-x}{h_i}y_i+\frac{x-x_i}{h_i}y_{i+1}.$$

若 $f\in C^2[a,b]$，令 $h=\max h_i$，Lagrange 余项立即给出

$$\|f-L\|_\infty\le\frac{1}{8}h^2\left\|f''\right\|_\infty.$$

这条误差界只需要二阶导数，不随节点总数要求越来越高的光滑性。它也是分段方法可靠的重要原因。

线性插值在节点处通常有折角。如果已知每个节点的斜率 m_i，令 $t=(x-x_i)/h_i$，可用三次 Hermite 多项式

$$\begin{aligned}H_i(x)=(2t^3-3t^2+1)y_i+(-2t^3+3t^2)y_{i+1}\\+h_i(t^3-2t^2+t)m_i+h_i(t^3-t^2)m_{i+1}.\end{aligned}\tag{3.7}$$

四个基函数分别控制左端值、右端值、左端斜率和右端斜率。斜率项前的 h_i 不能省略，因为 $\mathrm{d}/\mathrm{d}x=h_i^{-1}\mathrm{d}/\mathrm{d}t$。

四个三次基函数可以用待定系数推出来。例如，控制左端函数值的基函数 $h_{00}(t)$ 要满足

$$h_{00}(0)=1,\quad h_{00}(1)=0,\quad h'_{00}(0)=h'_{00}(1)=0.$$

设 $h_{00}=a+bt+ct^2+dt^3$。在 $t=0$ 处的值和导数条件给出 $a=1,b=0$，$t=1$ 处的两条条件变成 $c+d=-1$、$2c+3d=0$，解得 $c=-3,d=2$。另外三个基函数的条件也可列出。右端值基 h_{01} 有 $a=b=0$、$c+d=1$、$2c+3d=0$，故 $c=3,d=-2$。左端斜率基 h_{10} 有 $a=0,b=1$、$c+d=-1$、$2c+3d=-1$，故 $c=-2,d=1$。右端斜率基 h_{11} 有 $a=b=0$、$c+d=0$、$2c+3d=1$，故 $c=-1,d=1$。合起来得到

$$h_{01}=-2t^3+3t^2,\quad h_{10}=t^3-2t^2+t,\quad h_{11}=t^3-t^2.$$

因此局部插值就是 $h_{00}y_i+h_{01}y_{i+1}+h_ih_{10}m_i+h_ih_{11}m_{i+1}$。因 $\mathrm{d}/\mathrm{d}x=h_i^{-1}\mathrm{d}/\mathrm{d}t$，在斜率项前乘 h_i，才能使对 x 的导数等于给定的 m_i。

若 $m_i=f'(x_i)$ 且 $f\in C^4$，由 (3.4) 有

$$|f(x)-H_i(x)|\le\frac{\left\|f^{(4)}\right\|_\infty}{4!}(x-x_i)^2(x-x_{i+1})^2\le\frac{h_i^4}{384}\left\|f^{(4)}\right\|_\infty.$$

因此全局函数值误差为 $O(h^4)$。如果斜率只是近似值，其误差还要乘以 h_i 后加入函数误差：要保留四阶精度，通常需要节点斜率误差达到 $O(h^3)$。随便用一个一阶差商代替斜率，不会自动得到四阶精度。

这个四阶误差常数来自 $0\le t(1-t)\le1/4$：节点平方乘积是 $h_i^4t^2(1-t)^2\le h_i^4/16$，再除以 $4!=24$ 就是 $h_i^4/384$。

若使用的斜率变成 $m_i+\varepsilon_i,m_{i+1}+\varepsilon_{i+1}$，曲线的附加变化恰为

$$\Delta H_i(x)=h_i[h_{10}(t)\varepsilon_i+h_{11}(t)\varepsilon_{i+1}].$$

在 $[0,1]$ 上，$|h_{10}|=t(1-t)^2\le4/27$、$|h_{11}|=t^2(1-t)\le4/27$；这两个最大值分别在 $t=1/3,2/3$ 处取得。因此附加误差不超过 $8h_i\max(|\varepsilon_i|,|\varepsilon_{i+1}|)/27$。要使它保持 $O(h^4)$，斜率误差便需要达到 $O(h^3)$。

3.7 三次样条插值

高次多项式把整个区间绑在一起：改变一个节点，远处的曲线也可能变化。分段方法换了一种思路，先把大区间拆小，再在每段使用低次多项式。这样，精度主要通过网格变细来提高，而不必让次数不断增加。

但分段之后又产生一个新问题：小段在连接处应当多光滑？线性插值只保证函数连续，Hermite 插值可以保证一阶导数连续，三次样条则进一步要求二阶导数连续。

定义 3.8 (三次样条插值函数) 对划分 $a = x_0 < \cdots < x_n = b$，若 $S \in C^2[a,b]$，每个限制 $S|_{[x_i,x_{i+1}]} \in \mathcal{P}_3$，且 $S(x_i) = y_i$，则称 S 为三次样条插值函数。要唯一确定它，还需要两条合适的边界条件。

与一般分段三次 Hermite 相比，样条不预先指定所有节点斜率，而是让二阶导数连续这一条件协调相邻区间。这样得到的曲线有更高的整体光滑性，但各段也因此通过一个线性系统相互联系。

三次样条 S 满足：每个小区间上是次数至多 3 的多项式，$S(x_i) = y_i$，并且 $S \in C^2[a,b]$。

共有 n 段，每段四个系数，总计 $4n$ 个未知量。各段两端函数值共给出 $2n$ 个条件，内部 $n-1$ 个节点的一、二阶导数连续各给 $n-1$ 个条件，一共 $4n-2$ 个。还缺两条边界条件。

常见选择为：给定两端一阶导数的固支样条；给定两端二阶导数的样条；以及 $y_0 = y_n$ 时，使一、二阶导数首尾相等的周期样条。自然样条采用

$$S''(a) = S''(b) = 0.$$

这是一种边界模型，而不是所有函数都满足的真理。若真实端点曲率并不为零，自然边界会引入端点附近的偏差。

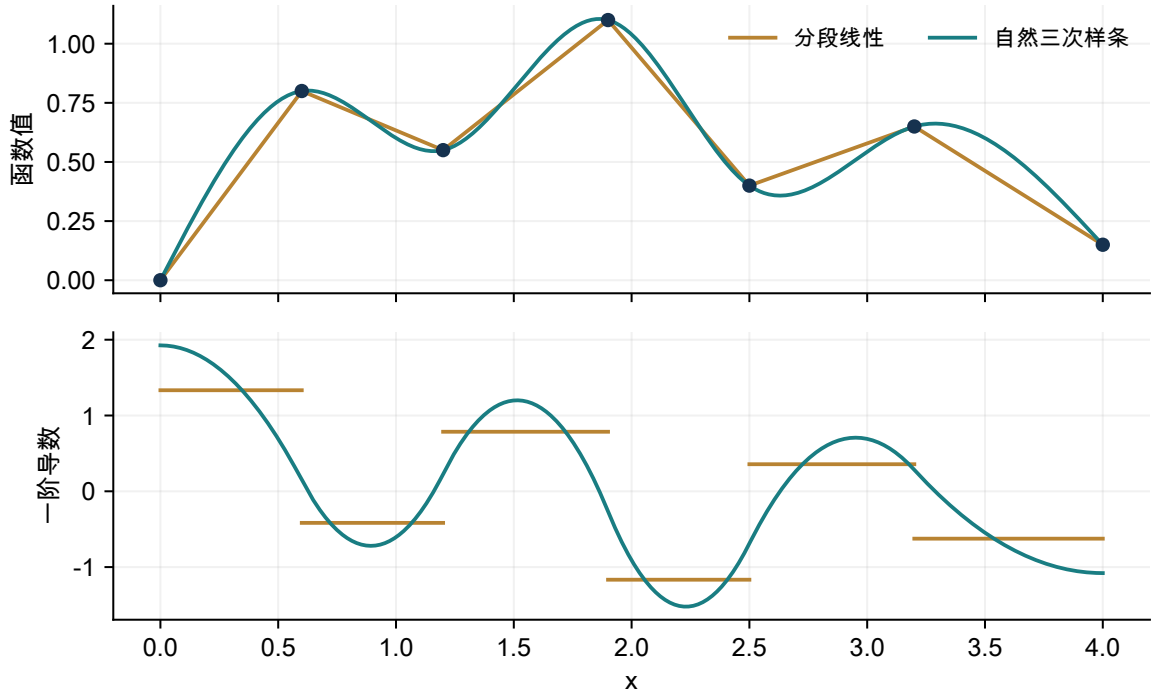


图 3.4 同一组离散值的分段线性插值与自然三次样条。上图比较曲线，下图比较导数：线性插值的斜率在节点处跳变，样条斜率连续。

三弯矩方程

令 $M_i = S''(x_i)$。由于每段 S_i 为三次，其二阶导数是一次函数；又因两端值已知，必有

$$S_i''(x) = M_i\frac{x_{i+1}-x}{h_i} + M_{i+1}\frac{x-x_i}{h_i}.$$

可以先对二阶导数写出一个方便积分的原函数：

$$S_i(x) = \frac{M_i(x_{i+1}-x)^3}{6h_i} + \frac{M_{i+1}(x-x_i)^3}{6h_i} + A_i(x_{i+1}-x) + B_i(x-x_i).$$

前两项求两次导数正好恢复给定的线性 S_i''，后两项合在一起是任意一次函数，代表两次积分留下的常数。在 x_i 处，只有 $M_ih_i^2/6 + A_ih_i$ 留下，故

$$A_i = \frac{y_i - M_ih_i^2/6}{h_i}.$$

同理，在 x_{i+1} 处得到 $B_i = (y_{i+1} - M_{i+1}h_i^2/6)/h_i$。代入以后就是下面的分段表达式。

积分两次，再用 $S_i(x_i) = y_i, S_i(x_{i+1}) = y_{i+1}$ 确定两个积分常数，得到

$$S_i(x) = \frac{M_i(x_{i+1}-x)^3}{6h_i} + \frac{M_{i+1}(x-x_i)^3}{6h_i} \tag{3.8}$$

$$+ \left(y_i - \frac{M_ih_i^2}{6}\right)\frac{x_{i+1}-x}{h_i} + \left(y_{i+1} - \frac{M_{i+1}h_i^2}{6}\right)\frac{x-x_i}{h_i}. \tag{3.9}$$

这一形式已经满足函数值插值和二阶导数连接。剩下的条件是内部节点的一阶导数连续。

记 $d_i = (y_{i+1}-y_i)/h_i$。对 (3.9) 求导，分别在两端取值：

$$S_i'(x_i) = d_i - \frac{h_i}{6}(2M_i + M_{i+1}), \qquad S_i'(x_{i+1}) = d_i + \frac{h_i}{6}(M_i + 2M_{i+1}).$$

在节点 x_i，令左段右端导数等于右段左端导数，整理得

$$h_{i-1}M_{i-1} + 2(h_{i-1}+h_i)M_i + h_iM_{i+1} = 6(d_i - d_{i-1}), \quad 1 \le i \le n-1. \tag{3.10}$$

每个方程只联系三个相邻弯矩，因此称为三弯矩方程。

左段在 x_i 的导数为 $d_{i-1}+h_{i-1}(M_{i-1}+2M_i)/6$，右段在同一点的导数为 $d_i-h_i(2M_i+M_{i+1})/6$。把它们相等的式子乘 6：

$$6d_{i-1} + h_{i-1}M_{i-1} + 2h_{i-1}M_i = 6d_i - 2h_iM_i - h_iM_{i+1}.$$

将含 M 的项放在左边，数据差放在右边，即得三弯矩方程。端点固支方程也由同一对端点导数式得来：分别令第一段的左导数等于 s_a、最后一段的右导数等于 s_b，再移项即可。

自然边界直接给出 $M_0 = M_n = 0$；固支边界 $S'(a) = s_a, S'(b) = s_b$ 则给出

$$2h_0M_0 + h_0M_1 = 6(d_0 - s_a),$$

$$h_{n-1}M_{n-1} + 2h_{n-1}M_n = 6(s_b - d_{n-1}).$$

这些系数形成三对角系统，后面可用 $O(n)$ 的追赶法求解。

> **定理 3.9**（自然三次样条的存在唯一性） 对严格递增节点和任意数据，自然三次样条存在且唯一。

证明. 把 $M_0 = M_n = 0$ 代入内部方程。剩下矩阵的对角元为 $2(h_{i-1} + h_i)$，每行非对角元绝对值之和不超过 $h_{i-1} + h_i$，故严格对角占优。
若该矩阵存在非零零空间向量 v，取 $|v_k| = \max_i |v_i| > 0$，由第 k 行可得

$$|a_{kk}||v_k| \le \sum_{j\neq k} |a_{kj}||v_j| \le \left(\sum_{j\neq k} |a_{kj}|\right) |v_k| < |a_{kk}||v_k|,$$

矛盾。因此弯矩唯一可解，再由 (3.9) 唯一确定每段。构造本身保证所有样条条件。 □

例 3.4 (三个节点的自然样条) 求通过 $(0,0),(1,1),(2,0)$ 的自然三次样条，并计算 $S(1/2)$ 和 $S'(1)$。

解 自然边界给出 $M_0 = M_2 = 0$，内部方程为 $4M_1 = 6(-1-1) = -12$，所以 $M_1 = -3$。代入分段公式，在 $[0,1]$ 上得到

$$S_0(x) = \frac{3}{2}x - \frac{1}{2}x^3.$$

对称性给出 $S_1(x) = S_0(2-x)$。特别地 $S(1/2) = 11/16$，且 $S'(1) = 0$。三个数据点并没有直接指定中点斜率，光滑连接条件把它确定了。

三转角方程与弯曲能量

也可以把节点斜率 $m_i = S'(x_i)$ 作为未知量。为看清所得方程的系数，对局部 Hermite 表达式求两次导数，并在两端代入 $t = 0, 1$：

$$S_i''(x_i) = \frac{6d_i - 4m_i - 2m_{i+1}}{h_i}, \qquad S_i''(x_{i+1}) = \frac{-6d_i + 2m_i + 4m_{i+1}}{h_i}.$$

在内部节点，把左段右端值与右段左端值相等：

$$\frac{-6d_{i-1} + 2m_{i-1} + 4m_i}{h_{i-1}} = \frac{6d_i - 4m_i - 2m_{i+1}}{h_i}.$$

乘 $h_{i-1}h_i/2$ 并移项，就得到下式。自然边界则分别把第一式的左端值与最后一段的右端值设为零，给出 $2m_0 + m_1 = 3d_0$ 和 $m_{n-1} + 2m_n = 3d_{n-1}$。

因此内部节点满足三转角方程

$$h_i m_{i-1} + 2(h_{i-1} + h_i)m_i + h_{i-1}m_{i+1} = 3(h_i d_{i-1} + h_{i-1}d_i). \tag{3.11}$$

这里的左右系数次序与三弯矩方程不同，不能凭外形照搬。自然边界在斜率形式下为 $2m_0 + m_1 = 3d_0$ 和 $m_{n-1} + 2m_n = 3d_{n-1}$；固支边界则直接给定 m_0, m_n。

样条的光滑性还有一个变分解释。设 g 是任何满足相同节点值、且有平方可积二阶导数的足够光滑函数。用

$$J(g) = \int_a^b [g''(x)]^2 \, \mathrm{d}x$$

衡量弯曲能量。在小斜率近似下，它对应薄弹性梁的弯曲代价。

定理 3.10 (自然样条的最小弯曲性质) 自然三次样条 S 在所有具有相同节点值的 $C^2[a,b]$ 函数中唯一最小化 $J(g)$。

证明. 令 $g = S + v$，节点条件给出 $v(x_i) = 0$。先展开平方：

$$J(g) = \int (S'' + v'')^2 = J(S) + 2\int S''v'' + J(v).$$

现在只需说明中间的交叉项为零。在第 i 段分部积分两次：

$$\int_{x_i}^{x_{i+1}} S_i''v'' = [S_i''v']_{x_i}^{x_{i+1}} - [S_i'''v]_{x_i}^{x_{i+1}} + \int_{x_i}^{x_{i+1}} S_i''''v.$$

S_i 是三次多项式，故最后一项为零；节点上 $v = 0$，所以第二个边界项为零。第一项按所有区间求和后，在内部节点留下

$$[S_{i-1}''(x_i) - S_i''(x_i)]v'(x_i) = 0,$$

因为 S'' 连续。区间两端还剩 $S''(b)v'(b) - S''(a)v'(a)$，自然边界使它也为零。于是 $J(g) = J(S) + J(v) \geq J(S)$。
若等号成立，则连续函数 $(v'')^2$ 的积分为零，只能处处为零。因而 v 是一次函数，又在至少两个不同节点为零，只能恒为零。这同时证明最小性和唯一性。 □

样条的平滑来自哪里。自然样条在必须穿过所有节点的前提下，选择总弯曲最小的曲线。它仍然是插值：数据若含噪声，样条也会穿过噪声。若希望平滑噪声，应引入数据拟合项与弯曲惩罚之间的权衡，而不是仅更换边界条件。

样条误差阶的来源

固支样条误差阶的推导. 先在等距网格上说明准确固支条件为何得到四阶函数误差。设 $f \in C^4[a,b]$，并使用真端点斜率。记样条节点斜率为 m_i，真斜率为 $v_i = f'(x_i)$。等距时三转角方程除以 h，成为

$$m_{i-1} + 4m_i + m_{i+1} = 3(d_{i-1} + d_i).$$

把真斜率代入左边并在 x_i 展开：

$$v_{i\pm1} = v_i \pm hf''(x_i) + \frac{h^2}{2}f'''(x_i) + O(h^3),$$

所以左边为 $6v_i + h^2f'''(x_i) + O(h^3)$。右边用

$$d_{i-1} + d_i = \frac{f(x_i + h) - f(x_i - h)}{h} = 2v_i + \frac{h^2}{3}f'''(x_i) + O(h^3)$$

展开，乘 3 后具有相同的前两项。故真斜率代入离散方程只留下 $r_i = O(h^3)$ 的缺陷。
令 $\varepsilon_i = m_i - v_i$，则端点误差为零，内部满足 $\varepsilon_{i-1} + 4\varepsilon_i + \varepsilon_{i+1} = -r_i$。取误差绝对值最大的分量，有

$$4\|\varepsilon\|_\infty \leq 2\|\varepsilon\|_\infty + \|r\|_\infty, \qquad \|\varepsilon\|_\infty \leq \tfrac{1}{2}\|r\|_\infty = O(h^3).$$

这里最大值若在端点，误差本来就是零；否则上面的内部方程适用。节点斜率因此准确到三阶，再乘局部 Hermite 公式中的 h，函数误差便达到四阶。
导数误差不能对含未知 $\xi(x)$ 的余项随意求导。可以换一个可逐项求导的比较对象：令 T_3 是左端的三次 Taylor 多项式，$g = f - T_3$。带积分余项的 Taylor 公式给出，在整段上

$$g = O(h^4), \qquad g' = O(h^3), \qquad g'' = O(h^2).$$

Hermite 插值精确再现 T_3，而 g 的右端函数值为 $O(h^4)$、右端斜率为 $O(h^3)$，左端二者为零。因此 $H(g) = h_{01}g(x_{i+1}) + hh_{11}g'(x_{i+1})$；对 x 求 r 次导数会带出 h^{-r}，所以 $H(g)^{(r)} = O(h^{4-r})$，$r = 0, 1, 2$。

结合斜率误差项 $h(h_{10}\varepsilon_i + h_{11}\varepsilon_{i+1})$，同样按每次求导除以 h 计数，得到

$$\|f - S\|_\infty = O(h^4), \qquad \|f' - S'\|_\infty = O(h^3), \qquad \|f'' - S''\|_\infty = O(h^2).$$

这说明三个阶数来自同一条误差链：节点斜率误差、局部基函数缩放和函数的四阶光滑性。 □

自然边界的情况要另外核对。若真实端点曲率本来为零，记 $z_i = f''(x_i)$，则端点弯矩误差为零。等距三弯矩方程为

$$M_{i-1} + 4M_i + M_{i+1} = \frac{6}{h^2}[f(x_{i+1}) - 2f(x_i) + f(x_{i-1})].$$

真曲率代入两边的缺陷为 $O(h^2)$，因为左边为 $6f''(x_i) + O(h^2)$，右边也为 $6f''(x_i) + O(h^2)$。同样的最大分量估计给出 $M_i - z_i = O(h^2)$。分段公式里弯矩的系数含 h^2，所以函数误差为 $O(h^4)$。为检查没有遗漏另一部分误差，可先用同样端点函数值、真端点曲率构造局部三次多项式；它精确再现 T_3，对 $f - T_3$ 的函数值与曲率数据分别乘以有界基函数和 h^2，其误差也为 $O(h^4)$。

如果真端点曲率非零，上述“端点误差为零”就失效。例如在 $[0, 1]$ 上取 $f(x) = x^2$、$h = 1/n$，真实曲率为 2，自然样条却设 $M_0 = M_n = 0$。令 $\delta_i = M_i - 2$，内部方程变成

$$\delta_{i-1} + 4\delta_i + \delta_{i+1} = 0, \qquad \delta_0 = \delta_n = -2.$$

试取 $\delta_i = r^i$，代入后得到 $r^2 + 4r + 1 = 0$。记模小于 1 的根为 $r = -2 + \sqrt{3}$，利用两端条件可验证

$$\delta_i = -2\frac{r^i + r^{n-i}}{1 + r^n}.$$

在第一段中点，分段公式的两项弯矩误差系数都为 $-h^2/16$，因此

$$S(h/2) - f(h/2) = -\frac{h^2}{16}(\delta_0 + \delta_1), \qquad \frac{S(h/2) - f(h/2)}{h^2} \longrightarrow \frac{\sqrt{3} - 1}{8} > 0.$$

所以不相容的自然边界确实会产生二阶端点误差，并非只是误差界估得过松。

数值上还要区分光滑性与保形性。普通三次样条即使在单调数据上也可能过冲。若任务要求浓度或概率始终非负、曲线严格单调，就需要额外限制斜率的保形插值方法。C^2 光滑并不自动包含这些约束。

几种插值方法的比较

方法	所需数据	主要特点	使用时的条件
Lagrange 与 Newton	节点函数值	同一个全局多项式的不同表示	节点互异，注意高次振荡
Hermite	函数值与导数	同时匹配位置和局部变化	导数数据精度影响结果
分段线性	节点函数值	局部、连续，通常二阶	节点处斜率一般不连续
分段三次 Hermite	函数值、节点斜率	一阶导数连续	准确斜率下函数值四阶
三次样条	函数值与边界条件	二阶导数连续，解三对角系统	边界条件影响端点精度

表 3.3 插值表示、所需信息与光滑性。误差阶均须结合相应的函数光滑性理解。

第 4 章　函数逼近

4.1　引言

插值要求每个节点都准确通过，但这未必是最合适的目标。如果数据有噪声，或者要在整个区间上控制误差，我们更关心一条曲线总体上是否接近目标函数。“接近” 必须由一个明确的误差度量定义。

平方误差把所有位置的偏差累加，适合用内积和正交投影分析；最大误差关注最坏位置，引出一致逼近和等幅交错。两者都叫 “最佳”，但最优解通常不同。

假设实验数据在一条直线附近上下波动。严格插值会把每个测量误差都当作必须满足的约束，导致曲线追着噪声变化。如果只希望描述总体趋势，就应允许部分点存在偏差，再规定怎样比较这些偏差。函数逼近从这里出发：先选择近似空间，再选择误差度量，最后在空间内寻找误差最小者。

定义 4.1 (逼近空间与最佳逼近)　给定目标函数 f、允许的函数集合 V 及误差度量 $\|\cdot\|$，若 $p_* \in V$ 满足

$$\|f - p_*\| = \inf_{p \in V} \|f - p\|,$$

则称 p_* 是该度量下的最佳逼近。不同的空间或度量，通常产生不同的最佳函数。

例如，同样用一次多项式逼近 x^2，最小化误差平方的积分与最小化最大误差，会给出不同常数。没有说明 “在哪个空间、用什么误差”，单独说某个近似 “最好” 没有确定含义。

4.2　正交多项式

为了把函数逼近转成几何问题，需要先把向量的内积推广到函数。对于离散向量，内积把对应分量的乘积相加；对于连续函数，自然的对应操作是把乘积积分。权函数用来调节不同位置的贡献。

定义 4.2 (实内积、正交与正交归一)　实线性空间中的内积 $\langle u, v\rangle$ 对第一个变量线性，满足对称性 $\langle u, v\rangle = \langle v, u\rangle$，以及 $\langle u, u\rangle \geq 0$，等号仅在 $u = 0$ 时成立。若 $\langle u, v\rangle = 0$，称 u, v 正交；一组向量或函数两两正交且各自范数为 1，称为正交归一组。

函数空间中，零函数应按所选内积的意义理解。例如连续正权积分下，平方范数为零的连续函数处处为零；对于平方可积函数，则把几乎处处相等的函数视为同一个元素。离散采样内积只观察节点值，若空间太大，可能存在非零函数在所有节点上都为零，此时它在整个函数空间上只是半内积。

设权函数 $w(x) > 0$ 几乎处处成立，且相关积分有限。定义

$$\langle f, g\rangle_w = \int_a^b w(x) f(x) g(x)\,\mathrm{d}x, \qquad \|f\|_w^2 = \langle f, f\rangle_w .$$

内积还给出后面会用到的 Cauchy–Schwarz 不等式。若 $v \neq 0$，把实数 $t = \langle u, v\rangle / \|v\|^2$ 代入非负量 $\|u - tv\|^2$，展开得

$$0 \le \|u\|^2 - 2t\,\langle u, v\rangle + t^2\,\|v\|^2 = \|u\|^2 - \frac{\langle u, v\rangle^2}{\|v\|^2}.$$

移项并开平方，得到 $|\langle u, v\rangle| \le \|u\|\,\|v\|$；$v = 0$ 时两边都为零。进一步

$$\|u + v\|^2 \le \|u\|^2 + 2\,\|u\|\,\|v\| + \|v\|^2 = (\|u\| + \|v\|)^2,$$

就得到内积诱导范数的三角不等式。对复向量，只要减去正交投影 $v(v^*u)/(v^*v)$ 并展开其长度平方，同样得到 $|v^*u| \le \|v\|_2\,\|u\|_2$。

权越大的位置，对总误差的贡献越大。离散数据也可以定义 $\langle u, v\rangle_w = \sum_i w_i u(x_i) v(x_i)$，其中 $w_i > 0$；此时需注意，内积对所选函数空间是否正定取决于采样是否足够。

定义 4.3（正交多项式序列） 若 $\deg \pi_k = k$，且 $\langle \pi_k, \pi_j\rangle_w = 0$ 对所有 $j \neq k$ 成立，则称 $\{\pi_k\}$ 是对应权与区间上的正交多项式序列。若最高次项系数取 1，称为首一正交多项式；若平方范数取 1，称为正交归一多项式。

性质 4.4（正交多项式的张成空间） 非零正交函数线性无关。对次数依次为 $0, \dots, n$ 的正交多项式，前 $n+1$ 项构成 $\mathcal{P}_n$ 的一组基；因此 π_n 与任意次数小于 n 的多项式正交。

证明. 若 $\sum_{j=0}^{n} c_j \pi_j = 0$，与 π_k 取内积，得 $c_k \|\pi_k\|_w^2 = 0$，故所有系数为零。它们共有 $n+1$ 个，等于 $\mathcal{P}_n$ 的维数，所以构成一组基。任何低次多项式都能用前面的基展开，再利用两两正交即可。 □

正交多项式并不是另一类逼近空间：它们仍然张成普通多项式空间。改变的是坐标，目的是避免单项式基中不同方向的强烈相关，使系数和误差更容易分析。

三项递推

从 $1, x, x^2, \dots$ 出发，逐步减去在已有空间中的投影，即可得到正交多项式。让每个多项式的最高次系数等于 1，记为 π_k。首一化使递推系数更容易比较。

所谓“减去已有方向上的投影”，可以具体写为

$$\pi_n(x) = x^n - \sum_{j=0}^{n-1} \frac{\langle x^n, \pi_j\rangle_w}{\|\pi_j\|_w^2}\,\pi_j(x).$$

对任一 $k < n$ 与 π_k 取内积，和式中只有 $j = k$ 的项不为零，得到 $\langle \pi_n, \pi_k\rangle_w = \langle x^n, \pi_k\rangle_w - \langle x^n, \pi_k\rangle_w = 0$。被减去的都是低次多项式，所以最高次项仍是 x^n。这同时检查了正交性与首一性。

因为 $x\pi_k$ 的次数为 $k+1$，可以在 $\pi_0, \dots, \pi_{k+1}$ 上展开。而当 $j \le k-2$ 时，

$$\langle x\pi_k, \pi_j\rangle_w = \langle \pi_k, x\pi_j\rangle_w = 0,$$

因为 $x\pi_j$ 的次数至多为 $k-1$。所以展开只剩下三个相邻次数：

$$\pi_{k+1}(x) = (x - \alpha_k)\pi_k(x) - \beta_k \pi_{k-1}(x), \tag{4.1}$$

其中

$$\alpha_k = \frac{\langle x\pi_k, \pi_k\rangle_w}{\|\pi_k\|_w^2}, \qquad \beta_k = \frac{\|\pi_k\|_w^2}{\|\pi_{k-1}\|_w^2} > 0.$$

第二式可由 $\langle x\pi_k, \pi_{k-1}\rangle_w = \langle \pi_k, x\pi_{k-1}\rangle_w = \|\pi_k\|_w^2$ 得到。初值为 $\pi_0 = 1$、$\pi_1 = x - \alpha_0$，$k = 0$ 时省略最后一项。

在 $x\pi_k$ 的展开中，最高次系数为 1，所以 π_{k+1} 前的系数为 1。与 π_k 取内积，得到中间系数 α_k。与 π_{k-1} 取内积，得到另一个系数

$$\frac{\langle x\pi_k, \pi_{k-1}\rangle_w}{\|\pi_{k-1}\|_w^2} = \frac{\langle \pi_k, x\pi_{k-1}\rangle_w}{\|\pi_{k-1}\|_w^2}.$$

因为 $x\pi_{k-1}$ 与 π_k 都是首一 k 次多项式，两者之差次数至多 $k-1$，与 π_k 正交。故分子等于 $\langle \pi_k, \pi_k\rangle_w$，系数就是正数 β_k。把 π_{k+1} 单独移到等号左侧，才出现递推式中的减号。

例 4.1 (在 $[-1,1]$ 上构造前三个首一正交多项式) 在 $[-1,1]$ 上取权函数 $w = 1$，构造次数为 $0,1,2$ 的首一正交多项式。

解 对称性使 $\alpha_0 = \alpha_1 = 0$。有 $\pi_0 = 1$、$\pi_1 = x$，且

$$\beta_1 = \frac{\int_{-1}^{1} x^2\,\mathrm{d}x}{\int_{-1}^{1} 1\,\mathrm{d}x} = \frac{1}{3}, \qquad \pi_2 = x^2 - \frac{1}{3}.$$

二次项减去均值后，与常数正交；它又是偶函数，所以自动与奇函数 x 正交。

定理 4.5 (零点全部位于区间内部) 设 $w > 0$ 几乎处处，π_n 是 $[a,b]$ 上的 n 次正交多项式，则它在 (a,b) 中有 n 个互异实零点。

证明. 把 π_n 在 (a,b) 中所有变号零点记为 $t_1, \dots, t_m$，令 $q(x) = \prod_{j=1}^{m}(x - t_j)$。乘积 $\pi_n q$ 在整个区间不变号，且并非恒零，所以 $\langle \pi_n, q\rangle_w \neq 0$。若 $m < n$，正交性却要求该内积为零，矛盾。因此 $m \geq n$。次数只有 n，故恰有 n 个变号零点，且均为单根，也不可能再有端点、区间外或非实零点。 □

零点交错可以把归纳步骤写完整。设 π_n 的零点为 $t_1 < \cdots < t_n$，且 π_{n-1} 的零点已与它们交错。相邻 t_i, t_{i+1} 之间恰有一个 π_{n-1} 零点，所以 $\pi_{n-1}(t_i)$ 与 $\pi_{n-1}(t_{i+1})$ 异号。在 t_i 处递推式为

$$\pi_{n+1}(t_i) = -\beta_n \pi_{n-1}(t_i), \qquad \beta_n > 0.$$

因此 π_{n+1} 在每两个相邻 t_i 之间都有一个零点。

还缺最外侧的两个零点。t_n 位于 π_{n-1} 的所有零点右侧，而它首一，故 $\pi_{n-1}(t_n) > 0$，从而 $\pi_{n+1}(t_n) < 0$；足够大的正数处 $\pi_{n+1} > 0$，所以右侧还有一个零点。左侧则有 $\pi_{n-1}(t_1)$ 的符号为 $(-1)^{n-1}$，$\pi_{n+1}(t_1)$ 为 $(-1)^n$，与负无穷处的符号 $(-1)^{n+1}$ 相反，故左侧也有一个零点。零点内部性定理保证它们都在 (a,b) 中。

归纳的起点 $n = 1$ 同样成立：π_2 在 π_1 的零点处等于 $-\beta_1 < 0$，在两侧远处均为正。因此两个零点分居两侧，归纳可以启动。

常用正交多项式

Legendre 多项式对应区间 $[-1,1]$ 和权 1，通常采用 $P_n(1) = 1$ 的归一化，而非首一归一化。Rodrigues 公式为

$$P_n(x) = \frac{1}{2^n n!}\frac{\mathrm{d}^n}{\mathrm{d}x^n}(x^2 - 1)^n.$$

对任意 $q \in \mathcal{P}_{n-1}$，分部积分 n 次，边界项因 $(x^2-1)^n$ 在两端有 n 重零点而消失，最后出现 $q^{(n)} = 0$，因此 P_n 与全部低次多项式正交。这给出了 Rodrigues 公式与正交性的直接联系。

前几项及递推关系为

$$P_0 = 1, \quad P_1 = x, \quad P_2 = \frac{1}{2}(3x^2-1), \quad P_3 = \frac{1}{2}(5x^3-3x),$$

$$(n+1)P_{n+1} = (2n+1)xP_n - nP_{n-1}, \qquad \int_{-1}^{1} P_n^2 \,\mathrm{d}x = \frac{2}{2n+1}.$$

Rodrigues 公式中的边界消失可以逐次检查。令 $F(x) = (x-1)^n(x+1)^n$。在 ± 1 处，$F, F', \dots, F^{(n-1)}$ 都为零。因此对 $\int qF^{(n)}$ 分部积分一次，边界项 $qF^{(n-1)}$ 为零；继续分部积分，直到 $q^{(n)} = 0$，所有边界项也都为零。这就证明了它与次数小于 n 的多项式正交。

最高次项 x^{2n} 求 n 次导数后，系数为 $(2n)!/n!$，所以 P_n 的最高次系数是

$$a_n = \frac{(2n)!}{2^n (n!)^2}.$$

在 $x = 1$ 处对 $(x-1)^n(x+1)^n$ 用乘积求导，只有把全部 n 次导数落在第一因子上的一项不为零，值为 $n!2^n$。所以 $P_n(1) = 1$。

现在计算平方范数。设 $J_n = \int_{-1}^{1}(1-x^2)^n \,\mathrm{d}x$。对 $x(1-x^2)^n$ 的导数积分，端点项为零，得

$$0 = J_n - 2n \int_{-1}^{1} x^2 (1-x^2)^{n-1} \,\mathrm{d}x = J_n - 2n(J_{n-1} - J_n).$$

于是 $J_n = 2nJ_{n-1}/(2n+1)$，从 $J_0 = 2$ 递推得

$$J_n = \frac{2^{2n+1}(n!)^2}{(2n+1)!}.$$

对 Rodrigues 表达式分部积分 n 次，$P_n^{(n)} = n! a_n$，所以

$$\int_{-1}^{1} P_n^2 \,\mathrm{d}x = \frac{a_n}{2^n} J_n = \frac{2}{2n+1}.$$

这里 $(x^2-1)^n = (-1)^n(1-x^2)^n$，恰好抵消分部积分产生的 $(-1)^n$。

递推系数也不必记忆。因权函数对称，P_n 具有与 n 相同的奇偶性，所以 xP_n 没有 P_n 分量，只含 P_{n+1} 与 P_{n-1}。比较最高次系数，前者系数是 $a_n/a_{n+1} = (n+1)/(2n+1)$；再在 $x = 1$ 处代入所有 $P_j(1) = 1$，后者系数就是 $n/(2n+1)$。乘以 $2n+1$，得到常用三项递推。

Chebyshev 多项式定义为

$$T_n(\cos\theta) = \cos(n\theta).$$

余弦加法公式给出 $T_{n+1} = 2xT_n - T_{n-1}$，其中 $T_0 = 1, T_1 = x$。代换 $x = \cos\theta$ 后，

$$\int_{-1}^{1} \frac{T_m(x)T_n(x)}{\sqrt{1-x^2}} \,\mathrm{d}x = \int_0^{\pi} \cos(m\theta)\cos(n\theta) \,\mathrm{d}\theta.$$

因此它们在权 $w(x) = (1-x^2)^{-1/2}$ 下正交。$n \geq 1$ 时平方范数为 $\pi/2$，$n = 0$ 时为 π。权在端点发散，但积分仍然有限。

令 $x = \cos\theta$，$0 \leq \theta \leq \pi$。由余弦和角公式，

$$\cos((n+1)\theta) + \cos((n-1)\theta) = 2\cos\theta\cos(n\theta),$$

这就是 $T_{n+1}=2xT_n-T_{n-1}$。换元时 $\mathrm{d}x=-\sin\theta\,\mathrm{d}\theta$，而 $\sqrt{1-x^2}=\sin\theta$；上下限从 $\pi,0$ 反向后，负号消失，得到正文中的无权余弦积分。

当 $m\neq n$，用 $2\cos m\theta\cos n\theta=\cos((m-n)\theta)+\cos((m+n)\theta)$，各项积分都在端点出现整数倍 π 的正弦，因而为零。当 $m=n\geq 1$，$\cos^2 n\theta=(1+\cos 2n\theta)/2$，积分为 $\pi/2$；$n=0$ 则是常数 1 的积分 π。

零点也从余弦定义直接求出：$\cos n\theta=0$ 意味着 $n\theta=(2j+1)\pi/2$。因此 n 个零点为 $x_j=\cos((2j+1)\pi/(2n))$。而在 $x_j=\cos(j\pi/n)$ 上，$T_n(x_j)=(-1)^j$，给出等幅交错的极值点。由递推比较最高次项，$a_1=1, a_{n+1}=2a_n$，所以 $a_n=2^{n-1}$，这也解释了首一化所需的比例。

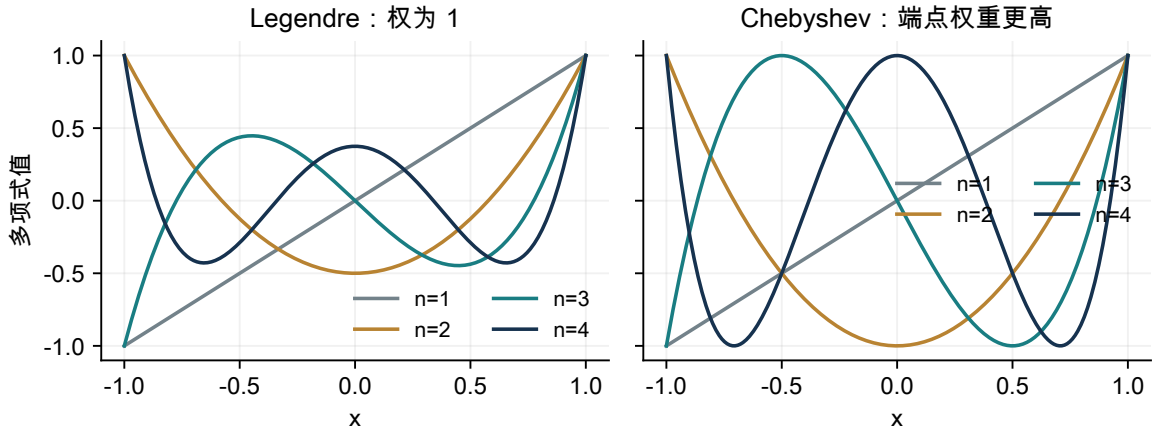


图 4.1 Legendre 多项式与 Chebyshev 多项式的前几项。它们使用不同权函数，因而“正交”对应不同的误差度量。

无界区间上也有相应的正交多项式。标准 Laguerre 多项式 L_n 对应 $[0,\infty)$ 与权 e^{-x}，可由

$$L_n(x)=\frac{e^x}{n!}\frac{\mathrm{d}^n}{\mathrm{d}x^n}(e^{-x}x^n)$$

构造。物理学约定的 Hermite 多项式 H_n 对应 $\mathbb{R}$ 与权 e^{-x^2}，定义为

$$H_n(x)=(-1)^n e^{x^2}\frac{\mathrm{d}^n}{\mathrm{d}x^n}e^{-x^2}.$$

它与概率论中使用权 $e^{-x^2/2}$ 的另一套 Hermite 归一化不同。使用公式时必须核对权与缩放。此处的 Hermite 多项式是一族正交多项式，与上一章利用导数数据的 Hermite 插值是不同概念。

无界区间上的正交性使用同一套分部积分。对 Laguerre 多项式，有 $e^{-x}L_n=(e^{-x}x^n)^{(n)}/n!$。与次数小于 n 的多项式 q 相乘，分部积分 n 次后出现 $q^{(n)}=0$；无穷远处，多项式乘 e^{-x} 的边界项趋于零；零点处，x^n 在少于 n 次求导后仍保证相应边界项为零。

对 Hermite 多项式，$e^{-x^2}H_n=(-1)^n(e^{-x^2})^{(n)}$。同样分部积分后，边界项是多项式乘 e^{-x^2}，在两端都趋于零。由定义实际求前几次导数，可得 $L_0=1, L_1=1-x, L_2=1-2x+x^2/2$，以及 $H_0=1, H_1=2x, H_2=4x^2-2$。这能帮助核对所用归一化。

4.3 连续函数的最佳逼近

上一节准备了正交基，现在用它寻找最佳函数。平方误差的关键优点是展开后只有二次项和交叉项，交叉项能否消失，恰好由内积和正交性控制。

定义 4.6 (最佳平方逼近与最佳一致逼近) 在有限维空间 V 中，使

$$\int_a^b w(x)[f(x)-p(x)]^2\,\mathrm{d}x$$

最小的 p 称为最佳平方逼近。若 f,p 连续，使 $\max_{[a,b]}|f-p|$ 最小的 p 称为最佳一致逼近。前者控制总体平方误差，后者控制最坏位置的误差。

先处理平方逼近。把近似函数沿空间中的任一方向微调，如果误差已经最小，一阶变化率就必须为零。这条最优性条件将转化为“残差与空间正交”。它不仅是一组求系数的方程，还解释了为什么解是全局最优而不是某个偶然驻点。

给定线性无关函数 $\phi_0,\dots,\phi_n$，令 $V=\operatorname{span}\{\phi_0,\dots,\phi_n\}$。我们寻找 $p_*\in V$，使 $\|f-p_*\|_w$ 最小。

定理 4.7 (有限维正交投影) 若内积在 V 上正定，则最佳平方逼近 p_* 存在唯一，且等价地满足

$$\langle f-p_*,v\rangle_w=0,\qquad \forall v\in V. \tag{4.2}$$

证明. 写 $p=\sum_{j=0}^n c_j\phi_j$。将误差平方完全展开：

$$J(c)=\langle f,f\rangle_w-2\sum_j c_j\langle f,\phi_j\rangle_w+\sum_{i,j}c_ic_j\langle\phi_i,\phi_j\rangle_w.$$

对第 k 个系数求偏导。最后的双重和中，c_k 既可能出现在第一个位置，也可能出现在第二个位置；利用内积对称性，两组贡献相等。因此

$$\frac{\partial J}{\partial c_k}=-2\langle f,\phi_k\rangle_w+2\sum_j c_j\langle\phi_j,\phi_k\rangle_w.$$

令它为零，得到 Gram 方程 $Gc=b$。对非零 z，线性无关性使 $\sum_j z_j\phi_j$ 不是零元素，故

$$z^TGz=\left\langle\sum_i z_i\phi_i,\sum_j z_j\phi_j\right\rangle_w>0.$$

如果 $Gz=0$，左侧就为零，与此矛盾，所以 G 可逆，系数存在唯一。方程每一行又正是 $\langle f-p_*,\phi_k\rangle_w=0$，线性组合后对任意 $v\in V$ 都成立。
还要说明这个驻点确实最小。任取另一个 $p=p_*+v$，展开

$$\begin{aligned}\|f-p\|_w^2&=\|(f-p_*)-v\|_w^2\\&=\|f-p_*\|_w^2-2\langle f-p_*,v\rangle_w+\|v\|_w^2\\&=\|f-p_*\|_w^2+\|v\|_w^2.\end{aligned}$$

最后一项非负，且只在 $v=0$ 时为零。所以 p_* 是唯一全局最小点，而不仅是偏导数为零的候选点。 □

若基函数两两正交，Gram 矩阵就是对角阵，系数可逐个求出：

$$c_j = \frac{\langle f, \phi_j \rangle_w}{\langle \phi_j, \phi_j \rangle_w}, \qquad \|f - p_*\|_w^2 = \|f\|_w^2 - \sum_{j=0}^{n} \frac{\langle f, \phi_j \rangle_w^2}{\|\phi_j\|_w^2}.$$

选好坐标系使耦合消失，这正是正交基的计算价值。

若基函数正交，方程的第 k 行只剩 $c_k \|\phi_k\|_w^2 = \langle f, \phi_k \rangle_w$。把这些系数代回误差展开，二次项为 $\sum_k c_k^2 \|\phi_k\|_w^2$，交叉项为 $-2\sum_k c_k \langle f, \phi_k \rangle_w$；每一项合并成

$$-2\frac{\langle f, \phi_k \rangle_w^2}{\|\phi_k\|_w^2} + \frac{\langle f, \phi_k \rangle_w^2}{\|\phi_k\|_w^2} = -\frac{\langle f, \phi_k \rangle_w^2}{\|\phi_k\|_w^2}.$$

因此得到正文的最小误差公式。每加入一个新的正交方向，就从误差平方中再减去一个非负量。

最佳平方逼近的计算

例 4.2 (用一次多项式逼近 x^2)　在 $[-1, 1]$、权 $w = 1$ 下，求 x^2 的最佳平方一次多项式逼近及最小误差平方。

解　设 $p = a + bx$。正交条件为

$$\int_{-1}^{1} (x^2 - a - bx)\,\mathrm{d}x = 0, \qquad \int_{-1}^{1} x(x^2 - a - bx)\,\mathrm{d}x = 0.$$

奇函数积分为零，所以 $a = 1/3, b = 0$。最佳平方逼近是常数 $1/3$，最小误差平方为

$$\int_{-1}^{1} (x^2 - 1/3)^2\,\mathrm{d}x = \frac{8}{45}.$$

注意误差的积分等于零，并不意味着误差处处为零；正负误差在内积中抵消了。

对一般 f，Legendre 展开的前 $n+1$ 项就是 $\mathcal{P}_n$ 中的最佳平方逼近：

$$p_n(x) = \sum_{k=0}^{n} a_k P_k(x), \qquad a_k = \frac{2k+1}{2} \int_{-1}^{1} f(x) P_k(x)\,\mathrm{d}x.$$

增加一项不会改变旧系数，因为新方向与旧空间正交。误差平方恰好减少 $a_{n+1}^2 \|P_{n+1}\|^2$。这给出一个清晰的逐阶改进过程。

有限阶投影的存在不要求 f 能展开成处处收敛的无穷级数。讨论无穷展开时，还要指明采用平方平均收敛、逐点收敛还是一致收敛。这些结论需要不同条件。

以 $f(x) = e^x$、区间 $[-1, 1]$、权 1 为例，把前四个 Legendre 系数分别截取到次数 $0, 1, 2, 3$。上排比较函数，下排直接观察 $e^x - p_n(x)$。即使两条函数曲线在印刷尺度下几乎重合，误差曲线仍能显示它们的差异。注意，误差平方积分逐阶减小，并不要求每一点的误差绝对值都同步减小。新方向在整体内积意义下改善近似，误差的局部分布仍可能改变。

连续函数为何可以用多项式逼近

后面的求积收敛证明需要一个存在性事实：连续函数总能被多项式一致逼近。这里给出构造，避免把这个事实当作没有理由的前提。

> **定理 4.8** (连续函数的多项式一致逼近)　若 $f \in C[a, b]$，则对任意 $\varepsilon > 0$，存在多项式 p，使 $\max_{[a,b]} |f - p| < \varepsilon$。

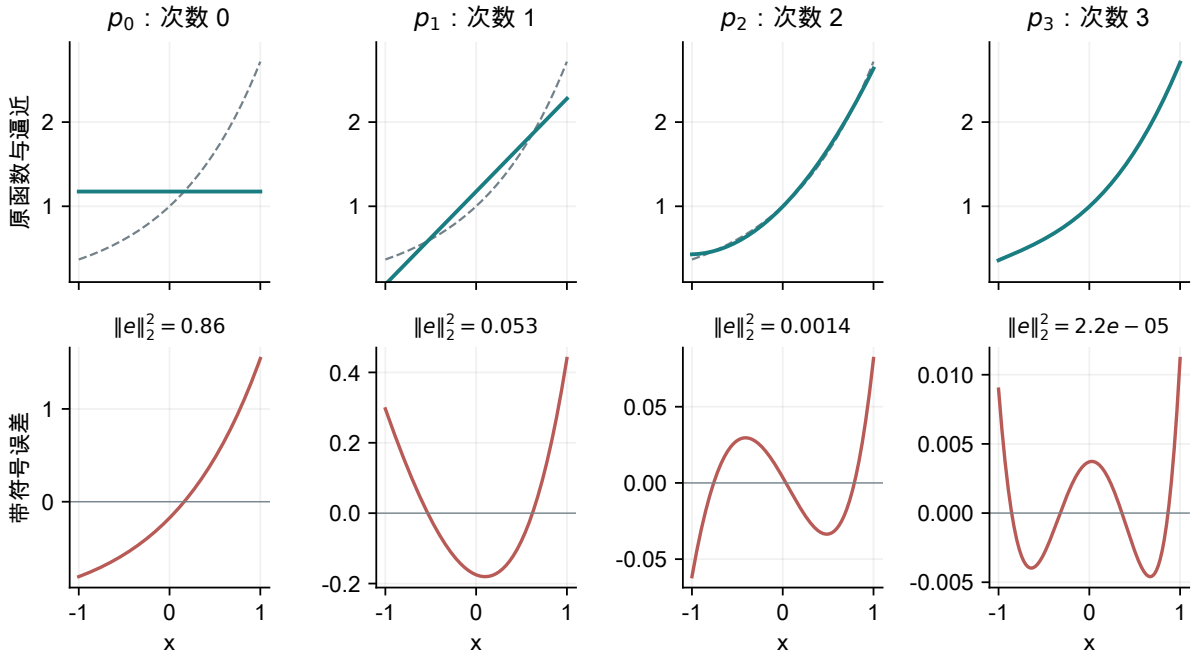


图 4.2 最佳平方逼近的次数与误差。上排各图共用纵轴范围，下排误差分别定标；标题给出误差平方积分。虚线为 e^x，青色为逼近函数。

证明. 先用线性换元将区间化为 $[0,1]$。定义 Bernstein 多项式

$$B_n f(x) = \sum_{k=0}^{n} f(k/n) b_{n,k}(x), \qquad b_{n,k}(x) = \binom{n}{k} x^k (1-x)^{n-k}.$$

这些权重非负，二项式公式给出 $\sum_k b_{n,k} = 1$。利用 $k\binom{n}{k} = n\binom{n-1}{k-1}$，把求和下标平移后，得到

$$\sum_k \frac{k}{n} b_{n,k} = x.$$

再用 $k(k-1)\binom{n}{k} = n(n-1)\binom{n-2}{k-2}$，得到 $\sum_k k(k-1)b_{n,k} = n(n-1)x^2$。因 $k^2 = k(k-1)+k$，整理即有

$$\sum_k \left(\frac{k}{n} - x\right)^2 b_{n,k} = \frac{x(1-x)}{n} \le \frac{1}{4n}.$$

这个式子说明权重主要集中在 k/n 接近 x 的位置。

连续函数在闭区间上一致连续。可以用反证法理解：若存在越来越近的 x_j, y_j 而函数值始终相差至少某个正数，就可从有界序列 x_j 中取出收敛子列；对应的 y_j 趋于同一个极限，连续性将迫使函数值之差趋零，矛盾。

因此，给定 $\varepsilon > 0$，可取一个对所有 x 都有效的 $\delta > 0$，使 $|t-x| < \delta$ 时 $|f(t)-f(x)| < \varepsilon/2$。记 $M = \max|f|$。将误差和分为近、远两部分：近处的贡献不超过 $\varepsilon/2$；远处的函数值之差不超过 $2M$，而

$$\sum_{|k/n - x| \ge \delta} b_{n,k} \le \frac{1}{\delta^2} \sum_k (k/n - x)^2 b_{n,k} \le \frac{1}{4n\delta^2}.$$

故对所有 x，

$$|B_n f(x) - f(x)| \le \frac{\varepsilon}{2} + \frac{M}{2n\delta^2}.$$

选取足够大的 n 使第二项小于 $\varepsilon/2$，便得到一致逼近。最后把变量换回 $[a,b]$，仍是多项式。 □

最佳一致逼近

现在改用 $\|f-p\|_\infty=\max_{x\in[a,b]}|f(x)-p(x)|$。我们要让最坏位置的误差尽量小。这里没有二次函数和正交方程，最优条件变成误差峰值的排列。

先记录一条用于计数零点的事实。

引理 4.9 (等幅交错导致多个零点) 若连续函数 g 在递增点 $t_0,\dots,t_m$ 上非零且符号交替，则每个 (t_i,t_{i+1}) 内至少有一个零点，因而至少有 m 个不同零点。

证明. 每个相邻区间的端点异号，由介值定理可得一个内部零点。各个开区间互不相交，所以这些零点互异。 □

定理 4.10 (Chebyshev 交错定理) 设 $f\in C[a,b]$ 且 $f\notin\mathcal{P}_n$。$p_*\in\mathcal{P}_n$ 是最佳一致逼近的充要条件是：存在 $n+2$ 个递增点 $t_0<\cdots<t_{n+1}$，使

$$f(t_i)-p_*(t_i)=\sigma(-1)^iE,\qquad E=\|f-p_*\|_\infty>0,\quad \sigma\in\{1,-1\}.$$

最佳一致逼近存在且唯一。若 $f\in\mathcal{P}_n$，最佳逼近就是 f 本身。

证明. 先证充分性。若另有 $q\in\mathcal{P}_n$ 的最大误差严格小于 E，则在 $f(t_i)-p_*(t_i)=E$ 的点必须有 $q(t_i)>p_*(t_i)$，否则正误差不能变小；在误差为 $-E$ 的点必须有 $q(t_i)<p_*(t_i)$。所以 $q-p_*$ 在 $n+2$ 个点交替变号，至少有 $n+1$ 个不同零点。但它次数至多为 n，不可能做到，矛盾。

再证必要性。记 $e=f-p_*$、$K=\{x:|e(x)|=E\}$。若没有 $n+2$ 个交错极值点，按从左到右的顺序，K 至多分为 $n+1$ 个符号交替的块。相邻异号块之间有正距离：否则可以取越来越接近的正、负极值点，由连续性将得到 $E=-E$，与 $E>0$ 矛盾。

在相邻块之间各选一个不属于 K 的点 z_j，构造 $q(x)=c\prod_j(x-z_j)$，次数至多 n。选取常数 c 的正负号，使 q 在第一块与 e 同号；每越过一个 z_j 两者同时换号，故在全部 K 上同号。又因 q 在 K 上不为零，紧性给出 $\eta=\min_K|q|>0$。

在 K 的一个足够小的邻域 U 内，仍有 $eq>0$、$|q|\ge\eta/2$、$|e|\ge E/2$。令 $Q=\max_{[a,b]}|q|$。若 $\delta Q<E/4$，扰动 $e-\delta q$ 不会在 U 内越过零，且

$$|e-\delta q|=|e|-\delta|q|\le E-\delta\eta/2<E.$$

剩余的闭集 $[a,b]\setminus U$ 不含极值点，所以在那里有 $|e|\le E-\gamma$，某个 $\gamma>0$。再选 $\delta Q<\gamma/2$，得到该处 $|e-\delta q|\le E-\gamma/2<E$。于是 $p_*+\delta q$ 在整个区间上都更好，与最优性矛盾。

存在性也需要说明。取一列多项式 p_j，使最大误差趋于误差下确界，并且误差一致有界。在固定的 $n+1$ 个互异点处，它们的函数值都有界；Vandermonde 矩阵固定可逆，所以系数向量也有界。有限维有界序列有收敛子列，设其系数趋于 $a_0,\dots,a_n$。因区间有界，

$$\max_x\left|\sum_{k=0}^{n}(a_{j,k}-a_k)x^k\right|\le\sum_{k=0}^{n}|a_{j,k}-a_k|\max(1,|a|,|b|)^k\to0.$$

子列一致趋于一个 $p_*\in\mathcal{P}_n$，误差也趋于同一极限，所以它达到下确界。

最后证唯一性。若 p,q 都达到误差 E，则平均多项式 $r=(p+q)/2$ 的误差不超过 E，因而也最佳。由必要性，它有 $n+2$ 个交错极值点。在任一点，$f-r$ 是两个属于 $[-E,E]$ 的数

$f-p, f-q$ 的平均；平均若等于 E，两个数就都得是 E，等于 $-E$ 时同理。故 $p=q$ 在这 $n+2$ 个点成立，$p-q$ 只能恒为零。 □

例 4.3 (平方最佳与一致最佳的区别) 求 x^2 在 $[-1,1]$ 上的最佳一致一次多项式逼近，并与最佳平方逼近比较。

解 取 $p_*=1/2$。误差在 $-1,0,1$ 依次为 $1/2,-1/2,1/2$，有三个交错点，故是最佳一致逼近。前面最佳平方逼近是 $1/3$。两者都正确，只是优化的目标不同。

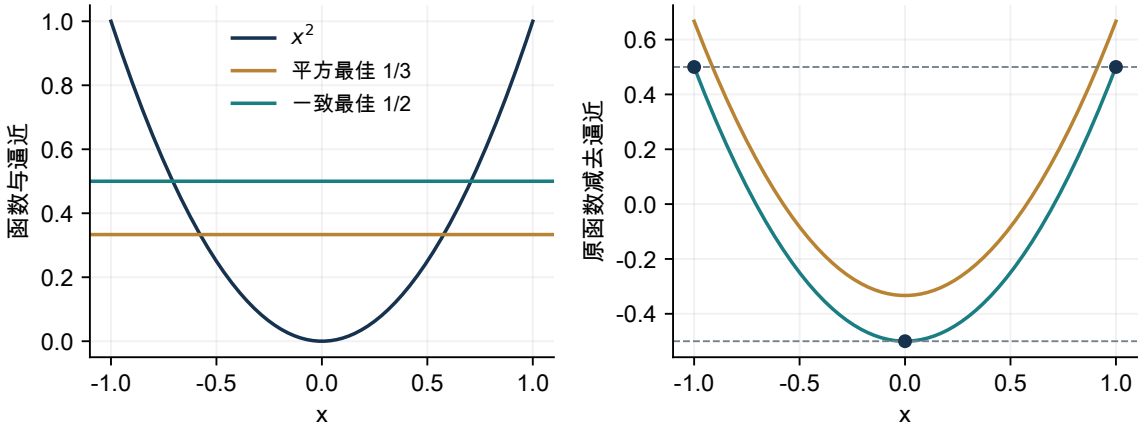


图 4.3 用一次多项式逼近 x^2：平方最佳为 $1/3$，一致最佳为 $1/2$。后者让端点与中点的最大误差等幅交错。

对 $n\ge 1$，T_n 的最高次系数为 2^{n-1}，故 $2^{1-n}T_n$ 是首一多项式，且在 $n+1$ 个极值点交错取值 $\pm 2^{1-n}$。如果另一个首一 n 次多项式具有更小的最大绝对值，两者之差至多 $n-1$ 次，却被迫在 n 个间隔内变号，矛盾。因此

$$\min_{q\ \text{为首一}n\ \text{次多项式}} \|q\|_\infty = 2^{1-n}.$$

这正是 Chebyshev 零点能减小插值节点乘积最大值的原因。

实际寻找一般函数的最佳一致逼近时，Remez 思路是先猜 $n+2$ 个交错点，联立求出多项式系数与共同误差 E，再寻找真实误差的极值并更新点组。它把无限多个不等式约束暂时压缩成有限组等幅条件，但需要可靠的极值搜索与点组更新，不能只解一次线性方程就结束。

交错条件同时解释了为什么一致最佳逼近的误差不倾向于集中在一个位置。如果一个正峰值明显高于其他负峰值，通常可以把多项式略向上移动，在不制造更大反向误差的情况下压低最坏值。到达最佳状态时，必须有足够多个正负峰值互相制约，次数为 n 的扰动多项式才无法同时改善它们。

交错定理的充分性证明正是把这一事实用于两个逼近多项式之差，再与“非零 n 次多项式至多有 n 个零点”比较。它体现了一条常用证明路线：先把误差大小要求变成符号约束，再把符号约束变成零点计数。

4.4 离散数据的曲线拟合

连续投影假设知道整个函数，实验数据却通常只提供有限个样本。此时把积分内积换成离散内积，平方逼近就转化为一个矩阵问题。

连续函数的平方逼近把整个区间上的误差积分；只有观测样本时，就把积分换成加权求和。权的选择应与数据含义对应：更可靠的观测通常应受到更大重视，但权不是用来事后迁就拟合结果的任意旋钮。

定义 4.11 (最小二乘拟合与残差)　给定观测 y_i 和模型值 $p(x_i;c)$，定义残差 $r_i = y_i - p(x_i;c)$。最小化 $\sum_i w_i r_i^2$（$w_i > 0$）称为加权最小二乘拟合。若模型对参数 c 线性，则是线性最小二乘；模型对自变量 x 不必是一次函数。

例如 $p(x) = c_0 + c_1 x + c_2 x^2$ 是关于 x 的二次函数，却仍是线性最小二乘模型，因为每个未知系数都以一次形式出现。相反，ae^{bx} 对参数 b 非线性，不能仅凭“只有两个参数”就按线性方程处理。

给定样本 (x_i, y_i)，$i = 1, \dots, m$，选择 $n+1$ 个基函数，通常 $m > n+1$。令

$$p(x) = \sum_{j=0}^{n} c_j \phi_j(x), \quad A_{ij} = \phi_j(x_i), \quad W = \operatorname{diag}(w_1, \dots, w_m), \quad w_i > 0.$$

加权最小二乘问题是

$$\min_{c} J(c), \qquad J(c) = (Ac - y)^T W (Ac - y).$$

把 $J(c) = \sum_i w_i (\sum_j A_{ij} c_j - y_i)^2$ 对 c_k 求导，每一项都要先对平方求导，再乘内部对 c_k 的导数 A_{ik}：

$$\frac{\partial J}{\partial c_k} = 2 \sum_i w_i A_{ik} \left(\sum_j A_{ij} c_j - y_i \right).$$

将求和中的 c_j 提出来，便是 $\sum_j (\sum_i w_i A_{ik} A_{ij}) c_j = \sum_i w_i A_{ik} y_i$。按矩阵乘法逐个核对括号内的元素，左边就是 $(A^T W A)_{kj}$，右边是 $(A^T W y)_k$。

对系数求导，得到正规方程

$$A^T W A\, c = A^T W y. \tag{4.3}$$

若 A 列满秩，则 $z^T A^T W A z = \left\| W^{1/2} A z \right\|_2^2 > 0$，所以系数唯一。若不满秩，拟合出的投影向量仍唯一，但表达它的系数未必唯一。

残差 $r = y - Ac$ 满足 $A^T W r = 0$。这不是说每个残差为零，而是说它无法再通过改变模型系数而一阶减小。几何上，拟合向量是数据向量在设计矩阵列空间上的加权正交投影。

例 4.4 (拟合直线)　对数据 $(0,1), (1,2), (2,2)$ 作等权最小二乘直线拟合，并验证残差的正交性。

解　设拟合直线为 $a + bx$。正规方程为

$$\begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}, \qquad a = \frac{7}{6}, \quad b = \frac{1}{2}.$$

残差依次为 $-1/6, 1/3, -1/6$，其和为零，与横坐标的内积也为零。最小残差平方和为 $1/6$。

拟合次数提高，训练样本上的最小平方误差不会增大，因为允许的空间变大了。但这不保证对新位置的预测更好。模型也可能把噪声拟合成剧烈的曲线；是否采用更高次数，需要结合数据精度与用途判断。

最小二乘的两种图像对应不同空间。在左图，横轴是自变量 x，残差是观测值与拟合值的竖直差；在右图，三个观测被组成 $\mathbb{R}^3$ 中的一个向量 y，模型值 Ac 落在二维子空间 $\operatorname{col}(A)$ 中，残差才是垂直于这个平面的向量。所以“残差正交”并不是说左图中的线段垂直于拟合直线。普通线性最小二乘最小化的是竖直残差平方和；垂直性发生在数据向量空间中。

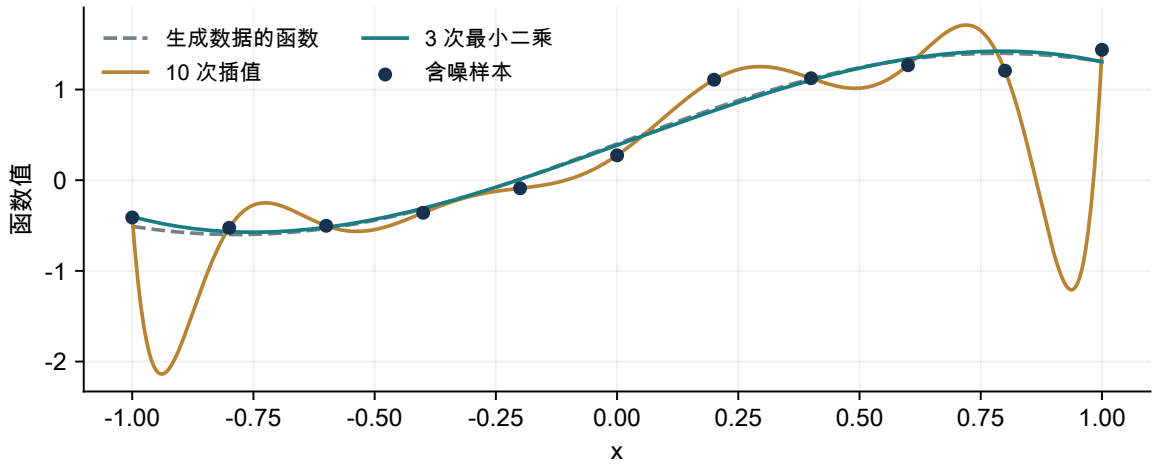


图 4.4 含噪声样本上的低次最小二乘与严格插值。插值必须穿过每个噪声点，低次拟合则允许局部残差，以换取较稳定的整体趋势。

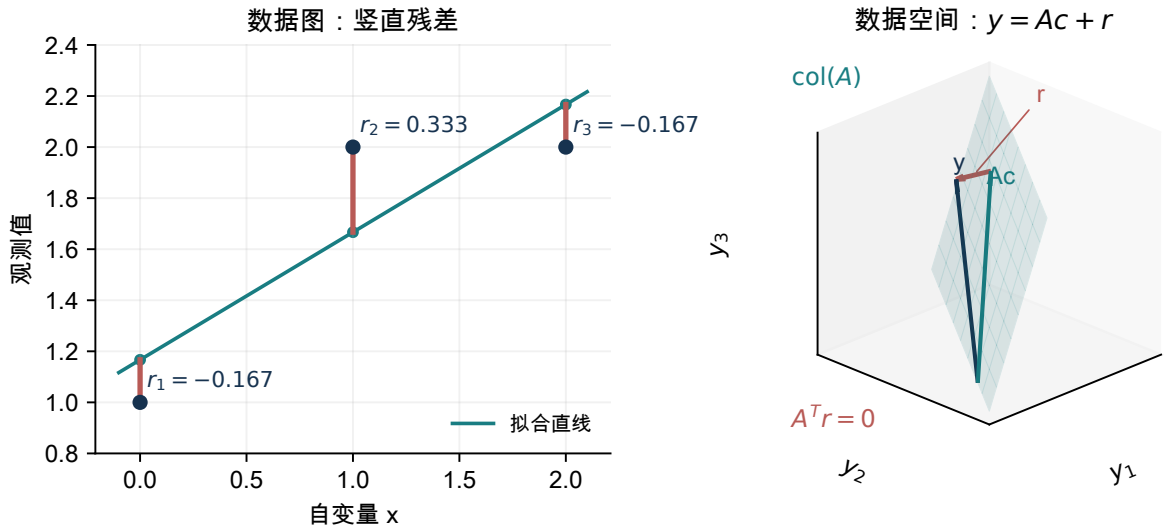


图 4.5 数据 $(0,1),(1,2),(2,2)$ 的最小二乘几何。左图的残差为 $(-1/6, 1/3, -1/6)$，右图满足 $y = Ac + r$ 与 $A^T r = 0$。右图三条轴分别代表三个观测分量。

正规方程的求解

设 $\widetilde{A} = W^{1/2}A$，$\widetilde{y} = W^{1/2}y$。列满秩时，2-范数条件数满足

$$\kappa_2(\widetilde{A}^T\widetilde{A}) = \kappa_2(\widetilde{A})^2,$$

因为 $\widetilde{A}^T\widetilde{A}$ 的特征值是 $\widetilde{A}$ 奇异值的平方。因此显式形成正规方程可能额外损失精度。

先令 $\widetilde{A} = QR$ 是薄 QR 分解，其中 Q 列正交，故 $P = QQ^T$ 满足 $P^2 = Q(Q^TQ)Q^T = P$，并把向量投影到 Q 的列空间。将右端分成 $\widetilde{y} = P\widetilde{y} + (I - P)\widetilde{y}$，残差成为

$$Q(Rc - Q^T\widetilde{y}) - (I - QQ^T)\widetilde{y}.$$

两项正交，因为 $Q^T(I - QQ^T) = Q^T - Q^T = 0$。展开范数平方时交叉项为零，且 $\|Qz\|_2^2 = z^TQ^TQz = \|z\|_2^2$，就得到下面的分解。第二项固定，第一项可以通过解 $Rc = Q^T\widetilde{y}$ 降为零。

条件数平方的来源也可核对：若 $\widetilde{A}$ 的奇异值为 $\sigma_i > 0$，则 $\widetilde{A}^T\widetilde{A}$ 的特征值是 σ_i^2。于是前者的最大最小伸缩比为 $\sigma_{\max}/\sigma_{\min}$，后者则为 $\sigma_{\max}^2/\sigma_{\min}^2$，正好平方。

作薄 QR 分解 $\widetilde{A}=QR$，其中 $Q^TQ=I$，R 为上三角阵。把残差分成列空间内与正交补上的分量：

$$\left\|\widetilde{A}c-\widetilde{y}\right\|_2^2=\left\|Rc-Q^T\widetilde{y}\right\|_2^2+\left\|(I-QQ^T)\widetilde{y}\right\|_2^2.$$

第二项与 c 无关，所以只需求解

$$Rc=Q^T\widetilde{y}.$$

正交变换保持 2-范数，是 QR 稳定性分析的核心。出现近似秩亏时，应进一步使用带列主元的 QR 或 SVD 分析有效秩。

```
import numpy as np

# A 的每一列是一种基函数在样本上的取值。
A = np.column_stack([np.ones_like(x), x, x*x])
Aw = np.sqrt(w)[:, None] * A
bw = np.sqrt(w) * y
# 用最小二乘求解器，避免手工形成 A.T @ A。
coef, _, rank, singular_values = np.linalg.lstsq(Aw, bw, rcond=None)
```

这是调用片段，x,y,w 是事先准备好的等长一维数组。返回的奇异值和秩提供了设计矩阵的信息，而不只是给出一组系数。

若 x 的尺度很大，先中心化并缩放到适当区间，或直接使用正交多项式基，通常更易计算。换基不改变理想精确算术下的拟合空间，却会改变矩阵的条件。

模型的线性化

有时拟合模型写为 $y=ae^{bx}$。取对数后得到 $\log y=\log a+bx$，看起来可以用线性最小二乘。但原来的目标

$$\sum_i(y_i-ae^{bx_i})^2$$

与变换后的目标

$$\sum_i(\log y_i-\log a-bx_i)^2$$

并不相同。小扰动下，$\Delta\log y\approx\Delta y/y$，后一个目标更接近关注相对误差。若 $y_i\le 0$，变换甚至无定义。

因此线性化可以简化计算，但必须说明接受了什么误差度量。若原问题要求最小化原尺度上的残差，就应直接处理非线性最小二乘，或把线性化结果作为初值。

4.5 三角多项式逼近与快速傅里叶变换

多项式适合描述区间上的平滑趋势，周期现象则具有另一种自然结构：一个周期结束后，函数应与下一个周期衔接。正弦和余弦自动满足周期条件，还能按频率把慢变化与快变化分开，因此适合作为周期逼近的基。

定义 4.12 (三角多项式与频率)　形如

$$p_n(x) = \frac{a_0}{2} + \sum_{k=1}^{n} [a_k \cos(kx) + b_k \sin(kx)]$$

的函数称为最高频率不超过 n 的 2π 周期三角多项式。整数 k 表示一个基本周期内的振荡次数，系数确定该频率分量的幅度与相位。

一组 Fourier 系数描述函数在这些方向上的投影。有限项的投影问题只需要有限维正交性；把项数趋于无穷以后，还要单独讨论级数在何种意义下趋于原函数。尤其不能把平方平均收敛直接读成每个位置的误差都很小。

对 2π 周期实函数，在 $[-\pi, \pi]$ 上考虑

$$p_n(x) = \frac{a_0}{2} + \sum_{k=1}^{n} [a_k \cos(kx) + b_k \sin(kx)].$$

三角函数间的正交关系可由积化和差公式推出。例如 $k \neq l$ 时

$$\int_{-\pi}^{\pi} \cos(kx) \cos(lx)\, \mathrm{d}x = 0,$$

而正整数 k 的 $\cos^2(kx)$ 与 $\sin^2(kx)$ 积分均为 π。应用投影定理，

$$a_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \cos(kx)\, \mathrm{d}x, \quad b_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \sin(kx)\, \mathrm{d}x.$$

a_0 按同一公式取 $k = 0$。常数项写成 $a_0/2$，是为了统一系数表达式。

这里可以把每种正交关系都归结为端点的正弦值。例如

$$\cos kx \cos lx = \tfrac{1}{2}[\cos((k-l)x) + \cos((k+l)x)].$$

当 $k \neq l$，对每个非零整数 m，$\int_{-\pi}^{\pi} \cos(mx)\, \mathrm{d}x = [\sin(mx)/m]_{-\pi}^{\pi} = 0$。正弦乘正弦也由积化和差化成余弦；正弦乘余弦是奇函数，积分为零。$\cos^2 kx$ 与 $\sin^2 kx$ 用半角公式积分，结果均为 π；常数 1 的平方积分则为 2π。

因此投影系数分别除以各自基函数的平方范数。常数基的系数是 $(\int f)/(2\pi)$，写为 $a_0/2$；其余基的系数除以 π，就是正文的 a_k, b_k。这些分母不是约定出来的任意系数，而是归一化所需。

对周期延拓后具有有限个分段点、且各段可延拓为 C^2 函数的情形，Fourier 部分和在连续点趋于 $f(x)$，在跳跃点趋于左右极限的平均。这是逐点结论。跳跃附近会出现 Gibbs 振荡，增大截断阶数会压缩振荡区域，却不会使最大过冲简单消失。误差在平方平均意义下趋于零，与局部仍存在过冲并不矛盾。

为什么有限部分和会趋于函数值或跳跃中点？以下在周期延拓后只有有限个分段点、各段可延拓为 C^2 函数的条件下说明。这个条件覆盖图中的分段常数方波。

Fourier 部分和收敛的推导. 先把投影系数代回部分和，并使用 $\cos k(x-t) = \cos kx \cos kt + \sin kx \sin kt$，得到

$$S_n f(x) = \frac{1}{2\pi} \int_{-\pi}^{\pi} f(x-t) D_n(t)\, \mathrm{d}t, \quad D_n(t) = 1 + 2\sum_{k=1}^{n} \cos kt = \frac{\sin((n+1/2)t)}{\sin(t/2)}.$$

最后一个等式可将 $2\sin(t/2)\cos kt$ 写成 $\sin((k+1/2)t)-\sin((k-1/2)t)$ 后逐项相消得到。它还给出 $\int_{-\pi}^{\pi} D_n = 2\pi$，因为非零频率的余弦积分都为零。

记 $L=[f(x^-)+f(x^+)]/2$。把正、负 t 配对，并减去常数函数 L 的部分和，得到

$$S_n f(x) - L = \int_0^{\pi} H(t)\sin((n+1/2)t)\,\mathrm{d}t,$$

$$H(t) = \frac{f(x-t)+f(x+t)-2L}{2\pi\sin(t/2)}.$$

在 $t\to 0^+$ 时，分子由两侧 Taylor 展开为 $O(t)$，分母也与 t 同阶，所以 H 有有限的右极限；在上述分段 C^2 条件下，它在每段有可积导数。对任一光滑段 $[u,v]$ 分部积分：

$$\int_u^v H(t)\sin(Kt)\,\mathrm{d}t = \left[-\frac{H(t)\cos(Kt)}{K}\right]_u^v + \frac{1}{K}\int_u^v H'(t)\cos(Kt)\,\mathrm{d}t.$$

绝对值不超过 $[|H(u)|+|H(v)|+\int_u^v |H'|]/K$。段数有限，令 $K=n+1/2\to\infty$，总误差趋零。因此在连续点得到 $f(x)$，在跳跃处得到两侧平均。

□

过冲为何仍然存在，可以看方波 $f(x)=\operatorname{sign}(\sin x)$。其部分和只含奇频率，写为 $S_m(x)=\frac{4}{\pi}\sum_{j=0}^{m-1}\sin((2j+1)x)/(2j+1)$。令 $x=z/(2m)$，则

$$S_m(z/(2m)) = \frac{2}{\pi}\sum_{j=0}^{m-1}\frac{\sin u_j}{u_j}\frac{z}{m}, \qquad u_j=(j+1/2)\frac{z}{m}.$$

这是 $[0,z]$ 上的中点积分和，极限为 $\frac{2}{\pi}\int_0^z \sin u/u\,\mathrm{d}u$。在 $z=\pi$ 处，这个数约为 1.179，大于右侧平台 1。过冲点的实际位置 $x=\pi/(2m)$ 越来越靠近跳跃，但过冲比例没有消失；它并不与固定连续点的收敛结论矛盾。

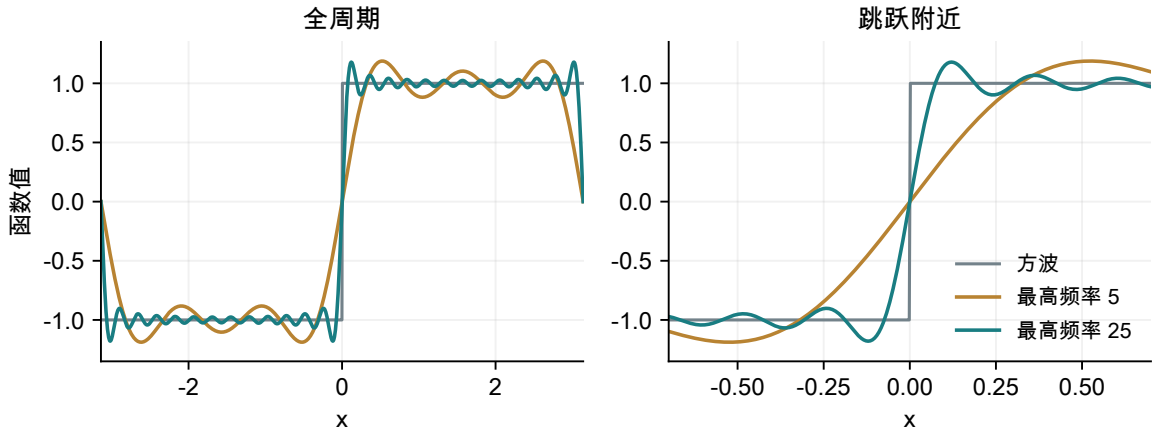


图 4.6 方波的 Fourier 部分和。增加项数使远离跳跃的位置更准确，但跳跃附近仍有过冲，说明不同收敛概念不能混用。

复指数形式更加紧凑：

$$c_k = \frac{1}{2\pi}\int_{-\pi}^{\pi} f(x)e^{-ikx}\,\mathrm{d}x, \qquad p_n(x)=\sum_{k=-n}^{n} c_k e^{ikx}.$$

对实函数，$c_{-k}=\overline{c_k}$；并且 $c_k=(a_k-ib_k)/2$，$k>0$。复数表达没有增加额外信息，只是把正弦与余弦合并。

离散傅里叶变换

令样本位于 $x_j = 2\pi j/N$。不同整数频率满足

$$\sum_{j=0}^{N-1} e^{2\pi i(k-l)j/N} = \begin{cases} N, & k \equiv l \pmod N, \\ 0, & \text{否则}. \end{cases}$$

证明只需有限等比数列公式：当比值不是 1 时，分子为 $1 - e^{2\pi i(k-l)} = 0$。

采用常见的未归一化正变换约定，

$$Y_k = \sum_{j=0}^{N-1} y_j e^{-2\pi ijk/N}, \qquad y_j = \frac{1}{N}\sum_{k=0}^{N-1} Y_k e^{2\pi ijk/N}. \tag{4.4}$$

把第一式代入第二式，再交换求和顺序，用上面的离散正交关系，即可验证逆变换。归一化系数必须与所用库的约定一致。

把正变换代入待验证的逆变换，保留两个不同的求和下标：

$$\begin{aligned} \frac{1}{N}\sum_{k=0}^{N-1} Y_k e^{2\pi ijk/N} &= \frac{1}{N}\sum_{k=0}^{N-1}\sum_{l=0}^{N-1} y_l e^{-2\pi ilk/N} e^{2\pi ijk/N} \\ &= \sum_{l=0}^{N-1} y_l \left[\frac{1}{N}\sum_{k=0}^{N-1} e^{2\pi i(j-l)k/N}\right]. \end{aligned}$$

当 $j = l$，中括号是 $N/N = 1$；当 $j \neq l$，它是一个公比不为 1、但公比的 N 次幂为 1 的等比和，等于零。整条和式因此只剩 y_j。

混叠也能直接在节点上验证：$e^{i(k+N)x_j} = e^{ikx_j}e^{2\pi ij} = e^{ikx_j}$。它们不是在连续区间上相同，而是在这 N 个采样点上无法区分。

DFT 不能区分相差 N 的频率，因为它们在这些节点上的值完全相同，这就是混叠。数据是有限采样时，不能把频谱中的一个峰无条件解释为真实连续信号的唯一频率。对偶数 N，频率 $N/2$ 的样本为 $(-1)^j$，它与 $-N/2$ 是同一模式，不能重复计数。

快速傅里叶变换

直接计算 (4.4) 需要 $O(N^2)$ 次运算。若 N 为偶数，分别把偶数下标与奇数下标取出：

$$Y_k = \sum_{r=0}^{N/2-1} y_{2r} e^{-2\pi irk/(N/2)} + e^{-2\pi ik/N}\sum_{r=0}^{N/2-1} y_{2r+1} e^{-2\pi irk/(N/2)}.$$

把两项中的短变换记为 E_k, O_k，令 $\omega_N = e^{-2\pi i/N}$，便得到

$$Y_k = E_k + \omega_N^k O_k, \qquad Y_{k+N/2} = E_k - \omega_N^k O_k, \quad 0 \le k < N/2.$$

一个长度 N 的问题被拆成两个长度 $N/2$ 的问题，再用 $O(N)$ 次运算组合。若 $N = 2^m$，

$$T(N) = 2T(N/2) + O(N) = O(N\log N).$$

组合公式中的第二个输出来自 $\omega_N^{k+N/2} = -\omega_N^k$，而 $E_{k+N/2} = E_k, O_{k+N/2} = O_k$，因为短变换的周期是 $N/2$。所以同一个乘积 $\omega_N^k O_k$ 同时参与一次相加与一次相减，无需再计算一遍。

复杂度可以按层数直接数：第一层共做 $O(N)$ 次组合，下一层有两个长度 $N/2$ 的问题，组合总量仍为 $O(N)$；再下一层有四个长度 $N/4$ 的问题，仍为 $O(N)$。长度从 $N = 2^m$ 缩到 1 一共 $m = \log_2 N$ 层，因此总量为 $O(N \log N)$。

FFT 是计算 DFT 的快速算法，不是一种新的变换，也不是对原 DFT 的截断近似。

对 $y = (1, 2, 3, 4)$ 作四点 DFT，偶下标序列 $(1, 3)$ 给出 $E = (4, -2)$，奇下标序列 $(2, 4)$ 给出 $O = (6, -2)$。再使用 $\omega_4 = -i$ 合并，得到

$$Y = (10, -2 + 2i, -2, -2 - 2i).$$

例如 $Y_1 = E_1 - iO_1 = -2 + 2i$，而 $Y_3 = E_1 + iO_1 = -2 - 2i$。二者共享同一对中间结果，正是

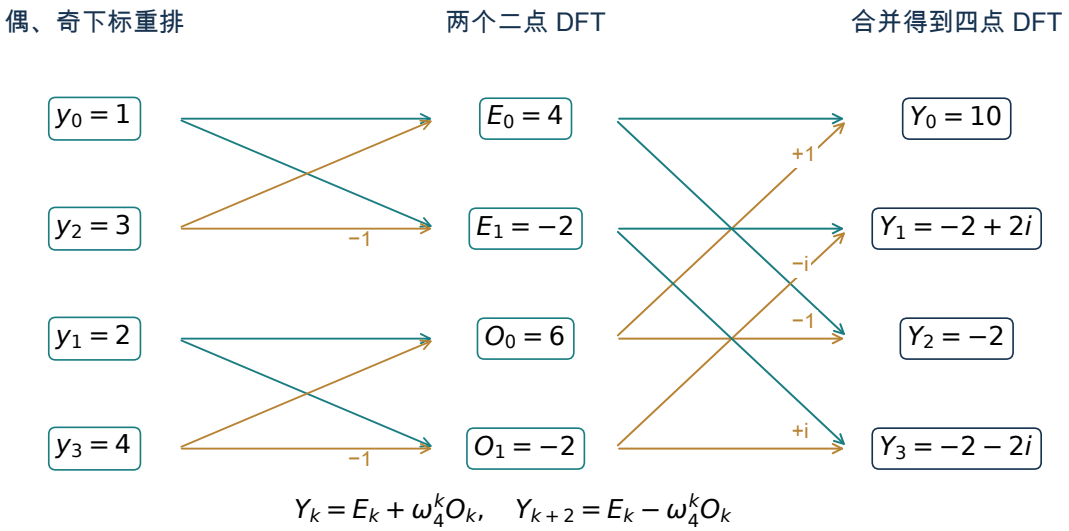


图 4.7 四点 FFT 的蝶形计算。箭头表示数据依赖，未标注的边权为 $+1$；标注 -1 或 $\pm i$ 的边先乘相应因子。左列已按偶、奇下标重排。

快速变换避免重复求和的地方。

三类逼近目标的比较

方法	要求或最小化的量	最优条件或特点
插值	指定节点上误差为零	先选函数空间，节点条件决定系数
最佳平方逼近	误差平方的积分或加权和	残差与逼近空间正交
最佳一致逼近	整个区间的最大绝对误差	多项式情形满足等幅交错条件

表 4.1 “最佳”依赖于误差度量。Fourier 有限部分和属于相应三角空间中的最佳平方逼近。

第 5 章　数值积分与数值微分

5.1　引言

许多积分没有方便的原函数，或者被积函数本身就是一个昂贵的程序。数值积分要在有限次函数求值的预算内，尽量准确地估计面积。选择哪些点、给每个点多大权重，决定了一个求积公式的精度与稳定性。

本章先固定节点，用插值导出求积；再通过复化与外推改善精度；最后让节点也参与设计，得到 Gauss 求积。

数值积分与数值微分都可以借助插值构造：先用简单函数近似 f，再对近似函数积分或求导。但两种运算的误差传播不同。积分把局部贡献累加，常有平均作用；求导依赖相邻值的差，再除以小步长，容易放大扰动。因此，本章不仅推导公式，也比较它们对数据精度和光滑性的要求。

一个求积问题通常先给定积分区间和可获得的函数信息。如果节点位置可以自由选择，就有优化节点的余地；如果只能使用已有等距采样，方法选择会受到限制。固定节点的 Newton-Cotes 与自由选点的 Gauss，正好对应这两种情况。

5.2　Newton-Cotes 求积公式

定义 5.1 (求积节点、权重与代数精度)　用有限和 $Q_m(f)=\sum_{i=1}^{m} A_i f(x_i)$ 近似积分，称为数值求积公式；x_i 是求积节点，A_i 是求积权重。若公式对所有 $p\in\mathcal{P}_d$ 精确，而并非对所有 $p\in\mathcal{P}_{d+1}$ 精确，则代数精度恰为 d。

代数精度之所以容易检验，是因为积分和加权求和都是线性操作。只要对基函数 $1,x,\dots,x^d$ 一一精确，就对它们的任意线性组合精确。这把一个涉及无穷多个多项式的条件，转成了有限组矩条件。

一般加权求积写为

$$I(f)=\int_a^b w(x)f(x)\,\mathrm{d}x \approx Q_m(f)=\sum_{i=1}^{m} A_i f(x_i).$$

若它对 $1,x,\dots,x^d$ 全部精确，而对至少一个 $d+1$ 次多项式不精确，则称代数精度为 d。这是对多项式的精确性指标，并不直接等于某个任意函数上的误差大小。

固定 m 个互异节点，插值 f 后积分，得

$$A_i=\int_a^b w(x)\ell_i(x)\,\mathrm{d}x.$$

因为对次数至多 $m-1$ 的多项式，插值完全恢复原函数，所以这种插值型求积至少具有 $m-1$ 次代数精度。反过来，若固定节点的求积对 $\mathcal{P}_{m-1}$ 精确，把各个 ℓ_i 代入就会唯一确定上述权重。

也可以通过矩条件设计公式：

$$\sum_{i=1}^{m} A_i x_i^k=\int_a^b w(x)x^k\,\mathrm{d}x,\qquad k=0,1,\dots,d.$$

这是把“对所有低次多项式精确”转成有限方程组的标准方法。

例 5.1 (对称二点公式) 在 $[-1,1]$ 上构造 $Q(f)=A[f(-c)+f(c)]$，使代数精度尽可能高，并说明其精度恰为多少。

解 由常数精确得 $2A=2$，故 $A=1$；奇次矩因对称性自动为零；二次矩要求 $2c^2=2/3$，故 $c=1/\sqrt{3}$。对 x^4，公式给 $2/9$，而积分为 $2/5$，所以代数精度恰为 3。

收敛性与稳定性

定义 5.2 (求积公式的收敛性与稳定性) 对一列求积公式 Q_m，若节点逐渐加密或阶数增加时 $Q_m(f)\to I(f)$，称其对 f 收敛。若节点函数值的小扰动只造成一致受控的求积扰动，则称该公式族对这类数据扰动稳定。

性质 5.3 (权重绝对值之和控制扰动) 若各节点数据误差不超过 ε，则

$$|\Delta Q_m|\le \varepsilon\sum_{i=1}^{m}|A_i|.$$

因此，$\sum_i |A_i|$ 随节点数一致有界，是对最大范数数据误差稳定的直接保证。

证明. 由 $\Delta Q_m=\sum_i A_i\Delta f_i$，使用三角不等式并代入 $|\Delta f_i|\le\varepsilon$ 即得。若扰动符号恰与权重符号相同，这一上界还可以达到。 □

具有高代数精度只说明公式能消去低次多项式误差，不限制权重绝对值之和。因此，“次数更高”和“对数据更稳定”是两个需要分别检验的性质。

Newton-Cotes 公式与误差

等距节点上的插值求积称为 Newton–Cotes 公式。最常用的三个低阶公式是中点、梯形与 Simpson：

$$\begin{aligned}
M(f)&=(b-a)f\left(\frac{a+b}{2}\right),\\
T(f)&=\frac{b-a}{2}[f(a)+f(b)],\\
S(f)&=\frac{b-a}{6}\left[f(a)+4f\left(\frac{a+b}{2}\right)+f(b)\right].
\end{aligned}$$

插值型权重可以从积分基函数逐个算出。用 $x=a+Ht$，其中 $H=b-a$，节点 $t=0,1$ 的线性基为 $1-t,t$，二者在 $[0,1]$ 上积分均为 $1/2$，再乘 H，就得到梯形的两个权重 $H/2$。

对节点 $0,1/2,1$，二次 Lagrange 基为

$$\ell_0=2t^2-3t+1,\quad \ell_1=4t-4t^2,\quad \ell_2=2t^2-t.$$

逐项积分，得到

$$\int_0^1\ell_0=\frac{2}{3}-\frac{3}{2}+1=\frac{1}{6},\quad \int_0^1\ell_1=2-\frac{4}{3}=\frac{2}{3},\quad \int_0^1\ell_2=\frac{2}{3}-\frac{1}{2}=\frac{1}{6}.$$

所以权重为 $H(1,4,1)/6$。公式对二次多项式精确是插值再现的结果；三次精确性还需要下面的对称性或误差分析。

中点公式使用一个内部节点。梯形公式来自线性插值的积分。Simpson 公式来自三个节点的二次插值，但因对称性使三次项误差也消失，代数精度达到 3。

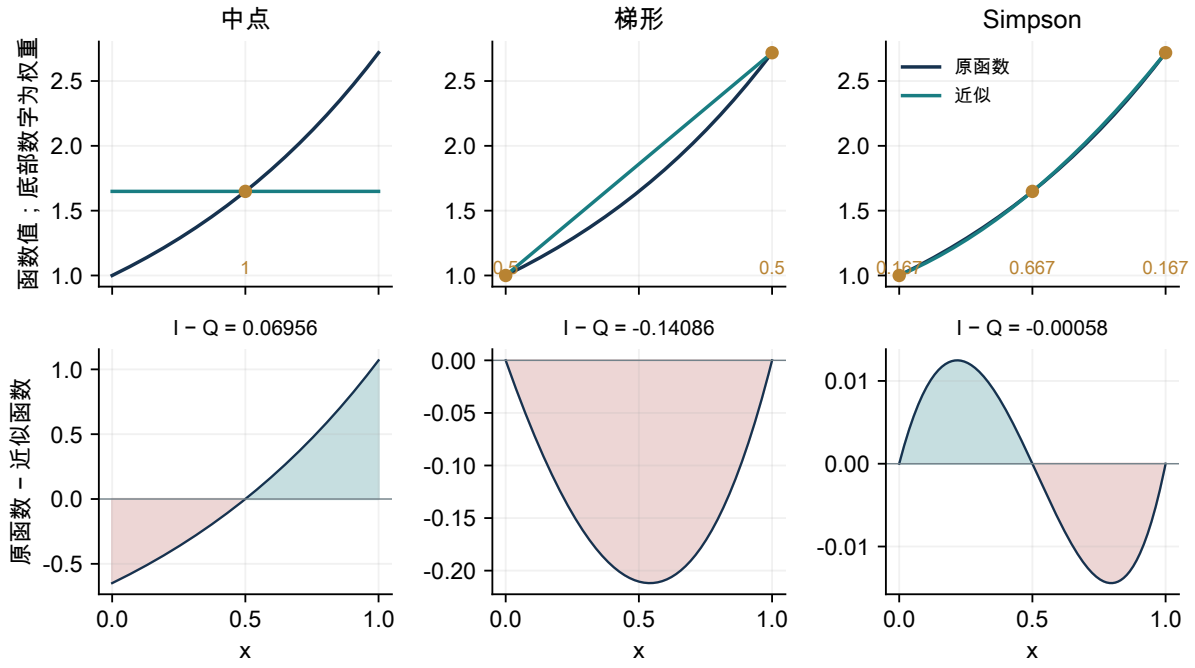


图 5.1 三种单面板公式的节点、权重与误差。上排的金色数字是权重；下排显示原函数减去近似函数，青色为正误差，红色为负误差。下排各图分别定标，标题列出带符号积分误差。

先说明“带权平均为何等于某处函数值”，再使用它。设 g 在 $[a,b]$ 连续，$w \geq 0$ 可积且 $W = \int_a^b w > 0$。记 $m = \min g$、$M = \max g$。逐点有 $mw \leq gw \leq Mw$，积分后除以正数 W，得到

$$m \leq \frac{\int_a^b g(x)w(x)\,\mathrm{d}x}{W} \leq M.$$

连续函数在最小值与最大值之间会取到每一个数，因此存在 $\xi \in [a,b]$，使中间的比值等于 $g(\xi)$，即

$$\int_a^b g(x)w(x)\,\mathrm{d}x = g(\xi)\int_a^b w(x)\,\mathrm{d}x.$$

若权始终非正，先对 $-w$ 使用同一论证即可。若权变号，这个推导就失效：例如在 $[-1,1]$ 上取 $g(x) = w(x) = x$，$\int w = 0$，但 $\int gw = 2/3$，无法写成 $g(\xi)\int w$。

对梯形，设 p_1 是端点线性插值，$T = \int_a^b p_1$。记

$$K(x) = \tfrac{1}{2}(x-a)(x-b) \leq 0.$$

插值余项逐点给出 $f(x) - p_1(x) = f''(\xi_x)K(x)$。我们并不需要选择一个连续的 ξ_x：只要令 $m = \min f''$、$M = \max f''$，就有

$$MK(x) \leq f(x) - p_1(x) \leq mK(x).$$

负号使不等号方向倒过来了。再计算核的积分。令 $u = x - a, H = b - a$，则

$$\int_a^b K(x)\,\mathrm{d}x = \frac{1}{2}\int_0^H (u^2 - Hu)\,\mathrm{d}u = \frac{1}{2}\left(\frac{H^3}{3} - \frac{H^3}{2}\right) = -\frac{H^3}{12}.$$

把逐点不等式积分，再除以这个负数，得到 $m \le (I-T)/(-H^3/12) \le M$。由 f'' 连续，存在一个 ξ 使该比值等于 $f''(\xi)$，故

$$I - T = -\frac{H^3}{12} f''(\xi).$$

这完整说明了负号、常数 $1/12$ 与中值点各自从哪里来。

中点公式则以 $c = (a+b)/2$ 展开：

$$f(x) = f(c) + f'(c)(x-c) + \tfrac{1}{2} f''(\eta_x)(x-c)^2.$$

积分时，线性项在对称区间上为零，第一项给出 $Hf(c)$。二阶余项的核为非负的 $(x-c)^2/2$，因此可以用 f'' 的上下界夹住积分。它的积分为

$$\frac{1}{2}\int_{-H/2}^{H/2} u^2 \,\mathrm{d}u = \frac{1}{2}\cdot\frac{2(H/2)^3}{3} = \frac{H^3}{24}.$$

再用相同的连续性论证，就得到 $I - M = H^3 f''(\eta)/24$。所以凸函数 $f'' \ge 0$ 时，梯形高估、中点低估。

Simpson 余项的推导. 对 Simpson，不能把三点插值的三阶导数余项直接提出积分。一个清楚的办法是让误差作用在四阶导数上。先把区间取成 $[-1,1]$，定义

$$E(f) = \int_{-1}^{1} f(x)\,\mathrm{d}x - \frac{f(-1) + 4f(0) + f(1)}{3}.$$

对 $1, x, x^2, x^3$ 分别代入，结果都是零：常数给 $2 - 2 = 0$，奇次项由对称性为零，二次项给 $2/3 - 2/3 = 0$。所以 E 消去全部三次多项式。

以 -1 为展开点，带积分余项的 Taylor 公式是

$$f(x) = T_3(x) + \int_{-1}^{x} \frac{(x-t)^3}{6} f^{(4)}(t)\,\mathrm{d}t.$$

若要核对这个公式，可对积分项连续求导四次：前三次边界项因 $(x-t)$ 的剩余幂为零而消失，第四次得到 $f^{(4)}(x)$；积分项在 -1 处的前四个初始值都为零，故与 Taylor 多项式合起来正好恢复 f。

将积分上限统一写到 1，只需把 $(x-t)^3$ 改成 $(x-t)_+^3$。对 x 使用 E 后，T_3 消失。求积的有限求和可以与积分交换；积分部分则把区域 $-1 \le t \le x \le 1$ 换序，得到

$$E(f) = \int_{-1}^{1} K(t) f^{(4)}(t)\,\mathrm{d}t, \quad K(t) = E_x\left[\frac{(x-t)_+^3}{6}\right].$$

把 E 的定义逐项代入，$x = -1$ 的项为零，剩下

$$K(t) = \frac{(1-t)^4}{24} - \frac{4(-t)_+^3 + (1-t)^3}{18}.$$

当 $0 \le t \le 1$，提出 $(1-t)^3$，得到

$$K(t) = (1-t)^3\left(\frac{1-t}{24} - \frac{1}{18}\right) = -\frac{(1-t)^3(1+3t)}{72}.$$

当 $-1 \le t < 0$，令 $s = -t$，通分后的分子是

$$3(1+s)^4 - 16s^3 - 4(1+s)^3 = -1 + 6s^2 - 8s^3 + 3s^4 = -(1-s)^3(1+3s).$$

所以两个区间合起来就是 $K(t) = -(1-|t|)^3(1+3|t|)/72 \le 0$。此时才具备使用带权平均的条件。
核的积分也直接算出：

$$\begin{aligned}\int_{-1}^{1} K(t)\,\mathrm{d}t &= -\frac{1}{36}\int_{0}^{1}(1-t)^3(1+3t)\,\mathrm{d}t \\ &= -\frac{1}{36}\int_{0}^{1}(1-6t^2+8t^3-3t^4)\,\mathrm{d}t \\ &= -\frac{1}{36}\left(1-2+2-\frac{3}{5}\right) = -\frac{1}{90}.\end{aligned}$$

由 $f^{(4)}$ 连续和 K 不变号，得到 $E(f) = -f^{(4)}(\xi)/90$。
最后恢复一般区间。令 $x = c + \ell t$，$c = (a+b)/2$、$\ell = (b-a)/2$，并设 $g(t) = f(c+\ell t)$。积分与求积值都多出一个 ℓ，而 $g^{(4)}(t) = \ell^4 f^{(4)}(c+\ell t)$。所以

$$I(f) - S(f) = -\frac{\ell^5}{90} f^{(4)}(\xi) = -\frac{(b-a)^5}{2880} f^{(4)}(\xi). \tag{5.1}$$

这五个区间尺度因子，一个来自积分换元，四个来自四阶导数换元。

□

负号可用 $f(x) = x^4$ 核对：Simpson 对它高估。

三次代数精度还可以从一个具体误差图看出来。在 $[-1,1]$ 上插值 $f(x) = x^3$，节点为 $-1, 0, 1$，得到的二次插值多项式实际退化为 $p_2(x) = x$。两条曲线并不重合，但 $f - p_2 = x^3 - x$ 为奇函数，左右两块误差面积分别为 $1/4$ 和 $-1/4$，积分恰好抵消。

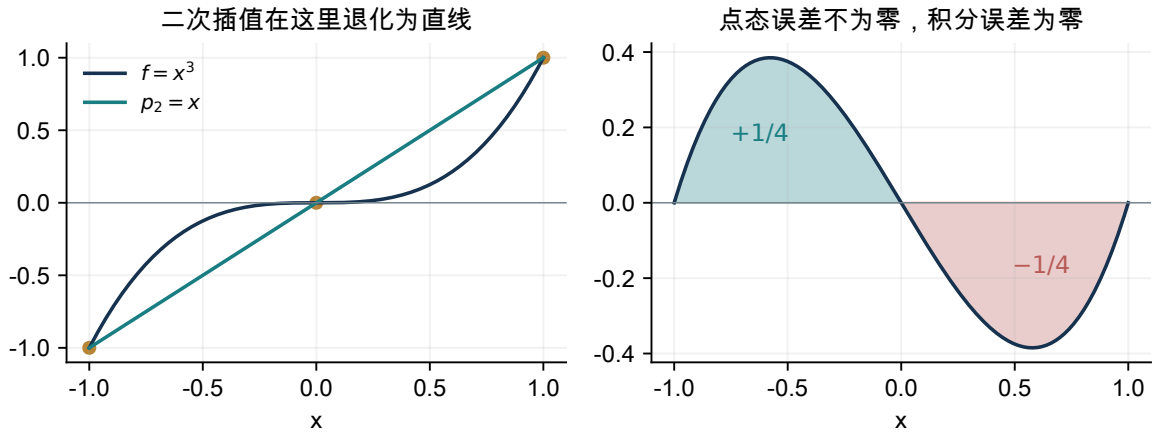


图 5.2 Simpson 对三次函数精确，并不要求插值函数处处等于原函数。这里精确的是带符号面积之和。

高次等距 Newton–Cotes 并不总是更好。部分权重变成负数后，数据误差的放大会变大；高次插值也可能振荡。通常更可靠的路线是在很多小区间重复使用低阶公式。

5.3 复化求积公式

单面板公式只用少量节点，在很长的区间上可能无法反映函数变化。提高单个插值多项式的次数是一种办法，但也会引入高次振荡。复化法保留低阶公式，只缩短每次近似负责的区间。

定义 5.4 (复化求积) 把积分区间划分成多个小区间，在每个小区间使用同一种低阶求积规则，再将所有近似相加，称为复化求积。全局误差是各个面板误差之和。

估计时要同时计算两件事：一个面板的误差随 h 怎样变化，以及面板数量随 h 怎样变化。固定区间长度下，面板数约为 $1/h$；所以局部 $O(h^{p+1})$ 的误差通常累积成全局 $O(h^p)$，这一规律还会在时间积分中再次出现。

把 $[a,b]$ 分成 N 个等长子区间，$h=(b-a)/N$，$x_i=a+ih$。复化梯形为

$$T_h = h\left[\frac{f(x_0)+f(x_N)}{2}+\sum_{i=1}^{N-1} f(x_i)\right].$$

每段局部误差为 $O(h^3)$，一共约 $1/h$ 段，因此总误差为 $O(h^2)$。更严格地，在 $f\in C^2$ 下，

$$I-T_h=-\frac{b-a}{12}h^2 f''(\xi),\quad |I-T_h|\le \frac{b-a}{12}h^2\left\|f''\right\|_\infty.$$

这里又使用了各段导数值加权平均后的介值性。

若 N 为偶数，复化 Simpson 每两个小区间组成一个面板：

$$S_h=\frac{h}{3}\left[f(x_0)+f(x_N)+4\sum_{\substack{1\le i\le N-1\\ i\text{ 奇}}} f(x_i)+2\sum_{\substack{2\le i\le N-2\\ i\text{ 偶}}} f(x_i)\right].$$

由 (5.1)，面板宽为 $2h$，总误差为

$$I-S_h=-\frac{b-a}{180}h^4 f^{(4)}(\xi). \tag{5.2}$$

h 指小区间宽度，而不是面板宽度。混淆这两个长度会带来 2^4 倍的常数错误。

复化梯形的每一小段都有误差 $-h^3f''(\xi_i)/12$。把 N 段相加，写成

$$I-T_h=-\frac{Nh^3}{12}\left[\frac{1}{N}\sum_{i=0}^{N-1} f''(\xi_i)\right].$$

中括号是导数值的普通平均，位于全区间的最小、最大二阶导数之间；连续性使它等于某处的 $f''(\xi)$。再用 $Nh=b-a$，得到全局系数 $-(b-a)h^2/12$。

对复化 Simpson，一个面板包含两个小区间，宽为 $2h$，其误差系数为 $-(2h)^5/2880=-h^5/90$。共有 $N/2$ 个面板，总系数因此为

$$-\frac{N}{2}\frac{h^5}{90}=-\frac{(b-a)h^4}{180}.$$

对各个四阶导数值再作平均，就得到全局余项。这同时解释了局部误差五次、全局误差四次的区别。

把同一个被积函数放到不同网格上，可以看见复化公式怎样工作。梯形每次连接相邻两个节点；Simpson 每次使用三个节点，覆盖两个小区间。下图两排共享函数与坐标范围，金色点是需要计算的函数值。

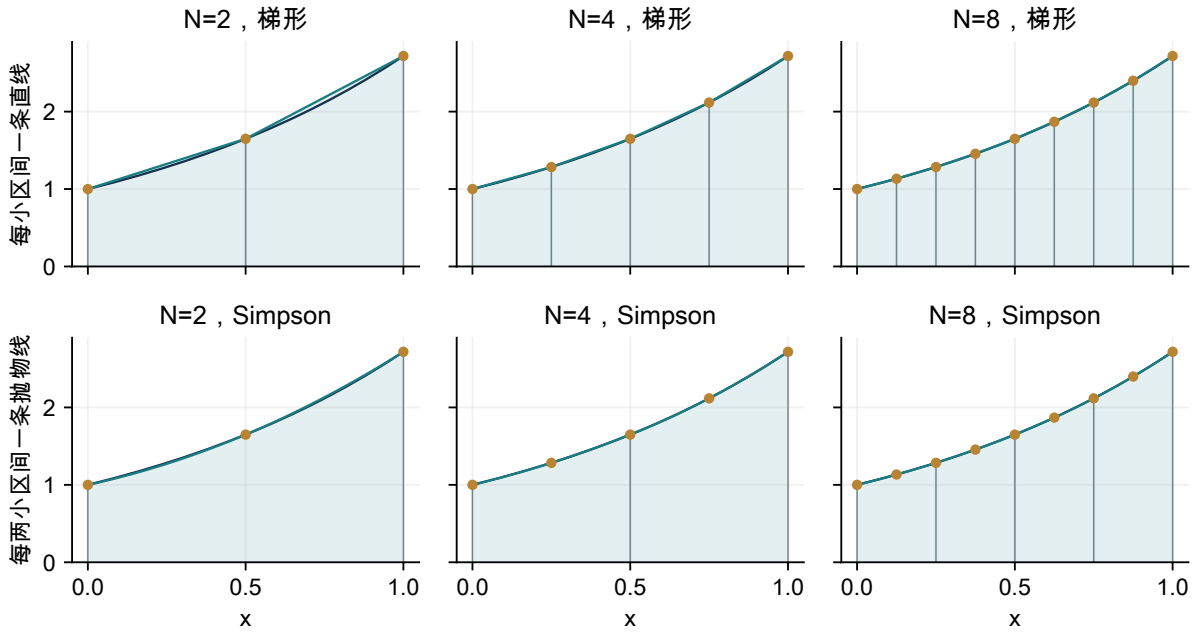


图 5.3 对 e^x 在 $[0,1]$ 上逐次加密网格。N 表示小区间数，下面一排实际含 $N/2$ 个 Simpson 面板。阴影表示数值积分的近似面积。

N	T_h	$\lvert I-T_h\rvert$	误差比	S_h	$\lvert I-S_h\rvert$	误差比
2	1.75393109	3.56×10^{-2}	–	1.71886115	5.79×10^{-4}	–
4	1.72722190	8.94×10^{-3}	3.988	1.71831884	3.70×10^{-5}	15.652
8	1.72051859	2.24×10^{-3}	3.997	1.71828415	2.33×10^{-6}	15.911
16	1.71884113	5.59×10^{-4}	3.999	1.71828197	1.46×10^{-7}	15.978

表 5.1 $I=e-1$ 的复化求积过程。两种方法使用相同小区间数。

表中的误差比使用前一行误差除以本行误差。步长减半以后，梯形比值趋于 4，Simpson 比值趋于 16，与二阶、四阶误差模型一致。这些比值来自实际计算，并非把理论数值直接填入表中。

例 5.2 (从容许误差选取子区间数)　用复化梯形和复化 Simpson 计算 $\int_0^1 e^x\,\mathrm{d}x$。若要求误差不超过 10^{-6}，分别给出满足余项界的子区间数。

解　被积函数的各阶导数均为 e^x，在区间上的上界为 e。梯形界要求 $e/(12N^2)\le 10^{-6}$，取 $N\ge 476$ 即可。Simpson 界要求 $e/(180N^4)\le 10^{-6}$，取正偶数 $N=12$ 即可。这比较的是导数界给出的充分保证，不表示每个实际函数都需要这么多节点。

自适应划分

当曲率集中在少数位置时，统一细网格会浪费计算。自适应 Simpson 在一个面板上计算粗值 S 和分成两半后的 S_2。在四阶主误差模型成立时，精细值的误差近似为

$$I-S_2\approx\frac{S_2-S}{15},\qquad I\approx S_2+\frac{S_2-S}{15}.$$

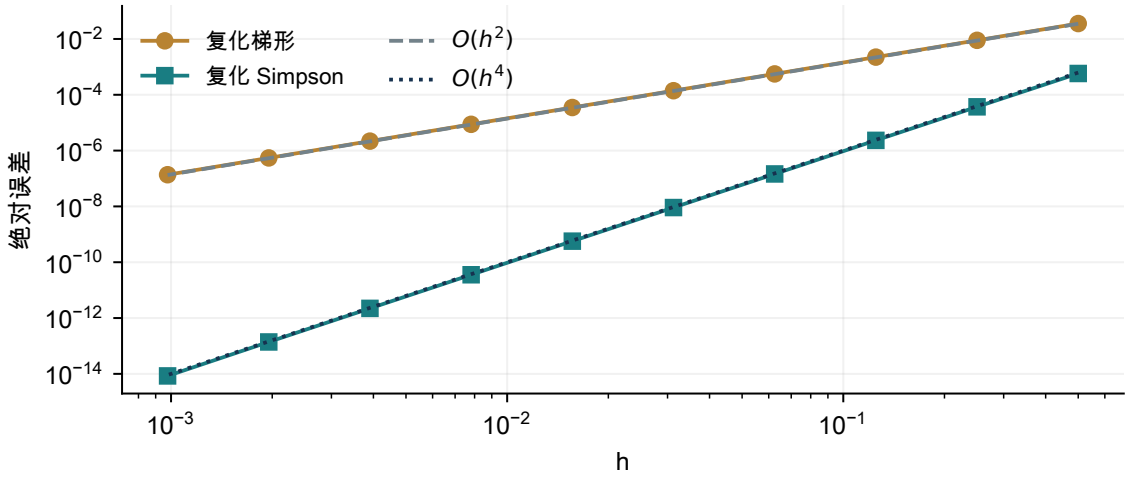


图 5.4 计算 $\int_0^1 e^x\,\mathrm{d}x$ 的实际误差。双对数图中，复化梯形与 Simpson 的渐近斜率分别对应二阶与四阶；误差接近浮点精度后不再遵循无限精度模型。

设粗网格 Simpson 误差为 $I - S = Ch^4 + O(h^6)$，这里 h 表示这个固定积分区间内的小网格宽度；把网格减半，有 $I - S_2 = Ch^4/16 + O(h^6)$。两式相减：

$$S_2 - S = (I - S) - (I - S_2) = \frac{15}{16}Ch^4 + O(h^6).$$

所以细结果的主误差为 $(S_2 - S)/15$，不是直接使用 $S_2 - S$。修正值 $S_2 + (S_2 - S)/15$ 正是扣去该主误差后的结果。对足够小的面板也可用局部五次误差解释同一个 16：两半段各有原来的 $1/32$，相加后为 $1/16$。

若估计不满足该区间的误差预算，就继续二分，并给子区间分配预算。实际程序还应设置深度与求值次数上限，避免在不光滑点附近无限递归。少量采样也可能完全错过狭窄尖峰；相邻公式一致只是基于当前采样信息的判断。

对局部尖峰函数，等距网格会把很多采样用在平缓区域。下面取

$$f(x) = \frac{1}{1 + 400(x - 0.3)^2}, \qquad 0 \le x \le 1,$$

并从整个区间开始自适应二分。每个区间比较一次与两次 Simpson 的结果，以差值的 $1/15$ 作为误差估计；二分后将该区间的误差预算各分一半。该函数有解析积分 $[\arctan 14 + \arctan 6]/20$，约为 0.1452568256。图中算法给出约 0.1452568714，可据此独立检查估计。误差估计依赖局部渐近模型，因而仍应区别“通过当前检验”与“对任意未知函数的严格误差保证”。

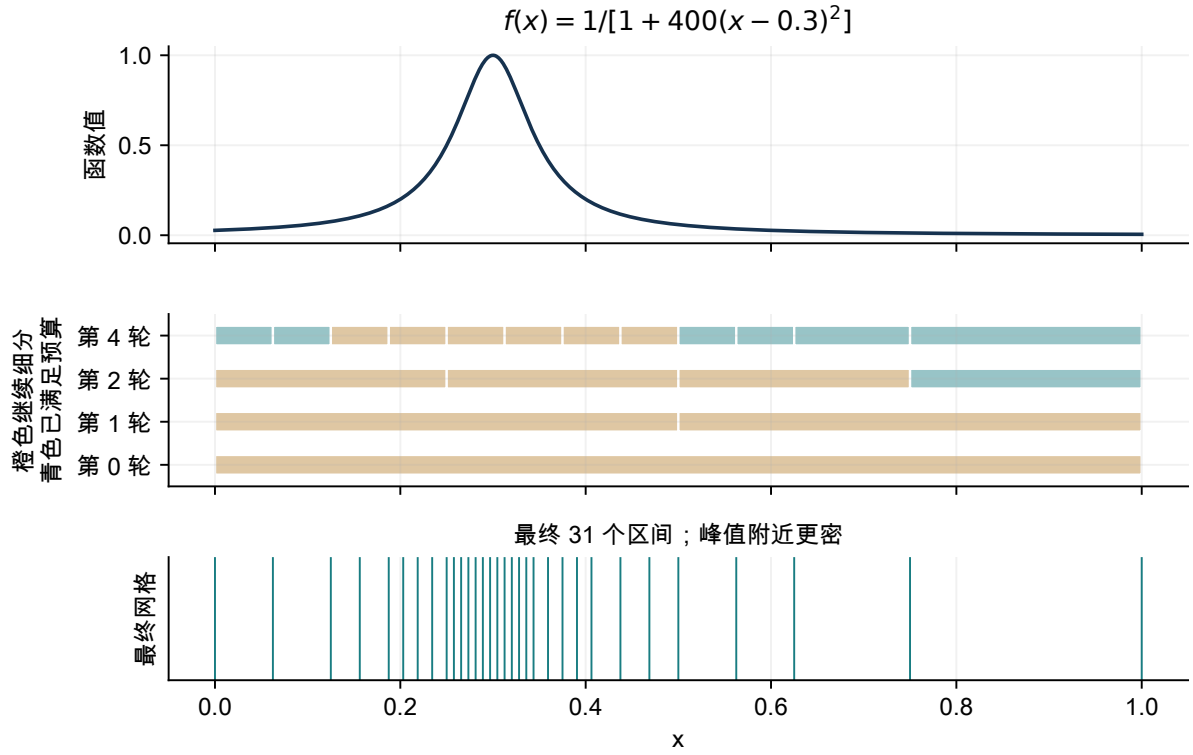


图 5.5 自适应 Simpson 的网格生成。中排橙色区间还需细分，青色区间已通过当前估计；下排是最终网格。这里总误差预算为 10^{-6}，最终使用 31 个区间。

5.4 外推原理与 Romberg 求积法

假设粗网格与细网格结果都已经进入同一种误差展开范围。它们的差主要来自那个尚未消失的低阶项，因此可以用这个差估计主误差，再把它扣掉。这是外推能提高阶数的原因。

> **定义 5.5** (Richardson 外推) 若近似 $Q(h)$ 具有已知主阶 p 的误差展开，通过不同步长的线性组合消去 h^p 项，称为 Richardson 外推。系数的选择依赖误差阶，而不是任意取平均。

例如，若两次结果只差 10^{-5}，仅凭这个差无法知道误差本身是 10^{-5}、10^{-3}，还是两者恰好发生了抵消。只有先建立 $Q(h) = I + ch^p + \cdots$ 的关系，才能把结果差转成误差估计。

假设已有近似 $Q(h) = I + ch^p + O(h^{p+q})$，其中 $p, q > 0$。步长减半后

$$Q(h/2) = I + \frac{c}{2^p}h^p + O(h^{p+q}).$$

两式消去未知 c：

$$\widehat{Q} = \frac{2^p Q(h/2) - Q(h)}{2^p - 1} = I + O(h^{p+q}). \tag{5.3}$$

外推并没有新测量误差，而是在已知主误差模型下，用两次近似估计并消除主项。

梯形的偶次幂展开并非凭经验猜测。先看一个以 c 为中点、长度为 h 的小区间。将端点值和积分分别在 c 展开，奇次项因对称性消失：

$$T_{\text{panel}} = hf(c) + \frac{h^3}{8}f''(c) + \frac{h^5}{384}f^{(4)}(c) + O(h^7),$$

$$I_{\text{panel}} = hf(c) + \frac{h^3}{24}f''(c) + \frac{h^5}{1920}f^{(4)}(c) + O(h^7).$$

相减得到 $T_{\text{panel}} - I_{\text{panel}} = h^3 f''(c)/12 + h^5 f^{(4)}(c)/480 + O(h^7)$。

为了把所有面板累加，改用端点导数差：

$$f'(c+h/2) - f'(c-h/2) = hf''(c) + \frac{h^3}{24} f^{(4)}(c) + O(h^5),$$

$$f'''(c+h/2) - f'''(c-h/2) = hf^{(4)}(c) + O(h^3).$$

第一式乘 $h^2/12$ 会给出 $h^5 f^{(4)}/288$，比所需的 $1/480$ 多。因此再减去第二式的 $h^4/720$ 倍，因为 $1/288 - 1/720 = 1/480$。于是

$$T_{\text{panel}} - I_{\text{panel}} = \frac{h^2}{12}[f'(x_{i+1}) - f'(x_i)] - \frac{h^4}{720}[f'''(x_{i+1}) - f'''(x_i)] + O(h^7).$$

对所有面板求和，内部端点一正一负相消，只剩区间两端；在足够光滑条件下得到

$$T_h - I = \frac{h^2}{12}[f'(b) - f'(a)] - \frac{h^4}{720}[f'''(b) - f'''(a)] + O(h^6).$$

更高阶也按同样方式逐项消去：对称展开只含奇次的局部 h 幂，端点奇阶导数差的首项可以依次消去它们，求和后则只留下偶次全局误差。这需要相应的更高阶导数，不能用于没有这种光滑性的函数。

令 $R_{k,0} = T_{(b-a)/2^k}$，逐列外推：

$$R_{k,j} = R_{k,j-1} + \frac{R_{k,j-1} - R_{k-1,j-1}}{4^j - 1}, \qquad 1 \le j \le k. \tag{5.4}$$

第一列消去 h^2 项，第二列消去 h^4 项，依次进行，这就是 Romberg 积分。对固定列 j，在相应光滑性和渐近展开成立时，其误差为 $O(h^{2j+2})$。

梯形加密时已有节点可以复用：

$$T_{h/2} = \frac{1}{2} T_h + \frac{h}{2} \sum_{i=0}^{N-1} f(x_i + h/2).$$

消去过程可以直接逐项算：将细网格式乘 2^p，其主误差变成 ch^p，再减去粗网格式，得

$$2^p Q(h/2) - Q(h) = (2^p - 1)I + O(h^{p+q}).$$

除以非零常数 $2^p - 1$，便得到外推值。Romberg 第 j 次外推面对的主项阶数是 $p = 2j$，所以分母为 $2^{2j} - 1 = 4^j - 1$。

网格复用式也可从节点权重核对。新步长为 $h/2$，旧端点和旧内部节点的系数都减半，合起来恰为 $T_h/2$；新出现的 N 个中点，每个系数为 $h/2$。这便给出 $T_{h/2} = T_h/2 + (h/2)\sum_i f(x_i + h/2)$。

只计算新插入的中点即可。外推表中系数很小的差值还可能受到舍入或噪声影响，不能无限加列。

外推与“多算一次”的区别。如果不知道误差随 h 怎样变化，两次近似接近并不能自动给出可靠误差。外推的力量来自误差展开，而不只是数字相近。误差估计通常要先确认已进入渐近区间。

仍用 $\int_0^1 e^x \,\mathrm{d}x = e - 1$。第一列只是不断加密的梯形值；其余每一个位置都由左边和左上方两个已知位置计算。表中青色的右端值，是相应行目前最高阶的结果。

k	N	$R_{k,0}$	$R_{k,1}$	$R_{k,2}$	$R_{k,3}$	$R_{k,4}$
0	1	1.8591409142				
1	2	1.7539310925	1.7188611519			
2	4	1.7272219046	1.7183188419	1.7182826879		
3	8	1.7205185922	1.7182841547	1.7182818422	1.7182818288	
4	16	1.7188411286	1.7182819741	1.7182818287	1.7182818285	1.7182818285

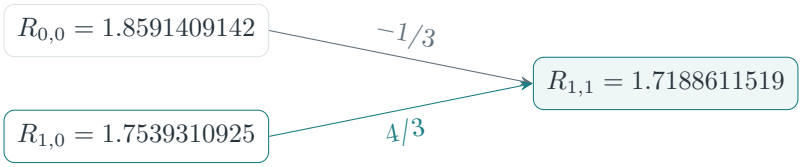


表 5.2 Romberg 计算表。$R_{k,0}$ 是步长 $h = 2^{-k}$ 的梯形值。

第一次外推实际计算的是

$$R_{1,1} = \frac{4 \times 1.7539310925 - 1.8591409142}{3} \approx 1.7188611519.$$

当添加新的一行时，旧函数值可以复用；需要新增的只是中点函数值和表中右侧的组合运算。

5.5 Gauss 求积公式

固定 m 个节点时，只有 m 个权重可调，通常只能保证到 $m-1$ 次。若连节点也一起设计，就多出 m 个自由参数。我们希望把这些自由度用在消去更高次误差上，而不是仅把已有节点移动得更均匀。

定义 5.6 (Gauss 型求积公式) 对给定区间与正权函数，使用 m 个互异节点，并达到最大可能代数精度 $2m-1$ 的求积公式，称为 m 点 Gauss 型求积公式。

正交多项式在这里重新出现，是因为求积误差需要同时消去一整族乘积 $q(x)\pi_m(x)$。它不是凭经验挑选出的一组“好看节点”，而是由精确性条件必然导出的节点结构。

用 m 个节点时，节点与权重共提供 $2m$ 个参数。能否让公式对 $2m$ 个单项式精确，即达到 $2m-1$ 次代数精度？正交多项式给出一个完整答案。

定理 5.7 (Gauss 节点的刻画) 设 $w > 0$ 几乎处处，π_m 是对应权下的首一 m 次正交多项式。以它的 m 个零点为节点，采用插值型权重，求积公式恰有 $2m-1$ 次代数精度。反之，具有此精度的 m 点公式，其节点多项式必与 $\mathcal{P}_{m-1}$ 正交。

证明. 对任意 $p \in \mathcal{P}_{2m-1}$，作多项式除法

$$p = q\pi_m + r, \qquad q, r \in \mathcal{P}_{m-1}.$$

由正交性，$\int wq\pi_m = 0$。在所有节点上 $\pi_m = 0$，故求积值也只保留 r。而插值型公式对 r 精确，因此对 p 精确。

反过来，设节点多项式为 ω_m，对任意 $q\in\mathcal{P}_{m-1}$，$q\omega_m$ 的次数至多 $2m-1$。其求积值为零，所以精确性要求 $\int wq\omega_m=0$，即所需正交性。
最后，任何 m 点公式都不可能对 ω_m^2 精确：求积值为零，但 $\int w\omega_m^2>0$。该多项式次数为 $2m$，所以 $2m-1$ 已是上限。 □

定理 5.8 (Gauss 权重为正及余项) Gauss 求积的每个权重 $A_i>0$，且若 $f\in C^{2m}[a,b]$，则

$$I(f)-Q_m(f)=\frac{f^{(2m)}(\xi)}{(2m)!}\int_a^b w(x)\pi_m(x)^2\,\mathrm{d}x. \tag{5.5}$$

证明. 先证权重为正。$\ell_i(x_j)=\delta_{ij}$，故将 $2m-2$ 次多项式 ℓ_i^2 代入已知精确的 Gauss 公式，右侧只剩 A_i：

$$A_i=\int_a^b w(x)\ell_i(x)^2\,\mathrm{d}x.$$

ℓ_i 不是零多项式，在某段小区间内非零；$w>0$ 几乎处处，因此这个非负积分严格大于零。
再证余项。令 $H\in\mathcal{P}_{2m-1}$ 是在 m 个节点上匹配函数值和一阶导数的 Hermite 多项式。因为节点函数值相同，$Q(f)=Q(H)$；因为 H 次数不超过精度上限，$Q(H)=I(H)$。所以 $I(f)-Q(f)=I(f-H)$。
记 $m_{2m}=\min f^{(2m)}$、$M_{2m}=\max f^{(2m)}$。Hermite 余项的节点乘积是 $\pi_m(x)^2\ge 0$，因此逐点有

$$\frac{m_{2m}}{(2m)!}\pi_m(x)^2\le f(x)-H(x)\le\frac{M_{2m}}{(2m)!}\pi_m(x)^2.$$

乘以非负权并积分，令 $J=\int w\pi_m^2>0$，得到

$$m_{2m}\le\frac{(2m)![I(f)-Q(f)]}{J}\le M_{2m}.$$

由 $f^{(2m)}$ 连续，中间比值等于某处的 $f^{(2m)}(\xi)$，即为所述余项。整个推导没有把随 x 变化的未知中值点直接移出积分。 □

三点 Gauss–Legendre 的节点来自 $P_3(x)=(5x^3-3x)/2$ 的零点，解得 $0,\pm\sqrt{3/5}$。对称性使左右权重相同，记为 A，中间权重为 B。要求对 $1,x^2$ 精确，得

$$2A+B=2,\qquad 2A\cdot\frac{3}{5}=\frac{2}{3}.$$

第二式给 $A=5/9$，再代入第一式得到 $B=8/9$，所以出现下面的三点公式。

Gauss–Legendre 使用 $[-1,1]$、权 1。二点规则已在前面得到；三点规则为

$$\int_{-1}^{1}f(x)\,\mathrm{d}x\approx\frac{5}{9}f\left(-\sqrt{\frac{3}{5}}\right)+\frac{8}{9}f(0)+\frac{5}{9}f\left(\sqrt{\frac{3}{5}}\right).$$

映射到一般区间时，令 $x=(a+b)/2+(b-a)t/2$，每个权重还要乘 $(b-a)/2$。

Gauss–Chebyshev 对应的是带权积分

$$\int_{-1}^{1}\frac{f(x)}{\sqrt{1-x^2}}\,\mathrm{d}x\approx\frac{\pi}{m}\sum_{i=1}^{m}f\left(\cos\frac{(2i-1)\pi}{2m}\right).$$

Gauss–Chebyshev 的等权也可以直接检验。令 $\theta_j=(2j-1)\pi/(2m)$。对 $1\le k\le 2m-1$，取 $\alpha=k\pi/(2m)$，使用正弦差公式逐项相消：

$$2\sin\alpha\sum_{j=1}^{m}\cos((2j-1)\alpha)=\sum_{j=1}^{m}[\sin(2j\alpha)-\sin((2j-2)\alpha)]=\sin(k\pi)=0.$$

由于此时 $\sin\alpha\neq 0$，余弦和为零。而连续积分 $\int_0^{\pi}\cos(k\theta)\,\mathrm{d}\theta$ 同样为零。常数项的连续积分为 π，离散求和用权重 π/m 也得 π。所以该公式对 $T_0,\dots,T_{2m-1}$ 全部精确，它们又是 $\mathcal{P}_{2m-1}$ 的一组基，因而达到所需精度。

一般区间的换元也要保留尺度：$x=c+\ell t$ 时，$\mathrm{d}x=\ell\,\mathrm{d}t$，因此 $\int_a^b f(x)\,\mathrm{d}x=\ell\int_{-1}^{1}f(c+\ell t)\,\mathrm{d}t$。映射节点的同时，所有权重都乘 $\ell=(b-a)/2$。

它不是普通无权积分的现成替代式。若把权混入 f，必须检查变换后的函数光滑性。

同样只作三次函数求值时，Simpson 固定等距节点，只调整权重；三点 Gauss 同时调整节点和权重。下图的竖线高度表示权重，并不是用矩形面积解释 Gauss 积分。

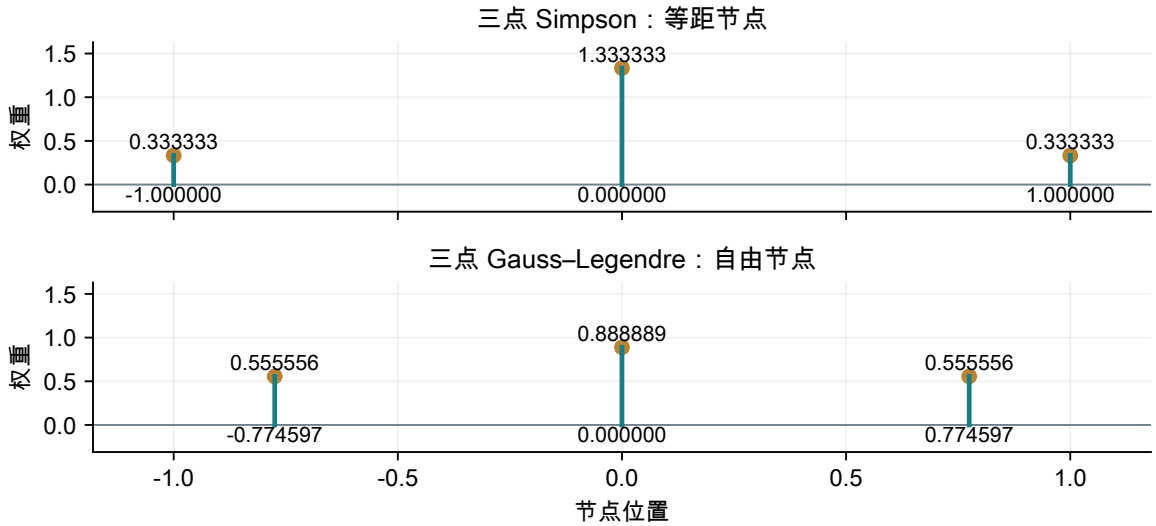


图 5.6 三点 Simpson 与三点 Gauss–Legendre 的节点及权重。所有权重均为正且总和为 2，但所满足的高次矩条件不同。

被积函数	准确积分	三点 Simpson	三点 Gauss
1	2	2	2
x	0	0	0
x^2	$\frac{2}{3}$	$\frac{2}{3}$	$\frac{2}{3}$
x^3	0	0	0
x^4	$\frac{2}{5}$	$\frac{2}{3}$	$\frac{2}{5}$
x^5	0	0	0
x^6	$\frac{2}{7}$	$\frac{2}{3}$	$\frac{6}{25}$

表 5.3 逐个单项式检查代数精度；积分区间为 $[-1,1]$。

对称公式都会精确积分奇函数，因此 Simpson 对 x^5 也精确。这不把它的代数精度提高到 5：x^4 已经失败，而代数精度要求此前**所有**次数都精确。

正权公式的收敛性

若节点数据各有不超过 ε 的绝对误差，则求积误差的扰动满足

$$|\Delta Q| \le \varepsilon \sum_i |A_i|.$$

正权公式对常数精确时，$\sum_i |A_i| = \sum_i A_i = \int w$，因此数据噪声不会因权重正负抵消而额外放大。

正权与不断提高的多项式精度还给出收敛性。对连续 f 和任意 $\epsilon > 0$，由多项式一致逼近定理选 p 使 $\|f - p\|_\infty < \epsilon$。当公式精度足够高时 $Q(p) = I(p)$，所以

$$|I(f) - Q(f)| \le |I(f-p)| + |Q(f-p)| \le 2\epsilon \int_a^b w(x)\,\mathrm{d}x.$$

这说明 Gauss 公式随节点数增加对连续函数收敛。这里使用的是有限总权重与正性，不要求 f 有任意高阶导数。

把最后一步的不等式拆开看。第 4 章的一致逼近构造给出一个固定多项式 p，满足 $|f-p| < \varepsilon$。当节点数足够多，公式对这个 p 精确。于是

$$I(f) - Q(f) = I(f-p) - Q(f-p).$$

第一项绝对值不超过 $\varepsilon \int w$。第二项因为权重为正，绝对值不超过 $\varepsilon \sum_i A_i$；公式对常数 1 精确，又给出 $\sum_i A_i = \int w$。两项相加得到 $2\varepsilon \int w$。先选 p，再增加节点数，这个顺序保证证明没有要求未知函数具备任意高阶导数。

5.6 数值微分

积分把很多函数值平均起来，微分却试图从很小的函数差中恢复局部变化率。这使微分更容易放大数据噪声。同样的插值思想可以构造两类公式，但它们面对误差时的行为很不相同。

定义 5.9 (差分近似与截断误差) 用有限个函数值的线性组合近似某点的导数，称为差分近似。把精确函数值代入差分公式后，与精确导数之间的差称为该公式的截断误差；输入函数值本身的误差应另外计入。

讨论求导公式时，需要明确三个对象：求导位置、可用节点以及目标导数的阶数。例如，中心差分在 x 两侧取值，而边界点可能只有单侧数据；同样的节点组合，也可能分别用于一阶或二阶导数。不能仅根据“用了三个点”判断公式精度。

中点方法与误差分析

在点 x 展开 $f(x \pm h)$：

$$f(x \pm h) = f(x) \pm h f'(x) + \frac{h^2}{2} f''(x) \pm \frac{h^3}{6} f'''(x) + \cdots.$$

作差可消去偶次项，因此

$$\frac{f(x+h) - f(x-h)}{2h} = f'(x) + \frac{h^2}{6} f'''(x) + O(h^4). \tag{5.6}$$

这里完整到 $O(h^4)$ 的展开可在足够高阶连续导数条件下成立；若仅有 $f \in C^3$，仍有二阶误差界。

同理，作和并减去 $2f(x)$ 得

$$\frac{f(x+h)-2f(x)+f(x-h)}{h^2}=f''(x)+\frac{h^2}{12}f^{(4)}(x)+O(h^4).$$

中心公式的高阶精度来自对称性。区间端点无法取到两侧值时，可以用单侧三点公式

$$f'(x)\approx\frac{-3f(x)+4f(x+h)-f(x+2h)}{2h},$$

其主误差为 $-h^2f'''(x)/3$，仍为二阶，但误差常数与噪声放大都不同。

把正负步长的展开并排相减，可以直接看到常数和所有偶次项消失：

$$f(x+h)-f(x-h)=2hf'(x)+\frac{2h^3}{3!}f'''(x)+\frac{2h^5}{5!}f^{(5)}(x)+\cdots.$$

除以 $2h$，三阶项变成 $h^2f'''/6$。若改为相加再减去 $2f(x)$，则奇次项消失：

$$f(x+h)+f(x-h)-2f(x)=h^2f''(x)+\frac{h^4}{12}f^{(4)}(x)+\cdots.$$

这里二阶项来自两份 $h^2f''/2!$，四阶项来自两份 $h^4f^{(4)}/4!$，所以常数分别是 1 和 $1/12$。

单侧公式的系数也能逐项核对。把 $f(x+h)$ 与 $f(x+2h)$ 展开后，组合 $-3f(x)+4f(x+h)-f(x+2h)$ 中，常数系数为 $-3+4-1=0$，一次系数为 $4-2=2$，二次系数为 $4/2-4/2=0$，三次系数为 $4/6-8/6=-2/3$。因此分子为 $2hf'(x)-2h^3f'''(x)/3+O(h^4)$；除以 $2h$，主误差就是 $-h^2f'''/3$。

差分系数可以从几何与代数两面读。几何上，前向和后向公式使用不同侧的割线；中心公式使用横跨两侧的割线。对凸函数，这条跨两侧的割线一般不通过中央真值点，但它的斜率仍能近似该点的切线斜率。

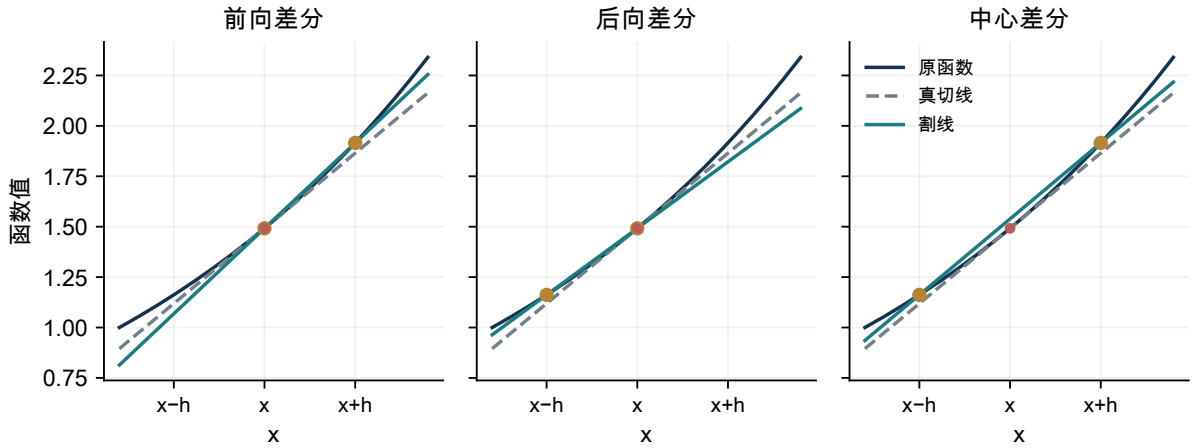


图 5.7 在 $x=0.4$、$h=0.25$ 处对 e^x 求导。金色点决定割线，红点是求导位置；灰色虚线是真切线。

公式	$f(x-h)$	$f(x)$	$f(x+h)$	分母	截断阶
前向一阶	0	-1	1	h	$O(h)$
后向一阶	-1	1	0	h	$O(h)$
中心一阶	-1	0	1	$2h$	$O(h^2)$
中心二阶	1	-2	1	h^2	$O(h^2)$

表 5.4 差分模板：每一行规定取哪些值、乘什么系数以及最后除以什么。

读表时先按表中系数把函数值相加，再除以最后一列的分母。中心一阶差分的系数反对称，使偶次 Taylor 项抵消；中心二阶差分的系数对称，使奇次项抵消。

插值型求导公式

设要设计

$$D_h f(x) = \frac{1}{h}\sum_{j=1}^{m} c_j f(x+\alpha_j h).$$

代入 Taylor 展开后，为使它近似一阶导数且误差为 $O(h^p)$，要求

$$\sum_j c_j = 0, \quad \sum_j c_j\alpha_j = 1, \quad \sum_j c_j\alpha_j^k = 0 \quad (2 \le k \le p).$$

假设 f 有连续的 $p+1$ 阶导数。把每个采样值展开到 p 阶，先按导数阶数而不是采样点编号合并：

$$D_h f = \frac{\sum_j c_j}{h} f + \left(\sum_j c_j\alpha_j\right) f' + \sum_{k=2}^{p} \frac{h^{k-1}}{k!}\left(\sum_j c_j\alpha_j^k\right) f^{(k)} + O(h^p).$$

第一项必须消失，否则常函数都会被算出非零导数；第二项系数必须为 1；从 h^1 到 h^{p-1} 的项必须为零，剩下的最早一项才是 h^p。这就得到所列矩条件。若求的是二阶导数，应改成分母 h^2，并要求 $\sum c_j\alpha_j^2 = 2!$，而不是 1。

常数项消失，一阶项保留，更高低阶项消失。把同一条件解释成“该公式对低次多项式求导精确”，便与插值多项式求导完全一致。

例 5.3 (四点中心公式)　使用 $x-2h, x-h, x+h, x+2h$ 四个节点构造 $f'(x)$ 的四阶差分，并给出主截断误差。

解　利用中心反对称性，先把未知公式写成

$$D = \frac{A[f(x+h)-f(x-h)] + B[f(x+2h)-f(x-2h)]}{h}.$$

其中 A, B 待定，偶次 Taylor 项已经自动消失。一次导数系数为 $2A+4B$，三次导数系数为 $h^2(A+8B)/3$。要保留一次项并消去二阶误差，解

$$2A + 4B = 1, \qquad A + 8B = 0,$$

得 $A = 2/3, B = -1/12$。因此

$$D_h^{(4)} f(x) = \frac{f(x-2h) - 8f(x-h) + 8f(x+h) - f(x+2h)}{12h}.$$

五阶导数的系数为

$$h^4\left(\frac{A}{60} + \frac{8B}{15}\right) = h^4\left(\frac{1}{90} - \frac{2}{45}\right) = -\frac{h^4}{30}.$$

所以在足够光滑条件下，$D_h^{(4)} f = f' - h^4 f^{(5)}/30 + O(h^6)$。若四个数据各有不超过 ε 的绝对误差，附加误差至多为

$$\frac{1+8+8+1}{12h}\varepsilon = \frac{3\varepsilon}{2h}.$$

同样步长的二点中心差分对应上界是 ε/h。四点公式提高了截断精度，也增大了这一数据误差上界，因此总误差不一定更小。

对非等距节点，直接对 Lagrange 基求导，得到 $p_n'(x) = \sum_i y_i \ell_i'(x)$。这样可统一构造边界与不规则网格公式，但大规模高阶权重计算需要注意条件数。

舍入误差与步长

若各函数值有独立但只知道绝对界的误差 $|\delta f_i| \le \varepsilon$，则

$$|\delta D_h| \le \frac{\varepsilon}{h} \sum_j |c_j|.$$

对于二点中心差分，系数绝对值之和为 1，噪声误差界为 ε/h。若 $|f'''| \le M_3$，总误差可界为

$$|D_h f - f'| \le \frac{M_3 h^2}{6} + \frac{\varepsilon}{h}.$$

对右端关于正步长求导，得到

$$h_{\mathrm{opt}} = \left(\frac{3\varepsilon}{M_3} \right)^{1/3}.$$

一般 p 阶一阶差分有误差模型 $C_T h^p + C_R \varepsilon / h$，最优步长尺度为 $\varepsilon^{1/(p+1)}$。二阶导数还要除以 h^2，因此对噪声更敏感。

令 $E(h) = M_3 h^2/6 + \varepsilon/h$，对正步长求导：

$$E'(h) = \frac{M_3 h}{3} - \frac{\varepsilon}{h^2} = 0 \quad \Longleftrightarrow \quad h^3 = \frac{3\varepsilon}{M_3}.$$

又有 $E''(h) = M_3/3 + 2\varepsilon/h^3 > 0$，所以它给出模型的最小值。对一般 $C_T h^p + C_R \varepsilon / h$，同样得到 $h^{p+1} = C_R \varepsilon / (p C_T)$；只看对 ε 的依赖，就是 $\varepsilon^{1/(p+1)}$。

随机噪声的标准差公式也来自平方展开。若两侧误差 η_1, η_2 零均值且独立，则 $\mathbb{E}(\eta_1 \eta_2) = 0$，所以 $\mathbb{E}(\eta_1 - \eta_2)^2 = \sigma^2 + \sigma^2$。中心差分再除以 $2h$，其方差为 $\sigma^2/(2h^2)$，开平方就是 $\sigma/(\sqrt{2}h)$。

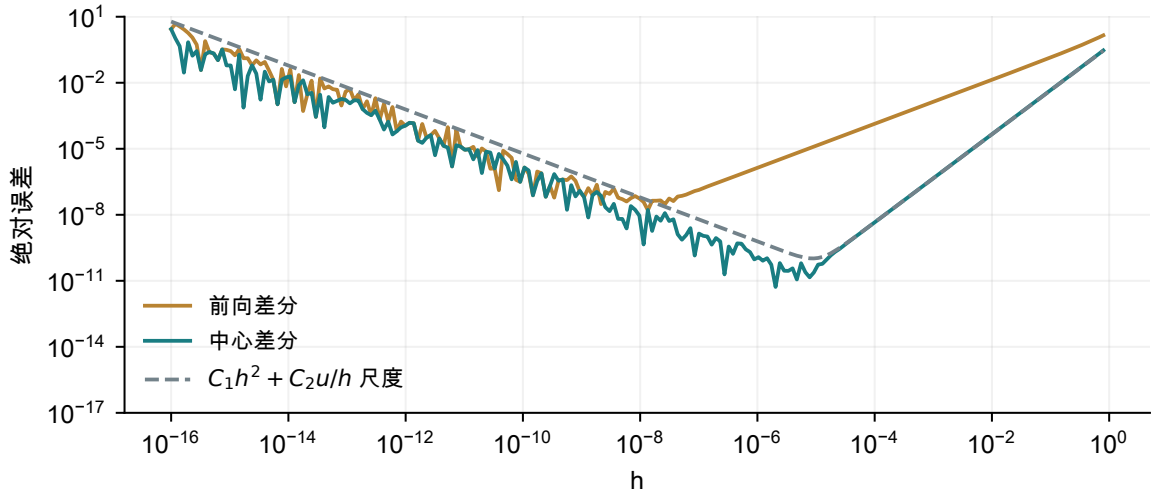


图 5.8 对 e^x 在 $x = 1$ 处求导。步长较大时截断误差占主导，步长很小时消去与舍入影响占主导；实际曲线在理论包络附近波动。

下面保持观测噪声的标准差 $\sigma = 0.01$ 不变，分别对 $\sin x$ 使用 $N = 40$ 和 $N = 400$ 个小区间。函数值上的噪声并不显著，但中心差分把相邻噪声之差除以 $2h$，细网格上的导数明显变得更抖。若两侧噪声独立且方差均为 σ^2，则导数噪声的标准差为

$$\sqrt{\frac{\sigma^2 + \sigma^2}{4h^2}} = \frac{\sigma}{\sqrt{2}h}.$$

因此把 h 缩小为原来的十分之一，会使这一随机误差尺度放大十倍。这里的统计尺度与前面的最坏情形绝对误差界不同，但都揭示了除以小步长的放大作用。

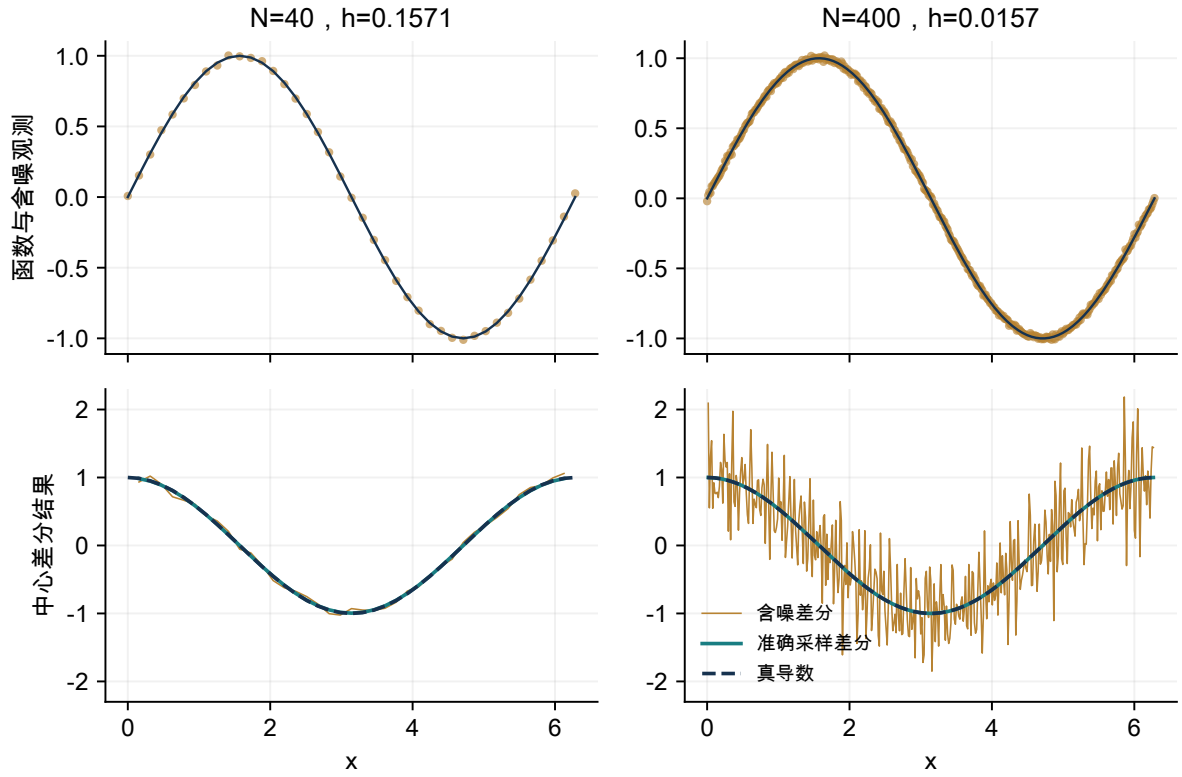


图 5.9 准确采样与含噪采样的中心差分。每个节点加入独立、零均值、标准差 0.01 的教学模拟噪声；两列导数图使用相同纵轴范围。

为什么“采样更密”仍可能求不好导数。噪声大小如果没有同步减小，相邻采样值越来越接近，真实差值会缩小，噪声差却未必缩小。除以更小的步长后，导数估计反而更抖。此时需要利用平滑性或统计假设，而不是盲目缩短间隔。

局部低次多项式拟合后再求导，可以利用多点平均缓解噪声。它改变了问题：我们先选一个局部函数模型，再估计模型导数。窗口过大造成平滑偏差，窗口过小又无法抑制噪声，仍然存在偏差与噪声之间的权衡。

求积与求导公式的比较

公式	典型误差阶	信息要求	主要限制
复化梯形	全局 $O(h^2)$	函数值，二阶光滑	局部误差累加
复化 Simpson	全局 $O(h^4)$	偶数网格，四阶光滑	节点与面板宽度须区分
m 点 Gauss	代数精度 $2m-1$	可自由选择节点	区间与权必须匹配
中心一阶差分	截断 $O(h^2)$	两侧函数值	数据误差按 $1/h$ 放大
中心二阶差分	截断 $O(h^2)$	三个函数值	数据误差按 $1/h^2$ 放大

表 5.5 求积的全局阶、求导的截断阶和代数精度是不同概念，应按各自定义比较。

外推与三次样条求导

中心差分具有偶次幂误差，记 $D(h)=f'(x)+c_2h^2+c_4h^4+\cdots$。使用 Richardson 外推，

$$D_{\mathrm{ext}}=\frac{4D(h/2)-D(h)}{3}=f'(x)+O(h^4).$$

把它展开，会得到使用偏移 $\pm h/2,\pm h$ 的四点公式。它与前面四点中心公式仅相差步长记法。这说明“提高精度”的代数操作可以有两种解释：消去 Taylor 误差项，或把不同网格的近似组合起来。

把两个中心差分代入外推式，可以直接恢复四点权重：

$$D(h/2)=\frac{f(x+h/2)-f(x-h/2)}{h},\qquad D(h)=\frac{f(x+h)-f(x-h)}{2h}.$$

所以

$$\frac{4D(h/2)-D(h)}{3}=\frac{f(x-h)-8f(x-h/2)+8f(x+h/2)-f(x+h)}{6h}.$$

令 $s=h/2$，分母 $6h=12s$，节点正好变成 $x\pm s, x\pm 2s$。这不是仅仅“形式类似”，而是同一公式在不同步长记号下的精确相等。

但外推也线性组合了噪声。若输入函数值本身不精确，高阶外推列可能越来越不稳定。判断停止时，应同时观察步长变化、误差估计趋势以及数据精度。

样条求导则先构造光滑曲线 S，然后解析计算 S' 或 S''。这样不同位置的导数由同一条曲线给出，连接关系更一致。但普通插值样条仍会穿过全部噪声点；只有明确加入平滑机制时，才真正进行噪声抑制。

第 6 章　线性方程组直接解法

6.1　引言

插值系数、样条弯矩、最小二乘和微分方程离散，最终常常要求解 $Ax=b$。在精确算术中，非奇异矩阵保证唯一解；在数值计算中，还要考虑怎样组织消元、何时交换行，以及残差多小才有意义。

直接法在有限次算术操作后给出结果。这个“有限次”是数学算法意义上的描述，并不表示结果没有舍入误差。

先把问题的代数前提说清楚。这里主要考虑 n 个未知量、n 个方程组成的方阵系统。矩阵非奇异时，任意右端都有唯一解；矩阵奇异时，可能无解，也可能有无穷多解，需要另外讨论相容性。

定义 6.1（非奇异矩阵与直接法）　方阵 A 若存在逆矩阵，称为非奇异矩阵；等价地，齐次系统 $Ax=0$ 只有零解。直接法通过有限次消元或分解，把原系统化成可直接前代、回代的形式。

理论上可以写 $x=A^{-1}b$，但这个表达只说明解如何由数据决定，并不规定最好怎样计算。数值算法通常先分解矩阵，再求解三角系统。这样既减少无用运算，也便于处理多个不同右端。

6.2　Gauss 消去法

消元的目标是把一个变量从其余方程中逐个消去，同时不改变解集。若两个方程都含 x_1，可以用第一个方程的合适倍数减去第二个方程，使第二式的 x_1 系数成为零。对剩余变量重复这一过程，就得到按顺序可解的上三角系统。

定义 6.2（主元、消元乘子与三角系统）　一次消元中用来消去同列其他元素的基准元素称为主元；相应行倍数称为消元乘子。上三角系统满足 $u_{ij}=0\ (i>j)$，可由最后一个方程向前回代；下三角系统则由第一个方程向后前代。

引理 6.3（初等行变换保持解集）　交换两个方程、将一个方程乘非零常数、把一个方程的倍数加到另一个方程，都不改变线性系统的解集。

证明. 每种变换都可逆：交换可以再次交换，非零缩放可以除回原数，加上某行的倍数可以减去同样的倍数。因此原系统与变换后系统能够相互推出，解集相同。 □

这一结论解释消元在精确算术中的正确性。舍入误差不会出现在这个代数证明中，必须等到讨论主元大小和中间量增长时再单独分析。

在第 k 步，若主元 $a_{kk}^{(k)} \neq 0$，对 $i > k$ 定义乘子

$$l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}},$$

把第 i 行减去第 k 行的 l_{ik} 倍，使第 k 列主元下方归零。最终得到上三角系统 $Ux = c$，通过回代求解

$$x_i = \frac{c_i - \sum_{j=i+1}^{n} u_{ij} x_j}{u_{ii}}, \quad i = n, n-1, \ldots, 1.$$

以第一列为例，令 $\ell = (0, l_{21}, \ldots, l_{n1})^T$，$e_1 = (1, 0, \ldots, 0)^T$。消元矩阵为 $E_1 = I - \ell e_1^T$，左乘 A 时，第 i 行恰好减去第 1 行的 l_{i1} 倍。由于 $e_1^T \ell = 0$，有 $(\ell e_1^T)^2 = 0$，故

$$(I - \ell e_1^T)(I + \ell e_1^T) = I.$$

这说明逆操作只需把减号换为加号。连续消元及其逆过程分别为

$$E_{n-1} \cdots E_1 A = U, \qquad A = \underbrace{E_1^{-1} \cdots E_{n-1}^{-1}}_{L} U.$$

更具体地，第 k 步的逆矩阵为 $I + \ell^{(k)} e_k^T$，其中 $\ell^{(k)}$ 前 k 个分量为零，后面存该步乘子。若 $i < j$，则 $e_i^T \ell^{(j)} = 0$，故按这一顺序乘开时所有交叉项都为零。因此

$$L = I + \sum_{k=1}^{n-1} \ell^{(k)} e_k^T,$$

它确实是把每一步乘子放到对应列下面的单位下三角阵。

每次行变换都是左乘一个可逆消元矩阵。把它们移到另一侧，就得到 $A = LU$，其中 L 是单位下三角阵，保存消元乘子，U 是最终的上三角阵。对多个不同右端，只需一次分解，之后分别作 $Ly = b$ 的前代与 $Ux = y$ 的回代。

定理 6.4 (不选主元的 LU 分解) 对非奇异矩阵 A，存在 L 单位下三角、U 非奇异上三角的分解，当且仅当所有前 $n-1$ 个顺序主子式非零；此时分解唯一。

证明. 设 $A = LU$，取左上角 $k \times k$ 的方块。因 L 下三角、U 上三角，该方块恰为 $L_k U_k$；$\det L_k = 1$，所以顺序主子式为 $\Delta_k = u_{11} \cdots u_{kk}$。$U$ 非奇异使每个对角元非零，因此所有 $\Delta_k \neq 0$。

反过来，第一主元是 $\Delta_1 \neq 0$。假设前 $k-1$ 步已经可行，消元不改变前 k 阶子式的行列式，而变换后的前 k 阶块为上三角形，所以

$$\Delta_k = u_{11} \cdots u_{k-1,k-1}\, u_{kk}.$$

前面的因子与 Δ_k 均非零，故当前主元 u_{kk} 也非零，可以继续。最后一步使用 $\Delta_n = \det A \neq 0$，因此全部消元完成，得到所需分解。

若 $L_1 U_1 = L_2 U_2$，两边分别乘可逆因子，得到 $L_2^{-1} L_1 = U_2 U_1^{-1}$。左边下三角且对角元全为 1，右边上三角；一个矩阵若同时上下三角，就只能是对角阵，再结合对角元为 1，得到单位阵。于是 $L_1 = L_2, U_1 = U_2$。 □

对下面的系统逐步消元，可以同时追踪系数和右端：

$$A=\begin{pmatrix}2&1&1\\4&3&3\\8&7&9\end{pmatrix},\qquad b=\begin{pmatrix}7\\19\\49\end{pmatrix}.$$

所用乘子 $2,4,3$ 依次存入 L 的第一列、第二列：



图 6.1 三阶系统的消元过程。青色单元格是当前主元，竖线右侧是同样参与行变换的右端；金色文字给出行更新。

$$L=\begin{pmatrix}1&0&0\\2&1&0\\4&3&1\end{pmatrix},\qquad U=\begin{pmatrix}2&1&1\\0&1&1\\0&0&2\end{pmatrix},\qquad A=LU.$$

回代先得到 $x_3=6/2=3$，再得 $x_2=5-x_3=2$，最后 $x_1=(7-x_2-x_3)/2=1$。L 保存的是消元历史，U 保存的是消元结果。

列主元消去法

非零主元仍可能太小。例如

$$\begin{pmatrix}10^{-20}&1\\1&1\end{pmatrix}\begin{pmatrix}x_1\\x_2\end{pmatrix}=\begin{pmatrix}1\\2\end{pmatrix}.$$

若第一步不交换行，乘子为 10^{20}，更新中会出现很大的中间量，并把有效信息丢在相减中。交换两行后，乘子变为 10^{-20}，计算就合理得多。

列主元消元在当前第 k 列的剩余行中选绝对值最大者，交换到主元位置。这里“列主元”表示在列中搜索，实际交换的是行。最终有 $PA=LU$，其中 P 是累计行置换。求解时必须对右端作同样置换：先解 $Ly=Pb$，再解 $Ux=y$。若已经存储了 L 的旧列，后续换行也必须同步交换相应历史乘子。

列主元使消元乘子满足 $|l_{ik}|\le 1$，有助于控制误差，但并不保证所有中间元素都不增长。舍入误差分析还依赖消元过程的增长因子。极端矩阵上增长可能很大，因此不能把“选了列主元”当作无条件前向高精度保证。实践中它通常是可靠的通用选择，仍应结合残差与条件估计检验结果。

例 6.1 (带行交换的两步计算)　用列主元消去法求解 $\begin{pmatrix} 0 & 2 \\ 1 & 3 \end{pmatrix} x = (4,7)^T$，说明首元素为零时应怎样处理。

解　首元素为零，但矩阵可逆。交换两行后，上三角系统为 $x_1 + 3x_2 = 7$、$2x_2 = 4$，所以 $x_2 = 2, x_1 = 1$。不能把“当前消元主元为零”直接判断为原矩阵奇异。

6.3　直接三角分解法

一般矩阵的直接三角分解

通过直接比较 $A = LU$ 的元素，可以按行计算 Doolittle 分解：

$$u_{kj} = a_{kj} - \sum_{s<k} l_{ks} u_{sj} \quad (j \geq k),$$

$$l_{ik} = \frac{a_{ik} - \sum_{s<k} l_{is} u_{sk}}{u_{kk}} \quad (i > k).$$

矩阵乘法给出 $a_{ij} = \sum_s l_{is} u_{sj}$。对第 k 行、$j \geq k$，下三角性使 $l_{ks} = 0$ $(s > k)$，且 $l_{kk} = 1$，所以

$$a_{kj} = \sum_{s<k} l_{ks} u_{sj} + u_{kj}.$$

将已经计算的和移到另一侧，就得到 u_{kj}。对第 k 列、$i > k$，上三角性使 $u_{sk} = 0$ $(s > k)$，因此

$$a_{ik} = \sum_{s<k} l_{is} u_{sk} + l_{ik} u_{kk}.$$

先减去旧项，再除以当前非零主元，便得到 l_{ik}。这些公式每次只引用前面完成的行列，所以能按 $k = 1, 2, \ldots, n$ 顺序执行。

运算量也可按更新区域估计。第 k 步约有 $(n-k)^2$ 个元素需要“一乘一减”，所以主量为 $2\sum_{r=1}^{n-1} r^2 = 2n^3/3 + O(n^2)$。前代或回代第 i 行只含约 i 个已知项，总量是 $1 + \cdots + n = O(n^2)$。

这与消元保存乘子的算法是同一件事，只是表达方式不同。若改令 U 的对角元为 1，则得到另一种归一化的三角分解。

稠密消元的主计算量约为 $2n^3/3$ 次浮点加乘，前代与回代各为 $O(n^2)$。计算 A^{-1} 再乘 b 通常增加工作量与误差途径，没有必要。Gauss–Jordan 消元进一步把主元上方也消为零，可用于小规模手算、求逆或理解行变换，但不是一般求解器的首选组织方式。

分解与求解是两个不同阶段。$A = LU$ 的系数只由 A 决定，不随右端 b 改变；每次新的右端只需完成 $Ly = b$ 与 $Ux = y$。因此，当同一矩阵对应很多载荷、时间步或观测向量时，复用分解能节省大量工作。

> **定义 6.5** (对称正定矩阵)　实矩阵 A 若满足 $A^T = A$，且对任意非零实向量 z 都有 $z^T A z > 0$，称为对称正定矩阵。$z^T A z$ 是对应的二次型；正定性表示它在任何非零方向都严格为正。

对称性允许只存储一半矩阵，正定性进一步保证 Cholesky 分解中的平方根参数为正。这两个条件提供了通用消元所没有的结构信息，因此值得在求解前检查，而不必所有矩阵都使用同一套算法。

三对角方程组与平方根法

三对角系统写为

$$a_i x_{i-1} + b_i x_i + c_i x_{i+1} = d_i.$$

边界处不存在的项省略。消去左下对角元时，不会产生更远的非零项，因而只需保存三条对角线。令

$$\widetilde{b}_1 = b_1, \quad \widetilde{d}_1 = d_1,$$

$$m_i = \frac{a_i}{\widetilde{b}_{i-1}}, \quad \widetilde{b}_i = b_i - m_i c_{i-1}, \quad \widetilde{d}_i = d_i - m_i \widetilde{d}_{i-1}.$$

回代为 $x_n = \widetilde{d}_n/\widetilde{b}_n$，$x_i = (\widetilde{d}_i - c_i x_{i+1})/\widetilde{b}_i$。这就是追赶法，时间和存储均为 $O(n)$。

第 $i-1$ 行前面已经消成 $\widetilde{b}_{i-1}x_{i-1} + c_{i-1}x_i = \widetilde{d}_{i-1}$。为消去第 i 行的 $a_i x_{i-1}$，乘以前式的 $a_i/\widetilde{b}_{i-1}$ 再相减，得到

$$\left(b_i - \frac{a_i}{\widetilde{b}_{i-1}} c_{i-1}\right) x_i + c_i x_{i+1} = d_i - \frac{a_i}{\widetilde{b}_{i-1}} \widetilde{d}_{i-1}.$$

这逐项给出新主元和新右端，而且没有产生更远的非零系数。最后一行只剩一个未知量，算出后逐行往上代入；每行只作固定次数运算，故总量为 $O(n)$。

追赶法可以把刚才的消元压缩成几列数字。考虑

$$\begin{pmatrix} 2 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 2 \end{pmatrix} x = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 1 \end{pmatrix}.$$

i	乘子 m_i	新主元 $\widetilde{b}_i$	新右端 $\widetilde{d}_i$	回代 x_i
1	–	2	1	1
2	$-\frac{1}{2}$	$\frac{3}{2}$	$\frac{1}{2}$	1
3	$-\frac{2}{3}$	$\frac{4}{3}$	$\frac{1}{3}$	1
4	$-\frac{3}{4}$	$\frac{5}{4}$	$\frac{5}{4}$	1

表 6.1 追赶法的前消元与回代。前三列按 $i = 1 \to 4$ 更新，最后一列按 $i = 4 \to 1$ 得到。

向下计算新主元与新右端时，只依赖上一行已经更新的值；向上回代时，只依赖已经得到的下一个分量。表中结果保持为分数，能直接核对每一步，例如

$$\widetilde{b}_3 = 2 - \frac{2}{3} = \frac{4}{3}, \qquad x_3 = \frac{1/3 + x_4}{4/3} = 1.$$

一般三对角矩阵仍可能出现零或危险的小主元。严格对角占优、对称正定等结构可提供保证；不能只因矩阵有三条对角线就省去所有适用性判断。

对实对称正定矩阵，可使用 Cholesky 分解

$$A = LL^{T}, \qquad l_{ii} > 0.$$

系数由

$$l_{kk}=\sqrt{a_{kk}-\sum_{j<k} l_{kj}^2},\qquad l_{ik}=\frac{a_{ik}-\sum_{j<k} l_{ij}l_{kj}}{l_{kk}}$$

计算。它利用对称性将计算与存储大致减半。

定理 6.6 (Cholesky 分解的存在唯一性) 每个实对称正定矩阵都有唯一的正对角 Cholesky 分解。

证明. 先把首行首列单独分出：

$$A=\begin{pmatrix} a & r^T \\ r & B \end{pmatrix},\qquad a>0.$$

若写成 LL^T，首对角元必须是 $\sqrt{a}$，首列其余分量必须是 $r/\sqrt{a}$。乘回去后，剩余方块要分解的就是 $S=B-rr^T/a$。
关键是证明 S 仍正定。任取非零 z，令 $t=-r^Tz/a$，把向量 $(t,z)^T$ 代入原二次型，逐项计算：

$$\begin{aligned}(t,z^T)A(t,z)^T &= at^2+2t\,r^Tz+z^TBz\\ &=\frac{(r^Tz)^2}{a}-2\frac{(r^Tz)^2}{a}+z^TBz\\ &=z^T\left(B-\frac{rr^T}{a}\right)z=z^TSz>0.\end{aligned}$$

最后的不等式来自 A 正定且 $(t,z)\neq 0$。因此可以对尺寸小一阶的 S 重复同一过程，直到一阶正数，完成分解。
在每一步，规定对角元为正就确定了平方根的符号；首列其余元素及剩余方块也随之确定。所以这个递归过程没有自由选择，分解唯一。元素公式中，$a_{kk}=\sum_{j<k} l_{kj}^2+l_{kk}^2$ 给出平方根，而 $a_{ik}=\sum_{j<k} l_{ij}l_{kj}+l_{ik}l_{kk}$ 给出除法公式。 □

LDL^T 形式把平方根放入对角矩阵 D，也是平方根法的一种常见组织方式。对正定矩阵，D 对角元为正；对一般对称不定矩阵，通常需要更谨慎的对称主元策略与可能的 2×2 块。

6.4 向量和矩阵的范数

单个数的误差可以用绝对值衡量，但线性方程组的误差是一个向量。某些分量可能大、某些分量可能小，需要一个一致的规则把整个向量的大小变成一个非负数。范数就是满足基本代数要求的这种大小度量。

定义 6.7（向量范数） 实或复向量空间上的函数 $\|x\|$ 若满足正定性、齐次性与三角不等式，即

$$\|x\| \geq 0, \quad \|x\| = 0 \Longleftrightarrow x = 0, \qquad \|\alpha x\| = |\alpha| \, \|x\|, \\ \|x + y\| \leq \|x\| + \|y\|,$$

则称为向量范数。

三角不等式保证把不同来源的误差相加时，可以用各自误差界的和来控制总误差。不同范数强调不同方面：无穷范数观察最大分量，1-范数累加全部分量，2-范数与欧氏几何和正交变换相容。

常用向量范数为

$$\|x\|_1 = \sum_i |x_i|, \qquad \|x\|_2 = \sqrt{\sum_i |x_i|^2}, \qquad \|x\|_\infty = \max_i |x_i|.$$

这里 A^* 表示先把每个复数元素取共轭、再转置；实矩阵时就是 A^T。满足 $A^* = A$ 的矩阵称为 Hermitian 矩阵，满足 $Q^*Q = I$ 的方阵称为酉矩阵。因为 $\|Qx\|_2^2 = x^*Q^*Qx = x^*x$，酉变换保持欧氏长度。实数情形称为正交矩阵。

诱导矩阵范数定义为

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

由定义立即有 $\|Ax\| \leq \|A\| \, \|x\|$ 和 $\|AB\| \leq \|A\| \, \|B\|$。对三种常见范数，

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \quad \|A\|_\infty = \max_i \sum_j |a_{ij}|, \quad \|A\|_2 = \sqrt{\lambda_{\max}(A^*A)}.$$

注意 2-范数一般不是 $\rho(A)$；只有实对称、Hermitian 或更一般的正规矩阵等特殊情况下，两者才相等。Frobenius 范数 $\|A\|_F = (\sum_{ij} |a_{ij}|^2)^{1/2}$ 也很有用，但它不是向量 2-范数的诱导范数。

性质 6.8（诱导范数的基本不等式） 对同一向量范数诱导的矩阵范数，有

$$\|Ax\| \leq \|A\| \, \|x\|, \qquad \|AB\| \leq \|A\| \, \|B\|, \qquad \|I\| = 1.$$

证明. 第一式来自上确界的定义。将第一式连续用于 ABx，得 $\|ABx\| \leq \|A\| \, \|B\| \, \|x\|$，再对非零 x 取比值上确界，便得第二式。$Ix = x$ 直接给出第三式。 □

对无穷范数，$|(Ax)_i| \leq \sum_j |a_{ij}| \, \|x\|_\infty$，所以最大行绝对值和是一个上界。取达到最大行和的那一行，并使 x_j 的符号或相位与该行系数配合，就能达到这个界。这说明矩阵无穷范数的行和公式不仅是估计，而且是精确表达。

矩阵 1-范数的公式可以从列出发证明。对任意 x，

$$\|Ax\|_1 \leq \sum_i \sum_j |a_{ij}||x_j| = \sum_j \left(\sum_i |a_{ij}| \right) |x_j| \leq \left(\max_j \sum_i |a_{ij}| \right) \|x\|_1 .$$

选择最大列和对应的坐标向量 $x = e_j$，Ax 就是那一列，达到等号，所以最大列和不是仅仅一个上界。

对无穷范数，先得到行和上界。零矩阵将每个向量映成零，范数为零；对非零矩阵，若第 i 行达到最大行和，实数情形取 $x_j=\operatorname{sign}(a_{ij})$；复数情形取 $x_j=e^{-\mathrm{i}\arg a_{ij}}$，零元素的位置任取模不超过 1 的值。于是该行所有乘积同为非负实数，$|(Ax)_i|=\sum_j|a_{ij}|$，且 $\|x\|_\infty=1$，达到上界。

对 2-范数，平方以后有

$$\frac{\|Ax\|_2^2}{\|x\|_2^2}=\frac{x^*A^*Ax}{x^*x}.$$

A^*A 是 Hermitian 半正定矩阵，可在正交特征基中写 $x=\sum c_iq_i$。分子为 $\sum\lambda_i|c_i|^2$，分母为 $\sum|c_i|^2$，所以比值不超过最大特征值，并在对应特征向量处达到。开平方就得到矩阵 2-范数公式。第 9 章会说明这种正交特征分解的依据。

这也说明奇异值如何得到。对非奇异实矩阵，取 A^TA 的单位正交特征向量 v_i，记对应特征值为 $\sigma_i^2>0$，定义 $u_i=Av_i/\sigma_i$。那么

$$u_i^Tu_j=\frac{v_i^TA^TAv_j}{\sigma_i\sigma_j}=\frac{\sigma_j^2v_i^Tv_j}{\sigma_i\sigma_j}=\delta_{ij},\qquad Av_i=\sigma_iu_i.$$

所以在输入基 v_i 与输出基 u_i 下，A 分别把各坐标乘 σ_i，而 $A^{-1}u_i=v_i/\sigma_i$。这就给出后面条件数中最大、最小奇异值之比的来源。复数情形把转置换成共轭转置。

引理 6.9 (Neumann 级数)　若某个诱导范数下 $\|E\|<1$，则 $I-E$ 可逆，且

$$(I-E)^{-1}=\sum_{k=0}^{\infty}E^k,\qquad\|(I-E)^{-1}\|\le\frac{1}{1-\|E\|}.$$

证明. 记 $q=\|E\|<1$，$S_m=I+E+\cdots+E^m$。对 $r>m$，次乘性与几何级数给出

$$\|S_r-S_m\|\le\sum_{k=m+1}^{r}q^k\le\frac{q^{m+1}}{1-q}\longrightarrow0.$$

因此矩阵的有限和是 Cauchy 序列，有极限 S。把有限和乘开，相邻幂次逐项相消，得到

$$(I-E)S_m=S_m(I-E)=I-E^{m+1}.$$

因为 $\|E^{m+1}\|\le q^{m+1}\to0$，取极限得 $(I-E)S=S(I-E)=I$，所以 S 就是逆矩阵。最后 $\|S\|\le\sum_{k=0}^{\infty}q^k=1/(1-q)$。

□

这个引理说明，离单位阵足够小的扰动不会立即造成奇异。后面的矩阵扰动界中出现 $1-\|A^{-1}\Delta A\|$ 一类分母，正是同一个几何级数机制。

6.5　方程组的性态与误差分析

计算完成后，即使残差很小，还需要知道这个残差对应多大的解误差。这取决于 A 是否把某些方向压得很小：如果大误差恰好落在这样的方向上，乘以 A 后就可能几乎看不见。

定义 6.10 (矩阵条件数) 对非奇异矩阵和指定的诱导范数，定义

$$\kappa(A) = \|A\| \left\|A^{-1}\right\|.$$

它衡量线性方程组解对相对数据扰动的最坏放大程度。$\kappa(A) \geq 1$；条件数很大时，方程组在相应意义下病态。

性质 6.11 (2-范数条件数与奇异值) 若 A 非奇异，最大、最小奇异值分别为 $\sigma_{\max}, \sigma_{\min}$，则 $\kappa_2(A) = \sigma_{\max}/\sigma_{\min}$。对实对称正定矩阵，该比值等于最大特征值与最小特征值之比。

奇异值描述矩阵在不同单位方向上的伸缩尺度。比值很大时，矩阵同时保留很大的尺度和很小的尺度；输入扰动经过逆变换后，沿小尺度方向容易被大幅放大。

对非奇异 A，定义 $\kappa(A) = \|A\| \left\|A^{-1}\right\| \geq 1$。若只有右端有扰动，

$$A(x + \Delta x) = b + \Delta b \quad \Longrightarrow \quad \Delta x = A^{-1}\Delta b.$$

又由 $\|b\| \leq \|A\| \, \|x\|$，得到

$$\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\Delta b\|}{\|b\|}. \tag{6.1}$$

这里假设 $b \neq 0$；这是最坏情况界，不是说每个扰动方向都会达到如此大的放大。

先检查下界：$I = AA^{-1}$，次乘性给出 $1 = \|I\| \leq \|A\| \left\|A^{-1}\right\|$。对 2-范数，正交的奇异向量分解把 A 化为各方向上乘 σ_i，把 A^{-1} 化为乘 $1/\sigma_i$，所以两个算子范数分别为 $\sigma_{\max}$ 与 $1/\sigma_{\min}$。

右端扰动公式中，$\|\Delta x\| \leq \left\|A^{-1}\right\| \|\Delta b\|$。要把它变成相对误差，使用 $\|b\| \leq \|A\| \, \|x\|$，即 $1/\|x\| \leq \|A\| \, / \|b\|$。乘起来得到

$$\frac{\|\Delta x\|}{\|x\|} \leq \left\|A^{-1}\right\| \|\Delta b\| \, \frac{\|A\|}{\|b\|} = \kappa(A) \frac{\|\Delta b\|}{\|b\|}.$$

这里每次除法都要求相应向量非零。

若 A 与 b 同时扰动，记

$$\epsilon_A = \frac{\|\Delta A\|}{\|A\|}, \qquad \epsilon_b = \frac{\|\Delta b\|}{\|b\|}.$$

由 $(A + \Delta A)(x + \Delta x) = b + \Delta b$ 得

$$\Delta x = A^{-1}(\Delta b - \Delta A \, x - \Delta A \, \Delta x).$$

取范数并移项，在 $\kappa(A)\epsilon_A < 1$ 时得到

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A)\epsilon_A}(\epsilon_A + \epsilon_b). \tag{6.2}$$

分母条件保证扰动足够小，使问题没有靠近奇异边界。这一步不能省略。

同时扰动 A, b 时，对误差方程取范数，先不要急于约去含误差的项：

$$\|\Delta x\| \leq \left\|A^{-1}\right\| \|\Delta b\| + \left\|A^{-1}\right\| \|\Delta A\| \, \|x\| + \left\|A^{-1}\right\| \|\Delta A\| \, \|\Delta x\|.$$

把最后一项移到左边，再除以 $\|x\|$，得到

$$[1 - \left\|A^{-1}\right\| \|\Delta A\|] \frac{\|\Delta x\|}{\|x\|} \leq \kappa(A)\epsilon_b + \kappa(A)\epsilon_A.$$

左边系数为 $1 - \kappa(A)\epsilon_A$。只有它为正，才可以除过去并保持不等号方向，得到正文的扰动界。这个条件还保证 $A + \Delta A = A(I + A^{-1}\Delta A)$ 可逆，因为 $\left\|A^{-1}\Delta A\right\| < 1$，可以使用 Neumann 级数。

例 6.2 (几乎平行的两个方程) 设 $A=\begin{pmatrix}1 & 1\\ 1 & 1+\epsilon\end{pmatrix}$、$b=(2,2+\epsilon)^T$，$\epsilon>0$。若只把右端第二项增加 δ，求解的变化。

解 原解为 $x=(1,1)^T$。将右端第二项改为 $2+\epsilon+\delta$，两方程相减得 $\epsilon x_2=\epsilon+\delta$，所以

$$x_2=1+\frac{\delta}{\epsilon},\qquad x_1=1-\frac{\delta}{\epsilon}.$$

当 ϵ 很小时，微小右端扰动也会使交点移动很远。这是问题本身的敏感性，不是消元方法制造的。

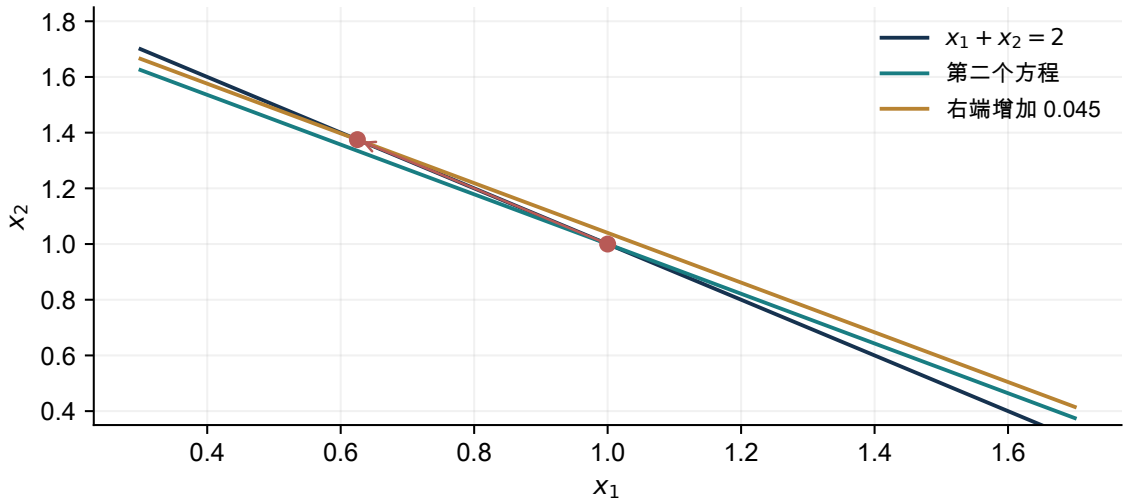


图 6.2 两条几乎平行的直线定义一个病态线性方程组。右端的小变化使交点显著移动。图中为了可读性使用较温和的参数。

条件数还可以从矩阵对圆的作用理解。下图使用一个对称正定矩阵，其两个特征方向相互正交，伸缩倍数分别为 1 和 0.1。单位圆被压成椭圆，而求解 $Ax=b$ 相当于执行相反的伸缩。所以

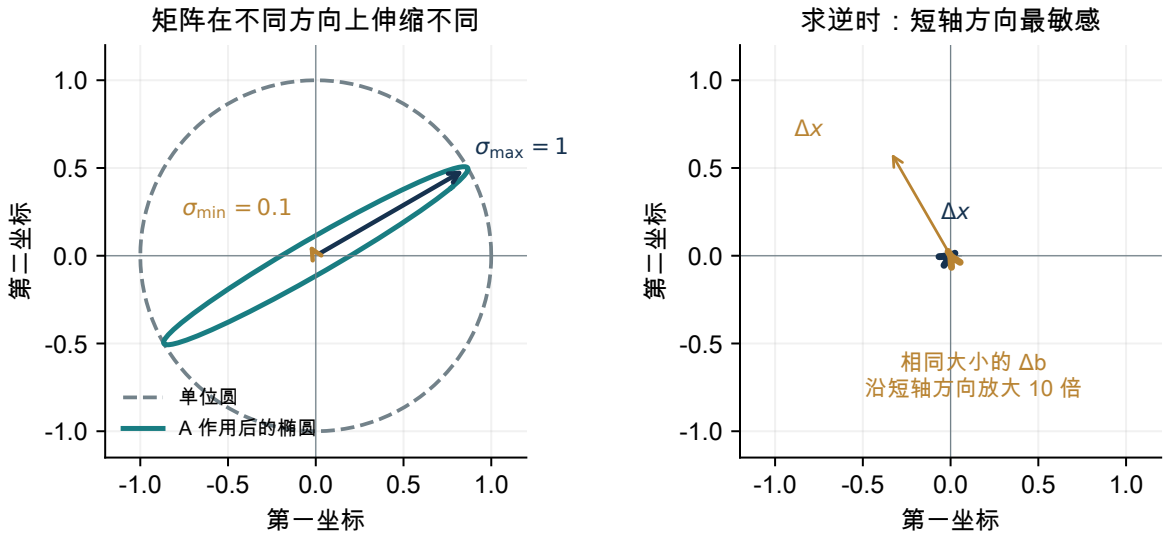


图 6.3 条件数为 10 的矩阵。相同大小的右端扰动沿长轴方向不放大，沿短轴方向经 A^{-1} 放大十倍。图中灰色圆是输入单位圆，青色椭圆是它的像。

“某次扰动影响很小”不能证明条件数很小；条件数关注最敏感的方向，而不是某一个偶然温和的扰动。

残差与误差估计

计算出 $\widehat{x}$ 后，容易得到的是残差 $r = b - A\widehat{x}$。由于

$$A(x - \widehat{x}) = r,$$

有

$$\frac{\|x - \widehat{x}\|}{\|x\|} \le \kappa(A)\frac{\|r\|}{\|b\|}. \tag{6.3}$$

所以小相对残差在良态问题中很有意义，在病态问题中却未必代表小前向误差。

常用的尺度化后向误差指标为

$$\eta = \frac{\|b - A\widehat{x}\|}{\|A\|\,\|\widehat{x}\| + \|b\|}.$$

分母同时计入矩阵作用和右端尺度，避免对不同单位或整体缩放的问题采用同一个无量纲解释错误的阈值。

残差公式只需将右端扰动估计中的 Δb 换成 r：$x - \widehat{x} = A^{-1}r$，然后仍用 $1/\|x\| \le \|A\|\,/\,\|b\|$。因此，小残差要通过条件数才能解释成小解误差。

后向误差指标的分母也有来源。若 $(A + \Delta A)\widehat{x} = b + \Delta b$，则

$$r = b - A\widehat{x} = \Delta A\,\widehat{x} - \Delta b.$$

若两个相对扰动都不超过 ϵ，取范数得到

$$\|r\| \le \epsilon[\|A\|\,\|\widehat{x}\| + \|b\|].$$

所以任何这样的解释都至少需要 $\epsilon \ge \eta$。在 2-范数下，$b \neq 0$ 且 $\widehat{x} \neq 0$ 时还可显式达到这个界：令

$$\theta = \frac{\|A\|\,\|\widehat{x}\|}{\|A\|\,\|\widehat{x}\| + \|b\|}, \quad \Delta A = \theta\frac{r\widehat{x}^T}{\|\widehat{x}\|^2}, \quad \Delta b = -(1-\theta)r.$$

则 $\Delta A\widehat{x} - \Delta b = r$，且两个相对范数都等于 η。这里用到秩一矩阵范数 $\left\|uv^T\right\|_2 = \|u\|_2\,\|v\|_2$：由 Cauchy–Schwarz 给出上界，取输入平行于 v 就达到上界。复数情形把转置改成共轭转置。

若有可复用的分解，可通过残差继续校正。先计算 $r_k = b - Ax_k$，再利用已有分解近似解 $Ad_k = r_k$，最后令 $x_{k+1} = x_k + d_k$。因为精确误差满足 $A(x_* - x_k) = r_k$，修正量 d_k 正是在估计尚未消除的解误差。

在精确算术中，这个修正一步就应到达真解；实际修正方程也有舍入误差，因此可能需要重复。残差最好用更高精度或更准确的累加方式计算，避免 b 与 Ax_k 接近时再次丢失信息。方法的效果仍依赖条件数与已有分解的质量。

第 7 章　线性方程组的迭代解法

7.1　引言

大规模稀疏矩阵的直接分解可能产生很多填充，消耗大量存储。迭代法每次只作便宜的更新，希望逐步逼近真解。它的核心问题不再是“有限次消元是否可行”，而是“误差经过一次更新后会怎样变化”。

直接法把工作集中在一次分解中，迭代法则把求解过程拆成很多轮简单更新。对于非零元素很少的稀疏矩阵，一次矩阵向量乘法可能很便宜，而直接分解会产生许多原来没有的非零元素。此时，迭代法在时间和存储上都有吸引力。

但它必须回答两个额外问题：初值是否会影响最终结果，迭代多少次才能达到精度。一个更新式能够执行，并不代表它收敛；一串数值看起来暂时变化很小，也不代表已经接近真解。

7.2　基本迭代方法

定义 7.1 (定常线性迭代)　形如 $x^{(k+1)} = Bx^{(k)} + c$，且矩阵 B 与向量 c 不随迭代次数改变的过程，称为定常线性迭代。B 称为迭代矩阵。用于求解 $Ax = b$ 时，需要保证原方程的解同时是该更新的不动点。

构造迭代矩阵不能随意进行。矩阵分裂 $A = M - N$ 提供了一种系统办法：把容易求解的部分留在新时刻，把其余部分放到旧时刻。不同分裂决定了每一步的成本，也决定了误差的传播矩阵。

把 $A = M - N$，其中 M 易于求解，写成

$$x^{(k+1)} = M^{-1}Nx^{(k)} + M^{-1}b = Bx^{(k)} + c.$$

这只是公式写法，实际通常通过解 M 系统计算，而不显式求逆。精确解 x_* 也满足 $x_* = Bx_* + c$，故误差

$$e^{(k+1)} = Be^{(k)}, \qquad e^{(k)} = B^k e^{(0)}.$$

迭代收敛完全由矩阵幂 B^k 的行为决定。

固定符号约定

$$A = D + L + U,$$

其中 D 为对角部分，L, U 为实际的严格下、上三角部分，不额外带负号。假设对角元都非零。

Jacobi 迭代为

$$x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \sum_{j\neq i} a_{ij}x_j^{(k)}\right), \qquad B_J = -D^{-1}(L+U).$$

所有新分量只使用旧值，可以并行计算。Gauss–Seidel 则立即使用已经更新的分量：

$$x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)}\right),$$

$$B_{GS} = -(D+L)^{-1}U.$$

后者相当于每次解一个下三角系统；变量的排列顺序会影响其迭代矩阵和速度。

把 Jacobi 的逐分量公式合并，只有对角项放在新时刻：

$$Dx^{(k+1)} = b - (L+U)x^{(k)}.$$

左乘 D^{-1}，就得到 $B_J = -D^{-1}(L+U)$。GS 则把对角和下三角项都放在新时刻，故

$$(D+L)x^{(k+1)} = b - Ux^{(k)},$$

左乘 $(D+L)^{-1}$ 得 B_{GS}。这也是为什么本章先明确 L, U 不额外带负号；若换一种分裂记号，迭代矩阵中的符号也必须同步调整。

例 7.1 (一个可以手算谱半径的系统)　对 $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$、$b = (1,2)^T$，写出 Jacobi 和 GS 迭代矩阵，并判断收敛性。

解　真解为 $(1/10, 3/5)^T$。迭代矩阵分别为

$$B_J = \begin{pmatrix} 0 & -1/4 \\ -2/3 & 0 \end{pmatrix}, \qquad B_{GS} = \begin{pmatrix} 0 & -1/4 \\ 0 & 1/6 \end{pmatrix}.$$

因此 $\rho(B_J) = 1/\sqrt{6}$，$\rho(B_{GS}) = 1/6$。这个例子中 GS 渐近更快，但不能由一个例子推断所有矩阵都如此。

以刚才的二阶系统为例，从 $x^{(0)} = (0,0)^T$ 出发。Jacobi 的第二个新分量仍使用旧 $x_1 = 0$；GS 则使用刚得到的 $x_1^{(1)} = 1/4$，所以第一轮就产生不同结果。

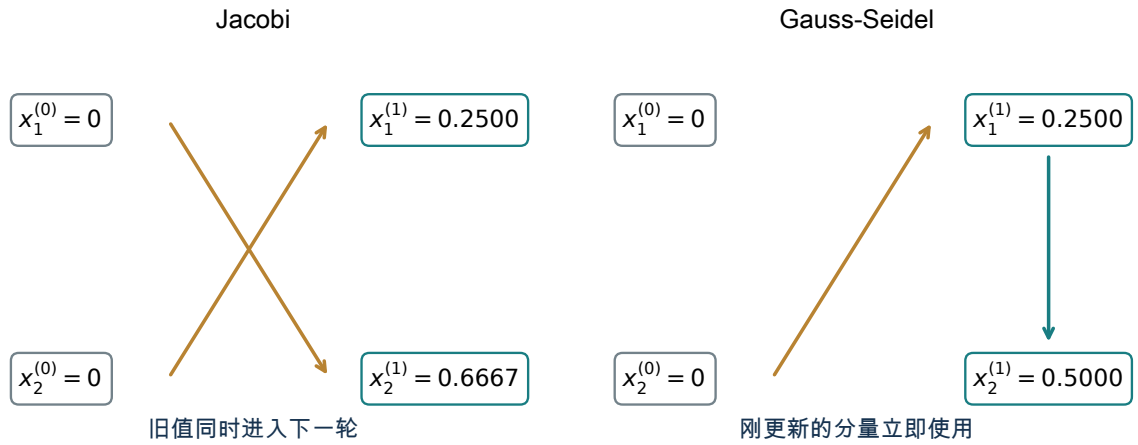


图 7.1　一轮更新的数据依赖。灰框为旧值，青框为新值；金色箭头读取旧值，青色箭头读取本轮刚更新的值。GS 图中的旧 x_1 在这一轮不再参与计算。

k	Jacobi x_1	Jacobi x_2	GS x_1	GS x_2
0	0.000000	0.000000	0.000000	0.000000
1	0.250000	0.666667	0.250000	0.500000
2	0.083333	0.500000	0.125000	0.583333
3	0.125000	0.611111	0.104167	0.597222
4	0.097222	0.583333	0.100694	0.599537

表 7.1 相同初值下的前四轮迭代。数值显示六位小数，实际更新使用未舍入的数。

两种方法最终都趋于 $(0.1, 0.6)^T$。差别不在要解的方程，而在每轮采用什么信息。程序如果把 Jacobi 写成原位逐分量更新，就会改变这张依赖图，也就改变了算法。

7.3 迭代法的收敛性

定义 7.2 (谱半径与迭代收敛) 矩阵 B 的谱半径定义为 $\rho(B) = \max_{\lambda \in \sigma(B)} |\lambda|$，其中 $\sigma(B)$ 为全部特征值。这里说迭代收敛，是指对任意初始向量，迭代都趋于同一个解，而不是仅对某个特殊初值成功。

误差满足 $e^{(k)} = B^k e^{(0)}$，因此考察收敛就是考察矩阵幂能否把所有方向都压向零。在某个特征方向上，误差每步乘以对应特征值；最大模特征值由此成为关键。但非对角化情形还含有 Jordan 块带来的多项式因子，所以完整证明需要同时处理它们。

定理 7.3 (定常迭代的收敛充要条件) 对任意初值，$x^{(k+1)} = Bx^{(k)} + c$ 都收敛到唯一不动点，当且仅当 $\rho(B) < 1$。

证明. 必要性先从一个特征方向看。若 $Bv = \lambda v$，则 $B^k v = \lambda^k v$；要让所有初始误差都趋零，必须 $|\lambda| < 1$。即使 B 为实矩阵而 v 为复向量，也可分别看 v 的实部、虚部：两个实误差都趋零才会使这个复误差趋零。

充分性不能假设 B 一定可对角化。先把它在复数域变成上三角形 $T = U^* B U$，其中 U 酉。这个变换可归纳构造：选一个单位特征向量作为第一基向量，补成正交基，矩阵的第一列便变成 $(\lambda, 0, \dots, 0)^T$；再对右下方块重复。这样得到的对角元就是全部特征值。

取 $\rho(B) < q < 1$，于是 $|t_{ii}| \le q$。T^k 的一个元素是许多乘积的和，例如 $t_{ii_1} t_{i_1 i_2} \cdots t_{i_{k-1} j}$。因为 T 上三角，索引只能不下降；每遇到一个非对角元素，索引严格增加，因此一条乘积中至多有 $n-1$ 个非对角因子。

设所有非对角因子的模不超过 M。恰有 m 次严格增加的项，先从 k 个位置中选择这 m 次跳跃的位置，共 $\binom{k}{m}$ 种；每次跳跃的目标索引最多有 n 种，所以项数不超过 $n^m \binom{k}{m}$，而每项绝对值不超过 $M^m q^{k-m}$。所以存在固定 C 使

$$|(T^k)_{ij}| \le C \sum_{m=0}^{n-1} \binom{k}{m} M^m q^{k-m}.$$

每一项都是固定次多项式增长乘几何衰减。它趋零可以看比值：$[(k+1)^m q^{k+1}]/[k^m q^k] = (1+1/k)^m q \to q < 1$，从某一步起按小于 1 的固定比例下降。故 $T^k \to 0$，也就有 $B^k = UT^kU^* \to 0$。

最后，因为 1 不是 B 的特征值，$I-B$ 可逆，不动点 $x_* = (I-B)^{-1}c$ 唯一。误差 $e^{(k)} = B^k e^{(0)}$ 因而对任意初值趋零。 □

若某个诱导范数满足 $\|B\| = q < 1$，则这是更容易验证的充分条件，并有

$$\left\|e^{(k)}\right\| \le q^k \left\|e^{(0)}\right\|.$$

因为相邻增量也按 B 传播，可将未来增量相加，得到后验界

$$\left\|x_* - x^{(k)}\right\| \le \frac{q}{1-q}\left\|x^{(k)} - x^{(k-1)}\right\|. \tag{7.1}$$

只有在已知 $q < 1$ 且 q 不太接近 1 时，相邻两次接近才是有力的停止依据。

令 $d_k = x^{(k)} - x^{(k-1)}$。两次更新式相减，得到 $d_{k+1} = Bd_k$，故 $\|d_{k+j}\| \le q^j \|d_k\|$。从当前值走到极限，差值是尚未做完的全部增量：

$$x_* - x^{(k)} = \sum_{j=1}^{\infty} d_{k+j}.$$

取范数并用几何级数求和，得到 $\left\|x_* - x^{(k)}\right\| \le (q + q^2 + \cdots)\|d_k\| = q\|d_k\|/(1-q)$。这说明分母 $1-q$ 很重要：若 q 接近 1，每步变化很小，未来累积的变化仍可能很大。

$\rho(B) < 1$ 并不要求某个预先指定的范数 $\|B\| < 1$，也不保证每一步误差都下降。非正规矩阵可能有明显的暂态增长，然后才进入渐近衰减。谱半径描述最终行为，范数界则能控制每一步。

定义 7.4 (对角占优与不可约性) 若每行均有 $|a_{ii}| > \sum_{j\ne i}|a_{ij}|$，称为严格对角占优；若将 $>$ 换成 $\ge$，称为弱对角占优。若不存在同时置换行列的方法把矩阵变成两个非空方块组成的上块三角形，则称矩阵不可约。

对角占优是逐行可检查的代数条件，谱半径则依赖整个矩阵。前者的价值在于：不必先算出特征值，就能获得后者所需的收敛保证。不可约性进一步保证不同分量之间的信息可以传递；如果方程分成互不影响的子系统，某一行的严格不等式未必能够控制另一个子系统。

对于正定矩阵，GS 的收敛还可以从能量下降理解。逐坐标求解相当于沿一个坐标方向精确最小化二次能量；每轮更新消除一些误差能量，最终只能停在唯一最小点。这条思路将在 SOR 的证明中给出更一般的表达。

定理 7.5 (严格对角占优) 若 $|a_{ii}| > \sum_{j\ne i}|a_{ij}|$ 对所有行成立，则 Jacobi 和 Gauss–Seidel 均收敛。

证明. Jacobi 满足

$$\|B_J\|_\infty = \max_i \frac{\sum_{j\ne i}|a_{ij}|}{|a_{ii}|} < 1.$$

对 GS，设 $B_{GS}v=\lambda v$，取 $|v_i|=\max_j|v_j|>0$。特征方程的第 i 行为

$$\lambda a_{ii}v_i=-\lambda\sum_{j<i}a_{ij}v_j-\sum_{j>i}a_{ij}v_j.$$

若 $|\lambda|\geq 1$，取绝对值并除以 $|\lambda|$，得到

$$|a_{ii}||v_i|\leq\sum_{j\neq i}|a_{ij}||v_i|,$$

与严格对角占优矛盾，故所有 $|\lambda|<1$。 □

弱对角占优只要求 $|a_{ii}|\geq\sum_{j\neq i}|a_{ij}|$。如果矩阵不可约，且至少一行严格不等式成立，则上述两方法也收敛。不可约的图像是：把非零 a_{ij} 看成从 i 指向 j 的边，整个有向图强连通。证明沿最大模特征向量分量传播等号条件；若有模至少为 1 的特征值，连通性会把等号传到严格占优行，从而矛盾。**“不可约”和“至少一行严格”都不能省略**。

“把等号沿图传播”具体是下面的过程。假设有 $|\lambda|\geq 1$ 的特征值，并取 $|v_i|=\max_j|v_j|=M>0$。Jacobi 的第 i 行在取绝对值后给出

$$|a_{ii}|M\leq\sum_{j\neq i}|a_{ij}||v_j|\leq\left(\sum_{j\neq i}|a_{ij}|\right)M\leq|a_{ii}|M.$$

首尾相同，所以全部不等式都必须是等号。于是该行不可能严格占优，而且对每个 $a_{ij}\neq 0$ 都必须有 $|v_j|=M$，否则中间会严格变小。

对 GS，从特征方程除以 $|\lambda|$ 后，上三角项还多一个 $1/|\lambda|\leq 1$，因此仍得到同样的等号要求。只要沿一条非零元素边走，就把最大模性质传到下一个分量。不可约性保证能走到任意一行，特别能走到至少一条严格占优行；在那里最后一个不等号严格，产生矛盾。因此不存在模至少为 1 的特征值。

对实对称正定 A，Gauss–Seidel 一定收敛，但 Jacobi 未必。因为

$$D^{1/2}B_JD^{-1/2}=I-D^{-1/2}AD^{-1/2},$$

右侧对称，且 $D^{-1/2}AD^{-1/2}$ 正定。故 $\rho(B_J)<1$ 当且仅当该正定矩阵的全部特征值小于 2，等价于 $2D-A$ 正定。

令 $H=D^{-1/2}AD^{-1/2}$。对称正定 A 的每个对角元为正，因为 $a_{ii}=e_i^TAe_i>0$，故这些平方根有定义。对任意非零 z，$z^THz=(D^{-1/2}z)^TA(D^{-1/2}z)>0$，所以 H 也正定。

Jacobi 矩阵与 $I-H$ 相似，特征值为 $1-\mu_i$，其中 $\mu_i>0$ 为 H 的特征值。因此 $|1-\mu_i|<1$ 等价于 $0<\mu_i<2$。另一方面，

$$2D-A=D^{1/2}(2I-H)D^{1/2}.$$

对任意向量作这个可逆变量代换，正定性保持不变。所以 $2D-A$ 正定等价于 $2I-H$ 的全部特征值 $2-\mu_i$ 为正，也就是同一组条件。

例 7.2（正定并不保证 Jacobi 收敛） 三阶矩阵 A 的对角元均为 1，非对角元均为 $3/4$。证明 A 正定，但 Jacobi 迭代不能对任意初值收敛。

解 其特征值为 $5/2,1/4,1/4$，所以正定。Jacobi 迭代矩阵为 $I-A$，特征值为 $-3/2,3/4,3/4$，谱半径 $3/2>1$，因而不能对任意初值收敛。GS 却由正定性保证收敛。

误差估计与停止条件

最直接的停止条件是尺度化残差

$$\eta_k = \frac{\|b - Ax^{(k)}\|}{\|A\|\,\|x^{(k)}\| + \|b\|} \le \text{tol}.$$

若还有可靠条件估计，就可以把它转换为前向误差判断。若用相邻两次的差停止，应同时具备 (7.1) 那样的收敛率界；否则很小的步长也可能只是迭代停滞。

实现应区分 GS 的新旧数组。Jacobi 必须整体使用旧向量；如果原位更新，就会无意间改变算法。GS 与 SOR 恰恰要按顺序利用新分量。对稀疏矩阵，应尽量只访问非零元素，单步成本才能与非零元个数相称。

从矩阵分裂看，选取容易求解且接近 A 的 M，是在重新组织方程的误差传播。这也是预条件思想的起点。更先进的 Krylov 方法会利用多个历史方向，但其数学主线仍然是：用便宜的矩阵作用构造有信息的修正，再控制残差与误差。

7.4 超松弛迭代法

GS 使用某个坐标方程给出的完整修正，但完整修正未必是迭代速度最好的选择。可以只走修正的一部分，也可以适当多走一点，以改变不同误差模式的衰减速度。这就是松弛参数的作用。

> **定义 7.6** (松弛迭代) 把旧值与一次基本更新值作加权组合 $x_{\text{new}} = (1-\omega)x_{\text{old}} + \omega x_{\text{basic}}$，称为松弛。$0 < \omega < 1$ 为欠松弛，$\omega > 1$ 为超松弛；对 GS 的逐坐标更新作这种处理，得到 SOR 方法。

“多走一点”可能加速，也可能把原本衰减的误差变成增长。参数范围必须由收敛分析给出，而不能把超松弛理解成无条件更快。

GS 给出一个坐标修正，SOR 再乘松弛因子 ω：

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \frac{\omega}{a_{ii}}\left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)}\right).$$

$\omega = 1$ 恢复 GS；$0 < \omega < 1$ 是欠松弛；$\omega > 1$ 是超松弛。矩阵形式为

$$B_\omega = (D + \omega L)^{-1}[(1-\omega)D - \omega U].$$

因两侧矩阵分别为三角阵，

$$\det B_\omega = (1-\omega)^n.$$

如果迭代收敛，则所有特征值模小于 1，所以 $|1-\omega| < 1$，即 $0 < \omega < 2$。这是一般情况下的必要条件，单独并不充分。

将逐分量 SOR 公式乘 a_{ii}，把本轮的下三角项移到左边，再按行合并，得到

$$(D + \omega L)x^{(k+1)} = [(1-\omega)D - \omega U]x^{(k)} + \omega b.$$

因此其迭代矩阵为正文所列的形式。分母矩阵是下三角，其行列式为 $\prod_i a_{ii}$；分子矩阵是上三角，其行列式为 $\prod_i (1-\omega)a_{ii}$。相除便得到 $(1-\omega)^n$。

行列式又等于全部特征值之积。若每个特征值的模都小于 1，乘积的模也小于 1，所以 $|1-\omega|^n<1$，再开 n 次方得 $|1-\omega|<1$，即 $0<\omega<2$。这只使用乘积信息，不能反过来保证每一个特征值都小于 1。

定理 7.7 (正定情形的 SOR 收敛)　若 A 实对称正定且 $0<\omega<2$，则 SOR 收敛。因此 GS 是其中 $\omega=1$ 的特例。

证明. 先将二次能量在精确解处配方。因 $Ax_*=b$、A 对称，代入 $x=x_*+e$ 后交叉项消失，得到

$$F(x)-F(x_*)=\tfrac{1}{2}e^TAe.$$

正定性使右侧在 $e\neq 0$ 时严格为正，所以 x_* 是唯一最小点。
更新第 i 个坐标时，当前残差为 $r_i=b_i-(Ax)_i$。令修正为 s，展开二次型：

$$F(x+se_i)-F(x)=se_i^T(Ax-b)+\tfrac{1}{2}s^2e_i^TAe_i=-sr_i+\tfrac{1}{2}a_{ii}s^2.$$

GS 的最优坐标修正由这个一元二次式求导得 $s=r_i/a_{ii}$；SOR 使用它的 ω 倍。因此

$$F(x+se_i)-F(x)=-\frac{\omega r_i^2}{a_{ii}}+\frac{\omega^2r_i^2}{2a_{ii}}=-\frac{\omega(2-\omega)}{2a_{ii}}r_i^2.$$

在 $0<\omega<2$ 时，每次非零修正都严格降低能量。
若一整轮的能量没有严格下降，则每个非正下降量都为零，故每次更新处 $r_i=0$、$s=0$。整个向量在这一轮完全未变，因此这些残差也就是起始向量的全部残差；它已满足 $Ax=b$。所以任意非零误差经一整轮后，能量范数 $\|e\|_A=(e^TAe)^{1/2}$ 都严格减小。
还要排除“每次略微下降却不趋零”的可能。一整轮对应固定线性映射 B_ω。单位能量球面是闭且有界的集合，连续函数 $\|B_\omega e\|_A$ 在其上达到最大值 q。因为最大点也具有严格下降，$q<1$。由齐次性，所有误差都满足 $\|B_\omega e\|_A\le q\,\|e\|_A$，反复使用后得到 q^k 的衰减，迭代因而收敛。 □

适当 ω 可以加速，但最佳值依赖矩阵与排序。某些特殊结构有显式最优公式，不能把它们直接用于任意矩阵。下图展示一个三对角正定问题的实际差异。

对于对称正定系统，迭代还可以画在二次能量的等高线上。下面取

$$A=\begin{pmatrix}4&1\\1&3\end{pmatrix},\qquad b=(1,2)^T,\qquad x^{(0)}=(-0.3,1.05)^T.$$

GS 的水平、竖直线段分别沿一个坐标方向寻找该方向的最小值；SOR 将该修正再乘 ω，因此可能越过坐标最小点。图中的 $\omega=1.3$ 只是一组示例参数，不代表普遍最优。

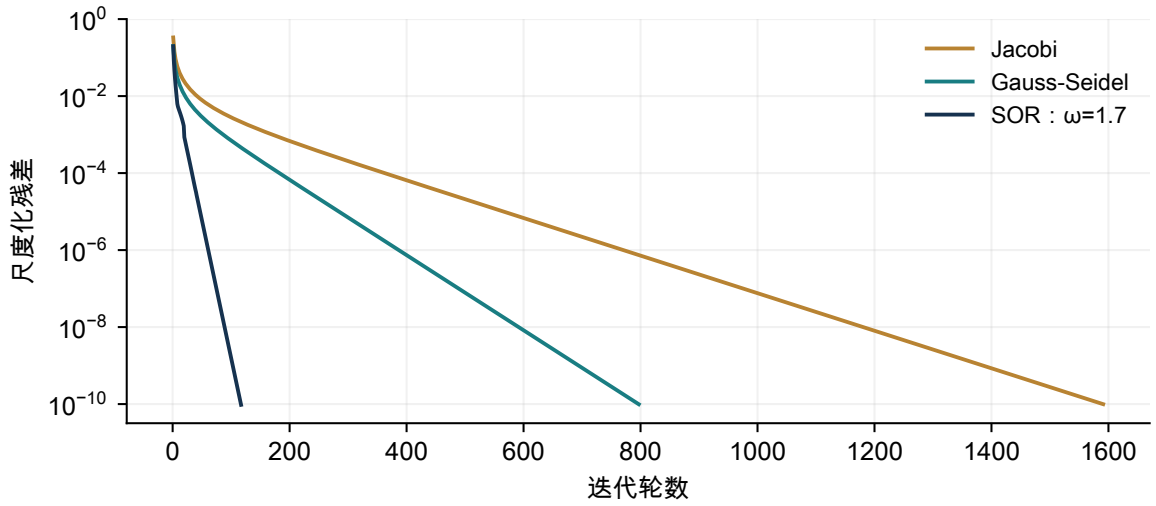


图 7.2 三对角正定系统上 Jacobi、Gauss–Seidel 与一个给定松弛参数的 SOR。纵轴是尺度化残差。这里 SOR 更快是此矩阵和参数下的表现。

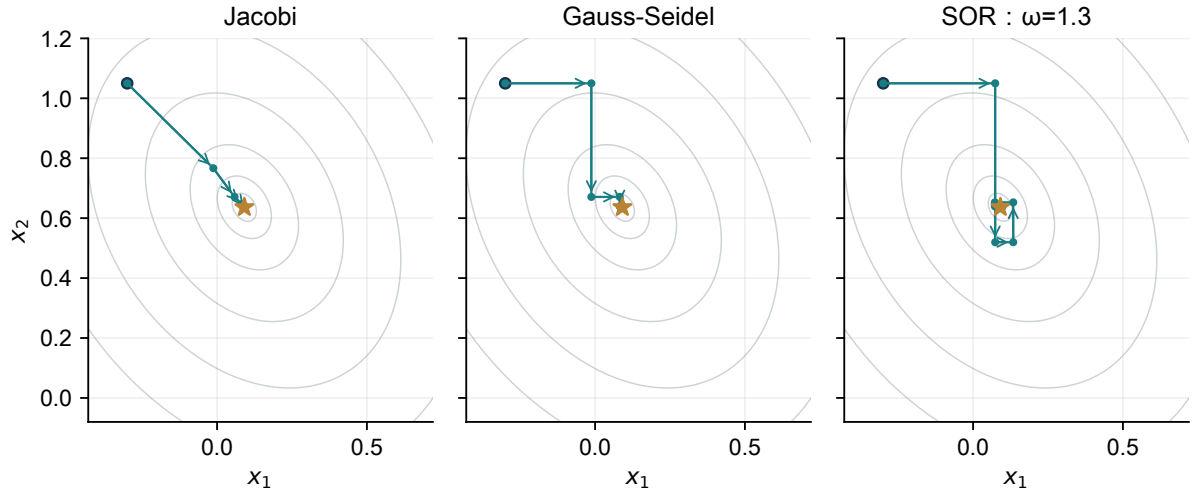


图 7.3 同一能量 $F(x) = x^T Ax/2 - b^T x$ 上的迭代路径。星号为精确解；Jacobi 连线表示整轮更新，GS 与 SOR 连线还显示轮内的逐坐标更新。

基本迭代方法的比较

方法	一轮中使用的数据	常见收敛保证	计算特点
Jacobi	全部使用上一轮值	严格对角占优；一般判据为 $\rho(B_J) < 1$	各分量可并行
Gauss–Seidel	已更新分量立即使用	严格对角占优，或实对称正定	依赖更新顺序
SOR	GS 修正乘以 ω	正定情形 $0 < \omega < 2$	参数影响速度；一般情形仍需另验收敛

表 7.2 充分条件不能当作必要条件；不同方法的迭代轮数还需结合单轮成本比较。

第 8 章　非线性方程的数值解法

8.1　引言

对 $f(x)=0$，通常没有一个适用于所有函数的显式解法。我们需要根据连续性、单调性和局部导数信息，逐步缩小可能的根位置。二分法提供可靠的范围保证，Newton 与割线法提供更快的局部修正；把两者结合，往往比只追求某一种收敛阶更实用。

定义 8.1 (方程的根、单根与重根)　若 $f(\alpha)=0$，称 α 为根。若 $f'(\alpha)\neq 0$，称为单根。若在根附近 $f(x)=(x-\alpha)^m g(x)$，其中 $g(\alpha)\neq 0$，则称 α 为 m 重根。

求根任务不仅是得到一个使 $f(x)$ 很小的数，还要判断它对应哪一个根，以及位置误差是否符合要求。函数有多个根时，需要先给出初始区间或其他先验信息，把希望求的根与其他根区分开。

若 α 是简单根，$f(\alpha)=0, f'(\alpha)\neq 0$。给函数值加入小扰动 δ，新的根满足 $f(\alpha+\Delta\alpha)+\delta=0$，一阶展开给出

$$\Delta\alpha \approx -\frac{\delta}{f'(\alpha)}.$$

根附近曲线越平，函数值误差越容易变成较大的位置误差。多重根处 $f'(\alpha)=0$，敏感性通常更严重。例如 $x^2=0$ 改为 $x^2=\delta$，根的变化是 $\sqrt{\delta}$ 量级，而非 δ 量级。

8.2　方程求根的二分法

二分法利用的是连续性。它不预测曲线的形状，只维护一段确定含根的区间。每次判断中点的符号，就能排除一半区间，因此计算过程有明确的范围保证。

定理 8.2 (异号区间内的根)　若 $f\in C[a,b]$ 且 $f(a)f(b)<0$，则 (a,b) 中至少有一个零点。若进一步 f 在区间内严格单调，则零点唯一。

证明. 存在性来自介值定理。若严格单调函数有两个不同零点，则这两个点的函数值应严格有序，与二者都为零矛盾。 □

若 f 在 $[a,b]$ 连续且 $f(a)f(b)<0$，介值定理保证至少有一个根。二分法取中点 $m=(a+b)/2$，保留仍然异号的半区间。每次保留根，区间长度减半。

经过 k 次二分后，新区间长度为 $(b-a)/2^k$，返回该区间的中点 m_k，则对区间中的某个根有

$$|m_k-\alpha|\le \frac{b-a}{2^{k+1}}.$$

若要求位置误差不超过 ε，只需选取满足该不等式的非负整数 k。不同教材把第一次中点计算计为第 0 或第 1 次，公式因此可能差一个 2；应先核对迭代计数。

二分只需要连续性和异号区间，不需要导数。但偶数重根两侧可能同号，因此“没有异号”不等于“没有根”。浮点实现也宜比较两个函数值的符号，避免直接相乘导致溢出。

可以把一次更新明确写成三个步骤：先计算中点及其函数值；若函数值恰为零则结束；否则用它替换与其同号的端点。更新后两端仍异号，所以含根不变量一直保持。

例 8.1（用二分法预先确定工作量） 对 $f(x)=x^3-x-1$，从 $[1,2]$ 开始，要求最终返回区间中点的误差不超过 10^{-6}，至少应作多少次二分？

解 有 $f(1)=-1$、$f(2)=5$，且 $f'(x)=3x^2-1>0$，所以区间内有唯一根。按“二分 k 次后返回新区间中点”的计数，误差界为 $2^{-(k+1)}$。要求 $2^{-(k+1)}\le 10^{-6}$，最小整数为 $k=19$。

第一次中点为 1.5，其函数值为 $0.875>0$，所以保留 $[1,1.5]$。下一次中点 1.25 的函数值为 $-0.296875<0$，保留 $[1.25,1.5]$。每一步只需要新增一次函数求值。

8.3 一元方程的不动点迭代法

定义 8.3（不动点与压缩映射） 若 $\varphi(\alpha)=\alpha$，称 α 为映射 φ 的不动点。若对某集合中的任意 x,y，存在统一常数 $0\le q<1$ 使 $|\varphi(x)-\varphi(y)|\le q|x-y|$，则称该映射在集合上具有压缩性。

不动点方程表达“更新以后不再改变”。压缩性更进一步，表达两条从不同初值出发的轨迹会相互靠近。把方程写成不动点形式只是代数步骤，是否压缩则是新的分析问题；并非所有等价改写都会保留良好的迭代行为。

把方程改写为 $x=\varphi(x)$，迭代

$$x_{k+1}=\varphi(x_k).$$

代数上等价的改写，收敛性质可能完全不同。例如 $x^2-a=0$ 可以写成 $x=a/x$，也可写成 $x=(x+a/x)/2$。前一种在正根处导数为 -1，可能来回循环；后一种在根处导数为零，误差衰减更快。

定理 8.4（区间上的压缩映射定理） 若 $\varphi:[a,b]\to[a,b]$，且存在 $0\le q<1$ 使

$$|\varphi(x)-\varphi(y)|\le q|x-y|\quad\forall x,y\in[a,b],$$

则区间中有唯一不动点 α，任意 $x_0\in[a,b]$ 的迭代均收敛到它，且

$$|x_k-\alpha|\le\frac{q^k}{1-q}|x_1-x_0|,\qquad |x_k-\alpha|\le\frac{q}{1-q}|x_k-x_{k-1}|.$$

证明. 自映射条件保证全部迭代点留在区间内。相邻差满足 $|x_{k+1}-x_k|\le q^k|x_1-x_0|$。对 $m>k$，

$$|x_m-x_k|\le\sum_{j=k}^{m-1}|x_{j+1}-x_j|\le\frac{q^k}{1-q}|x_1-x_0|.$$

因此序列是 Cauchy 序列，在闭区间内收敛到某个 α。φ 由 Lipschitz 条件连续，取极限得 $\alpha=\varphi(\alpha)$。若还有 β，则 $|\alpha-\beta|\le q|\alpha-\beta|$，故两者相同。让上面不等式中 $m\to\infty$ 得先验界，从第 k 步后的相邻差求和得后验界。 □

若 φ 可微，$\max|\varphi'|\le q<1$ 是压缩条件的常用充分条件，但仍须验证 $\varphi([a,b])\subset[a,b]$。只在一个区间估计导数，却让迭代跑出区间，证明就失去了基础。

局部结论更弱也更灵活：若 $\varphi(\alpha)=\alpha$、φ' 在附近连续且 $|\varphi'(\alpha)|<1$，则可以找到足够小的邻域，使它自映射并压缩，因此足够近的初值收敛。若 $|\varphi'(\alpha)|>1$，根附近通常排斥；等于 1 时，一阶分析不能判断，必须看更高阶项。

局部条件怎样给出完整的压缩区间，也可以写清楚。若 $|\varphi'(\alpha)|<1$，先选一个数 q 满足 $|\varphi'(\alpha)|<q<1$。导数连续使得在足够小的闭区间 $[\alpha-r,\alpha+r]$ 上都有 $|\varphi'|\le q$。由一元中值定理，

$$|\varphi(x)-\alpha|=|\varphi(x)-\varphi(\alpha)|\le q|x-\alpha|\le qr<r.$$

这同时证明了自映射和压缩性，所以可以使用前面的定理。

若 $|\varphi'(\alpha)|>1$，则在小邻域内可反过来得到 $|e_{k+1}|\ge q|e_k|$，某个 $q>1$，非零误差会被推出该邻域。等于 1 时不能这样判断：$\varphi(x)=x-x^3$ 在小的非零 x 处会缩小 $|x|$，$\varphi(x)=x+x^3$ 却会放大；两者在根 0 的导数都为 1。

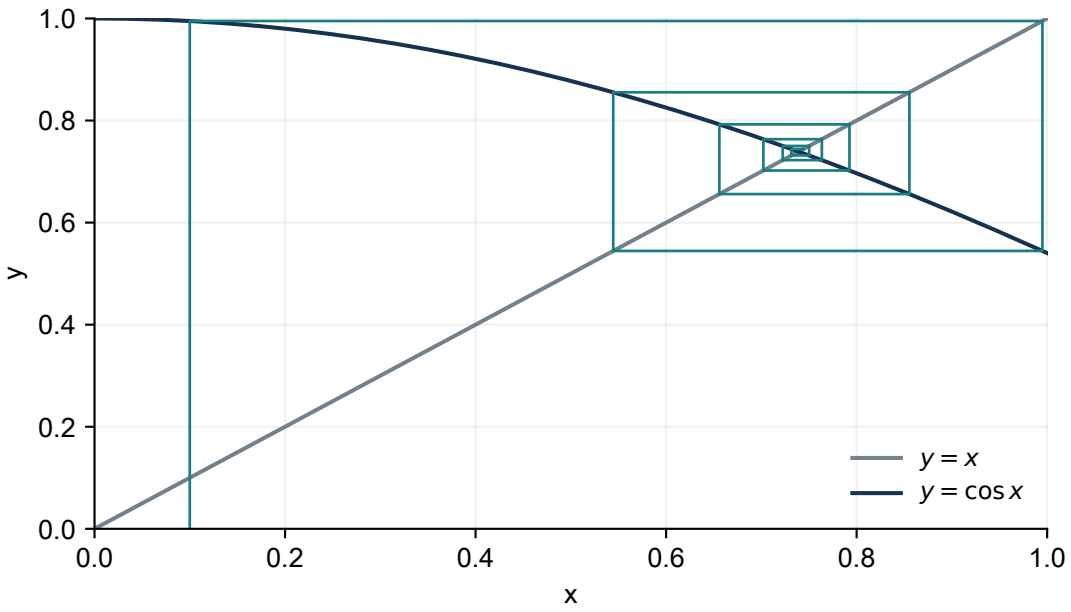


图 8.1 不动点迭代 $x_{k+1}=\cos x_k$ 的蛛网图。曲线与直线 $y=x$ 的交点是不动点；反复的竖直与水平移动表示一次函数求值和一次坐标传递。

局部收敛性与加速

只知道收敛还不够。对于相同的初始误差，有的方法每一步只按固定比例改进，有的方法在接近根以后会突然变得非常快。收敛阶用相邻误差之间的幂次关系区分这些速度。

定义 8.5（线性、超线性与二阶收敛） 设 $x_k\to\alpha$，$e_k=x_k-\alpha$。若 $|e_{k+1}|/|e_k|\to q$ 且 $0<q<1$，称为线性收敛；若该比值趋于零，称为超线性收敛。若 $|e_{k+1}|/|e_k|^2$ 趋于有限正数，则称为二阶收敛。

当主误差常数约为 1 时，二阶收敛意味着误差从 10^{-3} 降到约 10^{-6}，再降到约 10^{-12}。这只是进入局部范围后的尺度说明，不保证从任意初值就按这个速度前进。

设 $e_k=x_k-\alpha$。若

$$\lim_{k\to\infty}\frac{|e_{k+1}|}{|e_k|^p}=C,\qquad 0<C<\infty,$$

则称收敛阶为 p。$p=1$ 时还需 $C<1$ 才称线性收敛；$p>1$ 为超线性，$p=2$ 为二阶收敛。

若 φ 在根附近足够光滑，且

$$\varphi'(\alpha)=\cdots=\varphi^{(p-1)}(\alpha)=0,\qquad \varphi^{(p)}(\alpha)\neq 0,$$

Taylor 展开给出 $e_{k+1}=\varphi^{(p)}(\alpha)e_k^p/p!+o(e_k^p)$。高阶收敛的本质是低阶误差项消失。

对近似几何误差 $e_{k+1}\approx\lambda e_k$，有

$$x_{k+1}-x_k\approx(\lambda-1)e_k,\qquad x_{k+2}-2x_{k+1}+x_k\approx(\lambda-1)^2e_k.$$

消去 λ 和 e_k，得到 Aitken Δ^2 外推

$$\widehat{x}_k=x_k-\frac{(x_{k+1}-x_k)^2}{x_{k+2}-2x_{k+1}+x_k}.$$

它对严格几何误差一步消去主项。分母很小时会放大误差，需要防护。

Steffensen 方法把这一外推重新作为下一次迭代：先算 $y=\varphi(x)$、$z=\varphi(y)$，再取

$$x_{\text{new}}=x-\frac{(y-x)^2}{z-2y+x}.$$

在简单不动点附近，若 φ 足够光滑且 $\varphi'(\alpha)\neq 1$，Taylor 展开显示一阶误差被消去，可获得至少局部二阶行为；在根处出现的 0/0 按连续延拓或已经收敛处理。它不自动提供全局收敛保证。

先把 Aitken 看成精确的代数消元。若 $x_k=\alpha+c\lambda^k$ 且 $\lambda\neq 1$，则

$$\Delta x_k=c\lambda^k(\lambda-1),\qquad \Delta^2x_k=c\lambda^k(\lambda-1)^2.$$

因此 $(\Delta x_k)^2/\Delta^2x_k=c\lambda^k$，从 x_k 减去它就恰好剩下 α。一般线性收敛序列只是在主项上近似这种形式，所以外推主要消掉主误差。

Steffensen 的二阶性质可直接用除法核对。写 $e=x-\alpha$，并设

$$\varphi(\alpha+e)=\alpha+ae+be^2+O(e^3),\qquad a\neq 1.$$

先算 $y=\varphi(x)$，再代入同一展开算 $z=\varphi(y)$，得到

$$y-x=(a-1)e+be^2+O(e^3),$$

$$z-2y+x=(a-1)^2e+b(a-1)(a+2)e^2+O(e^3).$$

把分子平方，再用 $1/(1+t)=1-t+O(t^2)$ 作除法：

$$\frac{(y-x)^2}{z-2y+x}=e\frac{1+\frac{2b}{a-1}e+O(e^2)}{1+\frac{b(a+2)}{a-1}e+O(e^2)}=e-\frac{ab}{a-1}e^2+O(e^3).$$

所以新误差为 $abe^2/(a-1)+O(e^3)$，一次项消失。对足够小的非零误差，分母的主项 $(a-1)^2e$ 非零；取足够小邻域使 $|e_{\text{new}}|\le C|e|^2<|e|$，便得到局部收敛。若主常数也为零，阶数还可能更高。

8.4 一元方程的常用迭代法

Newton 迭代法

二分法每步只保留范围，不使用当前曲线的斜率。不动点方法利用一个人为设计的更新映射，速度也依赖该映射。Newton 法则直接从原方程的局部线性模型产生修正：当前函数值告诉我们偏离横轴多少，导数把这个竖直偏差换算成水平位移。

要使用这种换算，导数必须非零；要让局部线性模型有效，当前点还应处在目标根的合适邻域。先说明这两个条件，再看它为何能得到二阶收敛。

在 x_k 附近线性化 f：

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k).$$

令右侧为零，得到

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}. \tag{8.1}$$

几何上，这是切线与横轴的交点。算法用当前切线代替真实曲线，因此它需要初值已经足够接近目标根，或额外的全局保护。

定理 8.6 (简单根处的局部二阶收敛) 设 $f \in C^2$ 在简单根 α 的某邻域内成立，$f'(\alpha) \neq 0$。则足够近的初值使 Newton 迭代有定义并收敛，且

$$e_{k+1} = \frac{f''(\alpha)}{2f'(\alpha)} e_k^2 + o(e_k^2).$$

若 $f''(\alpha) = 0$，收敛可能更高阶，不能据此断言恰为二阶。

证明. 因为 $f'(\alpha) \neq 0$ 且导数连续，可以先取一个闭邻域，使 $|f'| \geq m > 0$、$|f''| \leq M$。这样分母不会在邻域中为零。以当前点 x_k 展开真根处的函数值：

$$0 = f(\alpha) = f(x_k) - f'(x_k)e_k + \tfrac{1}{2}f''(\xi_k)e_k^2, \qquad e_k = x_k - \alpha.$$

将 $f(x_k)$ 单独留下并除以 $f'(x_k)$，得到

$$\frac{f(x_k)}{f'(x_k)} = e_k - \frac{f''(\xi_k)}{2f'(x_k)} e_k^2.$$

而 Newton 新误差就是 $e_k - f(x_k)/f'(x_k)$，所以一次项恰好相消，留下

$$e_{k+1} = \frac{f''(\xi_k)}{2f'(x_k)} e_k^2, \qquad |e_{k+1}| \leq \frac{M}{2m}|e_k|^2.$$

令 $C = M/(2m)$，进一步缩小邻域半径 r 使 $Cr \leq 1/2$。若 $|e_0| \leq r$，则 $|e_1| \leq |e_0|/2 \leq r$；归纳得全部迭代留在邻域内，并且 $|e_k| \leq 2^{-k}|e_0| \to 0$。

在已经证明收敛以后，$x_k \to \alpha$，介于 x_k 与 α 之间的 ξ_k 也趋于 α。误差系数于是趋于 $f''(\alpha)/(2f'(\alpha))$，得到二阶渐近表达式。这个先后顺序避免了先假定收敛再用渐近式证明收敛的循环。 □

例 8.2 (平方根迭代及其全局单调性) 对 $a > 0$，推导计算 $\sqrt{a}$ 的 Newton 迭代，并证明任意正初值都收敛到 $\sqrt{a}$。

解 对方程 $x^2 - a = 0$，Newton 迭代为

$$x_{k+1} = \frac{1}{2}\left(x_k + \frac{a}{x_k}\right).$$

任取 $x_0 > 0$，由算术几何平均不等式有 $x_1 \geq \sqrt{a}$。当 $x_k \geq \sqrt{a}$，又有 $x_{k+1} \leq x_k$。所以从第一步起序列有下界且单调下降，其极限必须满足 $x = a/x$，因此等于 $\sqrt{a}$。

更直接地，

$$x_{k+1}-\sqrt{a}=\frac{(x_k-\sqrt{a})^2}{2x_k}.$$

这一个等式同时说明不越过根、误差非负与局部二阶收敛。取 $a=2, x_0=1$，前几步为 $1.5, 1.416666\ldots, 1.414215686\ldots$。

单调收敛结论也可以不用省略的“凸性”来解释。若 $x\ge\alpha$、$f'>0, f''\ge 0$，则 f' 单调不减，所以

$$f(x)=\int_\alpha^x f'(t)\,\mathrm{d}t\le (x-\alpha)f'(x).$$

除以正数 $f'(x)$，得到 $x-f(x)/f'(x)\ge\alpha$。另一方面 $f(x)\ge 0$，新点又不超过 x。所以迭代始终位于根右侧且单调下降，有极限 $L\ge\alpha$；对更新式取极限得 $f(L)=0$，而 $f'>0$ 保证根唯一，故 $L=\alpha$。

重根、阻尼与割线法

若 $f(x)=(x-\alpha)^m g(x)$，其中 $g(\alpha)\neq 0$、$m>1$，则

$$\frac{f(x)}{f'(x)}=\frac{x-\alpha}{m}+O((x-\alpha)^2),$$

普通 Newton 只有 $e_{k+1}=(1-1/m)e_k+O(e_k^2)$，即线性收敛。若重数已知，改用

$$x_{k+1}=x_k-m\frac{f(x_k)}{f'(x_k)}$$

可消去一阶项。若重数未知，可对 $g_1=f/f'$ 作 Newton，得到

$$x_{k+1}=x_k-\frac{f(x_k)f'(x_k)}{[f'(x_k)]^2-f(x_k)f''(x_k)}.$$

它需要二阶导数，且分母在数值上可能敏感，不能无条件替代普通方法。

乘积求导给出

$$f'(x)=(x-\alpha)^{m-1}[mg(x)+(x-\alpha)g'(x)].$$

令 $e=x-\alpha$，约去公共幂后，有

$$\frac{f(x)}{f'(x)}=\frac{eg(x)}{mg(x)+eg'(x)}=\frac{e}{m}\frac{1}{1+\frac{eg'(x)}{mg(x)}}=\frac{e}{m}+O(e^2).$$

因为 $g(\alpha)\neq 0$，邻域内可除以 g。普通更新 $e-f/f'$ 因而留下 $(1-1/m)e$；乘上重数以后，$e-mf/f'$ 的一次项消失。

若使用 $g_1=f/f'$，商的导数为

$$g_1'=\frac{(f')^2-ff''}{(f')^2}.$$

把 g_1/g_1' 中的公共分母约去，便得到 $ff'/[(f')^2-ff'']$。同时 $g_1(\alpha+e)=e/m+O(e^2)$，所以经连续延拓后它在 α 是单根，这说明对 g_1 作 Newton 能恢复局部二阶行为。

对 $f(x)=(x-1)^2e^x$，根 1 的重数为 2。写 $e_k=x_k-1$，两种更新可以精确整理为

$$e_{k+1}^{\text{Newton}}=\frac{e_k(1+e_k)}{2+e_k},\qquad e_{k+1}^{\text{modified}}=\frac{e_k^2}{2+e_k}.$$

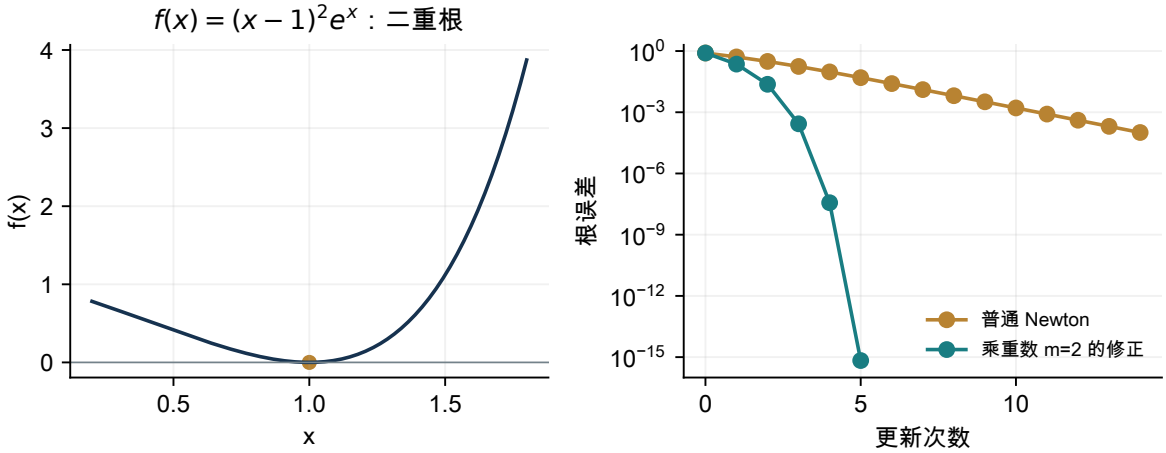


图 8.2 从 $x_0 = 1.8$ 出发的普通 Newton 与已知重数修正。右图按误差递推计算，避免接近根时再作相近量相减；低于 10^{-16} 的点未继续显示。

第一式保留一阶项 $e_k/2$，第二式从二阶开始，因此两条误差曲线具有不同形状。

远离根时，可尝试阻尼步 $x_{k+1} = x_k - \lambda_k f/f'$，其中 $0 < \lambda_k \le 1$。逐次减半寻找使 $|f|$ 下降的步长，能抑制某些过大的跳跃，但“函数值下降”本身不保证一定到达根。若已有连续异号区间，更可靠的做法是保留区间，只接受落在内部且有足够缩减作用的 Newton 步，否则回退到二分。

为什么缩短 Newton 步通常能找到下降，可以用一元导数检查。设 $d = -f(x)/f'(x)$，并考虑 $\psi(\lambda) = \frac{1}{2}[f(x + \lambda d)]^2$。若 $f(x) \neq 0, f'(x) \neq 0$，链式法则给出

$$\psi'(0) = f(x)f'(x)d = -f(x)^2 < 0.$$

所以存在足够小的正 λ 使 $\psi(\lambda) < \psi(0)$。这解释回溯缩步的局部依据，但没有证明所有远处初值最终都到达指定的根。

不便计算导数时，以差商替代 $f'(x_k)$，得到割线法

$$x_{k+1} = x_k - f(x_k)\frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}.$$

割线公式由一次插值的零点得到。写 $d_k = f[x_{k-1}, x_k]$，直线为 $p_1(x) = f(x_k) + d_k(x - x_k)$，令 $p_1(x_{k+1}) = 0$ 即得更新。

为了推导误差，在真根 α 处写出三节点 Newton 恒等式：

$$0 = f(\alpha) = f(x_k) + d_k(\alpha - x_k) + f[x_{k-1}, x_k, \alpha](\alpha - x_{k-1})(\alpha - x_k).$$

将最后两个因子换成误差，整理成

$$e_{k+1} = \frac{f[x_{k-1}, x_k, \alpha]}{f[x_{k-1}, x_k]} e_k e_{k-1} = C_k e_k e_{k-1}.$$

在简单根附近，分母趋于 $f'(\alpha) \neq 0$，分子趋于 $f''(\alpha)/2$，所以 $C_k \to C$。若 $|C_k| \le K$ 且两初始误差小于 r、$Kr < 1$，就有 $|e_{k+1}| \le Kr|e_k|$，这同时保证迭代留在邻域并收敛。

还可以把收敛阶的计算落实为一个收缩关系。取 $p > 1$ 满足 $p(p-1) = 1$，并令 $q_k = |e_{k+1}|/|e_k|^p$，暂时假设没有提前精确到根。由上式与 $|e_k| = q_{k-1}|e_{k-1}|^p$，得

$$q_k = \frac{|C_k|}{q_{k-1}^{p-1}}, \qquad \log q_k = \log|C_k| - (p-1)\log q_{k-1}.$$

当 $C \neq 0$ 时，令 $a = p-1 \in (0,1)$、$\ell = \log|C|/p$，再记 $d_k = \log q_k - \ell$、$\eta_k = \log|C_k| - \log|C|$。因为 $(1+a)\ell = \log|C|$，相减得到

$$d_k = -a d_{k-1} + \eta_k, \qquad \eta_k \to 0.$$

给定 $\varepsilon > 0$，从某个 N 起有 $|\eta_k| \le (1-a)\varepsilon/2$。展开递推并取绝对值，

$$|d_{N+r}| \le a^r |d_N| + \frac{(1-a)\varepsilon}{2} \sum_{j=0}^{r-1} a^j \le a^r |d_N| + \frac{\varepsilon}{2}.$$

再取 r 足够大使第一项小于 $\varepsilon/2$，便证明 $d_k \to 0$。于是 $q_k \to e^{\ell} = |C|^{1/p} > 0$，得到严格的收敛阶结论。

取大于 1 的根，就得到 $p = (1+\sqrt{5})/2 \approx 1.618$。若 $C = 0$，主项消失，上述常数与阶数结论需要重新分析。割线法每步只增加一个函数值，但并不自动保留异号区间。

抛物线法

Müller 方法用三点二次插值代替切线。记连续间隔为 $h_0 = x_1 - x_0, h_1 = x_2 - x_1$，差商为

$$\delta_0 = \frac{f_1 - f_0}{h_0}, \qquad \delta_1 = \frac{f_2 - f_1}{h_1}.$$

以 $s = x - x_2$ 为变量，插值多项式写为 $as^2 + bs + c$，其中

$$a = \frac{\delta_1 - \delta_0}{h_0 + h_1}, \quad b = \delta_1 + a h_1, \quad c = f_2.$$

为避免根公式相近项相减，使用

$$s = -\frac{2c}{b \pm \sqrt{b^2 - 4ac}},$$

并选择模较大的分母，再取 $x_3 = x_2 + s$。若判别式为负，迭代可能进入复数域；对只寻找实根的任务应明确处理策略。简单非退化根附近的典型局部阶约为 1.839，但它并不因此在所有任务上优于有保护的 Newton 或割线方法。

抛物线的系数来自以 x_2 为起点的 Newton 形式：

$$p(x) = f_2 + \delta_1 (x - x_2) + a(x - x_2)(x - x_1).$$

因 $x - x_1 = (x - x_2) + h_1$，令 $s = x - x_2$ 后，就得到 $p = as^2 + (\delta_1 + a h_1)s + f_2$，即所列的 b, c。

二次根公式原为 $s = (-b \pm \sqrt{b^2 - 4ac})/(2a)$。给分子、分母乘共轭表达式 $-b \mp \sqrt{b^2 - 4ac}$，分子变成 $4ac$，约去 $2a$ 后即得 $s = -2c/(b \pm \sqrt{b^2 - 4ac})$。取模较大的分母，既减轻消去，也对应模较小、较靠近当前点的那个修正。

阶数约 1.839 的来源与割线类似。插值余项在 α 处给出 $p(\alpha) = f[x_0, x_1, x_2, \alpha] e_0 e_1 e_2$。对选中的近根零点 x_3，$0 = p(x_3) = p(\alpha) + p'(\eta)(x_3 - \alpha)$，所以

$$e_3 = -\frac{f[x_0, x_1, x_2, \alpha]}{p'(\eta)} e_0 e_1 e_2.$$

在局部非退化情形，前面的系数趋于非零常数。为计算指数，暂按 $|e_{k+1}| \approx D|e_k|^p$ 记相邻误差的尺度，则往前一步、两步分别有 $|e_{k-1}|$ 约为 $|e_k|^{1/p}$ 的常数倍，$|e_{k-2}|$ 约为 $|e_k|^{1/p^2}$ 的常数倍。三者相乘的指数必须匹配，故

$$p = 1 + \frac{1}{p} + \frac{1}{p^2}, \qquad p^3 = p^2 + p + 1.$$

后一个方程在 $p>1$ 只有一个根：左边减右边的导数为 $3p^2-2p-1=(3p+1)(p-1)>0$，且在 $1,2$ 处分别为 $-2,1$。二分计算得到 $p\approx 1.839$。

还要核对指数匹配确实对应误差比的极限。在简单根附近选取靠近真根的实零点分支，设没有提前精确到根，写误差递推为 $e_{k+1}=C_k e_k e_{k-1}e_{k-2}$。光滑性使 C_k 有界；若 $|C_k|\le K$、三个初值误差不超过 r、$Kr^2<1$，就有 $|e_{k+1}|\le Kr^2|e_k|$，从而局部收敛。若进一步 $C_k\to C\neq 0$，令

$$L_k=\log\frac{|e_{k+1}|}{|e_k|^p},\qquad L_*=\frac{\log|C|}{p+1/p}.$$

将误差递推取对数，并用 $p^2-p-1/p=1$ 合并各项，得到

$$L_k=\log|C_k|-(p-1)L_{k-1}-\frac{1}{p}L_{k-2}.$$

常数 L_* 满足这个式子的极限方程。令 $d_k=L_k-L_*$，则

$$\begin{pmatrix} d_k \\ d_{k-1}\end{pmatrix}=\begin{pmatrix} -(p-1) & -1/p \\ 1 & 0\end{pmatrix}\begin{pmatrix} d_{k-1} \\ d_{k-2}\end{pmatrix}+\begin{pmatrix} \log|C_k|-\log|C| \\ 0\end{pmatrix}.$$

这个矩阵的特征方程是 $z^2+(p-1)z+1/p=0$。由 $1.8<p<1.9$，判别式小于 $0.9^2-4/1.9<0$，两根共轭；乘积为 $1/p$，所以二者的模均为 $1/\sqrt{p}<1$。两根不同，故其矩阵幂的范数不超过 C_0q^j，其中 $q=1/\sqrt{p}$、C_0 固定。把递推展开后，初始项按 q^j 衰减；输入项趋零，其和也趋零：先使后段每项小于 $\varepsilon(1-q)/(2C_0)$，几何求和后贡献不超过 $\varepsilon/2$，再让有限个前段项随幂次衰减到 $\varepsilon/2$ 以下。因此 $L_k\to L_*$，误差比趋于 $e^{L_*}>0$，阶数确为上面的 p。重根、主系数消失或选中远处分支时不能照搬。

三种方法可以放在同一个问题 $f(x)=x^2-2$ 上观察。二分从 $[1,2]$ 开始维护区间，Newton 从 2 开始使用切线，割线法从 $1,2$ 开始使用两个函数值。图中的竖虚线均为准确根 $\sqrt{2}$。

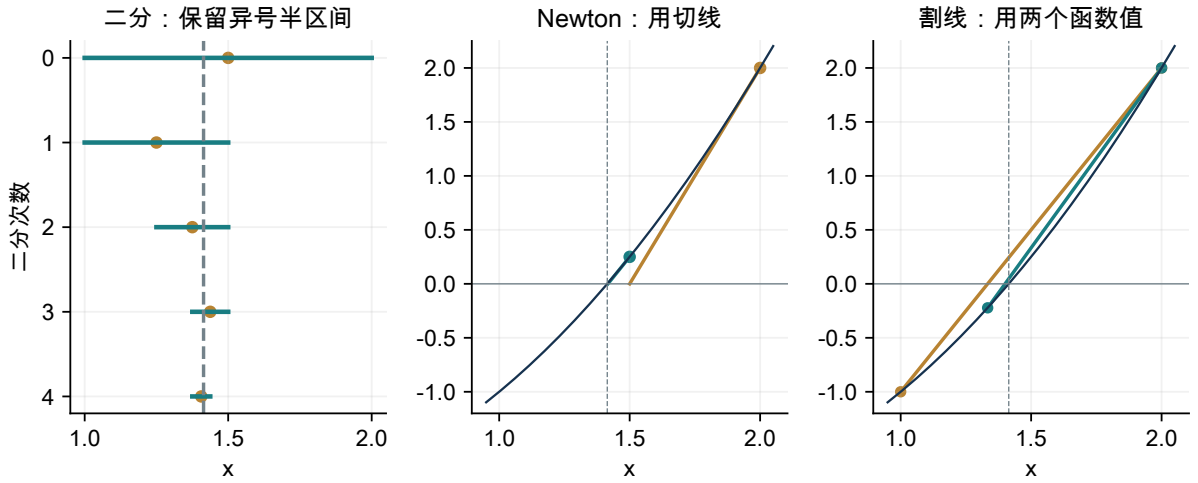


图 8.3 二分、Newton 与割线的几何步骤。二分图中的点是当前区间中点；另两幅图分别给出前两次切线或割线。

k	二分候选点	Newton 候选点	割线候选点
1	1.500000000	1.500000000	1.333333333
2	1.250000000	1.416666667	1.400000000
3	1.375000000	1.414215686	1.414634146
4	1.437500000	1.414213562	1.414211438

表 8.1 求 $\sqrt{2}$ 的新增候选点。准确值约为 1.4142135624。

表中的 k 表示新增候选点的次数。它便于比较候选点怎样移动，但并非完全相同的计算成本：Newton 还需要导数，割线法需要两个启动函数值。

常用求根方法的比较

方法	所用信息	典型速度	适用条件与限制
二分法	连续函数的异号区间	区间宽度每次减半	有范围保证；不能靠异号检测所有重根
不动点法	更新函数 φ	常见为线性	需验证自映射和压缩或局部条件
Newton 法	函数值与一阶导数	单根附近二阶	初值足够近，导数不为零
割线法	两个近期函数值	典型阶约 1.618	不保区间；需处理近零差商
Müller 法	三个近期函数值	典型阶约 1.839	可能进入复数域

表 8.2 局部阶数是在相应光滑性和非退化条件下的结论，不直接代表全局可靠性。

停止时可以同时检查区间宽度、步长和残差。如果在根附近有 $|f'| \geq m > 0$，中值定理给出

$$|x - \alpha| \leq \frac{|f(x)|}{m}.$$

没有导数下界时，小残差不一定对应小根误差；一个整体乘以 10^{-20} 的函数，残差天然很小，根的位置却没有变得更准确。

第 9 章　矩阵特征值问题的数值解法

9.1　引言

线性方程组求某个输入的响应，特征值问题则寻找矩阵自身的基本作用方向。振动系统的频率、迭代法的收敛率、二次型的曲率都与它有关。数值上通常不直接展开特征多项式求根，而是利用矩阵乘法和相似变换保留结构。

定义 9.1（特征值、特征向量与谱）　对方阵 A，若存在非零向量 v 使 $Av = \lambda v$，则称 λ 为特征值，v 为对应特征向量。全部特征值组成的集合称为谱，记为 $\sigma(A)$；特征多项式为 $\det(\lambda I - A)$。

特征向量描述矩阵作用后方向保持不变的模式。它的长度没有唯一标准，因为任意非零倍数仍是特征向量；计算时通常规定范数为 1。同一个特征值还可能对应多个线性无关方向，所以讨论向量的精度时，有时应关注整个特征子空间。

若 A 有 n 个线性无关特征向量，将其组成可逆矩阵 V，便有 $AV = V\Lambda$，即 $A = V\Lambda V^{-1}$，称为可对角化。不是所有矩阵都能这样分解。实对称矩阵则具有更强的性质：可以选择正交归一特征向量，使 $A = Q\Lambda Q^T$。

实对称矩阵的正交特征分解可以从一个最大值问题构造，不必预先假定它存在。

实对称矩阵正交对角化的推导. 在单位球面 $x^Tx = 1$ 上，连续函数 x^TAx 达到最大值。用 Lagrange 乘子求约束驻点，$\nabla(x^TAx) = 2Ax$、$\nabla(x^Tx) = 2x$，所以最大点 v 满足 $Av = \lambda v$。其中 $\lambda = v^TAv$ 是实数。
若 $z \perp v$，则 $v^TAz = (Av)^Tz = \lambda v^Tz = 0$。因此 A 把与 v 正交的子空间仍映到该子空间内。选这个子空间的一组正交基，限制后的矩阵仍是实对称矩阵，但维数少了 1。对它重复同一个最大值构造，直到一维，就得到 n 个正交归一的特征向量。
把这些向量作为 Q 的列，有 $Q^TQ = I$、$AQ = Q\Lambda$，左乘 Q^T 得 $Q^TAQ = \Lambda$。这既证明了所有特征值为实数，也证明了正交特征基的存在；重特征值只会使基的选择不唯一。
对复 Hermitian 矩阵也成立，可从特征向量直接看出：若 $Av = \lambda v$，则 v^*Av 等于自己的共轭，因而是实数，故 $\lambda = v^*Av/(v^*v)$ 为实数。若 $v^*z = 0$，则 $v^*Az = (Av)^*z = \lambda v^*z = 0$。因此其正交补仍保持不变，再按维数归纳便得到单位酉特征基。这补足了第 6 章对 A^*A 使用该分解的理由。

□

9.2　特征值的性质与估计

性质 9.2（相似变换、移位与求逆）　若 $B = S^{-1}AS$ 且 S 可逆，则 A, B 有相同特征多项式。若 $Av = \lambda v$，则 $(A - \mu I)v = (\lambda - \mu)v$；若 A 非奇异，则 $A^{-1}v = \lambda^{-1}v$。

证明. 有 $\det(zI - B) = \det[S^{-1}(zI - A)S] = \det(zI - A)$，故相似变换保持特征值及其代数重数。移位结论由直接展开得到；对 $Av = \lambda v$ 左乘 A^{-1}，并使用 $\lambda \neq 0$，即得求逆结论。　□

这三条性质分别支撑后面的 QR 相似迭代、移位加速与反幂法。它们改变矩阵的计算形式或特征值位置，却保留了可追踪的谱关系。选择变换的目的，是使目标模式更容易分离，或使矩阵结构更简单。

在真正迭代之前，先给特征值一个粗略范围很有用。它能帮助选择移位，也能排查明显不合理的计算结果。Gershgorin 圆盘只需要逐行求绝对值和，成本远小于完整求谱。

定理 9.3 (Gershgorin 圆盘定理)　矩阵 $A \in \mathbb{C}^{n\times n}$ 的全部特征值都落在

$$\bigcup_{i=1}^{n} D_i, \qquad D_i = \left\{ z \in \mathbb{C} : |z - a_{ii}| \le \sum_{j\neq i} |a_{ij}| \right\}$$

中。若其中 m 个圆盘组成的并集与其他圆盘分离，则该并集内恰有 m 个特征值，按代数重数计。

证明. 取特征对 $Av = \lambda v$，再取满足 $|v_i| = \max_j |v_j| > 0$ 的分量。第 i 行为

$$(\lambda - a_{ii})v_i = \sum_{j\neq i} a_{ij} v_j.$$

三角不等式和最大分量性质给出

$$|\lambda - a_{ii}||v_i| \le \sum_{j\neq i} |a_{ij}||v_j| \le \left(\sum_{j\neq i} |a_{ij}| \right) |v_i|.$$

除以非零的 $|v_i|$，得到第一个圆盘结论。

对计数部分，考虑 $A(t) = D + t(A - D)$，$0 \le t \le 1$。它的圆盘中心不变，半径乘 t，所以所有根始终在原来的圆盘并集中。两组不相交的圆盘并集是紧集，它们之间有正距离；根要从一组移到另一组，必须跨过没有任何圆盘覆盖的空隙。

这里需要说明根不会突然跳过空隙，而且必须计入重数。取任意 $t_l \to t_0$，各矩阵的 n 个根都在固定有界圆盘内。因此可选择子列，使这 n 个根分别趋于某些 $\zeta_1, \dots, \zeta_n$。特征多项式的系数由矩阵元素的加乘组成，随 t 连续，故

$$\det(zI - A(t_0)) = \lim_{l} \prod_{j=1}^{n} (z - \lambda_j(t_l)) = \prod_{j=1}^{n} (z - \zeta_j).$$

所以这些极限根按重数计恰好是 t_0 的全部根，没有根凭空消失或出现。由于两组之间有正距离，充分接近 t_0 时，每组内的根数必须相同。根数因此是关于 t 的局部常数，沿整个区间都不改变。

在 $t = 0$ 时矩阵为 D，特征值就是各对角元；所选 m 个圆盘的并集中恰有对应的 m 个对角元，按重数计。到 $t = 1$ 时数量仍为 m，完成证明。 □

对实对称矩阵，特征值全部为实数，可把圆盘与实轴相交成区间，进一步简化范围估计。行圆盘与对转置矩阵所得的列圆盘都有效，也可以结合使用。

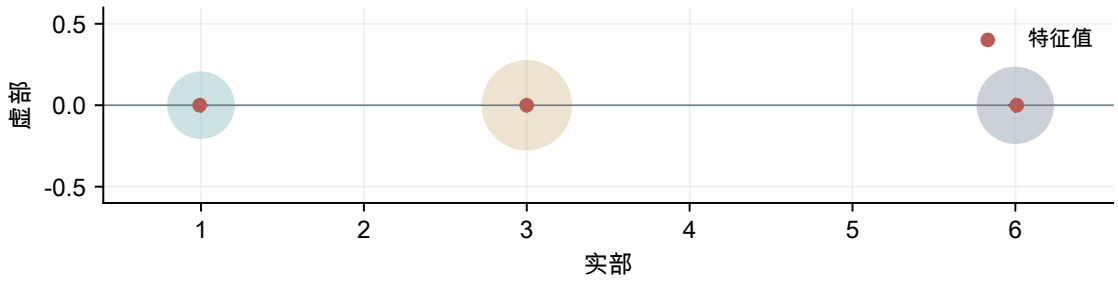


图 9.1 一个实对称矩阵的 Gershgorin 圆盘与实际特征值。圆盘用于包围谱的位置；当一组圆盘与其余圆盘分离时，还能数出其中的特征值个数。

Rayleigh 商

> **定义 9.4**（Rayleigh 商） 对实对称矩阵 A 和非零向量 x，$R_A(x) = x^TAx/(x^Tx)$ 称为 Rayleigh 商。它是沿方向 x 的二次型值经过长度归一化后的结果，因此不随 x 的非零倍数缩放而改变。

如果 x 恰好是特征向量，Rayleigh 商就等于对应特征值；如果只是接近特征方向，它仍可作为自然的特征值估计。关键是弄清楚：方向误差会以什么阶进入这个估计，以及怎样用可计算的残差检验它。

对实对称 A，定义

$$R_A(x) = \frac{x^TAx}{x^Tx}, \qquad x \neq 0.$$

写正交特征分解 $A = Q\Lambda Q^T$，令 $x = \sum_i c_i q_i$，则

$$R_A(x) = \frac{\sum_i \lambda_i c_i^2}{\sum_i c_i^2}.$$

它是特征值的加权平均，所以

$$\lambda_{\min} \le R_A(x) \le \lambda_{\max},$$

并且在相应特征向量上取到端点。等价地，它是二次型在单位球面上的极值问题。

若单位向量 $x = q_j\cos\theta + w\sin\theta$，其中 $w \perp q_j$、$\|w\| = 1$，正交性给出

$$R_A(x) - \lambda_j = (w^TAw - \lambda_j)\sin^2\theta.$$

因此向量方向有一阶小误差时，Rayleigh 商的特征值误差是二阶小量。这个结论依赖对称性。

对近似特征对 (μ, v)，取 $\|v\|_2 = 1$，定义残差 $r = Av - \mu v$。在正交特征基下，

$$\|r\|_2^2 = \sum_i |\lambda_i - \mu|^2 |c_i|^2 \ge \min_i |\lambda_i - \mu|^2,$$

故至少有一个特征值满足 $|\lambda_i - \mu| \le \|r\|_2$。要保证向量接近某一个指定的特征向量，还需要谱间隙；特征值聚集时，小残差可能只说明它接近一个特征子空间。

在正交特征基中，$q_i^Tq_j = 0$ $(i \neq j)$，所以展开 x^TAx 时交叉项全部为零：

$$x^TAx = \sum_{i,j} c_ic_j\lambda_j q_i^Tq_j = \sum_i \lambda_i c_i^2, \qquad x^Tx = \sum_i c_i^2.$$

将后者除过去，系数 $c_i^2/\sum_j c_j^2$ 非负且和为 1，因此 Rayleigh 商位于最小、最大特征值之间。

若 $x = q_j\cos\theta + w\sin\theta$，二次型的交叉项为 $2\sin\theta\cos\theta\, q_j^T A w$。由对称性，$q_j^T A w = (Aq_j)^T w = \lambda_j q_j^T w = 0$。所以 $R_A(x) = \lambda_j\cos^2\theta + (w^T A w)\sin^2\theta$；再减去 λ_j 并用 $\cos^2\theta - 1 = -\sin^2\theta$，得到二阶方向误差公式。

残差界中的单位范数同样重要。写 $v = \sum_i c_i q_i$，有 $\sum_i |c_i|^2 = 1$，于是 $\|r\|^2$ 是 $|\lambda_i - \mu|^2$ 的加权平均，不会小于其中最小值。若要控制特定特征向量 q_j 的夹角，还需 $\gamma = \min_{i\neq j}|\lambda_i - \mu| > 0$；这时

$$\|r\|_2^2 \geq \gamma^2 \sum_{i\neq j} |c_i|^2 = \gamma^2 \sin^2\theta,$$

从而 $|\sin\theta| \leq \|r\|_2 / \gamma$。特征值越拥挤，分母越小，同一个残差能给出的方向保证就越弱。

9.3 幂法与反幂法

最简单的特征值算法只重复作矩阵向量乘法。其直觉是：把一个向量分解到不同特征方向后，每乘一次 A，第 i 个方向就再乘一次 λ_i。重复很多次，模较大的特征值会逐渐占据主导。

这个解释同时揭示了限制。若初值根本没有目标方向的分量，精确运算不会凭空生成它；若两个特征值的模相同，也就没有一个模式能仅靠模的差异压过另一个模式。因此必须把初值和谱分离条件写进收敛结论。

假设 A 可对角化，特征值按模排序满足 $|\lambda_1| > |\lambda_2| \geq \cdots$，且初值在主特征方向上的系数 $c_1 \neq 0$。展开

$$A^k x_0 = c_1\lambda_1^k \left[v_1 + \sum_{j=2}^{n} \frac{c_j}{c_1}\left(\frac{\lambda_j}{\lambda_1}\right)^k v_j \right].$$

括号内其余方向逐步衰减，因此归一化后的方向趋于主特征方向，典型渐近速度由 $|\lambda_2/\lambda_1|$ 控制。

这个方向极限还可以给出范数界。先将 v_1 归一化为单位长度，把括号内余项记为 r_k。由三角不等式，

$$\|r_k\| \leq \sum_{j=2}^{n} \left|\frac{c_j}{c_1}\right| \|v_j\| \left|\frac{\lambda_j}{\lambda_1}\right|^k \leq C\left|\frac{\lambda_2}{\lambda_1}\right|^k.$$

若 $\|r_k\| < 1$，归一化后的偏差满足

$$\left\| \frac{v_1 + r_k}{\|v_1 + r_k\|} - v_1 \right\| \leq \frac{\|r_k\| + |\,\|v_1 + r_k\| - 1|}{\|v_1 + r_k\|} \leq \frac{2\,\|r_k\|}{1 - \|r_k\|}.$$

这里用了反三角不等式。公共因子 $c_1\lambda_1^k$ 的长度被归一化消去，它的符号或相位则解释了向量可能交替的问题。

为避免长度溢出或下溢，每步计算

$$y_{k+1} = Ax_k, \qquad x_{k+1} = \frac{y_{k+1}}{\|y_{k+1}\|_2}.$$

对称问题可用 $\mu_k = x_k^T A x_k$ 估计特征值，并用特征对残差停止。若主特征值为负，归一化向量可能正负交替；复特征值还可能带相位变化。因此严格地说，是方向或一维子空间收敛，不一定是原向量序列逐项收敛。

例 9.1 (初值不能遗漏目标方向)　对 $A = \mathrm{diag}(3, 2, 1)$，比较从 $(1, 1, 1)^T$ 和 $(0, 1, 1)^T$ 出发的幂法极限方向。

解　如果 $x_0 = (1, 1, 1)^T$，幂法会突出第一坐标，速度受 $2/3$ 控制；如果 $x_0 = (0, 1, 1)^T$，精确算术中第一坐标永远为零，算法只能看到特征值 2。所以“任取非零初值”不是充分条件。

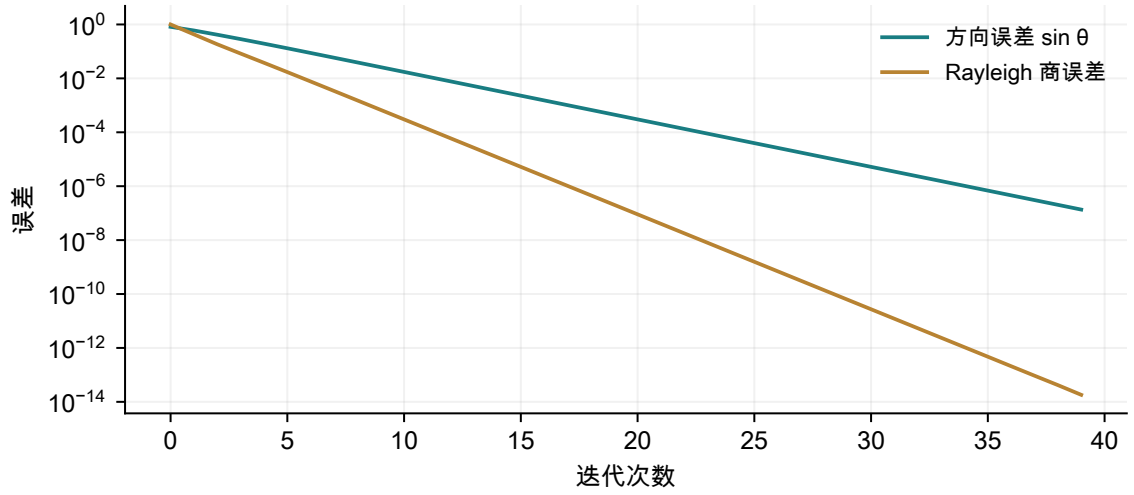


图 9.2 对角对称矩阵的幂法。方向误差约按主次特征值模比衰减，Rayleigh 商的误差通常衰减得更快；曲线末端受到浮点精度限制。

若主次特征值模很接近，幂法会慢；若最大模特征值不唯一，则可能振荡或停留在更高维不变子空间。移位 $A-\sigma I$ 会改变模的排序，有时可改善比例，但也可能把目标变成非主特征值，因此必须先分析谱位置。

反幂法与原点移位

要寻找靠近给定 σ 的特征值，可以对 $(A-\sigma I)^{-1}$ 应用幂法，其特征值为 $1/(\lambda_i-\sigma)$。离 σ 最近者的倒数模最大。

实际每步求解

$$(A-\sigma I)y_{k+1}=x_k,\qquad x_{k+1}=y_{k+1}/\|y_{k+1}\|.$$

不需要显式形成逆矩阵。固定移位时，可以复用一次 LU 分解。若 λ_j 是唯一最近的特征值，次近者为 λ_l，典型收敛因子为 $|\lambda_j-\sigma|/|\lambda_l-\sigma|$。

令每步移位取 Rayleigh 商，得到 Rayleigh 商迭代。对实对称矩阵、简单特征值以及足够好的初始方向，局部可达到很快的三阶方向收敛。这个高阶性质需要对称性和局部条件；一般非对称矩阵不能直接套用。

Rayleigh 商迭代的三阶局部速度可由两个已经出现的误差机制相乘得到。设当前单位向量与简单特征向量 q_j 夹角为 θ，移位 $\mu=R_A(x)$，则上一节给出 $|\mu-\lambda_j|=O(\theta^2)$。

在特征基中解移位系统，各分量为 $y_i=c_i/(\lambda_i-\mu)$。当移位系统可解、μ 足够接近 λ_j，其余特征值距 μ 都至少为某个 $\gamma>0$，故

$$\tan\theta_{\mathrm{new}}=\frac{\left(\sum_{i\neq j}|c_i/(\lambda_i-\mu)|^2\right)^{1/2}}{|c_j/(\lambda_j-\mu)|}\le\frac{|\lambda_j-\mu|}{\gamma}\tan\theta=O(\theta^3).$$

二阶的移位误差乘一次方向误差，便产生三阶。这一推导同时说明为什么需要谱间隙、对称性以及移位方程有定义；若某次移位恰为特征值而残差尚未达标，需要调整移位，不能继续除以零。

当移位接近特征值，线性系统变得近奇异，这恰好强化目标方向，但也要求可靠的线性求解与残差检查。已经达到特征对精度时，应先停止，避免继续求一个实际已奇异的系统。

下面把矩阵固定为 $A=Q\,\mathrm{diag}(3,1)Q^T$，其中 Q 是 30° 的二维旋转。从单位向量 $(1,0)^T$ 出发，左图反复乘 A，右图反复解 $(A-0.8I)y=x$，并在每步归一化。

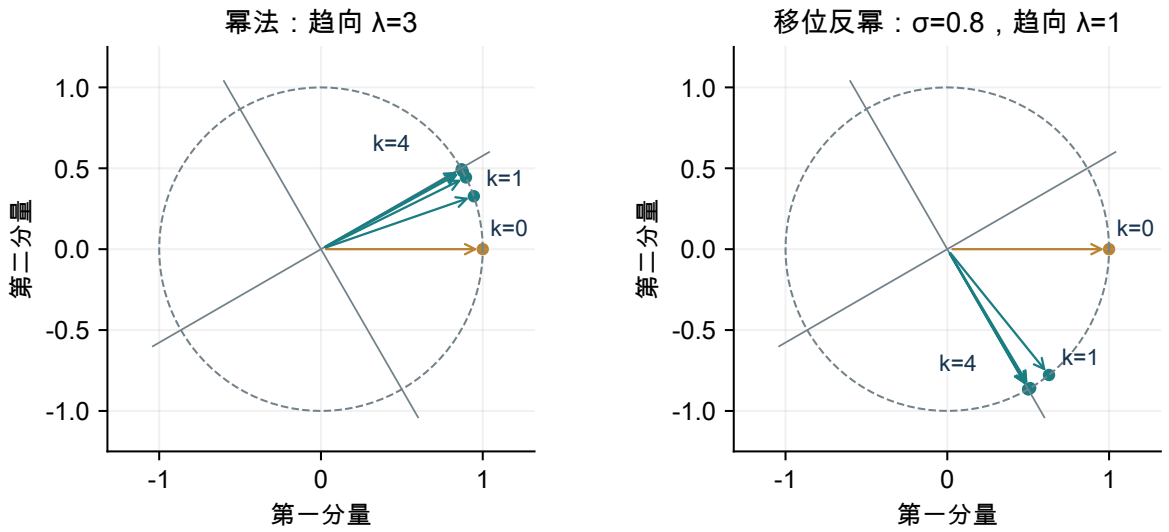


图 9.3 单位圆上的幂法与移位反幂法。灰色直线为两个特征方向；归一化保持长度为 1，真正变化的是方向。右图趋于较小特征值的一个带负号特征向量。

左图非目标分量相对于目标分量每步乘 $1/3$；右图的对应比值为 $|1-0.8|/|3-0.8| = 1/11$。移位改变了哪个方向占优，也改变了分离速度。

9.4 Jacobi 方法

幂法适合提取少数模式。如果希望得到实对称矩阵的全部特征值与正交特征向量，可以换一种目标：逐步消掉非对角项，把矩阵变得接近对角阵。此时对角元直接给出特征值，而累计变换记录特征方向。

> **定义 9.5** (平面旋转矩阵) 在两个坐标方向上作二维旋转、在其余坐标方向上保持不变的矩阵，称为平面旋转矩阵。它满足 $G^TG = I$，因此保持向量的欧氏长度和夹角。

左右两侧配套使用 G^T 与 G，既保持对称性，又保持特征值。若只从一侧消元，得到的一般只是与原矩阵等价的线性系统，并不自动与原矩阵同谱。这是特征值算法与线性方程组消元的重要区别。

本节的 Jacobi 方法用于特征值，与第七章求线性方程组的 Jacobi 迭代不同。它只针对实对称矩阵，通过正交相似变换不断减小非对角元素。

在坐标 p, q 平面上取旋转块

$$G_{pq} = \begin{pmatrix} c & s \\ -s & c \end{pmatrix}, \qquad c^2 + s^2 = 1,$$

其他坐标保持不动。令 $B = G^TAG$，则

$$b_{pq} = (a_{pp} - a_{qq})cs + a_{pq}(c^2 - s^2).$$

选角度使它为零。为避免角度公式中的消去，可令

$$\tau = \frac{a_{qq} - a_{pp}}{2a_{pq}}, \qquad t = \frac{\operatorname{sign}(\tau)}{|\tau| + \sqrt{1+\tau^2}}, \quad c = \frac{1}{\sqrt{1+t^2}}, \quad s = tc.$$

$\tau = 0$ 时可取 $t = 1$；$a_{pq} = 0$ 时无需旋转。不同教材采用不同旋转块符号，t 的公式应与之匹配。

把对应的 2×2 子块写成 $\begin{pmatrix} a & b \\ b & d \end{pmatrix}$。旋转后非对角元是

$$(c, -s) \begin{pmatrix} a & b \\ b & d \end{pmatrix} \begin{pmatrix} s \\ c \end{pmatrix} = cs(a - d) + b(c^2 - s^2).$$

若 $b \neq 0$，令 $t = s/c$，选择 $c \neq 0$，并把清零条件除以 bc^2，得到 $1 - t^2 - 2\tau t = 0$，其中 $\tau = (d - a)/(2b)$。因此

$$t^2 + 2\tau t - 1 = 0, \qquad t = -\tau \pm \sqrt{1 + \tau^2}.$$

取绝对值不超过 1 的根。若 $\tau > 0$，有 $t = \sqrt{1 + \tau^2} - \tau = 1/(\sqrt{1 + \tau^2} + \tau)$；若 $\tau < 0$，得到负的同类表达式。两者合并便是正文中避免相近量相减的公式。再用 $c^2 + s^2 = 1, s = tc$，得到 $c = 1/\sqrt{1 + t^2}$。

令 $\mathrm{off}(A)^2 = \sum_{i \neq j} a_{ij}^2$。正交变换保持 Frobenius 范数，而且本次消去使对角平方和增加 $2a_{pq}^2$，因此

$$\mathrm{off}(B)^2 = \mathrm{off}(A)^2 - 2a_{pq}^2.$$

若每次选绝对值最大的非对角元，则

$$a_{pq}^2 \geq \frac{\mathrm{off}(A)^2}{n(n-1)},$$

所以

$$\mathrm{off}(B)^2 \leq \left(1 - \frac{2}{n(n-1)}\right) \mathrm{off}(A)^2.$$

非对角量几何趋零。累计旋转矩阵的列给出对应的正交特征向量近似；存在重特征值时，其内部基的选择不唯一。

为何只减去 $2a_{pq}^2$？左乘正交矩阵保持每一列的欧氏长度，右乘正交矩阵保持每一行的欧氏长度，所以整个矩阵元素的平方和不变。所选 2×2 对角子块也只经过一个二维正交相似变换，因此

$$b_{pp}^2 + 2b_{pq}^2 + b_{qq}^2 = a_{pp}^2 + 2a_{pq}^2 + a_{qq}^2.$$

令 $b_{pq} = 0$ 后，这两个对角元的平方和增加了 $2a_{pq}^2$；其余对角元不变，而全矩阵平方和不变，故非对角平方和正好减少同样的量。

非对角元素共有 $n(n-1)$ 个，其中最大的平方至少为平均值 $\mathrm{off}(A)^2/[n(n-1)]$。每次消去这个元素，就得到相同的比例下降界；反复 k 次后，非对角平方和不超过初值乘 $[1 - 2/(n(n-1))]^k$，因此趋零。$n = 2$ 时该因子为零，正好对应一次旋转即可完全对角化。

以 $A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$ 为例，一次平面旋转即可把非对角元消为零。二次型的等值线是一条椭圆：原坐标中存在交叉项 $2x_1x_2$，旋转到主轴后，该交叉项消失。几何形状对应同一个二次型，只是坐标表示变了。对更高阶矩阵，每次只能消去选中的一个非对角元素，需要反复旋转。

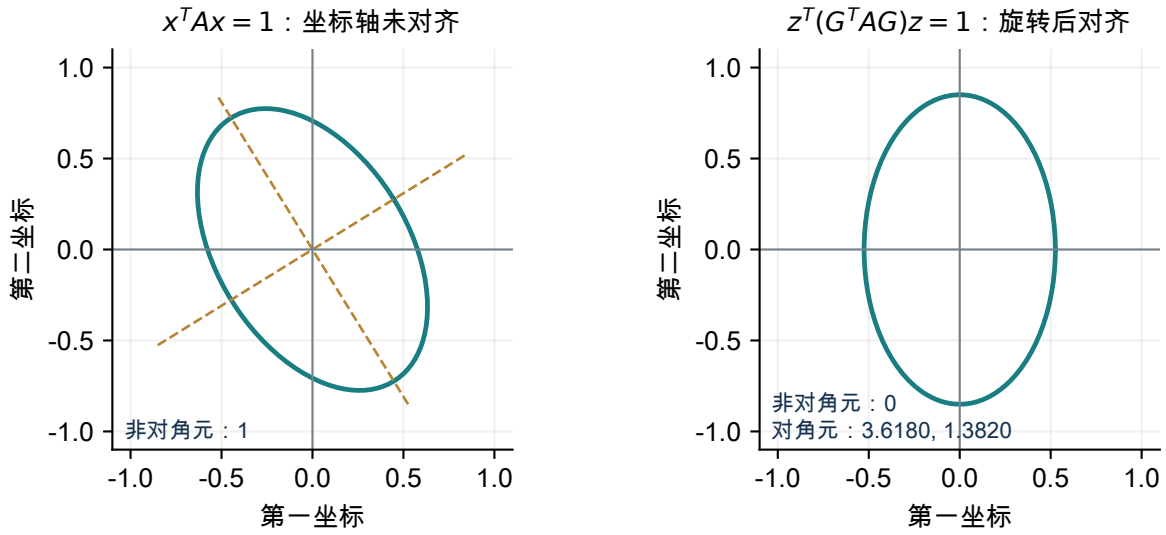


图 9.4 Jacobi 旋转作为坐标变换。左图的金色虚线是新坐标方向，右图使用 $z=G^Tx$ 表示同一二次型；矩阵特征值保持为约 $3.6180, 1.3820$。

9.5 QR 方法

定义 9.6 (正交相似变换与 QR 分解) 若 $Q^TQ=I$，称 Q 为正交矩阵，Q^TAQ 称为正交相似变换。将矩阵写成正交矩阵与上三角矩阵的乘积 $A=QR$，称为 QR 分解。

正交变换保持 2-范数，使计算不因坐标变换本身产生很大的长度伸缩。这种数值性质加上相似变换的保谱性质，使正交相似变换成为特征值计算的基本工具。

平面旋转一次处理一对坐标，Householder 反射则可以一次把一个向量的很多分量消为零。因此，反射适合先把稠密矩阵整理为更稀疏的结构，再进行重复的 QR 迭代。

Householder 矩阵定义为

$$H=I-2vv^T,\qquad \|v\|_2=1.$$

直接计算得 $H^T=H$、$H^TH=I$。几何上，它翻转沿 v 的分量，保持与 v 正交的分量。

性质 9.7 (Householder 反射的几何性质) 设 $\|v\|_2=1$、$H=I-2vv^T$。则 $H^T=H$、$H^2=I$；$Hv=-v$，而对任意 $z\perp v$ 有 $Hz=z$。

证明. vv^T 对称，所以 H 对称。展开平方并用 $v^Tv=1$，得 $H^2=I-4vv^T+4v(v^Tv)v^T=I$。另外 $Hv=v-2v=-v$；若 $v^Tz=0$，则 $Hz=z$。 □

若要把非零向量 x 变到第一坐标轴，取 $\alpha=-\operatorname{sign}(x_1)\,\|x\|_2$，$x_1=0$ 时约定符号为 1，令 $u=x-\alpha e_1$、$v=u/\|u\|$，便有 $Hx=\alpha e_1$。这样的符号选择让 $x_1-\alpha$ 发生同号相加，减少消去。

核对 $Hx=\alpha e_1$ 只需算两个内积。由于 $\alpha^2=\|x\|_2^2$、$u=x-\alpha e_1$，

$$u^Tx=\|x\|_2^2-\alpha x_1,\qquad u^Tu=\|x\|_2^2-2\alpha x_1+\alpha^2=2u^Tx.$$

因此

$$Hx=x-2u\frac{u^Tx}{u^Tu}=x-u=\alpha e_1.$$

所选符号使 $|x_1-\alpha|=|x_1|+\|x\|_2$，避免这个构造向量因减法而变得不必要地小。

构造 QR 时，第 k 个反射只作用在第 k 行以下的尾向量上，前 $k-1$ 个坐标保持不变。早先各列在这些行已经为零，所以新的反射不会破坏旧的零元。若最终 $R = H_{n-1}\cdots H_1 A$，每个 H_i 又对称正交，反过来就有 $A = (H_1\cdots H_{n-1})R = QR$。

化 Hessenberg 形时则保留第一条次对角线：第 k 步只对第 $k+1$ 行以下作反射，并在右侧乘相同变换以保持相似。右乘变换的前 k 列是单位作用，因此不会重新填入刚在第 k 列消掉的元素。实对称性又使下方的零元在上方对应位置也为零，从而成为三对角形。

逐列反射可以构造 QR 分解；对矩阵两侧作配套反射，可以先将一般矩阵化成上 Hessenberg 形，对称矩阵化成三对角形，减少后续特征值迭代的成本。

QR 迭代写为

$$A_k = Q_k R_k, \qquad A_{k+1} = R_k Q_k.$$

因 Q_k 正交，

$$A_{k+1} = Q_k^T A_k Q_k,$$

所以每一步都是相似变换，特征值不变。加移位时先分解 $A_k - \mu_k I = Q_k R_k$，再令 $A_{k+1} = R_k Q_k + \mu_k I$，同样保持相似性。

对一般实矩阵，理想终点是实 Schur 形，可能含代表复共轭特征值的 2×2 对角块，而不一定是实对角阵。对称矩阵则可趋于对角形式。实际算法还需要合适的移位、降阶判断和稳定的 Hessenberg 更新。

对称矩阵经过正交相似变换仍对称；若同时已成为上 Hessenberg 形，对称性就强制它为三对角形。这样，后续每次更新不再需要按原稠密矩阵的方式处理所有元素。QR 方法的效率不仅来自迭代公式，也依赖前面的结构化简。

相似性可以直接代入检验。无移位时，$Q_k^T A_k Q_k = Q_k^T Q_k R_k Q_k = R_k Q_k$；有移位时，$A_k = Q_k R_k + \mu_k I$，因此 $Q_k^T A_k Q_k = R_k Q_k + \mu_k I$。

QR 为什么会分离方向，可以先看二维对称、主特征值按模严格占优的情形。记累计正交矩阵 $U_k = Q_0\cdots Q_{k-1}$，于是 $A_k = U_k^T A U_k$，并且

$$A U_k = U_{k+1} R_k.$$

因为 R_k 上三角，其第一列只有首元素可能非零，所以第一列向量满足 $A u_1^{(k)} = r_{11}^{(k)} u_1^{(k+1)}$。这正是归一化幂法的关系；只要初始方向没有遗漏主特征分量，第一列就趋于主特征方向。二维中第二列必须与它正交，因而趋于另一个特征方向，矩阵表示就趋于对角形。

高维情形同时追踪一串嵌套子空间，实际还需要谱分离和移位策略。上面的二维推导解释了基本机制，但没有把单一幂法条件误当成任意高维无移位 QR 的完整收敛条件。

对称矩阵的 QR 迭代可以直接观察为一串数值矩阵。下面使用

$$A_0 = \begin{pmatrix} 4 & 1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 2 \end{pmatrix}, \qquad A_k = Q_k R_k, \quad A_{k+1} = R_k Q_k.$$

每次变化的是矩阵元素与坐标表示，谱一直不变；当非对角元足够小时，对角元才成为各特征值的好近似。这里选择对称正定矩阵展示基本过程，不把该图当作任意矩阵上无移位 QR 收敛速度的保证。

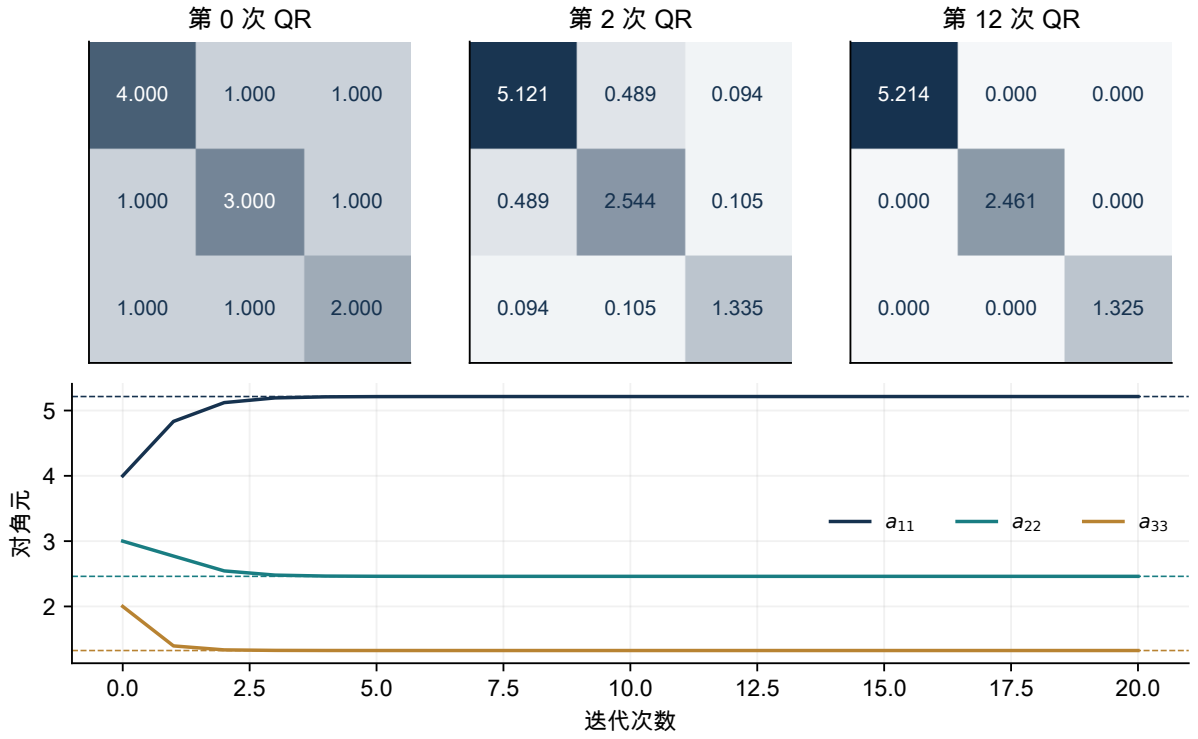


图 9.5 不带移位的 QR 迭代示例。上排显示若干步的矩阵元素，数字保留三位小数；显示为 0.000 不代表精确为零。下排是对角元随迭代的变化，虚线为准确特征值。

第 10 章　常微分方程的数值解法

10.1　引言

前面的求值、积分与线性求解通常针对一个固定问题。常微分方程则要求连续推进：当前近似成为下一步的输入，每一步误差都会影响后面。这使“单步很准确”与“整条轨迹可靠”之间多出一层稳定性问题。

考虑初值问题

$$y'(t) = f(t, y(t)), \qquad y(t_0) = y_0.$$

以下先用标量记号，向量系统可用同样方式书写。若 f 连续，并对 y 局部 Lipschitz，则初值问题有局部唯一解；要在整个给定区间上使用数值方法，还需解在该区间存在，且相关光滑性与界成立。局部存在不自动保证任意长时间不爆破。

定义 10.1（初值问题与离散解）　给定微分方程 $y' = f(t, y)$ 和起点值 $y(t_0) = y_0$，求满足二者的函数，称为初值问题。选择离散时刻 $t_0 < t_1 < \cdots$，以 y_n 近似 $y(t_n)$，得到数值离散解；相邻时刻之差称为步长。

数值解通常只提供网格时刻的近似值。若需要中间时刻，还须使用与方法相容的插值或连续扩展。y_n 中的下标表示时间步，不是向量分量；对向量方程，一个 y_n 本身就包含多个分量。

定义 10.2（对状态变量的 Lipschitz 条件）　若在所考虑的区域内存在与 t, y, z 无关的常数 L，使 $\|f(t, y) - f(t, z)\| \le L \|y - z\|$，称 f 对状态变量满足 Lipschitz 条件。

它限制的是两条接近状态所受到的斜率差异，因此既用于保证解的唯一性，也用于分析数值误差的传播。在有界区域内，连续且有界的状态导数 f_y 能给出这样的常数；但要覆盖整个计算区间，还需保证真解和数值轨迹处在相应区域中。

存在唯一性的局部理由，可以把微分方程改成积分方程来看。

局部存在唯一性的积分构造. 在起点附近取一个矩形区域 $|t - t_0| \le a, |y - y_0| \le b$，使 $|f| \le M$，并且对 y 的 Lipschitz 常数为 L。选择 $h > 0$ 满足 $h \le a$、$Mh \le b$、$Lh < 1$。对区间上的连续函数 u，定义

$$(\Phi u)(t) = y_0 + \int_{t_0}^{t} f(s, u(s))\, \mathrm{d}s.$$

如果 $|u - y_0| \le b$，就有 $|\Phi u - y_0| \le Mh \le b$，所以更新不会离开所选区域。对两函数，还满足

$$\|\Phi u - \Phi v\|_\infty \le \int_{t_0}^{t_0+h} L \|u - v\|_\infty \, \mathrm{d}s = Lh \|u - v\|_\infty .$$

从常函数 $u_0 = y_0$ 开始反复更新，相邻函数之差按 $q = Lh < 1$ 的比例收缩。把未来差值像几何级数一样相加，得到函数序列在最大范数下是 Cauchy 序列，因此一致趋于某个函数 u。

一致极限仍连续：先选一个与极限处处相差小于 $\varepsilon/3$ 的 u_n，再用该 u_n 的连续性控制两个足够近点之间的差，三项相加便小于 ε。Lipschitz 条件又保证 $f(s,u_n(s))$ 一致趋于 $f(s,u(s))$，所以积分方程可以取极限，得到 $u=\Phi u$。由微积分基本定理求导，$u'=f(t,u)$，且 $u(t_0)=y_0$。若还有另一个解 v 留在同一区域，它也满足积分方程，因此 $\|u-v\|_\infty \le q\,\|u-v\|_\infty$，只能相等。这个证明只构造长度为 h 的局部区间。要继续延长，需要解仍处在可控制区域内；例如 $y'=y^2, y(0)=1$ 的解 $1/(1-t)$ 会在 $t=1$ 发散，说明局部结论不自动覆盖任意终点。 □

10.2 简单数值方法

从积分恒等式出发：

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y(t))\,\mathrm{d}t.$$

用左端矩形近似积分，得到显式 Euler：

$$y_{n+1} = y_n + hf(t_n, y_n).$$

它也可以解释为沿当前切线走一步。用右端矩形得到隐式 Euler：

$$y_{n+1} = y_n + hf(t_{n+1}, y_{n+1}).$$

右侧含新值，每一步要解一个代数方程。用梯形积分则得到

$$y_{n+1} = y_n + \frac{h}{2}[f(t_n, y_n) + f(t_{n+1}, y_{n+1})].$$

前者用一个斜率，后者平均两端斜率。阶数改善来自对积分的更准确近似，但隐式方程的求解也进入了算法成本。

设 f 对 y 的 Lipschitz 常数为 L。用不动点方式解隐式 Euler 时，迭代函数 $z \mapsto y_n + hf(t_{n+1}, z)$ 的 Lipschitz 常数为 hL。因此 $hL<1$ 是该内迭代收敛的充分条件；这不是隐式 Euler 本身的绝对稳定步长限制。对于刚性问题，常用 Newton 法求隐式方程。

例 10.1 (同一个指数衰减方程) 对 $y'=-2y$，$y(0)=1$，分别写出显式 Euler、隐式 Euler 与隐式梯形的更新式，并比较 $h=0.1$ 时的第一步。

解 对 $y'=-2y, y(0)=1$，精确解为 e^{-2t}。步长 h 下，三种更新分别为

$$y_{n+1} = (1-2h)y_n, \qquad y_{n+1} = \frac{y_n}{1+2h}, \qquad y_{n+1} = \frac{1-h}{1+h}y_n.$$

取 $h=0.1$，第一步得到 $0.8, 0.833333\ldots, 0.818181\ldots$，真值为 $0.818730\ldots$。这也预示了隐式梯形法的二阶精度。

定义 10.3 (显式方法、隐式方法与单步方法) 若新值可以直接由已知数据算出，称为显式方法；若新值同时出现在待求方程两侧，需要解代数方程，称为隐式方法。只依赖当前一步的状态推进到下一步，称为单步方法。

显式与隐式描述每一步怎样计算，单步与多步描述使用多少历史信息。这是两个不同维度。例如隐式 Euler 仍是单步方法，因为它只把当前状态推进到下一状态，不需要更早时刻的数值解。

定义 10.4 (局部误差与整体误差) 假设某一步的起点取精确值，只观察这一数值步产生的误差，称为局部一步误差。实际从初值连续推进以后，$y(t_n)-y_n$ 称为整体误差，它同时包含当前误差和历史误差的传播。

区分二者是理解方法阶数的起点。局部分析可以把旧误差暂时清零，从 Taylor 展开得到简洁公式；整体分析则必须把各步重新连起来，不能把最后一步的局部界直接当成终点总误差。

局部误差和方法的阶

把一次数值更新写为 $y_{n+1}=\Psi_h(t_n,y_n)$。局部一步误差定义为从准确起点出发后的误差：

$$\delta_{n+1}=y(t_{n+1})-\Psi_h(t_n,y(t_n)).$$

若在固定区间上一致有 $\delta_{n+1}=O(h^{p+1})$，称方法具有 p 阶局部一致精度。整体误差 $e_n=y(t_n)-y_n$ 还包含以前各步传下来的误差。

有些教材把 δ_{n+1}/h 叫局部截断误差，于是它记为 $O(h^p)$。两种记法都可用，关键是明确是否除以 h。对隐式方法，还常把真解代入离散方程后的残差称为局部缺陷，它与解出隐式方程后的实际一步误差应区分。

把离散方程里的函数值换成真解导数，就能逐项计算缺陷。记当前准确值为 $y=y(t_n)$，所有导数暂时在 t_n 取值。Taylor 公式给出

$$y(t_n+h)-y=hy'+\frac{h^2}{2}y''+\frac{h^3}{6}y'''+O(h^4),$$

$$y'(t_n+h)=y'+hy''+\frac{h^2}{2}y'''+O(h^3).$$

显式 Euler 从第一式减去 hy'，剩下 $h^2y''/2+O(h^3)$。隐式 Euler 则减去第二式的 h 倍，所以二阶系数为 $1/2-1=-1/2$；隐式梯形减去 $h[y'+y'(t_n+h)]/2$，二阶项抵消，三阶系数为 $1/6-1/4=-1/12$。这分别得到正文中的三个主项。

为什么隐式方程的缺陷还能代表一步误差的阶数？以隐式 Euler 为例，设 Y 是从准确起点出发、精确解出隐式方程得到的数值，y_+ 是真终点。两式相减为

$$(y_+-Y)-h[f(t_{n+1},y_+)-f(t_{n+1},Y)]=d_{n+1}.$$

由 Lipschitz 条件，$|y_+-Y|\le|d_{n+1}|+hL|y_+-Y|$，所以当 $hL<1$，

$$|y_+-Y|\le\frac{|d_{n+1}|}{1-hL}.$$

小步长时分母有一致正下界，故两者具有相同误差阶。对梯形法，完全相同的相减过程把 hL 换成 $hL/2$。这是一条局部小步长估计，不是隐式方法绝对稳定步长的必要限制。

例如显式 Euler 的一步误差由 Taylor 公式直接得到

$$\delta_{n+1}=\frac{h^2}{2}y''(t_n)+O(h^3).$$

隐式 Euler 与梯形法代入真解后的方程缺陷分别为

$$d_{n+1}^{BE}=-\frac{h^2}{2}y''(t_n)+O(h^3),\qquad d_{n+1}^{TR}=-\frac{h^3}{12}y'''(t_n)+O(h^4).$$

在小步长下隐式求解映射良好时，对缺陷的响应因子有界，故它们分别是一阶和二阶方法。

定理 10.5（单步方法的整体误差界） 假设 $t_n \le T$，数值单步映射满足

$$|\Psi_h(t,u)-\Psi_h(t,v)| \le (1+Lh)|u-v|,$$

且局部误差 $|\delta_{n+1}| \le Ch^{p+1}$。则 $L>0$ 时

$$|e_n| \le e^{L(t_n-t_0)}|e_0| + \frac{C}{L}\left(e^{L(t_n-t_0)}-1\right)h^p.$$

当 $L=0$ 时，第二项按极限理解为 $C(t_n-t_0)h^p$。

证明. 在整体误差中加减从准确起点出发的数值结果：

$$\begin{aligned} e_{n+1} &= y(t_{n+1}) - \Psi_h(t_n,y_n) \\ &= \underbrace{y(t_{n+1}) - \Psi_h(t_n,y(t_n))}_{\delta_{n+1}} + \Psi_h(t_n,y(t_n)) - \Psi_h(t_n,y_n). \end{aligned}$$

因此 $|e_{n+1}| \le Ch^{p+1} + (1+Lh)|e_n|$。令 $a=1+Lh$，把前两步展开，就能看出每个旧误差要经过几次放大：

$$|e_1| \le a|e_0| + Ch^{p+1}, \quad |e_2| \le a^2|e_0| + (a+1)Ch^{p+1}.$$

按同一方式归纳，得 $|e_n| \le a^n|e_0| + Ch^{p+1}(1+a+\cdots+a^{n-1})$。当 $L>0$，几何级数为

$$1+a+\cdots+a^{n-1} = \frac{a^n-1}{a-1} = \frac{(1+Lh)^n-1}{Lh}.$$

所以第二项等于 $(C/L)[(1+Lh)^n-1]h^p$。最后利用 $1+Lh \le e^{Lh}$；例如由 $e^z \ge 1+z$ 的切线不等式即可核对。于是 $(1+Lh)^n \le e^{Lnh}$，并用 $nh=t_n-t_0$，得到定理。
若 $L=0$，原几何和退化为 n，无需除以零：误差项为 $nCh^{p+1} = C(t_n-t_0)h^p$，与所述极限一致。 □

因此，在稳定传播条件下，局部一步 $O(h^{p+1})$ 通常累计成固定时间区间上的整体 $O(h^p)$。少一阶不是神秘现象，而是总步数约为 $1/h$。证明同时说明初值误差也会传播，并不会因方法阶数提高而自动消失。

对 $y'=y$ 使用显式 Euler，误差传播在精确算术下可以直接写成

$$e_{n+1} = (1+h)e_n + \delta_{n+1}.$$

下面取 $h=0.4$，观察从 $t_n=0.8$ 到 1.2 的一步。旧误差约为 0.265541，传播后变为约 0.371757；本步局部误差约为 0.204360，二者合起来才是终点总误差。

两步 Euler 公式

在区间 $[t_{n-1},t_{n+1}]$ 上积分，并用中点 t_n 的斜率近似，得到

$$y_{n+1} = y_{n-1} + 2hf(t_n,y_n).$$

它也称显式中点多步公式。这里一次更新跨越两个小区间，所以前面的系数是 $2h$；它与在一个时间步内部评估中点斜率的 Runge–Kutta 中点法不同。

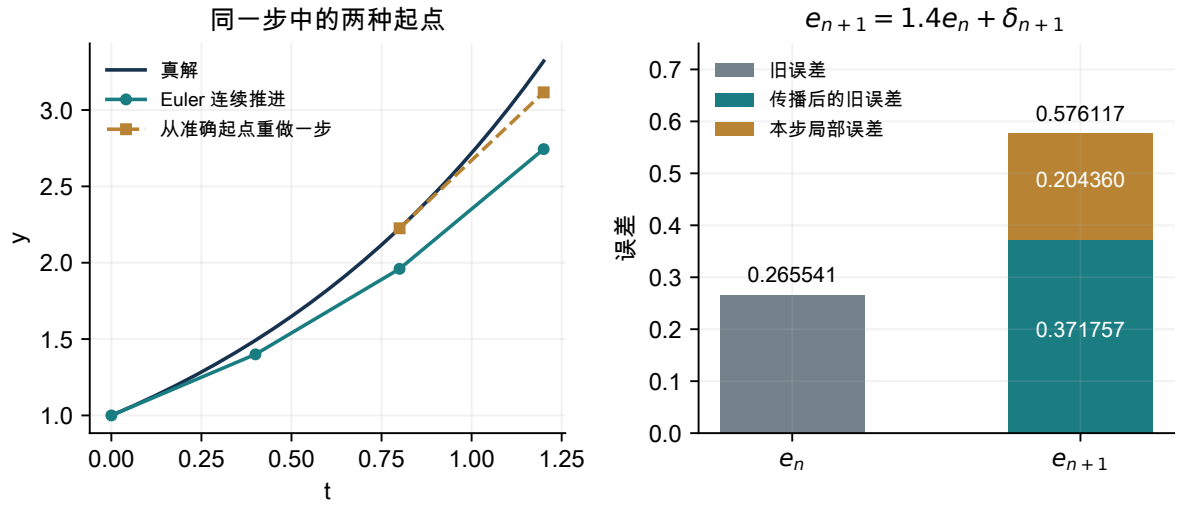


图 10.1 局部误差与整体误差的分解。左图从准确起点重做一步，隔离当前步自身的误差；右图把传播项与新增项堆叠，得到约 0.576117 的整体误差。

将真解在 t_n 两侧展开，得

$$y(t_n + h) - y(t_n - h) - 2hy'(t_n) = \frac{h^3}{3}y'''(t_n) + O(h^5).$$

因此该格式的代数阶为二阶。但它需要两个启动值，并含有一个交替符号的历史模式；是否适合具体问题，还需看多步稳定性，不能只按局部余项选择。

10.3 龙格-库塔方法

Euler 方法只观察起点斜率，相当于假设整个小区间内变化率不变。想提高精度，就应补充区间内部的变化信息。直接计算 y''、y''' 是一种途径，但对复杂的 $f(t, y)$，展开这些导数很麻烦。

> **定义 10.6** (Runge–Kutta 阶段与级数) 在同一时间步内，用若干中间状态计算斜率 k_i，再将这些斜率加权组合完成更新，称为 Runge–Kutta 方法。斜率求值次数称为级数，整体误差的渐近阶称为阶数，两者不是同一概念。

中间状态通常不是精确轨迹上的点，而是由已知阶段构造的预测。系数必须同时补偿时间位置和状态预测的误差。下面从最简单的二级形式逐项匹配 Taylor 展开，再看四阶公式怎样延续这一路线。

高阶 Taylor 法需要计算 $y'', y''', \ldots$。由微分方程，$y'' = f_t + f_y f$，更高导数会迅速变复杂。Runge–Kutta 用同一步内多个斜率取代显式高阶求导。

真解二阶导数需要沿轨迹求导，而不是把 f 当作仅依赖时间的函数。由链式法则，

$$y'' = \frac{\mathrm{d}}{\mathrm{d}t} f(t, y(t)) = f_t + f_y y' = f_t + f_y f.$$

在第二阶段中，时间增量是 ch，状态增量是 $ahk_1 = ahf$。二元 Taylor 一次展开因此给出 $k_2 = f + chf_t + ahff_y + O(h^2)$。乘以外面的 hb_2 后，两种偏导数组合的系数分别为 b_2c 和 b_2a；真解中二者系数都为 $1/2$，所以要分别匹配，不能只令它们的和正确。

考虑二级显式形式

$$k_1 = f(t_n, y_n), \quad k_2 = f(t_n + ch, y_n + ahk_1),$$

$$y_{n+1} = y_n + h(b_1k_1 + b_2k_2).$$

在准确起点展开 $k_2 = f + h(cf_t + af_yf) + O(h^2)$，于是数值更新为

$$y + h(b_1 + b_2)f + h^2b_2(cf_t + af_yf) + O(h^3).$$

真解展开为

$$y(t+h) = y + hf + \frac{h^2}{2}(f_t + f_yf) + O(h^3).$$

匹配独立项，得到

$$b_1 + b_2 = 1, \qquad b_2c = \frac{1}{2}, \qquad b_2a = \frac{1}{2}.$$

所以必须 $a = c \neq 0$，$b_2 = 1/(2c)$、$b_1 = 1 - 1/(2c)$。常见两种选择是：

取 $c = 1$，得到改进 Euler（Heun）法

$$k_1 = f(t_n, y_n), \quad k_2 = f(t_n + h, y_n + hk_1), \quad y_{n+1} = y_n + \frac{h}{2}(k_1 + k_2).$$

取 $c = 1/2$，得到显式中点法

$$y_{n+1} = y_n + hf\left(t_n + \frac{h}{2}, y_n + \frac{h}{2}f(t_n, y_n)\right).$$

两者都二阶，但对非线性问题通常给出不同结果。改进 Euler 只是用一次预测值替代了隐式梯形公式中的新值，**并不等于把隐式梯形方程解到收敛**，因此稳定性也不同。

四阶龙格-库塔公式

经典四级四阶 Runge–Kutta（RK4）为

$$\begin{aligned}
k_1 &= f(t_n, y_n),\\
k_2 &= f(t_n + h/2, y_n + hk_1/2),\\
k_3 &= f(t_n + h/2, y_n + hk_2/2),\\
k_4 &= f(t_n + h, y_n + hk_3),\\
y_{n+1} &= y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4).
\end{aligned}$$

第二、三阶段虽然同在半步时刻，却使用不同的状态预测，不能随意合并。

用 Butcher 系数矩阵 A、权向量 b 与时刻向量 $c = A\mathbf{1}$ 统一表示。经典 RK4 的表为

0	0	0	0	0
1/2	1/2	0	0	0
1/2	0	1/2	0	0
1	0	0	1	0
	1/6	1/3	1/3	1/6

在足够光滑条件下，四阶匹配要求

$$\begin{aligned}
b^T\mathbf{1} &= 1, & b^Tc &= \tfrac{1}{2},\\
b^Tc^{\circ 2} &= \tfrac{1}{3}, & b^TAc &= \tfrac{1}{6},\\
b^Tc^{\circ 3} &= \tfrac{1}{4}, & b^T\,\mathrm{diag}(c)Ac &= \tfrac{1}{8},\\
b^TAc^{\circ 2} &= \tfrac{1}{12}, & b^TA^2c &= \tfrac{1}{24}.
\end{aligned}$$

$c^{\circ q}$ 表示逐分量 q 次幂。这些条件分别匹配不同的导数组合，而不只是 f 本身的幂。例如 $b^T c^{\circ 2} = 1/3$ 对应二阶时刻效应，$b^T Ac = 1/6$ 对应阶段状态的嵌套影响。下面把这些条件的来源和代入检查一并写出。

八个四阶条件看起来抽象，实际上仍是二元 Taylor 展开的系数匹配。下面把需要的组合和它们的来源写出来。

四阶 *Runge–Kutta* 条件的推导. 所有偏导数均在当前点 (t, y) 取值。为避免反复写很长的式子，暂记

$$g = f_t + f_y f, \qquad u = f_{tt} + 2f f_{ty} + f^2 f_{yy}, \qquad w = f_{ty} + f f_{yy},$$
$$v = f_{ttt} + 3f f_{tty} + 3f^2 f_{tyy} + f^3 f_{yyy}.$$

这些只是偏导数组合的缩写。沿真解求导有 $y'' = g$。例如对任意 $F(t, y)$，沿轨迹求导是 $\mathrm{d}F/\mathrm{d}t = F_t + fF_y$。逐项用这一规则，

$$\frac{\mathrm{d}}{\mathrm{d}t} f_t = f_{tt} + f f_{ty}, \qquad \frac{\mathrm{d}}{\mathrm{d}t}(f_y f) = (f_{ty} + f f_{yy}) f + f_y g,$$

两式相加就是 $u + f_y g$。对 u 的三项求导则为

$$\begin{aligned}
\frac{\mathrm{d}}{\mathrm{d}t} f_{tt} &= f_{ttt} + f f_{tty}, \\
\frac{\mathrm{d}}{\mathrm{d}t}(2f f_{ty}) &= 2g f_{ty} + 2f(f_{tty} + f f_{tyy}), \\
\frac{\mathrm{d}}{\mathrm{d}t}(f^2 f_{yy}) &= 2f g f_{yy} + f^2(f_{tyy} + f f_{yyy}).
\end{aligned}$$

按导数种类合并，三阶偏导数部分为 v，其余两项是 $2g(f_{ty} + f f_{yy}) = 2wg$。
对 $g = f_t + f_y f$ 使用乘积与链式法则，得到 $y''' = u + f_y g$。进一步，$\mathrm{d}u/\mathrm{d}t = v + 2wg$，而

$$\frac{\mathrm{d}}{\mathrm{d}t}(f_y g) = wg + f_y(u + f_y g).$$

所以 $y^{(4)} = v + 3wg + f_y u + f_y^2 g$。准确一步因此展开为

$$y(t+h) = y + hf + \frac{h^2}{2} g + \frac{h^3}{6}(u + f_y g) + \frac{h^4}{24}(v + 3wg + f_y u + f_y^2 g) + O(h^5).$$

现在计算数值一步。一般显式阶段为 $k_i = f(t + c_i h, y + h\sum_{j<i} a_{ij} k_j)$，且 $c_i = \sum_{j<i} a_{ij}$。记状态增量为 $\Delta_i = h\sum_j a_{ij} k_j$。最初用 $k_j = f + O(h)$，得到 $\Delta_i = hc_i f + O(h^2)$；再代入一阶展开 $k_j = f + hc_j g + O(h^2)$，得到

$$\Delta_i = hc_i f + h^2 (Ac)_i g + O(h^3).$$

继续保留二阶项，阶段内的增量为

$$\Delta_i = hc_i f + h^2 (Ac)_i g + h^3 \left[(A^2 c)_i f_y g + \tfrac{1}{2} (Ac^{\circ 2})_i u \right] + O(h^4).$$

这里例如 $(Ac)_i = \sum_j a_{ij} c_j$，每一次 A 都对应把前一层阶段的系数再按 a_{ij} 加权。

对 $f(t+c_ih, y+\Delta_i)$ 写到三阶：

$$\begin{aligned} k_i = f &+ c_ih f_t + \Delta_i f_y \\ &+ \tfrac{1}{2}c_i^2h^2 f_{tt} + c_ih\Delta_i f_{ty} + \tfrac{1}{2}\Delta_i^2 f_{yy} \\ &+ \tfrac{1}{6}c_i^3h^3 f_{ttt} + \tfrac{1}{2}c_i^2h^2\Delta_i f_{tty} + \tfrac{1}{2}c_ih\Delta_i^2 f_{tyy} + \tfrac{1}{6}\Delta_i^3 f_{yyy} + O(h^4). \end{aligned}$$

将上面的 Δ_i 代入并按 h 的幂次合并，得到

$$\begin{aligned} k_i = f &+ hc_ig + h^2\left[(Ac)_i f_y g + \tfrac{1}{2}c_i^2 u\right] \\ &+ h^3\left[(A^2c)_i f_y^2 g + \tfrac{1}{2}(Ac^{\circ 2})_i f_y u + c_i(Ac)_i wg + \tfrac{1}{6}c_i^3 v\right] + O(h^4). \end{aligned}$$

例如 wg 项有两份来源：$c_ih\Delta_i f_{ty}$ 中用 Δ_i 的二阶项，以及 $\Delta_i^2 f_{yy}/2$ 中的一阶与二阶交叉项；合起来正是 $c_i(Ac)_i(f_{ty}+ff_{yy})g$。
最后使用 $y_{\text{new}} = y + h\sum_i b_ik_i$。比较 f, g, u, f_yg 的系数，依次得到

$$b^T\mathbf{1} = 1, \quad b^Tc = \tfrac{1}{2}, \quad \tfrac{1}{2}b^Tc^{\circ 2} = \tfrac{1}{6}, \quad b^TAc = \tfrac{1}{6}.$$

比较 v, wg, f_yu, f_y^2g，依次得到

$$\tfrac{1}{6}b^Tc^{\circ 3} = \tfrac{1}{24}, \quad b^T\operatorname{diag}(c)Ac = \tfrac{3}{24}, \quad \tfrac{1}{2}b^TAc^{\circ 2} = \tfrac{1}{24}, \quad b^TA^2c = \tfrac{1}{24}.$$

把分数整理后，就是前面列出的八条条件。它们保证一般光滑标量非自治方程的展开匹配到 h^4；对向量方程，对应偏导数组合逐分量展开，也得到同一组条件。 □

对经典 RK4，还可以实际核对这些矩阵乘积：

$$c = (0, 1/2, 1/2, 1)^T, \quad Ac = (0, 0, 1/4, 1/2)^T,$$

$$Ac^{\circ 2} = (0, 0, 1/8, 1/4)^T, \quad A^2c = (0, 0, 0, 1/4)^T,$$

$$\operatorname{diag}(c)Ac = (0, 0, 1/8, 1/2)^T.$$

与 $b = (1/6, 1/3, 1/3, 1/6)^T$ 点乘，得到

$$\begin{aligned} b^Tc &= \tfrac{1}{6}+\tfrac{1}{6}+\tfrac{1}{6}+\tfrac{1}{2}, & b^Tc^{\circ 2} &= \tfrac{1}{12}+\tfrac{1}{12}+\tfrac{1}{6}+\tfrac{1}{3}, \\ b^TAc &= \tfrac{1}{12}+\tfrac{1}{12}+\tfrac{1}{6}, & b^Tc^{\circ 3} &= \tfrac{1}{24}+\tfrac{1}{24}+\tfrac{1}{6}+\tfrac{1}{4}, \\ b^T\operatorname{diag}(c)Ac &= \tfrac{1}{24}+\tfrac{1}{12}+\tfrac{1}{8}, & b^TAc^{\circ 2} &= \tfrac{1}{24}+\tfrac{1}{24}+\tfrac{1}{12}, \\ b^TA^2c &= \tfrac{1}{6}\cdot\tfrac{1}{4}+\tfrac{1}{24}. \end{aligned}$$

再加上 $b^T\mathbf{1} = 1$，全部条件都满足。

对测试方程 $y' = \lambda y$，RK4 给出乘子

$$R(z) = 1 + z + \frac{z^2}{2} + \frac{z^3}{6} + \frac{z^4}{24}, \qquad z = h\lambda.$$

将测试方程 $f(t,y) = \lambda y$ 逐阶段代入，记 $z = h\lambda$，则

$$k_1 = \lambda y_n, \qquad k_2 = \lambda y_n(1 + z/2),$$

$$k_3 = \lambda y_n(1 + z/2 + z^2/4), \qquad k_4 = \lambda y_n(1 + z + z^2/2 + z^3/4).$$

按 $1,2,2,1$ 加权以后，括号和为 $6+3z+z^2+z^3/4$，外面再乘 $z/6$，得到增量因子 $z+z^2/2+z^3/6+z^4/24$。加上原来的 y_n，就是所列稳定多项式。

它与 e^z 的前五项一致，但仅核对这个线性测试方程不足以证明一般非线性问题的四阶精度：其他导数组合仍需上面的条件。

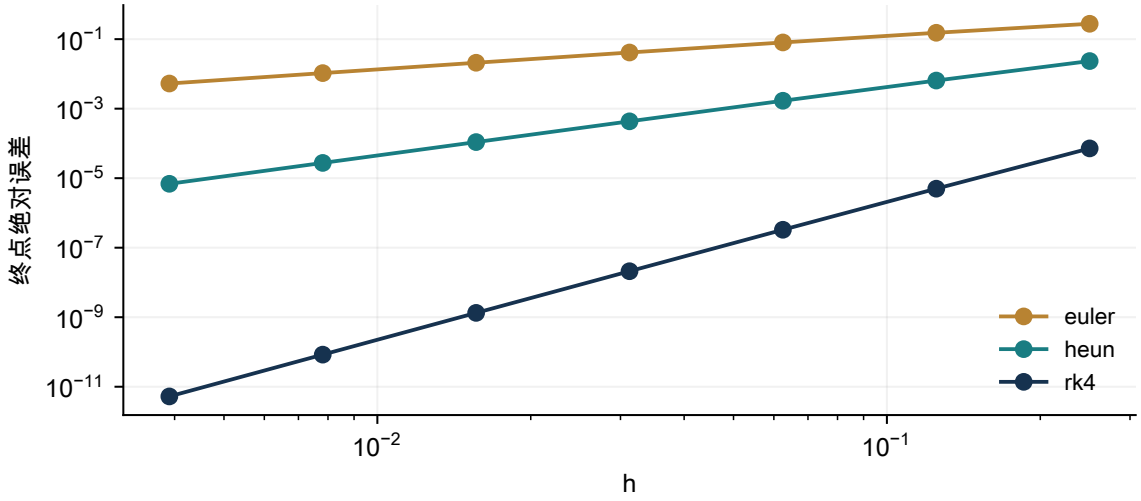


图 10.2 求解 $y'=y, y(0)=1$ 到 $t=1$ 的整体误差。Euler、改进 Euler 与 RK4 分别呈现一阶、二阶与四阶下降。比较计算成本时，还应计入每步函数求值次数。

把公式落实到一次可复算的更新。取 $y'=y, y(0)=1$ 和 $h=0.8$，则真终点为 $e^{0.8}$。Euler 只观察起点斜率；改进 Euler 先预测终点，再平均两端斜率；RK4 则使用四个预测位置的斜率。

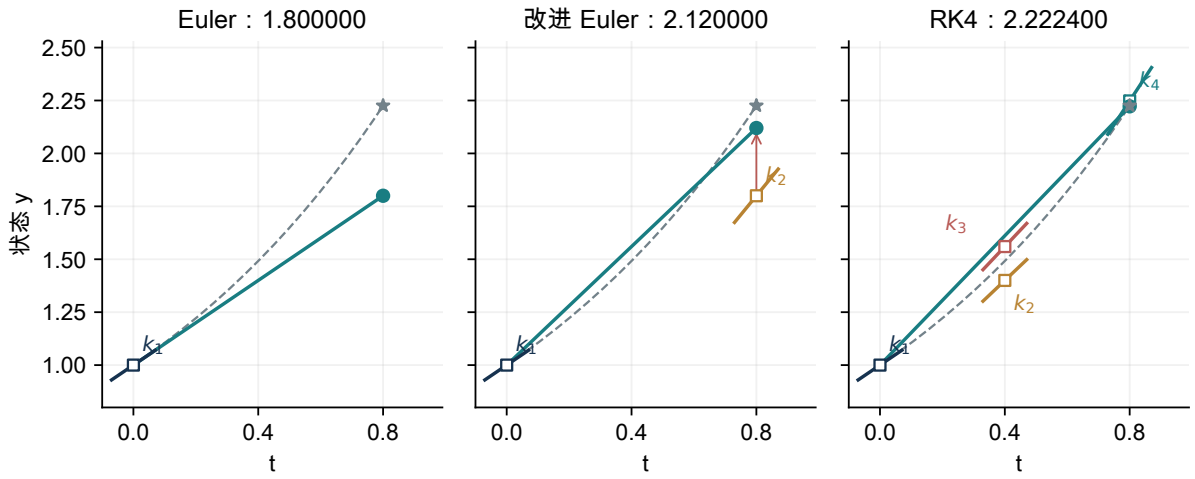


图 10.3 一个时间步内的阶段位置。空心方块是斜率求值处的预测状态，短线表示该处斜率，青色实点为最后更新值，灰色星号为真终点；连线仅表示这一步的构造。

阶段 i	时刻 t_i	预测状态 Y_i	斜率 k_i	最后权重 b_i
1	0.0	1.000	1.000	1/6
2	0.4	1.400	1.400	1/3
3	0.4	1.560	1.560	1/3
4	0.8	2.248	2.248	1/6

表 10.1 RK4 在 $y' = y$、$y_0 = 1$、$h = 0.8$ 下的一步计算。

两次半步时刻同为 $t = 0.4$，预测状态却分别为 1.4 和 1.56。它们并不是两个重复求值。最终

$$y_1 = 1 + \frac{0.8}{6}(1 + 2 \times 1.4 + 2 \times 1.56 + 2.248) = 2.2224,$$

而准确值约为 2.2255409285。阶段状态和最终状态应分开识别。

变步长龙格-库塔方法

从同一个准确或当前数值起点出发，用步长 h 走一步得到 Y_c，用 $h/2$ 走两步得到 Y_f。对 p 阶方法，在光滑且主误差模型成立时，粗步局部误差与细步累计局部误差之比约为 2^p。因此

$$y(t+h) - Y_f \approx \frac{Y_f - Y_c}{2^p - 1}.$$

这个估计反映当前一步的误差，不能直接当作整个积分区间最终误差的严格上界。

细网格为何是 2^p 而非 2^{p+1}？假设粗步的数值误差主项为 ch^{p+1}。两个半步各产生约 $c(h/2)^{p+1}$，第一半步误差在第二半步只多乘一个 $1 + O(h)$ 的传播因子，所以主项相加为

$$2c(h/2)^{p+1} = \frac{ch^{p+1}}{2^p}.$$

写成 $Y_c = y_* + ch^{p+1} + O(h^{p+2})$、$Y_f = y_* + ch^{p+1}/2^p + O(h^{p+2})$，相减并消去 c，得到 $y_* - Y_f \approx (Y_f - Y_c)/(2^p - 1)$。

步长更新则解另一个比例式：若主误差按 h^{p+1} 变化，那么 $E_{\text{new}}/E \approx (h_{\text{new}}/h)^{p+1}$。令希望的新误差为 τ，就有 $h_{\text{new}} = h(\tau/E)^{1/(p+1)}$。再乘小于 1 的安全因子，是给误差模型不完全准确留出余量。

若误差估计为 E，局部容许值为 τ，由于一步误差按 h^{p+1} 变化，可建议

$$h_{\text{new}} = s\,h\left(\frac{\tau}{E}\right)^{1/(p+1)}, \qquad 0 < s < 1.$$

s 是安全因子；还应限制单次增长或缩减倍数。对不同尺度的分量，常以

$$\frac{|E_i|}{\text{atol}_i + \text{rtol}_i \max(|y_{n,i}|, |y_{n+1,i}|)}$$

归一化后再决定接受或拒绝。这避免某个绝对量很大的分量支配所有误差判断。

嵌入式 Runge–Kutta 通过共享阶段、使用两套权重得到不同阶的近似，减少重复求值。它的步长指数取决于被估计误差的主阶，不能只看高阶方法的名字来填写。

同一个 $y' = y$ 问题还可以说明步长怎样调整。从当前数值起点出发，计算一个完整 RK4 步 Y_c 与两个半步 Y_f，用 $|Y_f - Y_c|/15$ 估计细结果的局部误差。若接受，则令新的状态等于 Y_f；若拒绝，时间与状态都留在原点。

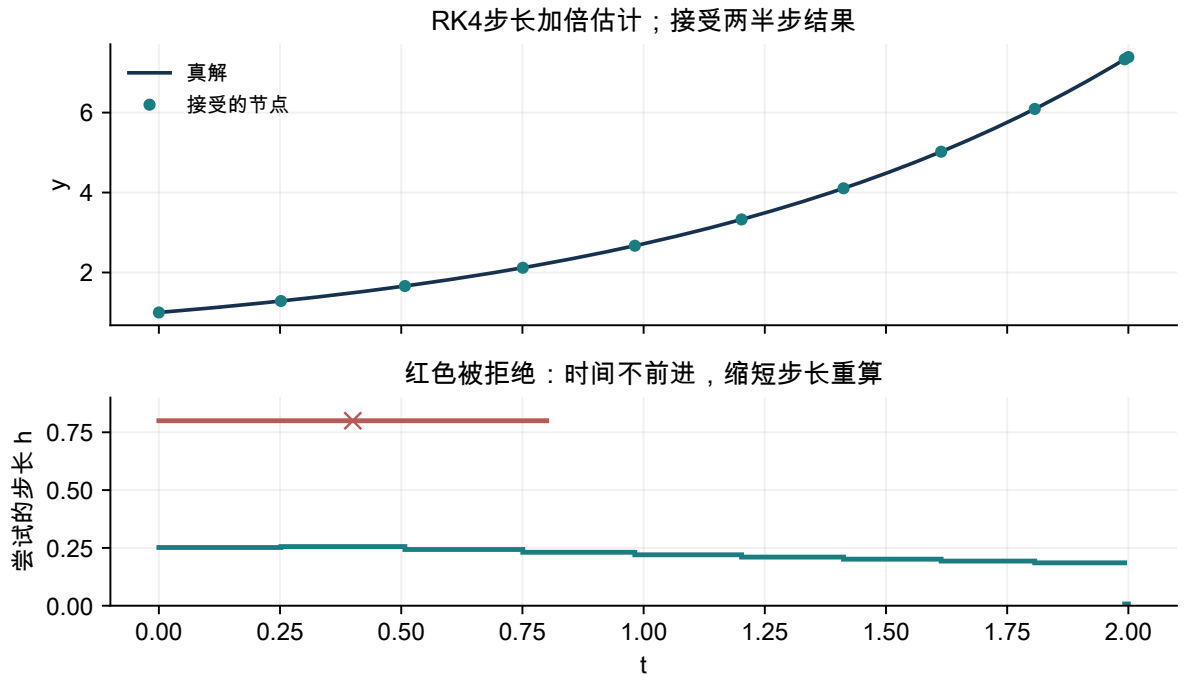


图 10.4 从 $h = 0.8$ 开始的自适应 RK4。绝对局部容许值为 10^{-6}；第一步被拒绝后，缩小步长重新计算。底部红色横段表示一次没有推进时间的尝试。

尝试	起始时刻	步长 h	误差估计 E	决定
1	0.000000	0.800000	1.91×10^{-4}	拒绝
2	0.000000	0.251782	5.46×10^{-7}	接受
3	0.251782	0.255766	7.60×10^{-7}	接受
4	0.507548	0.243178	7.61×10^{-7}	接受
5	0.750725	0.231133	7.52×10^{-7}	接受

表 10.2 前五次步长尝试，容许值均为 10^{-6}。拒绝后第二行仍从 $t = 0$ 出发。

这里步长建议采用 $0.9h(10^{-6}/E)^{1/5}$，并限制每次调整倍数。指数 $1/5$ 对应四阶方法的局部一步误差，而不是整体误差阶。

稳定性与步长

精度分析让 h 趋于零，而实际计算使用一个固定的有限步长。一个形式上高阶的方法，在当前步长下仍可能把应衰减的模式放大。因此还需要检验方法对最基本的线性模式有什么作用。

定义 10.7 (稳定函数与绝对稳定域) 对测试方程 $y' = \lambda y$，若一步更新为 $y_{n+1} = R(z)y_n$，$z = h\lambda$，称 R 为稳定函数。集合 $\{z \in \mathbb{C} : |R(z)| \le 1\}$ 称为绝对稳定域；内部点对应衰减，边界点只保证不放大。

测试方程虽然简单，却对应一般线性系统分解后的单个特征模式。它不能替代所有非线性稳定性分析，但能清楚展示步长、特征值位置与数值增长之间的联系。

考虑 $y' = \lambda y$, $\operatorname{Re}\lambda < 0$, 真解应衰减。如果数值方法给出 $y_{n+1} = R(h\lambda)y_n$, 则当 $|R(h\lambda)| \le 1$ 时，扰动不会逐步放大，称该点处绝对稳定。

显式 Euler 的 $R(z) = 1 + z$，稳定域是圆盘 $|1 + z| \le 1$。对实负 λ，要求 $0 \le h \le 2/|\lambda|$；在右端边界上乘子为 -1，只保证不增长，并不衰减。

隐式 Euler 的 $R(z) = 1/(1 - z)$，左半平面全部稳定，而且 $z \to -\infty$ 时 $R(z) \to 0$。梯形法的

$$R(z) = \frac{1 + z/2}{1 - z/2}$$

也覆盖左半平面，但 $z \to -\infty$ 时趋于 -1，极快衰减模式可能留下缓慢衰减的交替振荡。覆盖整个左半平面称为 A 稳定；进一步把无限刚性极限的放大因子压到零，则涉及 L 稳定性。

对显式 Euler, 代入测试方程就有 $y_{n+1} = (1+z)y_n$。若 $z = a+\mathrm{i}b$, 稳定条件为 $(1+a)^2+b^2 \le 1$, 因此是以 -1 为中心、半径为 1 的圆盘。对负实 λ，$|1 + h\lambda| \le 1$ 等价于 $-2 \le h\lambda \le 0$，除以负数时翻转不等号，得到 $0 \le h \le 2/|\lambda|$。

隐式 Euler 要先解新值：$y_{n+1} = y_n + zy_{n+1}$，故 $R(z) = 1/(1 - z)$。当 $a = \operatorname{Re} z \le 0$, $|1 - z|^2 = (1 - a)^2 + b^2 \ge 1$，所以整个左半平面稳定。

梯形法给出 $(1 - z/2)y_{n+1} = (1 + z/2)y_n$，故得到比值形式的 R。计算分母、分子模平方之差：

$$|1 - z/2|^2 - |1 + z/2|^2 = -2\operatorname{Re} z \ge 0.$$

所以分母模至少和分子一样大，$|R(z)| \le 1$。沿负实轴令 $z \to -\infty$，把分子分母同时除以 z，得到梯形因子趋于 -1；隐式 Euler 因子则趋于 0。这解释了二者对极快衰减分量的不同处理。

刚性例子的解析解也可核对。令 $v(t) = y(t) - \cos t$，则 $v' = y' + \sin t = -1000v$，所以 $v(t) = v(0)e^{-1000t}$。真解虽可能已接近缓慢的 $\cos t$，数值扰动仍会经过这个快速模式；显式 Euler 对它要求 $h \le 2/1000 = 0.002$。

刚性的一种典型表现是：真解已经变化很慢，但显式方法仍必须用很小步长，才能压住方程中快速衰减的模式。例子为

$$y' = -1000(y - \cos t) - \sin t,$$

其通解为 $y(t) = \cos t + (y(0) - 1)e^{-1000t}$。快速暂态消失后，主轨迹接近 $\cos t$，变化尺度约为 1，显式 Euler 却仍受到 $h \lesssim 0.002$ 的稳定限制。隐式法能用更大稳定步长，但准确性仍然需要控制。

三个不同的问题。一致性问单步离散能否逼近微分方程；收敛性问固定时间区间内、步长趋零时整体误差是否趋零；绝对稳定性问给定步长下某种衰减模式是否被错误放大。高阶精度不能自动代替稳定性。

稳定域的意义可以落实到一条实际轨迹。取 $y' = -20y, y(0) = 1$，步长 $h = 0.15$，则 $z = h\lambda = -3$。三种方法每步的放大因子分别为

$$R_E(-3) = -2, \qquad R_{BE}(-3) = \frac{1}{4}, \qquad R_{TR}(-3) = -\frac{1}{5}.$$

隐式梯形的因子虽然模小于 1，却为负数，因此出现正负交替。稳定、单调衰减和准确跟踪真解，是三项不同的要求。

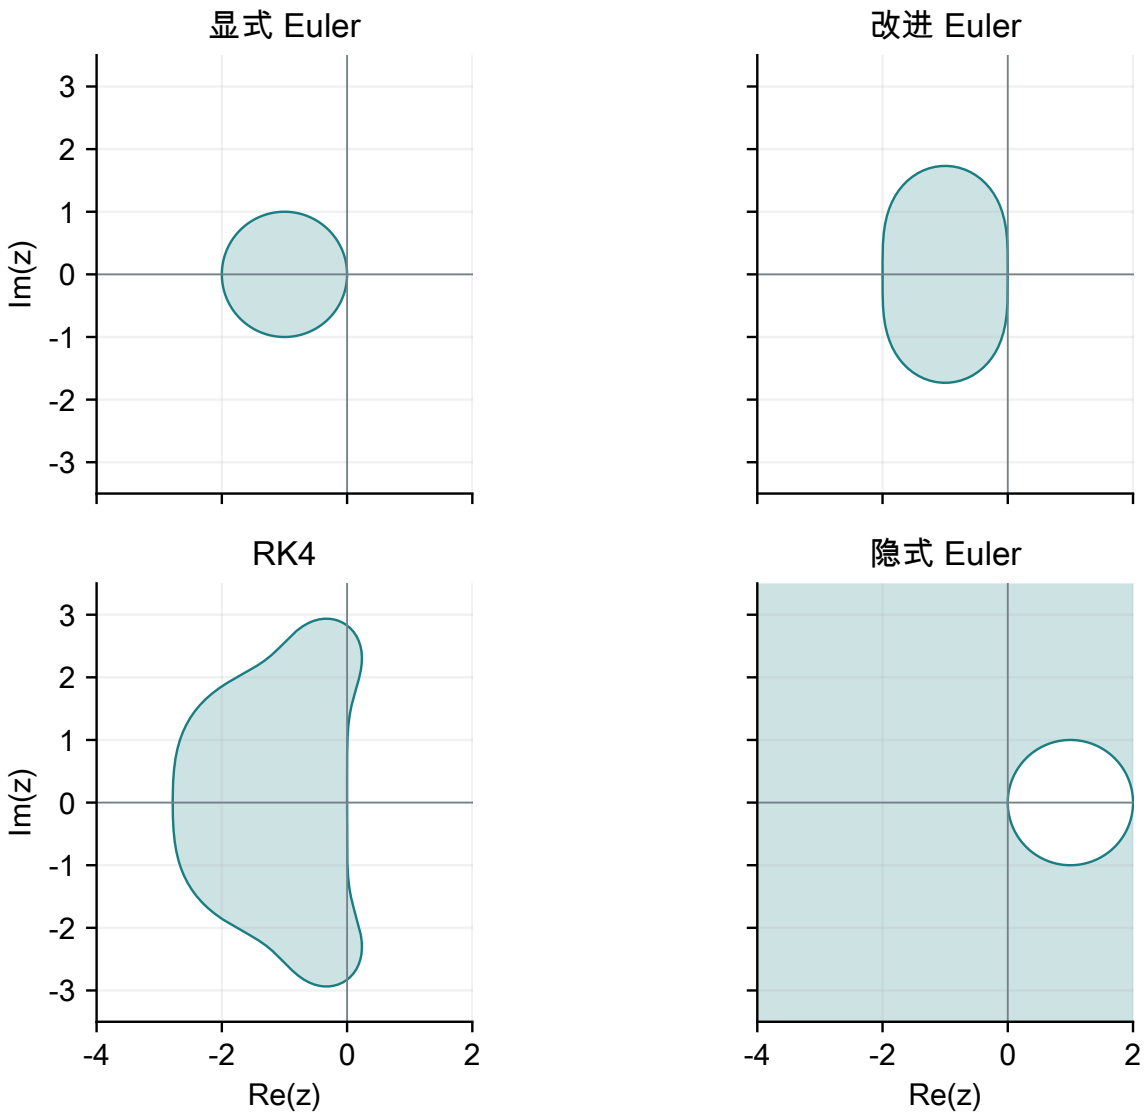


图 10.5 复平面上的绝对稳定域：显式 Euler、改进 Euler、RK4 与隐式 Euler。阴影表示 $|R(z)| \le 1$；隐式 Euler 的稳定域向左无限延伸，图中只显示有限窗口。

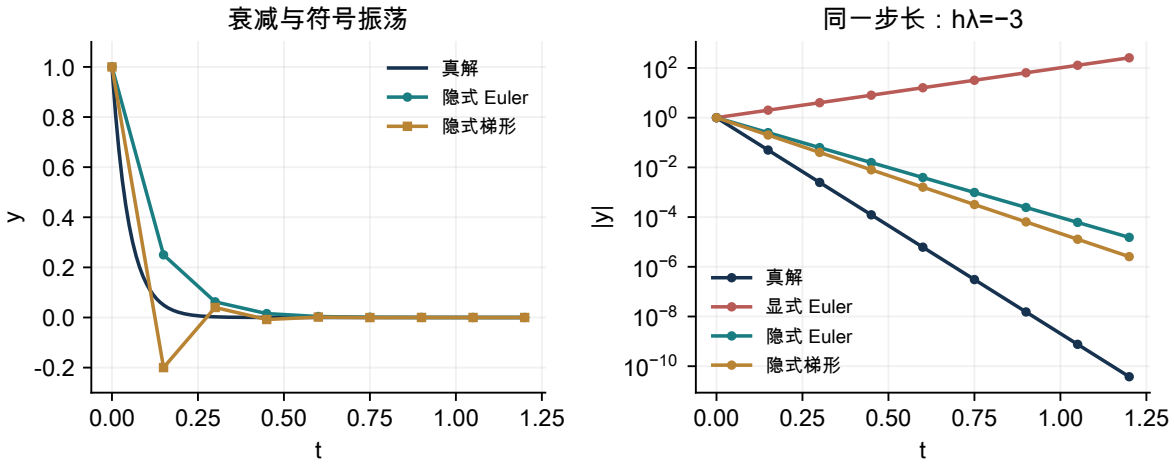


图 10.6 相同步长下的衰减计算。左图比较真解和两种隐式方法，右图以对数纵轴同时显示全部方法的绝对值。显式 Euler 把衰减问题变成了幅度增长。

10.4 线性多步法

定义 10.8 (线性多步方法) 若新状态与以前若干状态及其斜率满足固定系数的线性关系

$$\sum_{j=0}^{s}\alpha_j y_{n+j}=h\sum_{j=0}^{s}\beta_j f(t_{n+j},y_{n+j}),\qquad \alpha_s\neq 0,$$

则称为 s 步线性多步方法。$\beta_s=0$ 时为显式，否则通常为隐式。

与 Runge–Kutta 的区别在于信息来自哪里：前者复用过去时间步已经得到的值，后者主要在当前一步内构造新阶段。多步法可减少每步新增函数求值，但必须提供足够准确的启动值，改变步长时也要重新处理历史信息与系数。

Runge–Kutta 每步在内部重新采样多个斜率；多步方法复用过去若干步的斜率。仍从积分恒等式出发，在 $[t_n,t_{n+1}]$ 上，用历史数据插值 $g(t)=f(t,y(t))$。

用 g_n,g_{n-1} 作线性外推，令 $s=(t-t_n)/h$，则 $g(t)\approx g_n+s(g_n-g_{n-1})$。对 $s\in[0,1]$ 积分，得 Adams–Bashforth 二步法

$$y_{n+1}=y_n+\frac{h}{2}(3f_n-f_{n-1}).$$

继续使用四个历史斜率，得到四步四阶公式

$$y_{n+1}=y_n+\frac{h}{24}(55f_n-59f_{n-1}+37f_{n-2}-9f_{n-3}).$$

若把未来的 f_{n+1} 纳入插值，便得到 Adams–Moulton 隐式公式。例如常用四阶式为

$$y_{n+1}=y_n+\frac{h}{24}(9f_{n+1}+19f_n-5f_{n-1}+f_{n-2}).$$

四阶 Adams 系数可以像求积权重一样真正积出来。令 $s=(t-t_n)/h$，在 $[0,1]$ 上积分斜率插值。历史节点为 $0,-1,-2,-3$ 时，四个 Lagrange 基依次为

$$\ell_0=\frac{s^3+6s^2+11s+6}{6},\quad \ell_{-1}=-\frac{s^3+5s^2+6s}{2},$$

$$\ell_{-2}=\frac{s^3+4s^2+3s}{2},\quad \ell_{-3}=-\frac{s^3+3s^2+2s}{6}.$$

每一项按 $\int_0^1 s^r\,\mathrm{d}s=1/(r+1)$ 积分：

$$\begin{aligned}
\int_0^1\ell_0&=\tfrac{1}{6}(\tfrac{1}{4}+2+\tfrac{11}{2}+6)=\tfrac{55}{24},\\
\int_0^1\ell_{-1}&=-\tfrac{1}{2}(\tfrac{1}{4}+\tfrac{5}{3}+3)=-\tfrac{59}{24},\\
\int_0^1\ell_{-2}&=\tfrac{1}{2}(\tfrac{1}{4}+\tfrac{4}{3}+\tfrac{3}{2})=\tfrac{37}{24},\\
\int_0^1\ell_{-3}&=-\tfrac{1}{6}(\tfrac{1}{4}+1+1)=-\tfrac{9}{24}.
\end{aligned}$$

换回时间积分时再乘 h，便得到四步 Adams–Bashforth 公式。

隐式四阶式使用节点 $1, 0, -1, -2$。相应四个基的展开和积分为

$$\ell_1 = (s^3 + 3s^2 + 2s)/6, \qquad \int_0^1 \ell_1 = (1/4 + 1 + 1)/6 = 9/24,$$

$$\ell_0 = -(s^3 + 2s^2 - s - 2)/2, \qquad \int_0^1 \ell_0 = -(1/4 + 2/3 - 1/2 - 2)/2 = 19/24,$$

$$\ell_{-1} = (s^3 + s^2 - 2s)/2, \qquad \int_0^1 \ell_{-1} = (1/4 + 1/3 - 1)/2 = -5/24,$$

$$\ell_{-2} = -(s^3 - s)/6, \qquad \int_0^1 \ell_{-2} = -(1/4 - 1/2)/6 = 1/24.$$

节点 1 的函数值就是未来斜率 f_{n+1}，因此带有它的公式必须与新状态联立。

Milne 显式公式则在 $[-3, 1]$ 上积分节点 $-2, -1, 0$ 的二次斜率插值。三个基按 $0, -1, -2$ 的顺序是 $(s^2 + 3s + 2)/2, -s^2 - 2s, (s^2 + s)/2$。利用

$$\int_{-3}^{1} 1\,\mathrm{d}s = 4, \quad \int_{-3}^{1} s\,\mathrm{d}s = -4, \quad \int_{-3}^{1} s^2\,\mathrm{d}s = 28/3,$$

分别得到 $8/3, -4/3, 8/3$，即正文的权重。节点和积分区间都关于 $s = -1$ 对称，三次插值误差的节点乘积是关于该中心的奇函数，因此三次项积分也被消去，这才使局部误差达到五次。两步隐式 Simpson 公式则直接把第 5 章的 Simpson 规则用在 $[t_{n-1}, t_{n+1}]$ 上，中点就是 t_n。

“步数”按需要覆盖的历史间隔计，“阶数”按误差阶计；不同命名习惯可能把同一公式按节点数或历史步数编号，应以公式为准。

可以先用显式公式预测，再代入隐式公式校正。但只校正一次与将隐式方程解到指定容差并非同一算法，稳定域也不一定相同。多步法还需要启动值；若主方法四阶，启动误差通常也需与四阶整体误差相容，可用合适的 RK 方法生成。

Milne 型公式也可由积分构造。例如

$$y_{n+1} = y_{n-3} + \frac{4h}{3}(2f_n - f_{n-1} + 2f_{n-2})$$

是一个四步四阶显式公式，而

$$y_{n+1} = y_{n-1} + \frac{h}{3}(f_{n+1} + 4f_n + f_{n-1})$$

来自跨两个小区间的 Simpson 积分。这些公式虽然有较高代数阶，仍须分析多步误差传播，不能只根据插值次数作选择。

多步公式可以沿时间轴阅读。四阶 Adams–Bashforth 使用 t_n 及更早三个时刻的斜率；四阶 Adams–Moulton 使用 t_{n+1} 的斜率，所以需要与新状态一起求解。图中用空心圆突出这个未来量。两行都还要加上起点状态 y_n。这是时间更新公式中的权重，不应与正权求积公式的性质混淆；使用历史节点外推会自然产生负系数。

待定系数法与收敛条件

一般常步长线性多步法写为

$$\sum_{j=0}^{s} \alpha_j y_{n+j} = h \sum_{j=0}^{s} \beta_j f_{n+j}, \qquad \alpha_s \neq 0.$$

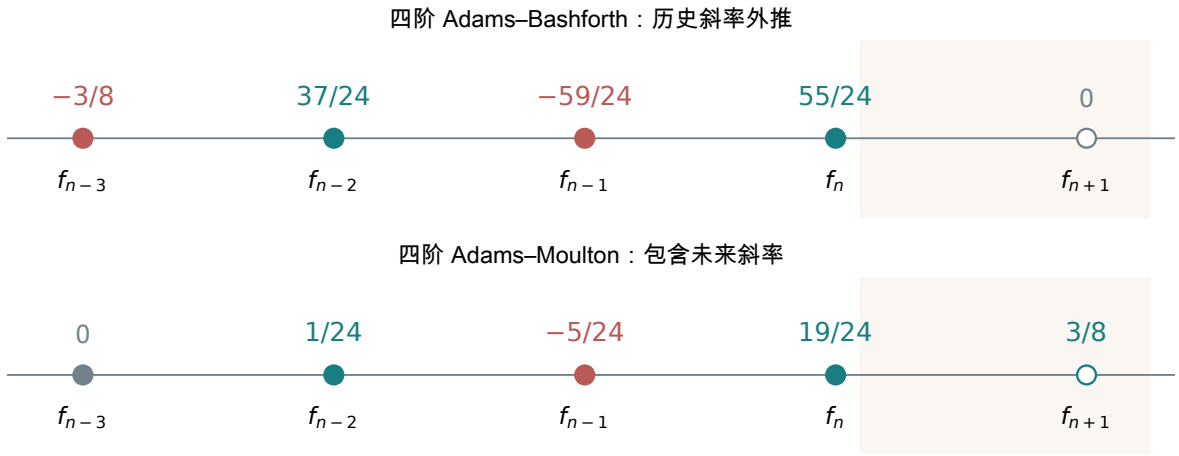


图 10.7 四阶 Adams 公式的斜率依赖。标注数字是乘在 hf_j 前的系数；青色为正权，红色为负权，灰色零权表示该时刻不参与该公式。

将真解代入，在 t_n 展开。$h^q y^{(q)}(t_n)$ 的系数为

$$C_0 = \sum_j \alpha_j, \qquad C_q = \frac{1}{q!}\sum_j \alpha_j j^q - \frac{1}{(q-1)!}\sum_j \beta_j j^{q-1} \quad (q \ge 1).$$

假设真解有连续的 $p+2$ 阶导数，逐项展开到有限阶；右侧已有一个 h：

$$y(t_n + jh) = \sum_{q=0}^{p+1} \frac{j^q h^q}{q!} y^{(q)}(t_n) + O(h^{p+2}),$$

$$hy'(t_n + jh) = \sum_{q=1}^{p+1} \frac{j^{q-1} h^q}{(q-1)!} y^{(q)}(t_n) + O(h^{p+2}).$$

左式从零次项开始，右式从一次项开始。因此零次系数只有 $\sum \alpha_j$；对 $q \ge 1$，将两边同一阶系数相减就得到 C_q。尤其 $C_1 = \sum j\alpha_j - \sum \beta_j = \rho'(1) - \sigma(1)$，所以最初两个一致性条件正是 $\rho(1) = 0$、$\rho'(1) = \sigma(1)$。

若 $C_0 = \cdots = C_p = 0$ 而 $C_{p+1} \neq 0$，则未除以 h 的方程缺陷为 $O(h^{p+1})$，方法代数阶为 p。这是待定系数法构造多步公式的系统办法。

定义

$$\rho(\zeta) = \sum_{j=0}^{s} \alpha_j \zeta^j, \qquad \sigma(\zeta) = \sum_{j=0}^{s} \beta_j \zeta^j.$$

至少一阶一致性要求 $\rho(1) = 0$、$\rho'(1) = \sigma(1)$。然而消去局部低阶误差并不足以保证收敛，还必须控制历史值误差的递推。

令 $f = 0$，扰动满足 $\sum_j \alpha_j e_{n+j} = 0$。若 ρ 有根 $|\zeta| > 1$，对应误差按 ζ^n 增长；若单位圆上的根有重数，则出现 $n\zeta^n$ 等多项式增长。因固定时间内 $n \sim 1/h$，这些增长会破坏 $h \to 0$ 时的稳定性。

定理 10.9 (零稳定性的根条件) 对固定系数、常步长线性多步法，零稳定性等价于：ρ 的全部根满足 $|\zeta| \le 1$，且单位圆上的根均为单根。在标准 Lipschitz 条件、适当的隐式可解性及收敛启动值下，一致性与零稳定性共同保证收敛；若要求对任意趋于准确初值的启动数据都收敛，则对一般初值问题，二者也是必需的条件。

根条件与多步收敛的推导. 先看 $f=0$ 时的齐次误差递推 $\sum_{j=0}^{s}\alpha_j e_{n+j}=0$。试取 $e_n=\zeta^n$，代入后得到 $\zeta^n\rho(\zeta)=0$，所以特征根决定基本误差模式。

重根为什么带来多项式增长，可以用移位算子 E 表示，其中 $(Ea)_n=a_{n+1}$。对

$$a_n^{(r)}=\binom{n}{r}\zeta^{n-r}$$

使用二项式关系 $\binom{n+1}{r}-\binom{n}{r}=\binom{n}{r-1}$，得到 $(E-\zeta)a^{(r)}=a^{(r-1)}$ $(r\geq 1)$；而 $(E-\zeta)a^{(0)}=0$。因此，若 ζ 是 m 重根，则 $r=0,\dots,m-1$ 给出对应模式；当 $\zeta\neq 0$ 时，它们的大小与 $n^r|\zeta|^n$ 同阶。当 $\zeta=0$ 时，用等价的导数定义 $a_n^{(r)}=(1/r!)(\mathrm{d}^r z^n/\mathrm{d}z^r)|_{z=0}$：只有 $n=r$ 时等于 1，其余等于 0，所以每个模式只在一个起始位置非零。

这些模式确实覆盖全部齐次解。s 阶递推由最初 s 个值唯一确定；上面各根按重数总共给出 s 个模式。它们在 $n=0,\dots,s-1$ 的初值矩阵，其元素是单项式对 ζ 的相应阶导数再除以阶乘。这正是第 3 章 Hermite 插值条件矩阵的转置，因唯一性而可逆，所以这些模式线性无关。

若 $|\zeta|<1$，几何衰减压过固定次的 n^r；若 $|\zeta|=1$ 且是单根，其模保持有界。反之，$|\zeta|>1$ 产生几何增长，单位圆重根产生至少一次的 n 增长。因此，全部齐次误差对初值具有一致有界的放大，当且仅当根条件成立，这就是零稳定性。

再把局部缺陷加进来。将递推写成状态向量的一步形式 $E_{n+1}=ME_n+g_n$，其中 E_n 收集连续 s 个误差，M 是固定移位矩阵。零稳定性使 $\left\|M^k\right\|\leq K$，常数与 k,h 无关。反复展开得到

$$E_n=M^nE_0+\sum_{l=0}^{n-1}M^{n-1-l}g_l,\qquad \|E_n\|\leq K\|E_0\|+K\sum_l\|g_l\|.$$

g_l 包含局部缺陷 $O(h^{p+1})$，以及由近似状态带来的 $h\sum_j\beta_j[f(t,y)-f(t,y_n)]$。用 Lipschitz 条件，每个历史误差在这些求和中只出现有限次，因此

$$|e_n|\leq K_1E_{\text{start}}+K_2h\sum_{j=0}^{n}|e_j|+K_3Th^p.$$

隐式公式可能含当前 e_n；当 h 足够小，先将 $K_2h|e_n|$ 移到左边并除以正数，便化为

$$|e_n|\leq a+bh\sum_{j=0}^{n-1}|e_j|,\qquad a=C(E_{\text{start}}+h^p),$$

其中 b,C 与 h 无关。归纳验证 $|e_n|\leq a(1+bh)^n$：把已有上界代入求和，几何级数恰给出 $a(1+bh)^n$。因 $nh\leq T$，得到 $|e_n|\leq ae^{bT}$。所以启动误差趋零且方法一致时，整体误差趋零；若启动误差为 $O(h^p)$，整体便保持 p 阶。

最后说明必要性。这里的收敛要求对任意趋于准确初值的启动数据都成立。若有 $|\zeta|>1$ 的模式，取其初始幅度为 h，起始误差趋零，但在 $n\sim T/h$ 时 $h|\zeta|^n$ 增长；若单位圆上有重根，取幅度为 h 的 $n\zeta^n$ 模式，到固定时间时仍为 $O(1)$。所以不满足根条件便不能保证收敛。

一致性条件也不能缺。对 $y'=0,y(0)=1$，收敛时同一步中的各数值趋于 1，代入离散式取极限，必须 $\sum\alpha_j=0$。再对 $y'=1,y(0)=0$，把从第 0 步到固定终点附近的离散方程相加。因 $\sum\alpha_j=0$，左侧内部项相消，只剩首尾各至多 s 个值。终点值趋于 T，起点值趋于 0，所以左侧趋于 $T\sum j\alpha_j$；右侧则趋于 $T\sum\beta_j$。故还必须 $\rho'(1)=\sigma(1)$。这完成了根条件、一致性与收敛之间的联系。 □

例 10.2 (一致但不收敛的多步格式) 检验 $y_{n+2}-3y_{n+1}+2y_n=-hf_n$ 的一致性和零稳定性，说明二者的区别。

解 其 $\rho(\zeta)=\zeta^2-3\zeta+2$，$\sigma(\zeta)=-1$。有 $\rho(1)=0$、$\rho'(1)=-1=\sigma(1)$，所以一致。但 ρ 的另一个根为 2，启动误差中若含有这一模式，会按 2^n 放大，方法不零稳定，因此不能保证收敛。

时间离散方法的比较

方法	阶数	每步主要工作	历史信息	稳定性特点
显式 Euler	1	一次斜率	当前状态	稳定步长受限制
隐式 Euler	1	解隐式方程	当前状态	左半平面稳定，强衰减模式可压低
隐式梯形	2	解隐式方程	当前状态	A 稳定，强衰减模式可能振荡
改进 Euler	2	两次斜率	当前状态	显式稳定域有限
经典 RK4	4	四次斜率	当前状态	高阶不等于无步长限制
Adams 多步法	依公式而定	复用历史斜率	多个历史点	需启动值与根条件分析

表 10.3 方法阶数描述光滑解上的误差尺度；工作量和稳定性还须单独比较。